

Agenti AI in azienda: dal chatbot alla delega governata

Riccardo Bovetti

Who am I? | [LinkedIn](#) | [All you need is thought](#)

Complessità & Sistemi di Senso

Settembre 2026

Indice

1	Parte I. Dal chatbot all'agente: le coordinate concettuali	4
1.1	Che cos'è, davvero, un agente AI	4
1.2	Il continuum dell'autonomia	5
1.3	Anatomia di un agente: modello, harness, contesto, ambiente	6
2	Parte II. L'infrastruttura comune: la logica di base indipendente dalle piattaforme	8
2.1	Il ciclo agentico e il tool use	8
2.2	Una mappa terminologica: prompt, istruzioni, skill, tool, connettore, MCP, plugin	12
2.3	Che cosa c'è sotto il connettore	19
2.4	Connettori e Model Context Protocol	20
2.5	I file di configurazione in Markdown (od in altro formato testo)	25
2.6	Contesto, memoria e RAG	26
2.7	Sistemi multi agente: coordinamento, non solo parallelismo	28
2.8	La verifica dell'esito: perché "ho fatto X" non basta	30
2.9	Guardrail, sandbox, permessi e hook	31
3	Parte III. Il fronte Anthropic	33
3.1	Claude Code e il Claude Agent SDK	33
3.2	Le skill come standard aperto e i plugin come distribuzione condivisa	33
3.3	Cowork e i connettori MCP nativi	34
3.4	I tre livelli di costruzione: Messages API, Agent SDK, Claude Managed Agents .	34
4	Parte IV. Il fronte OpenAI	35
4.1	Orientarsi nel catalogo: Chat, ChatGPT Work, Workspace Agents e Codex . . .	35
4.2	I tre livelli di costruzione: Responses API, Agents SDK, Agents API	35
4.3	Codex e il consolidamento del browsing agentico	36
5	Parte V. Il fronte Microsoft	36
5.1	Che cosa chiama "agente" Microsoft: una scala, non un oggetto unico	36
5.2	L'agente come identità aziendale: Entra Agent ID	38
5.3	Agent 365: il control panel (si lo so si chiama control plane, ma non mi piace) della flotta di agenti	38
5.4	Gli agenti dichiarativi: il file di configurazione secondo Microsoft	39
5.5	Copilot Studio: orchestrazione generativa, trigger e agent flow	40
5.6	MCP, connettori e agenti dichiarativi: Copilot Studio e Microsoft Foundry Agent Service	41
5.7	Il Microsoft Agent Framework per lo sviluppo su misura	42
5.8	GitHub Copilot Agent Mode: il fronte coding	42

5.9	Copilot Cowork: una licenza tecnologica tra concorrenti diretti	43
5.10	Frontier Firm e Work IQ: la cornice organizzativa	43
6	Parte VI. Lettura comparata e implicazioni nel processo di A(I)doption	43
6.1	Convergenze	43
6.2	Divergenze di filosofia	45
6.3	Che cosa è davvero portabile tra le piattaforme	45
6.4	Il quadro economico: abbonamenti, token, crediti e ore di esecuzione	46
7	Parte VII. Conclusioni: la nuova competenza manageriale	49

Il mercato sta investendo con una convinzione quasi assoluta negli agenti, ma, ad oggi, la distanza tra la sperimentazione e l'adozione matura resta ancora ampia e si misura esattamente nella capacità (e nella possibilità) di un'organizzazione di trasformare l'entusiasmo per gli agenti in una disciplina di delega governata.

Questo breve papello nasce con un duplice obiettivo. Il primo è chiarire, con necessaria precisione tecnica ma senza gergo superfluo, che cosa sia oggi un agente AI, quali componenti lo costituiscano e quali di questi componenti siano ormai comuni a qualunque piattaforma seria, indipendentemente dal fornitore che la propone. Il secondo è entrare nel merito dei tre ecosistemi che, insieme, definiscono oggi lo stato dell'arte per chi lavora in azienda: quello di Anthropic, quello di OpenAI e quello di Microsoft, quest'ultimo costruito attorno a una visione di agente peculiare e sufficientemente diversa da meritare un approfondimento (fosse anche solo perché la diffusione della piattaforma è oltremodo capillare).

Per rendere concreti i concetti che seguono, useremo lungo tutto l'articolo un unico caso di riferimento, scelto in un ambito trasversale a qualunque settore: il processo mensile di chiusura e reporting di controllo di gestione di un gruppo organizzato su più unità di business o più Paesi. È un processo che chiunque abbia un minimo di familiarità con l'amministrazione aziendale riconosce immediatamente, ricco abbastanza da attraversare quasi tutti i temi tecnici che affronteremo, dalla raccolta dei dati alla verifica dei risultati, e sufficientemente lontano dal linguaggio informatico da restare comprensibile a un pubblico di manager e non solo di tecnici.

1 Parte I. Dal chatbot all'agente: le coordinate concettuali

1.1 Che cos'è, davvero, un agente AI


La distinzione più utile per orientarsi in questo campo non è (solo) quella tra chatbot e agente, ma quella tra workflow e agente, così come la propone Anthropic in uno dei testi fondativi della letteratura tecnica su questo tema. In un workflow, il percorso di esecuzione è predefinito dal codice che orchestra modello e strumenti secondo passi fissati in anticipo: per quanto sofisticato, la sequenza delle azioni è nota prima ancora che il compito cominci. In un agente, è il modello stesso a dirigere dinamicamente (con un certo livello di autonomia che costituisce una delle tre caratteristiche definitorie) il processo e la scelta degli strumenti, decidendo passo dopo passo come procedere in base a ciò che osserva. È una distinzione architetturale che non implica alcuna "graduatoria di merito" (come invece capita spesso di "percepire" in questa stagione di FOMO da agenti): un processo prevedibile e ripetitivo, come il calcolo di un rimborso spese secondo regole fisse, è spesso servito meglio da un workflow rigido, più economico e più facile da verificare, che da un agente autonomo. Un reclamo incompleto, che richiede di cercare un ordine mancante, confrontarlo con una policy e costruire una proposta di soluzione, è invece il tipo di compito in cui l'autonomia dell'agente potrebbe iniziare a creare valore reale.

Conviene evitare, fin da questa prima definizione, la formula assoluta secondo cui "il chatbot parla, l'agente agisce": un sistema conversazionale può benissimo consultare un documento o

usare uno strumento isolato, per esempio calcolare un totale o cercare un dato, senza per questo ricevere la responsabilità di un intero processo. La differenza va spiegata attraverso il grado di delega dei passaggi, non attraverso un confine netto tra il generare testo e il fare. La definizione operativa che adotteremo per il resto dell’articolo è dunque la seguente: un agente AI è un sistema **basato su di un modello di linguaggio** che, ricevuto un obiettivo, sceglie ed esegue passi utilizzando **strumenti**, osserva i risultati e adatta il seguito del lavoro entro limiti stabiliti, fino a decidere **autonomamente** quando il compito può dirsi concluso. Il modello linguistico è un componente di questo sistema, non il sistema stesso: l’agente comprende anche il software che ne governa l’esecuzione, il contesto a cui accede e i permessi che gli sono assegnati, un punto su cui torneremo subito.

Applicata al nostro caso di riferimento, la differenza si vede subito. Un workflow di chiusura mensile applica regole fisse: consolida i dati, calcola gli scostamenti secondo formule predefinite, popola un template. Un agente di chiusura mensile, oltre a questo, nota che lo scostamento di una business unit supera la soglia di materialità, cerca autonomamente possibili spiegazioni nei documenti disponibili, richiede al responsabile della business unit una nota di commento se non trova nulla di conclusivo, e adatta la propria proposta di reporting in base a quanto scopre lungo il percorso. Il workflow è prevedibile e verificabile riga per riga; l’agente è in grado di “gestire” l’eccezione, ma richiede una progettazione della delega più attenta, il tema a cui è dedicata la parte centrale di questo articolo.

Workflow e agente a confronto



calling supervisionato, in cui l'agente propone un'azione e un umano la approva prima che venga eseguita. All'estremo opposto si trovano flussi che operano per ore, quando non per giorni, con supervisione solo asincrona, verificati a posteriori piuttosto che passo per passo. Nel mezzo si colloca la gran parte dei casi d'uso aziendali oggi realistici, in cui l'autonomia è ampia sui passaggi di analisi e raccolta dati, ma si restringe deliberatamente nei momenti in cui un'azione produce un effetto esterno irreversibile, come l'invio di un documento o l'aggiornamento di un sistema di produzione o che altri consultano.




Figura 2: Il continuum dell'autonomia

Questo spettro non è solo una descrizione tecnica: ha implicazioni dirette di governance, di costo e di rischio, che si intensificano man mano che ci si sposta verso l'estremo più autonomo. Un'osservazione che vale la pena di richiamare qui è che questo stesso spettro di autonomia riproduce, in forma nuova, un problema antico quanto l'organizzazione d'impresa, quello dell'agenzia: ogni volta che si delega un compito a un esecutore (umano o artificiale) di cui non si osservano direttamente tutte le azioni, si genera un'asimmetria informativa che va gestita con strumenti di controllo appropriati. Di questo tema ho approfonditamente parlato sia in diversi articoli precedenti che anche in uno specifico capitolo del mio libro.

1.3 Anatomia di un agente: modello, harness, contesto, ambiente

Il termine tecnico *harness* indica l'insieme di software che organizza il ciclo di lavoro dell'agente: la gestione degli strumenti, l'esecuzione dei comandi, la gestione del contesto, le interruzioni e la ripresa di un compito. Sia OpenAI, con la propria Agents API, sia Anthropic, con i Claude Managed Agents, descrivono oggi esplicitamente infrastrutture gestite dedicate proprio a questo compito, un fatto che segna una distinzione netta tra il semplice accesso a un modello e l'adozione di un vero e proprio ambiente operativo per il lavoro agentico.

Per orientarsi in modo consapevole in questo campo (consapevoli anche della sua costante evoluzione), propongo di tenere separati cinque livelli, una distinzione che vale la pena avere sempre presente perché torneremo a usarla in ogni sezione successiva dell'articolo: il **modello**, cioè il sistema linguistico che ragiona; l'**applicazione** che lo utilizza, cioè l'**interfaccia** con cui l'utente o l'organizzazione interagisce; l'**ambiente di esecuzione**, cioè dove effettivamente girano gli strumenti e il codice che l'agente invoca; le **integrazioni**, cioè i collegamenti verso i sistemi aziendali; e i **controlli**, cioè permessi, guardrail e audit. Il motivo per cui questa distinzione è operativamente rilevante e non solo tassonomica è che cambiare modello non trasferisce automaticamente memoria, strumenti, autorizzazioni e workflow: un'organizzazione che decide di passare da un modello a un altro, o da un fornitore a un altro, deve ricostruire o migrare separatamente ciascuno di questi livelli.



Figura 3: I cinque livelli di un sistema agentic

Nel nostro caso di riferimento, il valore pratico di questa distinzione si vede in un dettaglio apparentemente minore ma frequente nella realtà operativa: un'analisi di chiusura mensile automatizzata può interrompersi non per un limite del modello, che magari ragiona perfettamente, ma perché manca un file atteso nel repository condiviso o è scaduto l'accesso al sistema gestionale. Il valore di un buon harness è proprio conservare lo stato del lavoro già svolto e riprendere dal punto corretto, senza dover compiere a mano l'aggiornamento dei sistemi coinvolti quando l'*incidente* viene risolto.

2 Parte II. L'infrastruttura comune: la logica di base indipendente dalle piattaforme

Prima di entrare nelle specificità degli editori di modelli commerciali di maggiore diffusione con Anthropic, OpenAI e Microsoft, vale la pena fermarsi sugli elementi che, pur con implementazioni proprietarie diverse, sono ormai trasversali a qualunque piattaforma agentica seria. È la parte più “voluminosa” di questo lavoro, ma anche quella più genericabile e, si spera, duratura. I nomi dei singoli prodotti cambieranno ma questa grammatica di base è quella con cui continueremo a ragionare sugli agenti per diversi anni.

2.1 Il ciclo agentico e il tool use

Il meccanismo di base su cui poggia qualunque comportamento agentico è il cosiddetto **tool use** cioè la vecchia cara RFC (remote function calling). Il modello, oltre a generare testo, può chiamare una funzione esterna con parametri specifici, il software chiamato esegue quella funzione, e il risultato rientra nel contesto del modello, che lo usa per decidere il passo successivo. Questo scambio, ripetuto quante volte necessario, costituisce il **ciclo agentico**: un obiettivo iniziale, la scelta di un passo, l'azione, l'acquisizione e valutazione del risultato, un'eventuale verifica, e infine la decisione di continuare o di fermarsi, dichiarando il compito concluso o segnalando l'impossibilità di proseguire senza un intervento umano.

È utile distinguere, fin da questo primo blocco, gli strumenti che leggono da quelli che “scrivono” (o modificano). Leggere lo stato di una fattura o di un saldo contabile e modificarne il valore sono due operazioni radicalmente diverse sul piano del rischio, anche per quanto risultino tecnicamente simili nella loro implementazione: la prima è quasi sempre sicura da automatizzare con ampio margine di autonomia, la seconda richiede permessi più stretti e, spesso, un punto di verifica umana. Nel nostro caso “esemplificativo” di riferimento, un agente che consulta i saldi del sistema gestionale per calcolare uno scostamento opera in una zona a basso rischio; lo stesso agente che modifica un valore nel sistema contabile, oppure che invia il reporting package fuori dal perimetro autorizzato, si sposterebbe in una zona che richiede controlli diversi, di cui parleremo più avanti in questa stessa parte. Vale infine la pena di ricordare, perché è un errore comune nella comunicazione aziendale sull'AI, che una richiesta formalmente valida non è per questo una richiesta corretta sul piano del merito: un agente può costruire una query sintatticamente ineccepibile su un dato sbagliato, ed è per questo che la verifica dell'esito, di cui parleremo al paragrafo dedicato, non può mai essere sostituita dalla sola eleganza tecnica dell'esecuzione.

Vale la pena guardare da vicino come un tool si presenta (si “espone”) effettivamente al modello, perché è il punto in cui la retorica sugli agenti incontra la sua parte più prosaica e più rassicurante. Un tool non è un frammento di intelligenza: è una **dichiarazione**, scritta in un formato strutturato (di norma JSON Schema), che descrive un nome, uno scopo e i parametri accettati. Il modello riceve questa dichiarazione insieme al prompt, e ciò che “decide” è soltanto *se* invocarla e *con quali parametri*.

```

{
  "name": "get_account_balance",
  "description": "Restituisce il saldo di un conto per una BU e un periodo",
  "input_schema": {
    "type": "object",
    "properties": {
      "bu_code": { "type": "string" },
      "periodo": { "type": "string", "description": "formato AAAA-MM" }
    },
    "required": ["bu_code", "periodo"]
  }
}

```

Tre osservazioni ritengo sia necessario subito affrontare. La prima è che il campo **description** è la parte che fa davvero lavorare il sistema: è scritto in linguaggio naturale ed è, a tutti gli effetti, la documentazione sulla cui base il modello sceglie. Una descrizione ambigua produce chiamate sbagliate molto più spesso di quanto non faccia un modello “poco capace”, ed è la ragione per cui la qualità di un’integrazione agentica dipende, in misura sorprendente, da competenze di scrittura (ahi ahi ahi ... poveri noi) più che di programmazione. La seconda è che il modello non esegue nulla: invoca una funzione tramite una richiesta strutturata, il software che lo espone la esegue, e il risultato rientra come nuovo messaggio, così che il turno di lavoro in un ciclo agentico non è “domanda e risposta” ma “richiesta di strumento e ricezione del risultato dello strumento”, ripetuto finché serve. La terza è che la validazione dello schema avviene prima dell’esecuzione: un parametro fuori formato viene respinto dal software, non dal modello, ed è la prima e più economica barriera di sicurezza disponibile.

Vale la pena, a questo punto, seguire l’intera sequenza, per smontare l’impressione (che avrebbe potuto lecitamente sovvenire) che il modello “sappia” qualcosa dei sistemi a cui è collegato.

Nel momento in cui un collegamento viene attivato, l’applicazione chiede al sistema collegato l’elenco delle capacità disponibili ricevendo in risposta le dichiarazioni, ciascuna con il proprio nome, la propria descrizione e il proprio schema dei parametri. Quelle dichiarazioni vengono inserite nel contesto del modello, insieme alle istruzioni di sistema e alla richiesta dell’utente: sono testo, e il modello le legge come legge tutto il resto. Il modello non sa che il sistema gestionale esiste, ma gli è stato detto, in quella conversazione e soltanto in quella, che esiste una **funzione** con quel **nome**, quella **descrizione** e quei **parametri**. Spento il collegamento, quella conoscenza sparisce, per la semplice ragione che non è mai stata sua.

A quel punto l’utente formula la propria richiesta, e il modello, invece di produrre testo ordinario, produce un’uscita strutturata che nomina una delle funzioni dichiarate e ne valorizza i parametri. La corrispondenza fra la richiesta e la funzione avviene per somiglianza “di significato” (lo so, si potrebbe dire somiglianza semantica ma mi fa ancora senso parlare di semantica riferendomi a sti attrezzi) fra ciò che è stato chiesto e ciò che la descrizione dichiara di fare: è

una selezione fra opzioni dichiarate sulla base di un testo, non una comprensione del sistema. Il software intercetta quella richiesta, valida i parametri contro lo schema, esegue davvero la chiamata, e fa rientrare il risultato come nuovo messaggio, sul quale il modello decide se il compito sia concluso oppure se serva un altro passo.

Una traccia semplificata di ciò che attraversa effettivamente il filo, nel nostro caso di riferimento, rende la sequenza meno astratta:

[già in contesto, prima ancora della richiesta]

```
{ "name": "get_account_balance",  
  "description": "Restituisce il saldo di un conto per una BU e un periodo",  
  "input_schema": { "bu_code": "string", "periodo": "string (AAAA-MM)" } }  
{ "name": "get_budget",  
  "description": "Restituisce il budget approvato per una BU e un periodo", ... }
```

[utente] Qual è lo scostamento della BU Nord a marzo?

[modello] → get_account_balance(bu_code="IT-NORD", periodo="2026-03")

[software] ← {"saldo": 1284300, "aggiornato_al": "2026-04-02"}

[modello] → get_budget(bu_code="IT-NORD", periodo="2026-03")

[software] ← {"budget": 1230000, "delibera": "2026-01-18"}

[modello] Lo scostamento è di 54.300 euro, pari al 4,4 per cento del budget.

Si noti che una richiesta apparentemente semplice produce, quasi sempre, più di una chiamata, e che il secondo passo dipende dal risultato del primo: è il ciclo agentico in miniatura, e si osserva bene che l'informazione necessaria al passo successivo il modello non poteva averla prima. E siccome stiamo parlando di modelli linguistici che funzionano su base stocastica **la selezione non è deterministica** ovvero sia la stessa richiesta, in due sessioni diverse, può tradursi nella scelta di una funzione diversa o parametri diversi. Ne derivano due regole pratiche da appuntarsi come mantra primo che la qualità della descrizione conta più della capacità del modello, secondo più strumenti si dichiarano, peggio il modello sceglie. Trenta funzioni dichiarate insieme producono errori di selezione che cinque non producono, ed è un errore particolarmente insidioso perché le chiamate risultano comunque formalmente valide.

Da qui discende un principio di progettazione che è anche un principio organizzativo che conviene enunciare con chiarezza perché va contro la strada che a prima vista appare più comoda.

Quando un sistema espone già un'interfaccia di programmazione, la tentazione è forte perché la scorciatoia è disponibile: esistono strumenti che, a partire dalla specifica tecnica di quell'interfaccia, generano automaticamente una funzione dichiarata per ciascuna delle operazioni disponibili. Il risultato è un collegamento con ottanta strumenti, i cui nomi sono quelli pensati dagli sviluppatori per altri sviluppatori, e le cui descrizioni sono frammenti di documentazione tecnica scritti per chi già conosce il dominio. Un agente messo davanti a ottanta dichiarazioni di questo tipo sceglie **male**, e per le ragioni appena viste sceglie male nel modo più insidioso, cioè con chiamate formalmente ineccepibili.

La ragione di fondo è che un'interfaccia progettata per alimentare uno schermo non è un'interfaccia progettata per un agente. Uno schermo fa molte chiamate piccole e le ricompone davanti all'utente; un agente paga ogni chiamata in tempo e ogni risposta in contesto. Se nel nostro caso di riferimento, per ottenere lo scostamento di una business unit, occorrono una chiamata per il saldo di ciascun conto, una per il budget, una per la soglia di materialità e una per la data di aggiornamento, la funzione giusta da dichiarare non è nessuna di quelle: è una funzione sola, `calcola_scostamento`, che al proprio interno esegue tutte le chiamate necessarie e restituisce un oggetto di sei campi. Vale lo stesso per la forma della risposta. Un'interrogazione contabile restituisce facilmente centinaia di campi, fra codici interni, indicatori di stato e riferimenti tecnici, e riversarli tutti nel contesto del modello costa, non aggiunge nulla alla decisione e ne peggiora la qualità, perché diluisce l'informazione utile in un rumore che il modello è comunque costretto a leggere e dentro cui deve discriminare. Il connettore deve filtrare, e la scelta di che cosa filtrare è una decisione di merito che presuppone di sapere a che cosa il dato serva.

Il criterio, allora, è semplice da enunciare: gli strumenti si disegnano sui compiti, non sulle operazioni tecniche disponibili. La domanda da porsi non è quali chiamate esponga un certo sistema, ma quali siano le cinque o sei cose che l'agente deve saper fare, e per ciascuna di esse si costruisce una funzione sola, con un nome che anche una persona di business non IT possa capire senza spiegazioni, una descrizione scritta per essere letta e non per documentare, e una risposta ridotta all'essenziale e accompagnata dall'indicazione della freschezza del dato.

È a questo punto che la questione smette di essere tecnica e diventa, ahimè come tutto quello che riguarda l'AI, organizzativa. Decidere che l'agente disponga di una singola funzione `calcola_scostamento` e non di quindici operazioni elementari significa aver deciso quale sia l'unità di lavoro che si intende delegare, ed è esattamente la stessa decisione che si prende quando si scrive una procedura per una persona appena entrata in un ufficio. Ne esce confermata la considerazione che la qualità di un'integrazione agentica dipende in misura sorprendente da competenze di scrittura più che di programmazione, e, si potrebbe aggiungere ora, da competenze di progettazione organizzativa più che di architettura del software.

Nel nostro caso di riferimento la conseguenza è netta: se il perimetro di `get_account_balance` è la sola lettura, nessuna formulazione del prompt, per quanto abile o malevola, potrà trasformarla in scrittura, perché la funzione di scrittura semplicemente non esiste fra gli strumenti dichiarati. È un punto che vale la pena in tutti quei contesti in cui si tende a discutere a lungo di che cosa l'agente "potrebbe decidere di fare": il perimetro di ciò che un agente può fare non è una questione di istruzioni, è una questione di quali funzioni gli sono state messe a disposizione. Punto. (Chi è causa dei suoi mali quindi sa chi piangere, come avrebbe detto mia nonna).

Il ciclo agentico




Figura 4: Il ciclo agentico

2.2 Una mappa terminologica: prompt, istruzioni, skill, tool, connettore, MCP, plugin

Anche se verrà percepito come un “complicato approfondimento tecnico” ritengo che dotarsi di un glossario “rigoroso” e riferircisi con precisione sia il primo passo per una conversazione aziendale sensata sull’argomento.

Elemento	Funzione	Esempio nel caso di riferimento
Prompt	Esprime una richiesta puntuale (one shot) esprimendo (quando i prompt sono fatti bene) contesto di riferimento, attesa, istruzioni ed informazioni (do e do not), step operativi, meccanismi di controllo e vincoli	CONTESTO: Sei l’assistente di un Controller di ... TASK: Prepara la bozza di reporting per la BU Nord secondo gli standard di riferimento ... INFORMAZIONI: utilizza i dati ..., STEP1: inizia a preparare outline della presentazione ...
Istruzioni persistenti	Convenzioni o contesto di riferimento (aziendale, funzionale) applicabili a più attività, caricate ogni volta (mediante configurazione nel bot oppure file di configurazione)	Soglia di materialità, formato delle date, glossario di gruppo

Elemento	Funzione	Esempio nel caso di riferimento
Skill	Procedura riutilizzabile, con risorse (strumenti, template, formati etc) associate, caricata quando pertinente (sia a fronte di un richiamo esplicito nel “prompt” sia in forma “autonoma” a fronte del riconoscimento dell’ambito di competenza richiesto dall’azione)	Metodologia di reporting (modello di controllo, processo di closing etc), standard contabili di riferimento e template di reporting direzionale del gruppo
Tool (strumento)	Sistema informatico che espone uno o più “funzioni” (tramite API od altri protocolli come MCP) che vengono eseguite puntualmente con dati di input e producendo output	Lettura di un saldo dal sistema contabile, calcolo uno scostamento tramite il modello di reporting, aggiornamento di una cella in un foglio di lavoro
Connettore	Collegamento dell’agente a un’applicazione o a una fonte dati specifica	Accesso in sola lettura al sistema gestionale e al sistema di budget
MCP	Protocollo che definisce una modalità universale di esporre e usare capacità (funzioni) e contesto di applicazioni in modo standard	Un server MCP espone le operazioni di consultazione del gestionale a più applicazioni compatibili
Plugin	Pacchetto distribuibile che raggruppa skill, connettori e altre estensioni	Pacchetto “controllo di gestione” con metodo, connettori e controlli pre-configurati

Una precisazione va aggiunta proprio qui, perché la forma stessa della tabella rischia di indurre in errore: connettore e MCP compaiono come due voci affiancate, e questo suggerisce che siano due oggetti dello stesso genere fra i quali si debba scegliere. Non è così, e la domanda che sento porre più spesso nelle riunioni aziendali, cioè se convenga usare un connettore oppure il MCP, è una domanda malposta.

Connettore è una parola di prodotto. Risponde alla domanda su che cosa io abbia collegato, con quale autorizzazione e in che modo io possa revocarlo. È l’unità che vedo nell’interfaccia, quella che ha un nome, un’icona, un interruttore, una schermata di consenso e un pulsante per rimuoverla: un’unità di installazione, di consenso e di revoca.

MCP è una parola di protocollo. Risponde a una domanda diversa, cioè in che lingua si parlino il programma che sto usando e il sistema collegato. È il formato del dialogo, e non lo vedo mai, esattamente come non vedo mai il protocollo con cui il mio computer parla con la stampante.

L’analogia della stampa è del resto abbastanza fedele da poterla usare: il connettore è il driver che installo, con il suo nome e le sue impostazioni, mentre il MCP è il linguaggio che quel driver

parla con la stampante. Posso avere un driver che parla uno standard aperto e uno che parla un formato proprietario del produttore, e per me che stampo non cambia nulla, ma cambia tutto nel momento in cui devo collegare una stampante diversa.

Ne discende che le quattro combinazioni esistono tutte, e che dall'interfaccia non è dato distinguerle.

	Costruito su MCP	Non costruito su MCP
Confezionato come connettore	il caso più diffuso oggi: un server MCP remoto, con autenticazione delegata, presentato all'utente come un interruttore da accendere	un'integrazione proprietaria, costruita prima che il protocollo esistesse oppure dal fornitore stesso verso i propri servizi
Non confezionato	un server MCP configurato a mano in un file, senza consenso interattivo e senza catalogo	un semplice strumento dichiarato nel codice della propria applicazione

La conseguenza pratica è quella che conta, e riguarda una delle discussioni più frequenti sul rischio di dipendenza da un fornitore: il fatto che due prodotti mostrino entrambi un connettore verso il medesimo servizio non dice assolutamente nulla sul fatto che quel collegamento sia trasferibile dall'uno all'altro. Si scambia, in quel ragionamento, la portabilità dell'esperienza d'uso per la portabilità dell'integrazione, che sono cose diverse. È la ragione per cui, quando si valuta una piattaforma, la domanda utile non è se supporti i connettori, ma quali di essi siano costruiti su uno standard aperto, e che cosa resti in mano all'organizzazione nel giorno in cui quella piattaforma venisse sostituita.

Dove vive ciascun componente




Figura 5: Dove vive ciascun componente

Le **skill** meritano un approfondimento, perché sono probabilmente l'innovazione più concreta ultimi due anni in questo ambito. Una **skill** è una cartella che raccoglie istruzioni, metadati e risorse opzionali (script, “prompt” template, documenti di riferimento) che l'agente utilizza automaticamente quando pertinenti al compito in corso, senza che occorra reinserirle a ogni conversazione. L'architettura con cui Anthropic ha reso pubblico questo formato, oggi aperto, adotta un principio di caricamento progressivo su tre livelli: i metadati della skill (nome e breve descrizione) sono sempre presenti nel contesto del sistema, a un costo computazionale (i.e. token richiesti) minimo, le istruzioni vere e proprie vengono caricate solo quando la skill viene effettivamente attivata, le risorse più corpose, script inclusi, vengono lette solo se effettivamente referenziate durante l'esecuzione. Questo permette a un'organizzazione di dotare un agente di decine di competenze specialistiche senza che il solo elenco di ciò che l'agente “sa fare” occupi una porzione significativa della sua capacità (i.e costi) di ragionamento. Concretamente una skill si presenta come una cartella che contiene un file **SKILL.md**, con un breve intestazione di metadati (nome, descrizione sintetica, condizioni in cui va attivata) seguita dalle istruzioni operative vere e proprie, affiancata da sottocartelle con le risorse effettivamente da richiamare, per esempio un template in formato Excel e uno script di calcolo. Nel nostro caso di riferimento, la skill “reporting di controllo di gestione” avrebbe una descrizione del tipo “genera il pacchetto di reporting mensile per una business unit a partire dai saldi del gestionale e dal budget approvato”, una sezione di istruzioni che, oltre a fissare le convenzioni di formattazione delle date e delle valute, richiama la soglia di materialità già definita altrove, come istruzione persistente (per esempio 15.000 euro o il 5% del valore di budget, la minore delle due, tenuta in un file come **soglie.md** e importata dal **CLAUDE.md** di progetto, non ridefinita nella skill), e una cartella di risorse con il template del pacchetto direzionale del gruppo: solo quando l'agente riceve un compito che

può essere interpretato come aderente alle specifiche “capacità”, il sistema carica le istruzioni complete, e solo se lo script di calcolo viene effettivamente invocato ne legge il contenuto. Questa struttura permette il caricamento progressivo di cui sopra, ed assicura che ogni agente che la richiami produca un output coerente con lo standard aziendale, senza doverlo istruire ogni volta.

In termini di file, una skill è poco più di un documento di testo con un'intestazione strutturata:

```
---
name: reporting-controllo-di-gestione
description: Genera il pacchetto di reporting mensile per una BU a partire dai
    saldi del gestionale e dal budget approvato. Usare per chiusure e forecast.
---
```

Procedura

1. Estrarre i saldi del periodo (strumento: `get_account_balance`)
2. Confrontare con l'ultima versione approvata del budget
3. Evidenziare gli scostamenti oltre soglia (criteri in `soglie.md`)

accompagnato da una struttura di cartelle di questo tipo:

```
reporting-controllo-di-gestione/
├── SKILL.md
├── soglie.md
├── template/pacchetto-direzionale.xlsx
└── scripts/calcola_scostamenti.py
```

L'economia di questo meccanismo è più interessante della sua sintassi. Le due righe di `description` restano sempre nel contesto, al costo di poche decine di token; il corpo del `SKILL.md` entra solo quando la skill viene attivata, al costo di qualche migliaio; i file di supporto vengono letti solo se il percorso li richiede effettivamente. Un'organizzazione può quindi mantenere cinquanta procedure formalizzate pagando, a riposo, il costo di cinquanta descrizioni brevi. È la ragione per cui questo formato, nato come espediente tecnico per risparmiare contesto, è in realtà un fatto organizzativo di un certo peso: rende economicamente sostenibile **codificare il sapere operativo** invece di lasciarlo depositato nell'esperienza delle persone, che è poi il problema che il controllo di gestione si pone da sempre quando prova a documentare un processo.

Il caricamento progressivo di una skill




Figura 6: Il caricamento progressivo di una skill

Un punto da chiarire per evitare fraintendimenti comuni nella comunicazione aziendale: una skill non è cioè una forma di addestramento e come tale non modifica i pesi del modello linguistico che la usa (la bufala dell'impara mentre esegue che tanti fornitori marmaldi spacciano a tanti clienti ingenui) e non concede da sola il diritto di accedere a un'applicazione, che resta demandato al connettore e ai permessi assegnati.

Condivido un esempio tratto dalla mia esperienza diretta per mostrare non che cosa sia una skill (cosa che abbiamo già trattato), ma come se ne renda evidente la necessità.

Negli ultimi anni, lavorando con questi strumenti, mi sono accorto che una certa conversazione si ripeteva quasi identica: a partire da un saggio od un articolo lungo da me scritto di solito preparo (con un modello) il documento di istruzioni per un'altra AI incaricata di produrre le immagini di un carosello da pubblicare sui social per "presentare" l'articolo. Stesse tre domande preliminari (il testo va generato insieme all'immagine oppure composto dopo, quale formato, quante tavole), stessa struttura del documento, stesse convenzioni visive, stesse avvertenze sugli accenti che i modelli di immagine sbagliano con regolarità. Diversi saggi scritti a qualche mese di distanza, e la medesima procedura ricostruita ogni volta da capo.

Il criterio per capire se una conversazione ricorrente possa diventare una skill è semplice: se dovessi affidare quello stesso lavoro a un collega appena arrivato, gli consegnerei un foglio di istruzioni oppure dovrei sedermi con lui e discuterne? Nel primo caso è una skill, nel secondo non lo è, o non lo è ancora. Il brief del carosello è una procedura chiusa con un esito riconoscibile, ed è esattamente il genere di sapere che conviene codificare.

La costruzione è tutto sommato semplice. Una cartella, un file `SKILL.md` con un'intestazione di due righe (il nome, e una descrizione che dice che cosa fa la skill e quando va usata, scritta con le parole con cui formulerei la richiesta), e sotto la procedura in testo ordinario. Le parti

più voluminose, cioè le convenzioni cromatiche e un esempio completo di documento, stanno in file separati (in modo da poter scegliere un formato riconoscibile a seconda dell'audience e del contenuto), che il corpo della skill nomina esplicitamente rendendo operativo il terzo livello del caricamento progressivo. Nei prodotti Anthropic la cartella si carica compressa, dalla sezione di personalizzazione dell'applicazione, oppure si colloca in una directory dedicata quando si lavora con lo strumento per sviluppatori; da quel momento si attiva da sola quando la richiesta corrisponde alla descrizione, oppure la si richiama per nome.

Il collaudo va fatto su un caso diverso da quello da cui la skill è stata ricavata, e verifica tre cose: se si attiva senza essere nominata (in caso contrario va riscritta la descrizione), se produce la struttura prevista o se improvvisa (in caso contrario il corpo è troppo vago), e se legge i file di supporto quando servono (in caso contrario non sono stati nominati con sufficiente chiarezza).

Nulla, in tutto questo, è stato addestrato. Nessun peso è stato modificato, e il modello che usa la skill è identico a quello che non la usa. Un sapere operativo che fino al giorno prima viveva nella mia testa e nella cronologia delle conversazioni è diventato un file di testo con un'intestazione, che chiunque può aprire, leggere, correggere e cancellare. Finché resta nella cartella di una persona, però, è poco più di un appunto ben fatto. Diventa materiale a supporto della A(I)doption quando, soprattutto nell'ambito delle attività di LA(I)B diventa pratica comune condivisa in ambito aziendale.

Distinto dalla skill è il **plugin**, il meccanismo di confezionamento e distribuzione che può includere skill, server MCP e altre estensioni. OpenAI propone skill per ChatGPT e Codex e plugin per distribuirle insieme ai connettori; Anthropic propone plugin utilizzabili in Chat e in Cowork, mentre Claude Code dispone di un proprio meccanismo di estensioni. Formato condiviso e disponibilità su più prodotti non sono garanzia di comportamento identico né di piena portabilità delle dipendenze tra piattaforme, un tema su cui torneremo nella parte comparativa più avanti.

Se la skill risponde alla domanda “che cosa l'agente sa fare”, il plugin (o *package*, nella terminologia di alcuni prodotti) risponde a una domanda diversa e tipicamente aziendale: **come si distribuisce, si aggiorna e si revoca quel sapere**. È il passaggio in cui una procedura smette di essere un file sulla macchina di qualcuno e diventa un oggetto versionato, e la sua struttura è quella di un normale pacchetto software:

```
controllo-di-gestione/
├── .claude-plugin/plugin.json  # nome, versione, autore, descrizione
├── skills/                    # una o più skill
├── commands/                  # comandi richiamabili esplicitamente
├── agents/                    # subagenti specializzati
└── .mcp.json                  # server MCP inclusi nel pacchetto
```

La distribuzione avviene poi attraverso un repository, che nel caso aziendale è opportuno sia interno e controllato. Ed è esattamente qui che la materia smette di essere di pertinenza del singolo utente: versioni, dipendenze, provenienza del codice e diritto di installazione sono gli stessi problemi che poniamo da trent'anni a qualunque software aziendale. Non vedo alcuna

ragione per cui un pacchetto che contiene istruzioni operative, criteri di calcolo e accessi al sistema contabile debba essere trattato con meno rigore di un modulo del gestionale, e temo che in molte organizzazioni, in questa fase, stia accadendo esattamente il contrario.

2.3 Che cosa c'è sotto il connettore

Se le skill risolvono il problema di “che cosa l'agente sa fare”, i connettori e il Model Context Protocol risolvono quello, altrettanto centrale, di “a che cosa l'agente può accedere”. Prima però di guardare il protocollo conviene guardare lo step che lo precede perché è spesso quello in cui il vocabolario corrente confonde due cose distinte.

Una **API** è un contratto esposto dal sistema di origine. Sta dalla parte del sistema, è la porta che il gestionale apre verso il mondo, e definisce quali operazioni siano disponibili, con quali parametri e con quali risposte. Chi la usi, e per farne che cosa, non è affare suo.

Un **connettore** è invece software di integrazione che sta dalla parte di chi consuma. Sa parlare con quel sistema specifico e si fa carico di tutto ciò che il sistema di origine non fa per te: autenticarsi e rinnovare le credenziali, gestire il trasporto e i tempi di attesa, paginare i risultati lunghi, tradurre gli errori in qualcosa di comprensibile, riprovare quando riprovare ha senso, e soprattutto mappare il modello dati di partenza (che in un gestionale anziano è spesso un file con nomi di campo di sei caratteri ereditati dagli anni Ottanta) in un modello che abbia senso per chi lo usa. Nel vocabolario dei prodotti AI la parola ha poi assunto un significato più stretto e più commerciale, cioè quello di un'integrazione confezionata e installabile, con la propria schermata di consenso e il proprio interruttore (su questo torneremo in seguito).

Ne discende una precisazione che vale la pena fissare da subito: un connettore non ha bisogno strettamente di una API, ha bisogno di una via di accesso programmatica. Il più delle volte quella via è effettivamente una API, ma può benissimo essere un driver di database, una stored procedure, una coda di dati, un file depositato in una cartella condivisa o, nei casi peggiori, l'emulazione di un terminale (sacrosanta cosa da evitare sempre come la peste o la malaria, quando possibile). E se quella via non esiste, il primo compito del progetto non è scrivere il connettore ma creare la via.

Il caso limite (che nella realtà italiana delle imprese di media dimensione è la norma e non l'eccezione) è quello di un Legacy. Prendiamo un sistema su IBM i, l'ex AS/400, che molte aziende manifatturiere usano ancora per la contabilità e per la produzione. È un sistema che nessuno ha progettato pensando all'intelligenza artificiale, e che tuttavia risulta, contro ogni aspettativa, fra i più facili da integrare: il suo database è accessibile in SQL, e i programmi RPG o COBOL che vi girano sono invocabili per via programmatica senza doverne riscrivere una riga, attraverso stored procedure che li incapsulano, attraverso i servizi web che il sistema operativo sa generare da sé, oppure attraverso i componenti open source che la comunità mantiene da anni al fine di creazione di “backbone” di integrazione multilivello.

La catena completa, per quanto la si ami disegnare come una pila di livelli tecnologici, è in realtà molto semplice: il sistema con i suoi dati e i suoi programmi, sopra di esso una via

di accesso programmatica, sopra ancora il connettore che normalizza e protegge, poi il server che dichiara le capacità in forma tipizzata secondo il protocollo (MCP in questo caso), e infine l'applicazione agentica che le consuma. Il protocollo occupa soltanto il penultimo gradino perché definisce il canale, non costruisce la via di accesso, non decide chi possa usarla e non migliora di un grammo la qualità del dato che ci passa dentro.

Due punti, in questo percorso, meritano di essere decisi all'inizio l'identità con cui il connettore opera e la separazione (mandatoria) fra lettura e scrittura. Per il primo punto si può utilizzare un'utenza tecnica di servizio, oppure un'identità delegata, con la quale l'agente agisce per conto della persona collegata ed eredita i permessi che quella persona già possiede nell'applicativo. Per il secondo tema invece conviene adottare due profili distinti, e possibilmente due server distinti, perché il perimetro di ciò che si può leggere e quello di ciò che si può modificare non hanno alcuna ragione di coincidere, né sul piano del rischio né su quello delle approvazioni.

Nel nostro caso di riferimento, tutto questo si traduce in un esercizio di pragmatica concretezza: prima di intavolare qualunque discorso sugli agenti, occorre sapere quale vista del sistema contabile contenga i saldi che servono, con quale utenza la si possa interrogare, chi in azienda abbia il titolo di autorizzare quell'accesso, e se esista già una funzione che registri una rettifica oppure se quella funzione vada costruita. Sono quattro domande che non hanno nulla di innovativo o sexy, ed è esattamente per questo che si è reticenti a porsele.

2.4 Connettori e Model Context Protocol

Il MCP è stato introdotto da Anthropic nel novembre 2024 come standard aperto per collegare i modelli a dati e strumenti esterni, con l'obiettivo dichiarato di sostituire le integrazioni personalizzate punto- punto, che crescono in modo combinatorio con il numero di fonti dati e di applicazioni coinvolte, con un protocollo comune di tipo client-server. L'architettura va compresa distinguendo tre ruoli: l'host applicativo, cioè il programma con cui l'utente interagisce; il client MCP, integrato nell'host, che parla il protocollo; e il server MCP, che espone dati e capacità secondo tre primitive standard: - gli strumenti (tool) - le risorse (resource) - i prompt riutilizzabili

Vale la pena vedere come si presenta concretamente un server MCP, perché la sua semplicità spiega buona parte della sua diffusione. Esporre una funzione significa, in pratica, annotare una funzione che esiste già:

```
@mcp.tool()
def get_account_balance(bu_code: str, periodo: str) -> dict:
    """Restituisce il saldo di un conto per una BU e un periodo (AAAA-MM)."""
    row = erp.query(bu=bu_code, period=periodo)
    return {"saldo": row.amount, "valuta": row.currency,
            "aggiornato_al": row.updated_at}
```

Del resto si occupa il protocollo: quando un'applicazione compatibile si collega, chiede al server l'elenco delle capacità disponibili e riceve in risposta le firme dichiarate, dopodiché può invocarle. Lo scambio, nella sua forma essenziale, è questo:

```

→ {"method": "tools/list"}
← {"tools": [{"name": "get_account_balance", "inputSchema": {...}}]}

→ {"method": "tools/call",
    "params": {"name": "get_account_balance",
               "arguments": {"bu_code": "IT-NORD", "periodo": "2026-03"}}}
← {"content": [{"type": "text",
                  "text": '{"saldo': 1284300, 'aggiornato_al': '2026-04-02'}"}]}

```

Due dettagli meritano attenzione, perché sono quelli che nella pratica separano un progetto che funziona da uno che si arena. Il primo è il **trasporto**: un server MCP può girare in locale, sulla macchina dell'utente, comunicando attraverso i canali standard del sistema operativo, oppure essere esposto in rete su HTTP. Sono due mondi diversi per autenticazione, sicurezza e gestione operativa, e la confusione fra i due è all'origine di parecchie sperimentazioni che funzionano benissimo sul portatile di chi le ha costruite e si rivelano impraticabili quando devono servire quaranta persone. Il secondo è che “supportare MCP” significa cose diverse a seconda del lato: essere **client**, cioè consumare server altrui, ed essere **server**, cioè esporre le proprie capacità, sono capacità distinte, e un prodotto può avere l'una senza l'altra, come mostra il caso di Codex che richiameremo più avanti.

Resta a questo punto una domanda che rischia di generare confusione cioè chi debba scrivere questi server, e se per usare un'applicazione attraverso il protocollo sia necessario attendere che il suo produttore ne metta a disposizione uno.

Il client è la parte più semplice della vicenda perché è un componente dell'applicazione agentica, e lo realizza chi quell'applicazione la costruisce (sia esso un sw di mercato oppure un agent custom). Il server, invece, può avere quattro provenienze, ciascuna con le proprie verifiche da compiere.

Provenienza	Quando accade	Che cosa verificare
Il produttore dell'applicazione	sempre più spesso, ed è ormai prassi per i principali fornitori di software in cloud	che cosa esponga davvero (di norma la lettura è coperta, la scrittura molto meno), con quale identità operi, e se sia incluso nella licenza
Il fornitore della piattaforma agentica	che costruisce il collegamento verso i servizi più diffusi e lo presenta come connettore	che il perimetro dichiarato corrisponda a quello di cui si ha effettivamente bisogno
Un terzo, spesso open source	esistono cataloghi pubblici con migliaia di server	provenienza, manutenzione, e chi ne abbia collaudato il codice

Provenienza	Quando accade	Che cosa verificare
L'organizzazione stessa, o il suo partner di integrazione	quando il sistema è proprio, specifico, o semplicemente nessuno se ne è ancora occupato	soltanto il tempo di chi lo scrive

Il server non gira dentro l'applicazione di destinazione e non richiede il permesso di chi la produce: sta dalla parte di chi consuma, e dialoga con quell'applicazione attraverso la via di accesso che già esiste. Detto in una frase, il produttore controlla l'interfaccia di programmazione, non il protocollo. Se l'applicazione espone una via di accesso, il server lo si può scrivere, e per cinque o sei funzioni è lavoro di giorni, non di mesi; se non la espone, allora sì che si è in ostaggio, ma il blocco sta al livello precedente e il protocollo non c'entra.

La casella più delicata della tabella è la terza. Un server è software che opera con le credenziali dell'organizzazione verso un sistema dell'organizzazione, e installarne uno prelevato da un catalogo pubblico equivale, sul piano del rischio, a installare un componente con privilegi all'interno del perimetro aziendale, con un'aggravante specifica: le descrizioni degli strumenti entrano nel contesto del modello, e possono quindi essere scritte per indurlo a comportamenti non previsti. Valgono qui, identici, i criteri di provenienza, versionamento e collaudo già richiamati a proposito dei pacchetti. Nulla impone, del resto, di pubblicare un server che si è scritto: può vivere interamente dentro la rete aziendale, in un piccolo catalogo interno mantenuto dai sistemi informativi, che è il modello verso cui si stanno orientando le organizzazioni più strutturate.

Anche la seconda casella merita attenzione, per ragioni opposte. Un collegamento a una casella di posta elettronica, nella forma in cui è disponibile alla data di stesura presso uno dei principali fornitori, dichiara trenta strumenti: sei si limitano a leggere, gli altri ventiquattro modificano in qualche modo lo stato della casella, dall'etichettatura dei messaggi fino all'invio e all'inoltro. L'utente che accende quell'interruttore per "farsi riassumere la posta" ha in realtà concesso un perimetro assai più ampio di quello che aveva in mente, e nessuna schermata glielo ha fatto notare.

Lo standard aperto, infine, ribalta la relazione di forza fra chi produce un'applicazione e chi la usa, ma non la annulla. Il produttore continua a controllare l'interfaccia sottostante, e con essa può cambiarne i formati, introdurre limiti di frequenza, o vietare nei termini contrattuali l'accesso automatizzato di terzi. Un server costruito su un'interfaccia che il fornitore non intende vedere usata in quel modo è tecnicamente possibile e contrattualmente fragile, ed è una verifica che conviene fare con chi si occupa dei contratti prima che con chi scrive il codice.




Figura 7: Il MCP: da N per M integrazioni a N più M

A fronte dell'adozione ufficiale del protocollo MCP da parte OpenAI, Google e Microsoft la specifica ha continuato a evolvere nel 2026 e gli aggiornamenti del 28 luglio 2026 (ultima major disponibile alla data di stesura del testo) introducono un'impostazione stateless più adatta al bilanciamento di carico su larga scala, un meccanismo di richieste multi round trip che sostituisce gli stream persistenti precedenti, e alcuni miglioramenti sull'autenticazione, con adozione riportata da fornitori cloud primari e da diverse aziende di prodotto. Non è corretto, in ogni caso, descrivere come pienamente retrocompatibile il ciclo di inizializzazione delle versioni precedenti rispetto a questa revisione: supportare MCP non significa implementarne tutte le estensioni o l'ultima revisione della specifica.

Applicato al nostro caso di riferimento, il valore del MCP si vede bene: un server MCP che espone le operazioni di consultazione del sistema gestionale e del sistema di budget può essere utilizzato, con gli opportuni permessi, da più applicazioni (esecuzioni?) agentiche diverse, dell'uno o dell'altro fornitore, senza che occorra costruire un'integrazione separata per ciascuna. Concretamente, quel server dichiarerebbe uno strumento con un nome esplicito, per esempio `get_account_balance`, con parametri tipizzati come `bu_code` e `periodo`, e restituirebbe non un testo libero ma un valore numerico accompagnato dalla data dell'ultimo aggiornamento del dato sottostante: è un contratto verificabile tra il server e chi lo interroga, non un'istruzione in linguaggio naturale da interpretare volta per volta, ed è proprio questa tipizzazione a permettere a un controllo programmatico, di cui parleremo più avanti in questa stessa parte, di verificare che il valore restituito corrisponda davvero al sistema di origine. Il MCP non risolve ovviamente i problemi di qualità del dato, di identità e di permessi: definisce il canale, non decide chi può usarlo e per fare che cosa, decisioni che restano di competenza dell'organizzazione.

Convien chiudere questa parte sciogliendo un equivoco che la catena descritta poco sopra

rischia di alimentare. Sistema di origine, via di accesso, connettore, server, applicazione agentica: cinque gradini, disegnati uno sopra l'altro che non rappresentano (necessariamente) sistemi da acquistare, installare e mantenere. Sono livelli concettuali non necessariamente componenti sw distribuiti.

Il connettore, in particolare, non è quasi mai un servizio a sé che si installa da qualche parte ma è codice che sta dentro il server MCP e incapsula la funzione che apre la connessione, si autentica, chiama, traduce l'errore e normalizza la risposta. Quando si dice “scriviamo il connettore verso il gestionale e poi ci costruiamo sopra il server”, nella realtà si sta scrivendo un solo programma, in cui un modulo parla con il gestionale e le funzioni dichiarate costituiscono gli strumenti. Lo stesso vale per il gradino della via di accesso, che spesso esiste già: una vista in un database, una stored procedure, un'interfaccia che il gestionale espone da anni ad altri sistemi, per altre finalità.

Inoltre, pubblicare un'interfaccia intermedia fra il database e il server non è di per sé un passaggio obbligato. Se l'unico consumatore di quel dato è l'agente, il server può parlare direttamente con il database attraverso il suo driver, invocando le stored procedure già esistenti ed interporre un'interfaccia ulteriore aggiunge solo un servizio da mantenere, un insieme di credenziali da ruotare e un punto in più in cui le cose si rompono, e si giustifica soltanto quando esistono (o sono previsti) altri consumatori dello stesso dato.

Un esempio concreto, adatto a un contesto aziendale comune, è quello di un gestionale in cloud che espone le proprie interfacce (ad esempio Business Central, per restare nel mondo Microsoft), di un database su cui gira la reportistica direzionale (un SQL Server con Power BI), e di un archivio di documentazione non strutturata da cui l'agente dovrebbe ricavare informazioni utili a fornire commenti ai risultati. Ciò che si distribuisce effettivamente può essere molto meno di cosa a prima battuta si sarebbe portati a credere.

Componente	Nuovo?	Che cosa è, fisicamente
Gestionale	esistente	un servizio del fornitore; non si installa nulla, si ottengono credenziali
Database della reportistica, con viste e stored procedure	esistente, da arricchire	oggetti dentro il database, non un servizio nuovo
Archivio vettoriale per il recupero documentale	nuovo	un database dedicato, più una procedura che spezza i documenti, ne calcola le rappresentazioni e li indicizza
Server MCP	nuovo	uno o più processi, tipicamente in container, con un indirizzo e un'autenticazione
Applicazione agentica	esistente o acquistata	il prodotto che ospita il client

Il server, dunque, è semplicemente un processo nel senso di un programma in esecuzione su una macchina, con un eseguibile, una configurazione, delle credenziali e dei log, esattamente come qualunque altro servizio interno. Da subito è importante ragionare su di un paio di questioni fondanti (e che come tali meritano di essere smarcate in anticipo). La prima è se costruirne uno solo o uno per sistema, e la risposta ragionevole è quasi sempre la seconda, perché cicli di vita, credenziali e permessi dei diversi sistemi non hanno ragione di coincidere, e perché la possibilità di spegnere un collegamento senza spegnere gli altri è precisamente ciò che la governance richiede. La seconda riguarda il luogo in cui il server gira: deve stare dove sta il dato, cioè nella rete che raggiunge il database, e se l'applicazione agentica è un servizio in cloud occorre stabilire fin da subito come quel servizio possa raggiungerlo senza esporre ciò che non va esposto. È il punto in cui i progetti rischiano di schiantarsi se non progettato anticipatamente.

Non va trascurato, infine, un dettaglio che l'esempio fa emergere: un archivio documentale indicizzato senza portare con sé i permessi di lettura dei documenti di origine restituirà tranquillamente il paragrafo di un documento che chi interroga non avrebbe titolo per leggere. I permessi vanno portati dentro l'indice e applicati al momento del recupero, non aggiunti dopo.

2.5 I file di configurazione in Markdown (od in altro formato testo)

Un elemento tecnico ma concreto sono i file di testo semplice, (ad esempio in formato Markdown), che guidano il comportamento dell'agente in un dato progetto o ambiente. Il Markdown è, di per sé, un formato di testo neutro: il suo significato operativo dipende dal nome del file, dalla sua posizione, e dal prodotto specifico che lo carica, non ogni file con estensione `.md` diventa automaticamente un'istruzione eseguita dall'agente.

In Codex, l'agente per lo sviluppo di OpenAI, la scoperta delle istruzioni di progetto avviene attraverso un file `AGENTS.md`, affiancato in alcuni casi da un file `AGENTS.override.md` per le eccezioni locali. In Claude Code, l'agente per lo sviluppo di Anthropic, il file principale è `CLAUDE.md`: Claude Code non legge direttamente un file `AGENTS.md` come proprie istruzioni native, ma può importarlo indirettamente se richiamato esplicitamente da `CLAUDE.md`. Le gerarchie dei due prodotti, insomma, non vanno presentate come identiche solo perché entrambe si basano su un file Markdown alla radice del progetto, un dettaglio facile da semplificare in modo scorretto in una trattazione divulgativa. Concretamente, un estratto di un file di questo tipo per il nostro caso di riferimento potrebbe contenere righe come “usa sempre il formato data GG/MM/AAAA nei documenti destinati alla direzione”, “la soglia di materialità è definita nel file `soglie.md`, non va mai stimata a occhio”, “non diffondere il pacchetto direzionale senza l'approvazione esplicita del controller”: frasi semplici, dirette, più vicine a una nota operativa lasciata a un collaboratore che a una configurazione software in senso tradizionale, ed è proprio questa leggibilità a renderle uno strumento che un responsabile di funzione, non solo un tecnico, può scrivere e mantenere aggiornato.

Un estratto realistico, nel nostro caso di riferimento, avrebbe questa forma:

```
# Istruzioni di progetto - Controllo di gestione
```

Convenzioni

- Formato data GG/MM/AAAA nei documenti destinati alla direzione
- Valuta EUR, arrotondamento al migliaio nelle tabelle di sintesi

Regole non negoziabili

- La soglia di materialità è definita in `soglie.md`. Non stimarla mai.
- Non diffondere il pacchetto direzionale senza approvazione del controller.

Fonti autorizzate

- Saldi: server MCP `erp-readonly` (sola lettura)
- Budget: cartella `/budget/approvato/`, solo l'ultima versione approvata

Un aspetto rilevante, quanto meno sulla base della mia esperienza pratica, è che questi file esistono di norma su **più livelli che si sommano invece di sostituirsi**: un livello aziendale, valido per tutti i progetti, uno di progetto, versionato insieme al progetto stesso, e uno personale, con le preferenze del singolo, non condivise. La conseguenza organizzativa è notevole: il file di progetto, essendo versionato, è l'unico punto in cui la procedura aziendale diventa leggibile, discutibile e approvabile con gli stessi strumenti con cui si approva una modifica a un sistema, con una storia delle revisioni e un autore per ciascuna. Chi governa il controllo di gestione dovrebbe pretendere che quel file fosse trattato come un documento normativo interno, non come un appunto tecnico lasciato a discrezione di chi ha configurato l'agente.

Il punto concettuale più importante, che vale a prescindere dal singolo prodotto, è distinguere ciò che un file di istruzioni **può fare** da ciò che deve invece essere fatto altrove. Nel nostro caso di riferimento, un'istruzione come “non diffondere il pacchetto direzionale senza l'approvazione del controller” appartiene correttamente a un file di questo tipo, letto e rispettato dall'agente nella normale conduzione del compito; ma il blocco effettivo, quello che impedisce l'invio non autorizzato anche nel caso in cui l'agente, per un errore di ragionamento o per un tentativo di manipolazione esterna, provasse comunque a farlo, deve vivere nei permessi del sistema che gestisce l'invio e non nel solo file di istruzioni. Un'istruzione testuale, per quanto ben scritta, resta una **raccomandazione** rivolta a un sistema probabilistico che la interpreterà pertanto in questa modalità “stocastica”, non un vincolo tecnico assoluto.

2.6 Contesto, memoria e RAG

Tre nozioni che nel linguaggio comune vengono spesso confuse meritano di essere tenute separate per i gradi di complessità (anche di gestione) che implicano. Il **contesto** è l'insieme delle informazioni disponibili al modello durante un singolo passaggio di lavoro. La **memoria** mantiene informazioni tra elaborazioni o sessioni diverse, secondo meccanismi specifici del prodotto utilizzato. Il recupero documentale, comunemente indicato con l'acronimo **RAG** (retrieval-augmented generation), seleziona materiale esterno pertinente da usare nella risposta o nel lavoro corrente.

Di nuovo, **nessuno di questi tre meccanismi equivale ad addestrare il modello**: sono tutti modi di fornire, in momenti diversi, informazioni a un modello che resta lo stesso (cioè che mantiene inalterato il sistema di pesi delle reti che lo determinano). La disciplina che si occupa di decidere quali istruzioni, documenti, risultati intermedi e strumenti rendere disponibili al momento opportuno prende il nome di *context engineering*, un termine relativamente recente ma già consolidato nella letteratura tecnica. Un tema logicamente afferente è quello della **compattazione**, ossia la sintesi della cronologia di un compito lungo per proseguire entro i limiti di contesto disponibili, che va progettata avendo ben chiaro quali dettagli non ci si può permettere di perdere lungo la strada. Nel nostro caso di esempio, il valore di questa disciplina è immediato: per calcolare correttamente uno scostamento serve il budget nella sua versione approvata più recente, non una versione precedente ancora presente, magari per inerzia, nell'archivio documentale condiviso. Un archivio più grande non produce necessariamente un'analisi migliore se fa riemergere condizioni ormai superate o peggio ancora contraddittorie perché la **qualità** del contesto conta più della sua **quantità**. Un esempio concreto di che cosa la memoria conserva effettivamente, da un mese all'altro, aiuta a rendere la distinzione meno astratta: una nota di questo tipo, salvata dall'agente al termine della chiusura di marzo, potrebbe leggere "la soglia di materialità per la BU Nord è stata aggiornata a 15.000 euro con delibera del 3 marzo 2026, in sostituzione della soglia precedente di 10.000 euro; applicare la nuova soglia a partire dalla chiusura di aprile". È un'informazione puntuale, datata e verificabile, non un riassunto vago della conversazione precedente: una memoria ben progettata conserva fatti di questo tipo, con la loro data di validità, non impressioni romanzate sull'attività passata.

Conviene chiarire come una memoria funzioni davvero perché non si tratta di un esoterico stato interno del modello, ma di un molto essoterico insieme di file che l'agente ha il permesso di leggere e riscrivere attraverso strumenti dedicati (crea, leggi, sostituisci una porzione, cancella), conservati in una directory riservata:

```
memoria/
├── definizioni-kpi.md      # "EBITDA rettificato: esclude oneri non ricorrenti..."
├── soglie-e-delibere.md    # "BU Nord: soglia 15.000 € dal 03/03/2026"
└── verifiche-aperte.md    # "Riconciliazione intercompany IT-DE: aperta da aprile"
```

Il fatto che si tratti di file ordinari ha tre conseguenze pratiche che un manager di business (magari il responsabile amministrativo per rimanere nel nostro esempio) apprezzerà più di qualunque discorso sull'intelligenza artificiale: la memoria è **ispezionabile**, si può cioè leggere che cosa l'agente crede di sapere, ed è un esercizio che consiglio di fare almeno una volta perché è spesso istruttivo; è **correggibile**, si può riscrivere una riga sbagliata senza rifare nulla e senza riaddestrare alcunché; ed è **cancellabile in modo verificabile**, il che non è affatto un dettaglio secondario quando la stessa memoria contiene, come quasi sempre accade, dati riferibili a persone identificabili.

Contesto, memoria e RAG: tre orizzonti diversi




Figura 8: Contesto, memoria e RAG: tre orizzonti diversi

2.7 Sistemi multi agente: coordinamento, non solo parallelismo

Quando un compito è sufficientemente complesso da beneficiare della divisione del lavoro, entrano in gioco i sistemi multi agente. Come il nome stesso dice intendiamo con questo termine più agenti, spesso specializzati su una specifica funzione/attività o su di una porzione del problema, che collaborano secondo pattern ormai ricorrenti, come l'orchestratore che delega a sub agenti (subagent nella terminologia più diffusa, handoff quando si tratta di un vero e proprio passaggio di responsabilità da un agente a un altro), o l'esecuzione parallela seguita da una fase di sintesi. Anthropic ha documentato in modo dettagliato un caso di questo tipo nel proprio sistema di ricerca multi agente, in cui la divisione del lavoro tra agenti specializzati e la successiva sintesi hanno prodotto risultati superiori a un singolo agente generalista sullo stesso compito.

È interessante come, l'emergere e la diffusione di uso di queste modalità "multi", stia facendo emergere problemi di coordinamento e fenomeni di "conformismo operativo" mostrando che agenti impostati in modo simile tendono a replicare gli stessi errori invece di correggersi a vicenda. È un risultato circoscritto a pochi esperimenti ma indebolisce un'intuizione diffusa e pericolosa, quella per cui il consenso tra più agenti equivalga automaticamente a maggiore affidabilità. Nel nostro caso di riferimento, tre sub agenti che validano in modo concorde lo stesso scostamento di budget, se impostati in modo simile e senza controlli indipendenti tra loro, non triplicano l'affidabilità del giudizio: possono, al contrario, mascherare un errore sistematico condiviso nella fonte dei dati, per esempio un valore di budget non aggiornato che tutti e tre gli agenti hanno consultato allo stesso modo. La revisione indipendente, va sottolineato, non è la stessa cosa del semplice consenso tra agenti impostati in modo analogo.

Vale la pena, sempre in tema di coordinamento, distinguere i diversi modi di coinvolgere un

secondo agente (spesso confusi nella comunicazione divulgativa alla “tik-tok”) da un lato abbiamo l’handoff, cioè un vero e proprio passaggio di responsabilità da un agente a un altro, che da quel momento dirige autonomamente il seguito del lavoro, dall’altro la semplice invocazione di un agente specializzato come se fosse uno strumento, in cui il coordinatore mantiene la responsabilità complessiva e si limita a usare il risultato prodotto dallo specialista. Nel nostro caso di riferimento, la differenza è tutt’altro che astratta: chiedere a un sub agente una verifica locale sui dati di una country, e poi valutarne il risultato prima di includerlo nel consolidato, è cosa diversa dal trasferirgli, con un handoff, la piena responsabilità di decidere se quel dato sia pronto per la diffusione.

Anche i subagenti, nella pratica, si dichiarano come semplici file di testo, e la loro definizione dice molto sul modello mentale sottostante:

```
---
name: verificatore-country
description: Verifica la coerenza dei dati di una country prima del consolidato.
  Usare al termine di ogni estrazione locale.
tools: [get_account_balance, leggi_budget]  # perimetro ristretto, sola lettura
---
Verifica che i saldi estratti corrispondano alla fonte, che il periodo sia
quello richiesto e che non manchino conti rispetto al mese precedente.
Segnala le anomalie, non correggerle.
```

Si noti la riga degli strumenti, che è la parte concettualmente più densa dell’esempio: il subagente riceve un perimetro **più stretto** di quello del coordinatore. È il modo corretto di intendere la specializzazione in questo contesto, e va contro l’intuizione comune: un subagente non è “più bravo” su un tema, è solo più specializzato e pertanto più limitato, perché dispone di meno strumenti, di meno contesto e di un compito più definito, e proprio per questo produce risultati più verificabili. L’ultima riga dell’esempio, “segnala le anomalie, non correggerle”, è poi la traduzione operativa del principio di separazione fra chi rileva e chi decide, che in amministrazione conosciamo da molto prima che esistessero gli agenti e che qui ritorna, identico, in veste tecnica.

I pattern multi agente




Figura 9: I pattern multi agente

Se dovessimo indicare, oggi, l'ambito applicativo in cui gli agenti (singoli o multi che siano) hanno raggiunto la maggiore maturità e la più vasta adozione professionale, sarebbe senza dubbio quello dello sviluppo software. Un agente per il coding può leggere l'intero contesto di un progetto, modificare più file in coerenza tra loro, eseguire test, e proporre una modifica pronta per la revisione umana, non semplicemente completare una riga di codice come facevano gli strumenti di una generazione precedente. È un caso di studio interessante perché è al tempo stesso il terreno di sperimentazione più avanzato e quello più facile da comprendere per analogia: un agente per il coding somiglia, nel modo in cui viene introdotto in un team, più a un collaboratore junior a cui si assegna un perimetro definito e che si rivede prima di dare il proprio benestare, che a uno strumento software tradizionale.

2.8 La verifica dell'esito: perché "ho fatto X" non basta

A mio giudizio, uno dei temi più rilevanti nella trattazione generalista sugli agenti è quello della verifica del risultato. Un agente, come qualunque sistema che riporta il proprio operato attraverso il linguaggio, può descrivere un'azione in un modo che non corrisponde esattamente a ciò che è realmente accaduto nell'ambiente su cui ha operato: non per malafede, ma per la natura stessa di un sistema che genera testo per descrivere le proprie azioni. Anthropic distingue esplicitamente, in un proprio approfondimento tecnico, ciò che un agente dichiara di aver fatto da ciò che è effettivamente accaduto, e descrive tre approcci complementari per colmare questa distanza: i controlli programmatici, che verificano lo stato del sistema in modo automatico e oggettivo; le valutazioni condotte da un modello terzo, che esaminano il lavoro prodotto con un giudizio più flessibile di un controllo puramente meccanico; e il giudizio umano, indispensabile per i casi in cui il criterio di correttezza non è del tutto codificabile.

Nel nostro caso di riferimento, questo si traduce in un principio molto concreto: la frase “ho aggiornato il pacchetto di reporting” restituita dall’agente non è, di per sé, una prova di nulla. Occorre controllare che i numeri riportati corrispondano effettivamente ai saldi di origine nel sistema gestionale, che nessuna business unit sia stata omessa dal consolidato, e che le note di commento raccolte siano state attribuite alla voce corretta. Per rendere questo principio operativo ed operativo si potrebbe pensare di definire una dashboard di misurazione aziendale per qualunque processo delegato in parte od in toto ad un agente: il tasso di risultati accettati sul totale prodotto, il tasso di errori materiali rilevati, la frequenza degli interventi correttivi umani richiesti, il tempo complessivo impiegato, comprensivo della revisione, il costo per risultato effettivamente accettato, e il numero di incidenti registrati nel periodo osservato. Nessuna di queste misure sostituisce le altre ma insieme, restituiscono un quadro molto più onesto di quanto non faccia il solo entusiasmo per la demo iniziale.

2.9 Guardrail, sandbox, permessi e hook

Chiudiamo questa parte comune con il tema che, nella pratica, decide se un’organizzazione può fidarsi di un agente al di là della fase di sperimentazione: la governance dell’esecuzione. Sandbox, permessi sugli strumenti, approvazioni puntuali e hook sono meccanismi distinti che vanno definiti con precisione. La **sandbox** è l’ambiente isolato in cui l’agente esegue le proprie azioni, contenendo eventuali effetti indesiderati entro un perimetro definito. I **permessi** stabiliscono quali strumenti l’agente può usare e su quali dati. Le **approvazioni** sono momenti in cui, per un’azione specifica, si richiede un consenso umano esplicito prima di procedere. Gli **hook**, infine, sono punti del ciclo di vita dell’agente in cui è possibile eseguire controlli programmatici personalizzati, la cui efficacia dipende però interamente da come sono stati implementati, non è una garanzia automatica derivante dalla loro sola presenza. Codex distingue esplicitamente le barriere di esecuzione dalle approvazioni richieste all’utente, mentre Claude Code offre un proprio sistema di hook per questo scopo.

Conviene vedere che forma assumono, concretamente, questi due meccanismi, perché la differenza fra loro è sostanziale e viene quasi sempre appiattita. I permessi si esprimono come regole dichiarative, tipicamente con una logica a tre stati (consentito, da approvare, vietato):

```
{
  "permissions": {
    "allow": ["mcp__erp-readonly__get_account_balance", "Read(./budget/**)"],
    "ask":   ["Edit(./reporting/**)"],
    "deny":  ["Bash(curl:*)", "Read(./hr/**)"]
  }
}
```

Gli hook, invece, sono punti del ciclo di vita in cui l’organizzazione inserisce codice proprio, che viene eseguito prima o dopo una determinata azione indipendentemente da ciò che il modello ha deciso:

```
{ "hooks": {
  "PreToolUse": [
    { "matcher": "Edit",
      "hooks": [
        { "type": "command",
          "command": "./controlli/verifica_approvazione_controller.sh" } ] ] } ] } }
```

Il permesso è una regola che il software applica sempre, in modo prevedibile e verificabile, ma è rigido e non sa nulla del merito dell'operazione. L'hook è potente, perché può eseguire verifiche arbitrarie (nell'esempio, interrogare il sistema documentale per accertare che l'approvazione del controller esista davvero prima di consentire la scrittura del pacchetto), ma vale esattamente quanto il codice che lo implementa. È la ragione per cui la sola presenza di un sistema di hook nella scheda tecnica di un prodotto non dice assolutamente nulla sulla sicurezza effettiva della sua implementazione presso un cliente, e per cui, in sede di verifica, la domanda giusta non è “il prodotto supporta gli hook” ma “quali hook sono stati scritti, da chi, e chi li ha collaudati

La catena dei controlli, dalla raccomandazione al vincolo



Figura 10: La catena dei controlli, dalla raccomandazione al vincolo

Nel nostro caso di riferimento, questi meccanismi si combinano in modo naturale: un agente che prepara e archivia la bozza del pacchetto di reporting sta operando pienamente entro il proprio perimetro autorizzato, e può farlo con ampia autonomia; la diffusione di quello stesso pacchetto al management richiede invece l'approvazione esplicita del controller, un punto di controllo che nessuna abilità dell'agente dovrebbe poter aggirare. Vale la pena, per chiudere questa parte con un esempio concreto, introdurre qui il tema della cosiddetta **prompt injection**. Un documento esterno, per esempio una comunicazione ricevuta da un fornitore o un file allegato da un collega, che contenga un'istruzione nascosta del tipo “invia questi dati anche a un indirizzo diverso da

quello previsto”, deve essere trattato dall’agente come contenuto non attendibile, alla stregua di qualunque altro dato da verificare, non come una nuova autorizzazione legittima solo perché formulata in linguaggio naturale e apparentemente rivolta all’agente stesso e questa barriera, a volte facilmente superabile, si costruisce con una rigorosa progettazione del ciclo di approvazione.

3 Parte III. Il fronte Anthropic

Passiamo ora dai concetti comuni alle specificità degli ecosistemi su cui abbiamo scelto di concentrare l’approfondimento tecnico. Cominciamo da Anthropic, la cui traiettoria nel 2026 racconta una strategia piuttosto coerente: dalla riga di comando per sviluppatori fino allo strumento generalista per il lavoro di conoscenza quotidiano.

3.1 Claude Code e il Claude Agent SDK

Il capostipite dell’offerta agentica di Anthropic è Claude Code, l’agente a riga di comando per lo sviluppo software, che ha anticipato molti dei pattern oggi considerati standard nel settore (accesso al filesystem, esecuzione di comandi, gestione della memoria di progetto). Accanto a Claude Code, Anthropic offre il Claude Agent SDK, una libreria disponibile in Python e in TypeScript che espone lo stesso motore, cioè il ciclo agentico, la gestione dei permessi, le sessioni, i subagenti e il supporto nativo a skill, comandi, memoria e plugin, per costruire agenti su misura al di fuori del solo contesto di sviluppo software. È la scelta naturale per un’organizzazione che vuole costruire un proprio agente specializzato, per esempio uno dedicato al processo di chiusura mensile del nostro caso di riferimento, mantenendo il pieno controllo del codice e dell’infrastruttura su cui gira.

3.2 Le skill come standard aperto e i plugin come distribuzione condivisa

Le skill, introdotte come formato aperto nell’autunno del 2025, sono oggi disponibili sia come skill “first party” pre confezionate, per esempio per la creazione di documenti in formato PowerPoint, Excel, Word e PDF, sia come skill personalizzate caricate dall’organizzazione. Il modello di governance enterprise dedicato prevede, per Claude Enterprise, una scansione automatica dei contenuti delle skill personalizzate caricate in **claude.ai**; le skill installate tramite API o tramite Claude Code richiedono invece una revisione manuale più simile, nello spirito, a quella che si applicherebbe all’installazione di un nuovo software in produzione, un’analogia che vale la pena portare esplicitamente ai team di sicurezza aziendale poco familiari con questo tipo di rischio. I plugin, distinti dalle skill, sono il meccanismo con cui Anthropic distribuisce insieme skill, connettori e altre estensioni sia in Claude Chat sia in Cowork, mentre Claude Code mantiene un proprio meccanismo di estensioni dedicato.

3.3 Cowork e i connettori MCP nativi

Nel gennaio 2026 Anthropic ha introdotto Claude Cowork che porta le capacità agentiche già mature di Claude Code (automazione multi passo, accesso a file locali, esecuzione in un ambiente isolato) ad un livello di utilizzo non tecnico, slegato dall’approccio a riga di comando. A distanza di poche settimane sono arrivati i connettori nativi basati su MCP verso strumenti già ampiamente diffusi nelle organizzazioni, come Slack, Canva, Figma e Box, che permettono all’agente di agire direttamente dentro gli strumenti aziendali già in uso, invece di limitarsi a produrre un output da trasferire manualmente altrove.

Nell’esemplificazione che stiamo percorrendo, un controller potrebbe usare direttamente Cowork per raccogliere i dati di più fonti, applicare la skill di reporting del gruppo, e predisporre la bozza da sottoporre a revisione, senza dover passare attraverso un team di sviluppo AI per farlo ma utilizzando una “superApp” molto simile ad un ambiente di lavoro “grafico”. _

3.4 I tre livelli di costruzione: Messages API, Agent SDK, Claude Managed Agents

Per chi debba costruire un agente su misura, Anthropic offre, come vedremo essere il caso anche per OpenAI, tre livelli distinti tra cui scegliere, ciascuno con un diverso compromesso tra controllo e responsabilità operativa. Il livello più basso è l’accesso diretto alle API (la Messages API), in cui l’organizzazione implementa da sé l’intero ciclo agentico. Il livello intermedio è l’Agent SDK già descritto, che fornisce il ciclo, i subagenti e gli strumenti già pronti di Claude Code, lasciando all’organizzazione la responsabilità dell’infrastruttura su cui il tutto viene eseguito. Il livello più gestito sono i Claude Managed Agents, un servizio in cui è Anthropic stessa a occuparsi di sandboxing, stato e infrastruttura per agenti a esecuzione lunga o asincrona, pensato per chi non vuole, o non può, gestire in proprio questa complessità. Le release note più recenti mostrano sui Managed Agents un servizio in evoluzione attiva con evoluzioni tipo l’implementazione di una politica `auto` con cui il server stesso valuta le chiamate a uno strumento, eseguendole, negandole o richiedendo un’approvazione, un meccanismo che può sostenere la gestione delle operazioni autorizzate nel nostro caso di riferimento, senza per questo sostituire le regole aziendali. ###
Computer use e memoria: la maturazione produttiva

Due capacità che fino a poco tempo fa erano considerate sperimentali meritano un aggiornamento. Il computer use, la capacità dell’agente di operare un’interfaccia grafica come farebbe una persona, muovendo il cursore, cliccando, digitando, è oggi utilizzabile e sufficientemente maturo anche a livello di API senza la necessità di header sperimentali. Il memory tool, dal canto suo, risolve un problema distinto, quello di conservare informazioni che l’agente potrà rileggere in un passaggio successivo: la documentazione precisa che è l’applicazione a dover implementare la gestione effettiva delle operazioni di lettura e scrittura in memoria, non il solo fatto che il modello sappia richiederle a implicare che il fornitore conservi automaticamente ogni informazione al posto dell’organizzazione.

Nel nostro caso di riferimento, un agente potrebbe conservare in memoria una nota sulla definizione approvata di un indicatore o sulle verifiche ancora aperte da un mese all'altro: il team deve stabilire con chiarezza durata, accesso e criterio di aggiornamento di quelle note, perché una memoria che conserva un'informazione ormai superata rende il sistema coerentemente sbagliato piuttosto che utile (oltre ad aprire scenari legati al GDPR che i nostri amici d'oltreoceano spesso tendono ad ignorare)

4 Parte IV. Il fronte OpenAI

La traiettoria di OpenAI segue una logica in parte diversa da quella di Anthropic, più centrata sulla componibilità a livello di piattaforma e sull'apertura verso team meno tecnici attraverso strumenti visuali, pur convergendo, come vedremo nella parte comparativa, su molti degli stessi concetti di fondo.

4.1 Orientarsi nel catalogo: Chat, ChatGPT Work, Workspace Agents e Codex

Uno degli errori più comuni in cui incorre chi scrive di OpenAI per un pubblico generalista è trattare come sinonimi prodotti che, in realtà, rispondono a esigenze diverse. ChatGPT, nella sua forma conversazionale, è e resta lo strumento per il dialogo e per compiti puntuali. “ChatGPT Work” è invece il termine più aggiornato per il lavoro delegato su attività articolate, documentato specificamente per compiti che restituiscono un risultato pronto per la revisione, non una semplice risposta testuale. Esiste inoltre un prodotto distinto, “Workspace Agents”, pensato per agenti riutilizzabili a livello di team, con documentazione dedicata ai trigger esterni (per esempio l'arrivo di un nuovo documento) e a un percorso di creazione dell'agente in linguaggio naturale, pensato per chi non scrive codice. Codex, infine, resta l'agente dedicato allo sviluppo software, oggi disponibile anche come applicazione a sé ed in generale come “superapp” che integra le diverse funzioni.

Applicato al nostro caso di riferimento: un brainstorming preliminare sul formato del reporting trimestrale avviene in Chat; la produzione periodica del pacchetto di reporting mensile, ripetuta ogni mese con le stesse regole, è il caso d'uso naturale per Workspace Agents; un intervento sullo script di consolidamento dati è compito di Codex.

4.2 I tre livelli di costruzione: Responses API, Agents SDK, Agents API

Come per Anthropic, anche OpenAI offre tre livelli distinti per chi debba costruire un agente su misura. Il livello più diretto è l'uso della Responses API stessa, con cui un'organizzazione può orchestrare autonomamente strumenti integrati come la ricerca web o la ricerca su file. Il livello intermedio è l'Agents SDK, rilasciato come framework open source per orchestrare flussi multi agente attorno a tre concetti chiave: gli agenti, cioè modelli configurati con istruzioni e strumenti; gli handoff, il trasferimento controllato di un compito da un agente a un altro; e i guardrail,

controlli automatici di validazione su input e output. Il livello più gestito è la Agents API, l'infrastruttura con sessioni e ambienti propri di cui OpenAI stessa si occupa, concettualmente parallela ai Claude Managed Agents di Anthropic.

La scelta tra questi tre livelli, per un'organizzazione, dipende in larga misura dalla stessa domanda che abbiamo posto per Anthropic: chi deve possedere, e mantenere nel tempo, la responsabilità dell'infrastruttura su cui l'agente gira.

4.3 Codex e il consolidamento del browsing agentico

Un elemento di recente, utile per mostrare quanto velocemente si stia ancora muovendo il mercato anche sul fronte meno discusso del “browsing agentico”, riguarda ChatGPT Atlas, il browser con funzionalità AI lanciato da OpenAI e già dismesso perché le relative capacità di navigazione e di uso del computer sono state riassorbite direttamente nell'app ChatGPT, sia nella versione desktop sia nell'estensione per Chrome, ed in Codex, segno di un consolidamento della strategia agentica attorno a meno superfici prodotto, ma più profondamente integrate tra loro. Un dettaglio tecnico minore ma corretto da riportare, per chi lavorasse a un livello di maggiore profondità tecnica: in una versione recente Codex ha rimosso il comando che esponeva Codex stesso come server MCP, mantenendo però invariato il supporto di Codex come client verso server MCP esterni, una distinzione, Codex consuma MCP ma non lo espone più, che vale la pena chiarire per chi si affidasse a una guida ormai superata.

5 Parte V. Il fronte Microsoft

La traiettoria di Microsoft in questo campo racconta una logica diversa da quella di Anthropic e di OpenAI, ed è proprio questa diversità, più che una minore maturità tecnica, a renderla rilevante per chi opera in un contesto aziendale strutturato: mentre Anthropic e OpenAI hanno costruito, innanzitutto, capacità dell'agente (che cosa un agente sa fare, con quale autonomia), Microsoft ha costruito, innanzitutto, infrastruttura di governo della popolazione di agenti (chi è un agente, a nome di chi opera, come si controlla una flotta di migliaia di agenti nel tempo), una scelta coerente con la posizione che l'azienda occupa da tempo nella gestione delle identità aziendali attraverso Entra ID (già noto come Azure Active Directory).

5.1 Che cosa chiama “agente” Microsoft: una scala, non un oggetto unico

Prima di entrare nei singoli prodotti conviene sciogliere un equivoco che, nella mia esperienza, genera una certa confusione perché nell'ecosistema Microsoft la parola “agente” copre oggetti molto diversi (in termini di architettura e capability). L'agente che un utente costruisce in dieci minuti dall'interfaccia di chat di Microsoft 365 Copilot e l'agente costruito in Copilot Studio, magari con trigger e con flussi di automazione, condividono il nome commerciale e quasi nulla dell'architettura.

Il primo, costruito con l'**Agent Builder** integrato in Copilot, si configura con un nome, una descrizione, un testo di istruzioni (fino a ottomila caratteri), fino a venti fonti di conoscenza (siti e cartelle SharePoint, connettori, eventualmente contenuti web) e poche capacità predefinite come l'interprete di codice o la generazione di immagini. Non esiste, in quella interfaccia, una sezione dedicata alle azioni obbligando a passare a Copilot Studio per integrare servizi esterni. Soprattutto (questo è il punto dirimente in questo momento di marketing del terrore), non può agire di propria iniziativa. Se si legge la tabella comparativa ufficiale alla voce interazioni proattive, per questa tipologia di Agenti si atterra su di un laconico "non supportate, dipendono da un'interazione avviata dall'utente". A questo si aggiunge un limite architetturale dichiarato apertamente, cioè l'assenza di un vero ciclo di ragionamento iterativo, perché l'ancoraggio alle informazioni e le chiamate agli strumenti avvengono in sequenza e non dentro un ciclo di pianificazione, mentre l'orchestratore e il modello non sono sotto il controllo di chi costruisce l'agente ma restano quelli di Microsoft. Gli strumenti a disposizione di questo tipo di agente sono descritti come interazioni "a turno singolo" che significa che l'agente può "toccare" un sistema esterno una volta, dentro il proprio turno, ma non può pianificare, iterare, né riprendersi da un proprio errore. Detto questo va precisato che il turno singolo non significa necessariamente che l'agente in questione **si incapace di scrivere sui sistemi** (e quindi fare danni). Se costruito con gli strumenti di sviluppo, cioè con il Microsoft 365 Agents Toolkit, e dotato di plugin verso API o verso server MCP, può creare, aggiornare ed eliminare dati. L'asse corretto lungo cui distinguere, dunque, non è "legge oppure scrive", ma **chi possiede il ciclo di orchestrazione** e **chi dà l'avvio al lavoro**: su entrambi, l'agente costruito dall'interfaccia di chat sta al gradino più basso, perché il ciclo è di Microsoft e l'avvio è di una persona che digita.

Propongo quindi di leggere l'intera offerta lungo tre assi, che a ben vedere si applicano anche agli altri due fornitori e che ho trovato essere l'unico modo per orientarsi senza smarrirsi fra i nomi commerciali. Il primo è **chi possiede il ciclo di orchestrazione**: Microsoft, nel caso degli agenti dichiarativi, oppure l'organizzazione, nel caso dei cosiddetti *custom engine agent*, costruiti con il proprio modello e il proprio orchestratore e semplicemente ospitati nella superficie Copilot. Il secondo è **chi dà l'avvio al lavoro**: una persona che scrive in chat, oppure un evento che accade in un sistema. Il terzo è **come è vincolata l'esecuzione**: dal giudizio generativo del modello, oppure da un percorso deterministico definito in anticipo. Un agente costruito in Agent Builder si colloca all'estremo conservativo di tutti e tre; un agente Copilot Studio con trigger e flussi si sposta su ciascuno di essi, ed è per questo che merita di essere trattato come un oggetto diverso, non come una versione più ricca del primo.

La scala degli agenti Microsoft letta su tre assi

		Chi possiede il ciclo di orchestrazione Microsoft ↔ L'organizzazione	Chi dà l'avvio al lavoro Una persona che scrive ↔ Un evento che accade	Come è vincolata l'esecuzione Percorso definito dall'autore ↔ Giudizio generativo del modello	Che cosa comporta sul piano organizzativo
7	Custom engine agent	■	■	■	un'applicazione a tutti gli effetti
6	Agente Copilot Studio autonomo, con trigger e agent flow	◀	■	■	un processo aziendale: committente, responsabile, controlli, continuità, costo
5	Agente Copilot Studio, orchestrazione generativa	◀	◀	■	un servizio con un responsabile
un processo aziendale					
uno strumento personale					
4	Agente dichiarativo con plugin API o MCP	◀	○	◀	uno strumento personale con accessi da governare
3	Agente dichiarativo da Agent Builder	○	○	◀	uno strumento personale
2	Agenti pre-costruiti (Researcher, Analyst)	■	○	○	nessuna formalità
1	Microsoft 365 Copilot (chat)	■	○	○	nessuna formalità

Legenda degli indicatori (per le prime tre colonne)

○ Polo sinistro (es. Microsoft / una persona che scrive / percorso definito)

◀ Posizione intermedia

■ Polo destro (es. l'organizzazione / un evento che accade / giudizio generativo)

Nota: Le righe 3 e 4 possono entrambe scrivere sui sistemi. La differenza non è fra leggere e scrivere, è fra agire su richiesta e agire di propria iniziativa.

Figura 11: La scala degli agenti Microsoft letta su tre assi

5.2 L'agente come identità aziendale: Entra Agent ID

Il tratto più caratterizzante dell'impostazione Microsoft è che l'agente riceve, da subito, un'identità digitale propria, distinta sia da un account utente sia da un service principal tradizionale (la forma con cui, finora, un'applicazione automatizzata si presentava ai sistemi aziendali). Microsoft Entra Agent ID estende alla popolazione di agenti gli stessi meccanismi già maturi per le identità umane: controllo del rischio in tempo reale, policy di accesso condizionale, e modelli di configurazione riutilizzabili chiamati "Agent Identity Blueprint", pensati per replicare in modo coerente la stessa postura di sicurezza su flotte di centinaia o migliaia di agenti, non per configurarli uno per uno. Applicato al nostro caso di riferimento, questo significa concretamente che l'agente di chiusura mensile della country italiana e quello della country tedesca, pur eseguendo lo stesso compito con lo stesso metodo, ricevono ciascuno una propria identità Entra Agent ID, tracciabile individualmente nei log di accesso al sistema gestionale, e che un unico blueprint può imporre a entrambi, in un colpo solo, la stessa regola di accesso condizionale, per esempio il divieto di autenticarsi da un indirizzo IP esterno alla rete aziendale durante la finestra di chiusura. È una logica di anagrafica e di ciclo di vita dell'identità, più vicina, sul piano amministrativo, a come si tratterebbe un nuovo dipendente o un fornitore esterno, che alla logica di permessi e guardrail attorno a un singolo agente con cui ragionano prevalentemente Anthropic e OpenAI.

5.3 Agent 365: il control panel (si lo so si chiama control plane, ma non mi piace) della flotta di agenti

Coerente con questa impostazione è Microsoft Agent 365 descritto esplicitamente come strumento per governare l'intera flotta di agenti aziendali, a prescindere da dove siano stati creati. Il prodotto

si articola in cinque componenti: un registro centralizzato (Registry) che include anche gli agenti non autorizzati, cioè creati al di fuori di un percorso approvato dall'IT; un controllo degli accessi basato sul rischio (Access Control); un cruscotto che mappa le connessioni tra agenti, utenti e risorse (Visualization); un livello di interoperabilità tra agenti costruiti su piattaforme diverse (Interoperability); e un livello di sicurezza integrato con gli strumenti Microsoft già in uso per la protezione dei dati aziendali (Security). Nel nostro caso di riferimento, il valore pratico del Registry si vede in una situazione tutt'altro che ipotetica: un analista della country francese, senza coinvolgere l'IT centrale, costruisce con Copilot Studio un proprio agente per velocizzare la propria parte di chiusura mensile. Senza un control "plane" di questo tipo, quell'agente resterebbe invisibile al responsabile della sicurezza del gruppo fino al primo incidente; con Agent 365, l'agente compare nel registro centralizzato non appena creato, con i propri permessi e le proprie connessioni visibili al resto dell'organizzazione, permettendo di portarlo entro lo stesso perimetro di governance degli altri agenti del gruppo prima, e non dopo, che diventi un problema.

5.4 Gli agenti dichiarativi: il file di configurazione secondo Microsoft

Se in Anthropic e in OpenAI il file di configurazione dell'agente è un documento in Markdown, in Microsoft 365 Copilot la stessa funzione è svolta da un manifesto dichiarativo in formato JSON, articolato in quattro componenti: - la definizione dell'agente (nome, descrizione, istruzioni comportamentali) - le capacità (le azioni che l'agente può compiere, spesso esposte come plugin) - le fonti di conoscenza (i documenti e i dati su cui l'agente può basare le proprie risposte) - i metadati dell'applicazione (icona, informazioni di pubblicazione).

Nella sua forma essenziale il manifesto si presenta così, e il confronto con il file Markdown della sezione precedente è più eloquente di qualunque commento:

```
{
  "version": "v1.5",
  "name": "Assistente di chiusura mensile",
  "description": "Risponde su procedure, definizioni e scadenze della chiusura",
  "instructions": "Applica sempre le soglie di materialità del gruppo...",
  "capabilities": [
    { "name": "OneDriveAndSharePoint" },
    { "name": "CodeInterpreter" }
  ],
  "actions": [ { "id": "erpPlugin", "file": "plugin.json" } ]
}
```

La scelta del JSON al posto del Markdown riflette una filosofia in cui l'agente nasce come oggetto gestito da una piattaforma con un proprio ciclo di pubblicazione e approvazione, più vicino nella sua natura a un'applicazione da distribuire nel catalogo aziendale che a un file di istruzioni curato direttamente dall'utente finale. Coerentemente con l'apertura verso team meno

tecnici Microsoft offre quattro percorsi di creazione per un agente dichiarativo: l'Agent Builder, un percorso no-code integrato in Copilot; il Microsoft 365 Agents Toolkit, pensato per lo sviluppo pro-code in ambiente Visual Studio Code; Copilot Studio, un ambiente visuale low code e la creazione diretta da SharePoint, no-code, a partire da una raccolta documentale esistente. Nel nostro caso di riferimento, un agente dichiarativo “assistente di chiusura mensile” avrebbe, nel proprio campo istruzioni, un testo concettualmente identico a quello che useremmo in un file Markdown (la soglia di materialità, il formato delle date, il divieto di diffusione non autorizzata), ma incapsulato in un manifesto JSON pubblicato, versionato e distribuito come un'applicazione a un gruppo definito di utenti attraverso il catalogo di Microsoft 365 Copilot.

5.5 Copilot Studio: orchestrazione generativa, trigger e agent flow

Copilot Studio è un oggetto di natura diversa, e vale la pena spiegare in che cosa consista esattamente la differenza, perché è la stessa che separa un assistente da un processo aziendale automatizzato.

Il primo elemento è il **tipo di orchestrazione**. In quella classica, l'agente seleziona un *topic*, cioè un percorso di dialogo costruito dall'autore, confrontando la richiesta dell'utente con frasi di attivazione predefinite, e gli strumenti possono essere invocati soltanto in modo esplicito dall'interno di un topic: siamo, a tutti gli effetti, nel mondo dell'albero decisionale, per quanto raffinato. In quella generativa, invece, l'agente sceglie fra topic, strumenti e fonti di conoscenza sulla base della loro descrizione, può combinarli, e li invoca in sequenza ponendo all'utente le domande necessarie a colmare le informazioni mancanti. L'esempio che usa Microsoft è istruttivo proprio per la sua banalità: alla richiesta “mi servono gli orari del negozio e qual è il punto vendita più vicino”, l'agente in orchestrazione generativa seleziona due topic distinti e li concatena, mentre l'orchestrazione classica tenterebbe di ricondurre la richiesta a un unico percorso.

Il secondo elemento sono i **trigger**, ed è qui che l'agente smette di essere un interlocutore e diventa un processo. Un trigger di evento consente all'agente di agire autonomamente quando accade qualcosa: un elemento creato in SharePoint, un file caricato, un'attività completata, una riga aggiunta o modificata in Dataverse, oppure semplicemente una ricorrenza temporale. La differenza rispetto al trigger conversazionale è netta e conviene formularla così: nel primo caso qualcuno ha scritto qualcosa, nel secondo il mondo è cambiato e nessun essere umano è nella conversazione. Due vincoli, però, meritano di essere portati all'attenzione di chi governa i rischi, perché raramente compaiono nelle presentazioni commerciali. Il primo è che l'autonomia è disponibile **solo** con l'orchestrazione generativa attiva: non si può avere insieme un agente autonomo e un percorso interamente deterministico deciso dall'autore. Il secondo, più delicato, è che i trigger e le azioni che richiedono autenticazione utilizzano **le credenziali di chi ha creato l'agente**, il che significa che l'agente autonomo agisce sui sistemi come quella specifica persona, con i suoi permessi. Chiunque abbia dimestichezza con la segregazione dei compiti comprende immediatamente perché un dettaglio apparentemente tecnico sia in realtà una questione di controllo interno, e perché un agente di questo tipo non dovrebbe mai essere creato dall'utenza di

chi detiene anche poteri di approvazione sul processo che l'agente esegue.

Il terzo elemento sono gli **agent flow**, cioè i flussi di automazione, che Microsoft distingue esplicitamente dagli agenti con una formula che condivido: un flusso è deterministico, esegue azioni seguendo un percorso a regole, e lo stesso input produce sempre lo stesso output. Il rapporto con Power Automate è di parentela stretta ma non di identità, dal momento che gli agent flow nascono dentro Copilot Studio, sono fatturati sul consumo di quest'ultimo invece che su una licenza Power Automate, e portano con sé limiti propri (non si possono condividere né assegnare a più proprietari, e la conversione di un flusso Power Automate esistente è un'operazione irreversibile, un dettaglio che conviene conoscere prima e non dopo). Il punto architetturale, però, è assai più interessante delle questioni di licenza: un agent flow può essere collegato a un agente **come se fosse uno strumento**, ed è questa la configurazione matura verso cui, a mio giudizio, converge il buon senso progettuale. Non “flusso oppure agente”, ma un agente generativo che decide *se e quando* agire, e flussi deterministici e verificabili che definiscono *come* l'azione viene eseguita. È esattamente la stessa logica con cui, nel controllo di gestione, lasciamo al giudizio del responsabile la valutazione di un'anomalia ma non la libertà di inventarsi la procedura di registrazione contabile.

Applicato al nostro caso di riferimento, la scala si legge senza sforzo. Un agente dichiarativo costruito dal controller in una pausa pranzo, che risponde a domande sul manuale di chiusura e sulle definizioni degli indicatori attingendo alla cartella SharePoint della funzione, è utile, è a basso rischio, e resta un assistente documentale: se smettesse di funzionare domani, qualcuno dovrebbe cercare le informazioni a mano, e nulla di più. L'agente che invece, il quinto giorno lavorativo del mese, si attiva da solo perché è stata caricata l'ultima estrazione contabile, verifica le riconciliazioni, invoca un flusso deterministico per popolare il template e apre un'attività di approvazione al controller, non è un assistente: è un processo aziendale, e come tale richiede un committente, un responsabile, un disegno dei controlli, una procedura di continuità e una voce di costo. Chiamarli entrambi “agenti” è corretto sul piano commerciale e fuorviante su quello organizzativo, ed è precisamente questa ambiguità a produrre, nelle organizzazioni, il fenomeno per cui un processo critico finisce per dipendere da qualcosa che nessuno ha mai formalmente approvato.

5.6 MCP, connettori e agenti dichiarativi: Copilot Studio e Microsoft Foundry Agent Service

Microsoft ha aderito al MCP e lo supporta su più fronti della propria offerta, non come funzionalità isolata. Un agente dichiarativo può collegarsi direttamente a un server MCP esterno: la piattaforma ne scopre automaticamente gli strumenti disponibili e genera, senza intervento manuale, la porzione di manifesto necessaria a esporli come azioni dell'agente, aggiornando in automatico i file `manifest.json`, `ai-plugin.json` e `declarativeAgent.json` che compongono il pacchetto dell'agente, mentre l'autenticazione verso il server, quando richiesta, viene gestita tramite SSO e OAuth 2.0 attraverso il Microsoft 365 Agents Toolkit. Microsoft Foundry Agent

Service (già Azure AI Foundry), il livello più orientato allo sviluppo pro-code dell'offerta, offre a sua volta supporto nativo per collegare un agente a server MCP come strumenti invocabili in fase di esecuzione. Nel nostro caso di esempio, lo stesso server MCP che abbiamo descritto nella parte comune di questo articolo, quello che espone in sola lettura i saldi del sistema gestionale, potrebbe essere collegato indifferentemente a un agente Copilot Studio o a un agente costruito con il Claude Agent SDK o con l'Agents SDK di OpenAI: è precisamente questo il punto pratico dell'interoperabilità promessa dal MCP.

5.7 Il Microsoft Agent Framework per lo sviluppo su misura

Per chi debba costruire un agente in modo programmatico sulla piattaforma Microsoft, il punto di riferimento unico è oggi il Microsoft Agent Framework, nato dalla fusione di due framework storici dell'azienda: Semantic Kernel, orientato all'integrazione enterprise e alla componibilità con i sistemi aziendali esistenti, e AutoGen, orientato alla conversazione e all'orchestrazione tra più agenti. È il livello concettualmente più vicino al Claude Agent SDK di Anthropic e all'Agents SDK di OpenAI descritti nelle parti precedenti, con una precisazione pratica che vale la pena riportare: ovverosia che il pacchetto `autogen` disponibile su PyPI, il registro pubblico dei pacchetti Python, installa la versione community del progetto (nota come AG2), non il Microsoft Agent Framework, un equivoco di packaging facile da commettere e capace di far perdere tempo prezioso a un team che non ne fosse consapevole. Copilot Studio resta, in questo stesso ecosistema, lo strumento low-code per chi preferisce comporre un agente senza scrivere codice, mentre il Microsoft Agent Framework resta la scelta per chi ha bisogno del controllo più fine offerto da una libreria di programmazione.

5.8 GitHub Copilot Agent Mode: il fronte coding

Come Anthropic con Claude Code e OpenAI con Codex, anche Microsoft ha il proprio agente per lo sviluppo software maturo, integrato in GitHub Copilot attraverso l'Agent Mode: a differenza della modalità di editing tradizionale, che suggerisce modifiche puntuali riga per riga, l'Agent Mode può pianificare ed eseguire autonomamente un compito che coinvolge più file, eseguire i comandi necessari, e correggere i propri stessi errori attraverso un ciclo di autocorrezione (`autoFix`) che ripete il tentativo quando un test fallisce o il codice non compila, oltre a poter invocare strumenti esposti tramite server MCP nello stesso modo già descritto per gli altri due ecosistemi. Nel nostro caso di riferimento, un team che lavori nell'ecosistema Microsoft userebbe l'Agent Mode esattamente per il tipo di intervento già descritto a proposito di Claude Code e di Codex, la correzione di uno script di consolidamento dati che alimenta il reporting mensile, con lo stesso criterio di verifica, i test superati e la correttezza dei dati prodotti, a decidere il valore reale dell'intervento, non il numero di righe modificate.

5.9 Copilot Cowork: una licenza tecnologica tra concorrenti diretti

A marzo 2026 Microsoft ha presentato “Copilot Cowork”, la propria funzionalità per la gestione di compiti multi passo in Microsoft 365 Copilot, dichiarando esplicitamente di aver “lavorato a stretto contatto con Anthropic” per integrare “la tecnologia alla base di Claude Cowork” nel proprio prodotto. Lo interpreto come il segnale più concreto di quanto il mercato degli agenti si stia già ricomponendo lungo linee più pragmatiche delle rivalità dichiarate tra i singoli fornitori, e un argomento in più contro l’idea che scegliere un fornitore di modelli significhi necessariamente rinunciare per sempre alla tecnologia di un altro.

5.10 Frontier Firm e Work IQ: la cornice organizzativa

Microsoft colloca l’insieme di questi elementi dentro una cornice concettuale più ampia, che chiama “Frontier Firm”: un’organizzazione in cui gli agenti diventano estensioni della forza lavoro umana, visibili e governabili con gli stessi strumenti già usati per le persone, non entità informatiche separate. La condizione abilitante di questa visione è “Work IQ”, il livello che fornisce agli agenti il contesto organizzativo completo, file, riunioni, chat, relazioni, invece di frammenti isolati di informazione. Se dovessimo racchiudere in un’unica frase la differenza di approccio rispetto ai due ecosistemi già descritti, potremmo dire che mentre OpenAI e Anthropic ragionano prevalentemente in termini di capacità dell’agente, che cosa sa fare e con quale autonomia, Microsoft ragiona in termini di governo della popolazione di agenti come fosse una nuova categoria di risorsa aziendale, un’inclinazione naturale per chi parte da una posizione dominante nella gestione delle identità e degli asset aziendali, e che nel nostro caso di esempio si tradurrebbe, concretamente, nel poter rispondere in ogni momento, per l’intero gruppo, alla domanda “quali agenti operano oggi sul processo di chiusura mensile, con quali permessi, e chi ne è responsabile”, una domanda a cui un registro centralizzato risponde in modo strutturalmente diverso da un elenco informale di script sparsi tra i vari team.

6 Parte VI. Lettura comparata e implicazioni nel processo di A(I)doption

6.1 Convergenze

Il primo dato che colpisce, mettendo a confronto i tre percorsi appena descritti, è quanto le architetture di fondo si somiglino tra Anthropic e OpenAI, nonostante le denominazioni diverse scelte da ciascun fornitore, e quanto Microsoft, pur condividendo lo stesso strato tecnico di base, ne ridisegni la priorità attorno al governo della flotta piuttosto che attorno alla sola capacità dell’agente. Tutti e tre condividono lo stesso protocollo di connessione ai dati esterni, il MCP, un fatto tutt’altro che scontato tra fornitori che restano concorrenti diretti su quasi ogni altro fronte. Anthropic e OpenAI, in particolare, hanno finito per offrire la stessa architettura a tre livelli per chi costruisce un agente su misura (accesso diretto al modello, framework o SDK

intermedio, esecuzione interamente gestita dal fornitore), architettura che Microsoft replica a sua volta con Foundry Agent Service, Microsoft Agent Framework e Copilot Studio, sebbene incorniciata dentro un livello aggiuntivo di identità e governance che gli altri due non trattano come priorità di prodotto. Tutti e tre, infine, hanno sviluppato un concetto di competenza modulare e riutilizzabile (la skill in Anthropic e in OpenAI, le capacità dichiarate nel manifesto in Microsoft) e un meccanismo di configurazione dell'agente, in Markdown per i primi due, in JSON dichiarativo per il terzo. La convergenza sul nucleo tecnico riflette il fatto che i problemi da risolvere, per chiunque costruisca un sistema agentico serio, sono in larga parte gli stessi, a prescindere dal fornitore.

La tabella seguente riassume questa corrispondenza, esigenza per esigenza, come mappa di lettura più che come dichiarazione di equivalenza funzionale: prodotti collocati sulla stessa riga rispondono a un bisogno simile, non possiedono necessariamente gli stessi strumenti, gli stessi permessi o le stesse modalità di distribuzione, e la colonna Microsoft, in particolare, va letta tenendo presente che l'unità di governo di riferimento, per questo fornitore, è spesso la flotta di agenti nel suo insieme, non il singolo prodotto isolato.

Esigenza	Anthropic	OpenAI	Microsoft
Esperienza conversazionale	Claude Chat	ChatGPT “classic”	Microsoft 365 Copilot Chat
Lavoro delegato su elaborati	Cowork	ChatGPT Work	Copilot Cowork
Agente riutilizzabile per team	Plugin e connettori in Chat e Cowork	Workspace Agents	Agenti dichiarativi (Agent Builder, Copilot Studio)
Coding	Claude Code	Codex	GitHub Copilot Agent Mode (CLI e Code in Cowork)
Accesso diretto al modello	Messages API	Responses API	Foundry Agent Service (API)
Costruzione tramite libreria/SDK	Claude Agent SDK	Agents SDK (Codex SDK per integrare Codex)	Microsoft Agent Framework
Riutilizzo e diffusione di un metodo	Skill e plugin	Skill, plugin e Workspace Agents	Manifesto dichiarativo e catalogo Copilot
Esecuzione interamente gestita	Claude Managed Agents	Agents API	Foundry Agent Service (gestito)
Governo dell'identità e della flotta di agenti	Permessi e controlli per singolo agente	Permessi e controlli per singolo agente	Entra Agent ID e Agent 365 (control plane dedicato)

Vale la pena di soffermarsi su due righe in particolare. La prima è quella dedicata all'agente riutilizzabile per team, perché nasconde una differenza reale sotto un'apparente corrispondenza: un plugin, un Workspace Agent e un agente dichiarativo Microsoft non sono lo stesso tipo di oggetto. Il primo distribuisce estensioni (skill, connettori) che un utente richiama all'interno di una conversazione o di un ambiente come Cowork; il secondo rappresenta, in OpenAI, un modo diverso di organizzare lavoro riutilizzabile, con un proprio ciclo di vita, propri trigger esterni e una propria modalità di pubblicazione a livello di team; il terzo è, per costruzione, un'applicazione pubblicata in un catalogo aziendale, con un proprio processo di approvazione. Accostarli nella stessa riga aiuta a orientarsi per esigenza, non autorizza a trattarli come lo stesso prodotto con un nome diverso. La seconda riga da sottolineare è l'ultima, quella sul governo dell'identità e della flotta: è la riga in cui la differenza tra Microsoft e i primi due fornitori è di sostanza.

6.2 Divergenze di filosofia

Le differenze, dove esistono, vanno lette su due piani distinti. Tra Anthropic e OpenAI, sono più di forma che di sostanza perché l'approccio Anthropic appare più centrato sullo sviluppatore, con un'estensione progressiva verso l'utente non tecnico che parte da Claude Code e arriva, attraverso Cowork, a un pubblico generalista, mantenendo lungo tutto il percorso una forte coerenza architettuale tra i vari livelli di prodotto. L'approccio OpenAI appare più centrato sulla piattaforma e sulla componibilità visuale per team di business fin dall'inizio, con AgentKit come tentativo esplicito di offrire uno strumento no-code, salvo poi, come abbiamo visto, riposizionare parte di quella stessa offerta verso strumenti più strutturati. Rispetto a Microsoft, invece, la differenza è di sostanza, non di accento: Anthropic e OpenAI chiedono entrambi, in ultima istanza, "che cosa deve poter fare questo agente", mentre Microsoft chiede prima di tutto "chi è questo agente, e come si inserisce nell'anagrafica delle risorse dell'organizzazione".

6.3 Che cosa è davvero portabile tra le piattaforme

Uno standard condiviso come il MCP, e un formato aperto come quello delle skill, riducono certamente parte del lavoro di integrazione necessario per passare da un ecosistema all'altro, ma non lo eliminano. Una skill che codifica il metodo di reporting del nostro caso di riferimento può in linea di principio essere trasferita da Anthropic a OpenAI, o viceversa, conservandone il metodo e la struttura, ma non senza riverificare, nel nuovo ambiente, connettori, permessi e criteri di verifica: la portabilità del formato non è portabilità del comportamento effettivo. Verso Microsoft, il salto è più netto: lo stesso metodo andrebbe ritrascritto nel manifesto dichiarativo, il che non significa perdere il valore intellettuale del lavoro già svolto (il testo delle istruzioni, la soglia di materialità, la struttura del template restano riutilizzabili), ma richiede un passaggio di trasposizione che con Markdown puro non sarebbe necessario. È una distinzione da tenere bene a mente in ogni discussione, sempre più frequente nelle organizzazioni, sul rischio di vendor lock-in perché lo standard aperto riduce il rischio sul piano del formato, non lo azzerava sul piano


operativo, ed è tanto più vero quanto più un fornitore, come nel caso di Microsoft, integra la configurazione dell'agente dentro un proprio ciclo di pubblicazione e governance.

6.4 Il quadro economico: abbonamenti, token, crediti e ore di esecuzione

Per quanto soggetto a prevedibili evoluzioni nel breve periodo (anche perché prima o poi gli editori di questi modelli passeranno “alla cassa”), credo sia importante quanto meno provare ad introdurre il tema dei diversi modelli di prezzo perché determina che cosa si può mettere a budget in anticipo, che cosa può sfuggire di mano, e soprattutto quale unità di misura entra nel controllo di gestione dell'iniziativa. Il problema, per chi deve costruire un business case, è che oggi convivono almeno cinque logiche diverse, spesso nello stesso fornitore e talvolta persino nello stesso prodotto.

La prima logica è l'**abbonamento per utente**: la più familiare, la più prevedibile, e quella su cui si fonda ancora la maggior parte delle offerte rivolte all'utente finale. La seconda è il **consumo a token**, cioè la quantità di testo elaborata in ingresso e in uscita, che è la logica nativa delle API e quella che si applica quando l'organizzazione costruisce qualcosa di proprio. La terza è il **credito prepagato**, un'unità di conto proprietaria che il fornitore vende a pacchetti e consuma secondo tariffari propri, e che introduce un livello di astrazione fra ciò che si paga e ciò che si consuma. La quarta, più recente e nata proprio con gli agenti, è il **tempo di esecuzione dell'infrastruttura**: quando un agente lavora per ore in modo asincrono, il costo dell'ambiente isolato in cui gira non è esprimibile in token e viene quindi fatturato a tempo. La quinta, infine, è la **tariffa fissa per azione**, in cui un compito (una ricerca approfondita, un turno in modalità agente) vale un numero predefinito di unità a prescindere dal lavoro effettivamente svolto sotto.

Il costo di un agente in produzione: una pila, non una riga



Nessuna di queste voci è nascosta. Tutte sono documentate. Nessuna compare nel preventivo, se non viene cercata.

Figura 12: Il costo di un agente in produzione: una pila, non una riga

Il quadro che segue fotografa la situazione a settembre 2026 e descrive le logiche di costo e non i listini sia perché cambiano troppo rapidamente per essere attendibili sia perché come tutto nella vita possono essere oggetto di negoziazione.

Fornitore	Componente	Unità di fatturazione	Prevedibilità
Anthropic	Piani Pro, Max, Team	Abbonamento per utente, con limiti d'uso a finestre temporali	Alta
Anthropic	Piano Enterprise	Abbonamento per utente più consumo a token a tariffa API	Media
Anthropic	Messages API	Token di ingresso, di uscita e di cache	Bassa
Anthropic	Managed Agents	Token più ore di sessione dell'infrastruttura	Bassa
OpenAI	Piani ChatGPT e Business	Abbonamento per utente, con posti standard e posti premium	Alta
OpenAI	Uso oltre soglia, Codex, Workspace Agents	Crediti prepagati, a tariffa per azione oppure per token	Bassa
OpenAI	API e Agents API	Token, più tariffe per chiamata di alcuni strumenti integrati	Bassa
Microsoft	Microsoft 365 Copilot	Abbonamento per utente	Alta
Microsoft	Agent 365	Abbonamento per utente umano , non per agente	Alta
Microsoft	Copilot Studio	Crediti prepagati a pacchetto, non cumulabili fra mesi, oppure consumo su Azure	Media
Microsoft	Foundry Agent Service	Token, più ore di calcolo, più memoria e archiviazione	Bassa

Fornitore	Componente	Unità di fatturazione	Prevedibilità
Microsoft	GitHub Copilot	Abbonamento per posto più crediti consumati a token	Media
Microsoft	Power Automate (flussi invocati)	Licenza per utente oppure per singolo processo automatizzato	Alta per unità

Da questo quadro emergono quattro considerazioni che mi paiono più utili delle cifre puntuali, destinate comunque a invecchiare in fretta.

La prima è che **il workplace non compra più il lavoro**. Il posto compra l'accesso, la sicurezza e la governance; l'attività vera e propria viene misurata a parte. Anthropic lo dichiara nel modo più esplicito per il proprio piano Enterprise, dove il canone per utente convive con la fatturazione separata di ogni token consumato a tariffa API; OpenAI ha introdotto posti dedicati allo sviluppo fatturati interamente a consumo; Microsoft, con Copilot Studio, azzerava il costo di alcune azioni per chi possiede la licenza Copilot ma ne fattura altre per intero, in particolare quelle esposte all'esterno delle proprie superfici. Per chi costruisce un budget, la conseguenza è che la voce "licenze" ha smesso di essere una ragionevole approssimazione del costo dell'iniziativa, e chi continua a usarla come tale otterrà un preventivo sistematicamente ottimista.

La seconda riguarda **la trasparenza dell'unità di misura**, intesa come assenza della medesima. Quando l'eccedenza è fatturata in valuta a tariffe pubblicate, il committente può ricostruire il costo unitario di un'elaborazione e confrontare due soluzioni; quando è fatturata in crediti, unità proprietaria il cui controvalore non sempre è pubblicato e che in alcuni casi scade dopo dodici mesi, la stessa ricostruzione richiede un tariffario che non viene necessariamente fornito in modo spontaneo. Non è una questione di correttezza del fornitore, è una ordinaria questione di asimmetria informativa: chiedere per iscritto, prima della firma, il tasso di conversione fra crediti e valuta, la politica di scadenza e il trattamento dell'inutilizzato dovrebbe essere prassi standard, esattamente come si fa da sempre per qualunque altra unità di consumo contrattuale.

La terza è che **gli agenti hanno costretto il mercato a inventare un'unità nuova**. Sia Anthropic sia OpenAI, in modo indipendente e a pochi mesi di distanza, hanno introdotto una fatturazione a tempo per gli ambienti isolati in cui gli agenti eseguono codice, semplicemente perché il consumo di un contenitore che resta acceso per ore non è esprimibile in token. È un dettaglio tecnico con un'implicazione gestionale precisa: un agente che lavora a lungo costa anche quando "pensa" poco, e la metrica di efficienza rilevante non è più il numero di parole elaborate ma la durata del compito e il grado di occupazione della risorsa. Chi ha esperienza di controllo di gestione riconoscerà senza fatica la differenza fra un costo variabile proporzionale al volume e un costo di capacità proporzionale al tempo di impegno di un fattore produttivo: è la stessa distinzione di sempre, riproposta in un contesto che sembrerebbe nuovo e non lo è.

La quarta, e la più insidiosa in fase di preventivazione, è che **il costo di un agente in produzione è una pila, non una riga**. Un agente costruito in Copilot Studio che si attiva su un evento, interroga dati aziendali e invoca un flusso di automazione può consumare, contemporaneamente, i crediti del pacchetto prepagato, un costo maggiorato per l'ancoraggio ai dati aziendali (nell'ordine di alcune volte il costo di una risposta generativa semplice), le azioni del flusso, una licenza dedicata per il processo automatizzato, una quota delle chiamate disponibili alla piattaforma, e infine la licenza di governo per gli utenti coinvolti. Nessuna di queste voci è nascosta, tutte sono documentate, ma nessuna compare nel preventivo se non viene cercata. Il preventivo corretto si costruisce quindi **per processo e non per strumento**, ed è forse il punto in cui la competenza di chi si occupa di controllo di gestione è più direttamente applicabile a una materia che a prima vista sembrerebbe di esclusiva pertinenza informatica.

Vale la pena, per chiudere, collegare questo quadro alla scheda di misurazione proposta nella parte comune. Il costo per risultato accettato, che è l'unica metrica capace di integrare prezzo e qualità, si calcola soltanto se si conoscono entrambi i termini: il denominatore richiede la disciplina della verifica, il numeratore richiede di sapere quali unità si stanno consumando e in quale punto del processo. Un'organizzazione che misura l'uno senza l'altro finirà inevitabilmente per confrontare soluzioni sulla base del prezzo di listino del modello, che è l'unica cifra facile da reperire e la meno significativa di tutte. Aggiungo, per completezza, che tutti e tre i fornitori hanno introdotto nel corso del 2026 strumenti di controllo della spesa piuttosto seri (limiti per singolo utente, tetti per singolo agente con disattivazione automatica al superamento, notifiche di soglia, attribuzione dei costi per progetto): esistono, funzionano, e nella mia esperienza vengono configurati quasi sempre il giorno dopo il primo conto inatteso, anziché il giorno prima.

7 Parte VII. Conclusioni: la nuova competenza manageriale

Ogni volta che un'organizzazione delega un compito a un esecutore di cui non osserva direttamente ogni singola azione, umano o artificiale che sia, genera un problema di agenzia, nel senso classico che questo termine ha nella teoria economica dell'organizzazione: un'asimmetria informativa tra chi delega e chi esegue, che va gestita con strumenti di controllo appropriati, non ignorata nell'entusiasmo per la nuova capacità tecnica. Il risultato di ricerca sui problemi di coordinamento multi agente richiamato in precedenza è un promemoria utile in questo senso: più agenti, e più autonomia, non equivalgono automaticamente a più affidabilità, e la disciplina della verifica, non l'entusiasmo per la scala, resta il vero indicatore di maturità di un'adozione.

Se dovessi indicare la competenza manageriale più rilevante che emerge da questo intero percorso, non sarebbe una competenza tecnica in senso stretto, ma la capacità di progettare lavoro delegabile, nello stesso senso in cui l'adozione dell'AI in azienda richiede che competenze, procedure e uso quotidiano procedano insieme: formulare obiettivi verificabili invece di istruzioni vaghe, esplicitare il sapere operativo che prima viveva solo nell'esperienza di chi svolgeva un compito, predisporre le informazioni necessarie nel formato e nella qualità richiesti, assegnare l'autorità appropriata a ciascun passaggio, e infine giudicare gli esiti con gli stessi criteri di

rigore che applicheremmo a qualunque collaboratore umano. Nel nostro caso di riferimento, il responsabile del controllo di gestione che mantiene la proprietà del metodo di reporting, lo aggiorna quando cambia una politica aziendale, e usa i risultati della verifica per decidere cosa delegare ulteriormente e cosa no, non sta solo supervisionando uno strumento: sta esercitando, in una forma nuova, la stessa responsabilità manageriale che ha sempre esercitato.