

Pensa per noi, ci fa lavorare di più, e continua a sembrarci pure una buona idea

*Tre teorie sull'impatto cognitivo dell'intelligenza artificiale e un tentativo di metterle
insieme*

Riccardo Bovetti

[LinkedIn](#) | [All you need it thought](#)

Febbraio 2026

Sommario

Questo articolo prova a fare una cosa semplice (che poi semplice non è): smettere di discutere di AI come se le alternative fossero solo “ci rende tutti più produttivi” oppure “ci ruba il lavoro” e spostare la domanda dove fa un po’ più male: cosa sta succedendo dentro la testa di chi la usa tutti i giorni? Quando deleghi a un modello generativo pezzi di scrittura, analisi e ragionamento, non stai solo risparmiando tempo: stai anche cambiando (a volte senza accorgertene) il modo con il quale cerchi e valuti informazioni ed alternative e quanto ti fidi del tuo giudizio. Per capirci qualcosa metto in dialogo tre lenti recenti: il *System 0* (l’AI che “prepara” il mondo prima che tu attivi System 1 e System 2), la *Tri-System Theory* (l’AI come terzo sistema cognitivo esterno, che può aiutarti o sostituirti a seconda di come la usi) e un filone più organizzativo che mostra un paradosso curioso (ma ampiamente verificabile): invece di alleggerire il lavoro, spesso lo intensifica. Letti insieme, questi pezzi suggeriscono un corto circuito auto-alimentante: più comfort e più capacità percepite, meno vigilanza e autonomia cognitiva reale, e in mezzo una bella dose di *automation bias*. Nella seconda parte mi prendo la libertà di fare quello che si fa quando la ricerca corre più lenta del fenomeno da ricercare (sapendo che il risultato durerà quanto gelato nel deserto): speculare onestamente. Propongo un modello a fasi della relazione cognitiva con l’AI e l’idea di “resa cognitiva qualificata e consapevole”: non un invito alla resa, ma un tentativo di darle regole, confini e un minimo di dignità operativa (cioè: come usarla senza farci usare). Per lo meno ci ho provato

Indice

1	Introduzione: il problema che nessuno vi aveva (ancora) detto di avere	3
2	Tre lenti per mettere a fuoco il medesimo fenomeno	4
2.1	System 0: l'AI che pensa prima di te	4
2.2	Tri-System Theory: l'AI che pensa con te (o al posto tuo)	5
2.3	L'intensificazione silente: quando l'AI ti fa lavorare di più	6
3	Lettura sinottica: dove convergono, dove divergono e cosa sembra mancare	7
4	Contributo speculativo formale e concettuale: un modello a fasi e una competenza da costruire	9
4.1	Le fasi della deriva cognitiva	9
4.2	La resa cognitiva qualificata come competenza e non difetto	12
5	Implicazioni e domande aperte	14
6	Conclusione	15
	Bibliografia	16

-

1 Introduzione: il problema che nessuno vi aveva (ancora) detto di avere

Il dibattito pubblico sull'intelligenza artificiale ha una struttura narrativa piuttosto prevedibile che contrappone i profeti dell'efficienza *uber alles* (l'AI ci libererà dal lavoro ripetitivo, ci renderà più produttivi, ci permetterà di concentrarci su ciò che conta davvero) ai catastrofisti (l'AI ci ruberà il lavoro, ci renderà obsoleti, ci ridurrà a spettatori della nostra stessa vita professionale). La partita retorica (fondamentalmente basata sul nulla) ha oramai stancato anche i più pazienti. Ci sono però domande che questa disputa dialettica non risolve, ed una delle più interessanti secondo me è “cosa sta succedendo dentro la testa di chi usa l'AI?” Non in senso metafisico metaforico o filosofico bensì in senso cognitivo, misurabile e, almeno in qualche misura, documentabile. Quando un professionista delega una bozza di analisi ad un chatbot o chiede a un Copilot di sintetizzargli venti pagine di report, quando un ingegnere lascia che un assistente AI generi il codice al posto suo, che cosa cambia (se qualcosa cambia) nel modo in cui quella persona pensa, decide, valuta e giudica? La domanda non è nuova, in realtà, perché la ricerca sull'*automation bias* (inteso come la tendenza sistematica a fidarsi eccessivamente dei sistemi automatizzati) ha almeno tre decenni di storia, a partire dai lavori di Parasuraman e Riley negli anni Novanta [12] e dalle successive formalizzazioni di Parasuraman e Manzey [11]. In aviazione, in medicina, nelle funzioni di supporto così come nei sistemi di controllo industriale, il fenomeno è documentato con abbondanza: gli esseri umani che lavorano con sistemi automatizzati tendono ad accettarne gli output anche quando sono sbagliati (purché non palesamente) ed a ridurre progressivamente la propria vigilanza perdendo (a volte) nel tempo le competenze necessarie per operare senza assistenza automatica. Quello che l'AI generativa porta di nuovo non è il meccanismo di base ma la sua estensione a domini cognitivi che fino a ieri erano stati risparmiati: il ragionamento, la scrittura, l'analisi, la sintesi, il giudizio professionale.

Nelle mie peripatesi di lettura compulsiva mi sono imbattuto in tre contributi recenti che hanno iniziato a esplorare questa estensione con una profondità che merita attenzione, due dei quali, partendo da una comune “base logica”, articolano concetti a complementari (alla base logica comune così come tra essi) che ho trovato molto interessanti (digressioni, io sono sempre affascinato da come lavorando su teorie esistenti si riescano a trovare punti di vista sempre nuovi e laterali... come affinare la lama di un coltello, oppure del rasoio di quello là, se preferite). Come sempre mi succede una volta che ho iniziato ad unire i puntini mi è stato impossibile non provare a costruirvi sopra il mio vestito di “meta analisi” per renderli (in primo luogo a me stesso) maggiormente digeribili (non dirigibili). Il primo è il lavoro di Massimo Chiriatti e colleghi, che propone il concetto di **System 0**: l'AI come preprocessore cognitivo che agisce prima ancora che il nostro pensiero intuitivo o deliberativo entri in gioco [2]. Il secondo è lo studio di Shaw e Nave alla Wharton School, che formalizza una **Tri-System Theory** della cognizione umana nell'era dell'AI, con una dimostrazione empirica della nostra tendenza alla “resa cognitiva” [15]. Il terzo è il lavoro “organizzativo” di Ranganathan e Ye pubblicato su Harvard Business Review,

che documenta come l'AI, lungi dal ridurre il carico lavorativo, lo intensifichi sistematicamente attraverso meccanismi che gli stessi lavoratori faticano a riconoscere [13].

Letti separatamente, ciascuno di questi contributi illumina un angolo del problema ma letti insieme trovo che disegnino un quadro che si presta ad una speculazione interessante: un ciclo autoalimentante in cui l'AI espande le nostre capacità percepite, erode la nostra autonomia cognitiva reale ed intensifica il lavoro in una spirale che ci affanniamo a presentare, paradossalmente, come progresso. Una sorta di rilettura “sotto steroidi” dell'*automation bias* che concerne però il pensiero stesso, non solo l'esecuzione di compiti. Quello che provo a fare qui è duplice nel suo intento. Nella prima parte, sintetizzo e metto in dialogo i tre contributi, facendo emergere convergenze e tensioni possibili solo nelle letture a posteriori. Nella seconda, propongo due costrutti speculativi “pseudo originali”: un modello a fasi della relazione cognitiva con l'AI e il concetto di “resa cognitiva qualificata e consapevole” che, pur mancando di validazione empirica autonoma, ho trovato utile per chi come me si occupa di progettare l'adozione dell'AI nelle organizzazioni. Dico “speculativi” senza imbarazzo: in un campo dove la velocità del fenomeno supera quella della ricerca, l'onestà epistemica è il minimo sindacale.

2 Tre lenti per mettere a fuoco il medesimo fenomeno

2.1 System 0: l'AI che pensa prima di te

Il contributo di Chiriatti e colleghi [2] parte da un assunto semplice e potente: nella tassonomia di Kahneman [7] (con cui penso quasi tutti abbiamo fatto i conti almeno due volte: la prima quando lo abbiamo letto magari qualche anno fa, la seconda quando, dopo la sua recente scomparsa, siamo andati a cercare gli appunti di quella lettura) il **System 1** (pensiero rapido, intuitivo) e il **System 2** (pensiero lento, deliberativo) presuppongono entrambi che il soggetto abbia accesso a informazioni grezze su cui esercitare il proprio giudizio. Ma cosa succede quando le informazioni arrivano già filtrate, sintetizzate e riformulate da un'AI?

Il System 1 reagisce a stimoli che non sono più “naturalisti” ma pre-elaborati; il System 2 delibera su materiale che è già stato selezionato e organizzato da qualcun altro (o da qualcos'altro). È questo il senso del termine **System 0**: non un terzo modo di pensare, ma uno strato che si interpone tra il mondo e la nostra cognizione, plasmando il substrato informativo su cui entrambi i sistemi kahnemaniani operano. L'AI non decide al nostro posto (almeno, non ancora nella maggior parte dei casi), ma ridefinisce lo spazio delle possibilità cognitive: cosa vediamo e consideriamo rilevante e, di conseguenza, quali opzioni ci appaiono disponibili. È il meccanismo noto con il nome di *framing effect* indotto dall'automazione, in cui il sistema automatizzato non impone una decisione ma vincola lo spazio decisionale in modo che certe opzioni diventino più salienti di altre [3]. Il merito principale del lavoro di Chiriatti et al. è secondo me quello di aver collocato l'AI nel modello cognitivo dominante senza forzature. Il limite (che gli autori stessi riconoscono come “in divenire”) è che la proposta resta essenzialmente concettuale. I sette framework che propongono per un'integrazione responsabile (literacy critica, diversificazione delle

fonti, governance, trasparenza algoritmica e così via) sono adeguati ma generici perché dicono cosa dovremmo fare, non come farlo, e soprattutto non affrontano la questione di cosa succede quando (non) lo facciamo, che è probabilmente la domanda più urgente.

Un elemento particolarmente interessante è il riferimento al “comfort-growth paradox” di Riva [14]: l’idea che la comodità dell’assistenza AI crei una zona di comfort che inibisce la crescita cognitiva. È un’intuizione che troverà eco (e sostanza empirica per quanto limitata) nel lavoro di Shaw e Nave [15]. Ed è anche il meccanismo che nella ricerca sul deskilling da automazione è documentato fin dagli studi di Bainbridge (1983) sull’“ironia dell’automazione”: si automatizza precisamente perché gli esseri umani sono inaffidabili, ma l’automazione li rende ancora più inaffidabili eliminando la pratica necessaria a mantenere le competenze [1].

2.2 Tri-System Theory: l’AI che pensa con te (o al posto tuo)

Il paper di Shaw e Nave alla Wharton School compie un salto di ambizione teorica significativo [15]. Anche loro inseriscono l’AI nel modello di Kahneman ma propongono in aggiunta di riscrivere interamente il modello, trasformandolo da duale a triadico (e si sa che *three is the magic number*). Nella loro formulazione, l’AI diventa un **System 3** ovvero un sistema cognitivo esterno al cervello, con proprie caratteristiche di velocità, accuratezza e bias, che si affianca ai sistemi 1 e 2 in un’architettura cognitiva nuova. La distinzione (per me) più interessante che introducono è quella tra *cognitive offloading* e *cognitive surrender*.

- Il **cognitive offloading** è strategico: il soggetto decide consapevolmente di delegare un compito cognitivo all’AI, mantenendo la capacità (e l’intenzione) di verificare e correggere l’output.
- La **cognitive surrender** è invece acritica (e quasi involuzione passiva): il soggetto accetta l’output dell’AI senza valutazione indipendente, non per pigrizia ma per una combinazione di fiducia eccessiva, costo percepito della verifica, e sostanziale incapacità di valutare quando la delega è appropriata e quando no.

Nella cognitive surrender risuonano gli echi della formalizzazione AI-specifica di ciò che Parasuraman e Manzey (2010) chiamarono *automation-induced complacency*: la riduzione della vigilanza e del monitoraggio attivo che si verifica quando un operatore lavora con un sistema automatizzato percepito come affidabile [11]. I tre esperimenti che sono alla base della formulazione teorica del paper producono risultati che dovrebbero preoccupare chiunque si occupi di adozione AI nelle organizzazioni.

- Nel primo, dimostrano che la cognitive surrender si verifica in modo massiccio anche quando i partecipanti sono esplicitamente avvertiti che l’AI potrebbe sbagliare.
- Nel secondo, mostrano che incentivi economici legati all’accuratezza non riducono significativamente il fenomeno.

- Nel terzo, documentano che la pressione temporale, lungi dall'aumentare la resa cognitiva come ci si potrebbe aspettare, produce effetti più complessi e differenziati a seconda dei tratti individuali.

Tutti e tre i risultati sono coerenti con la letteratura sull'automation bias, che ha ripetutamente documentato la resistenza del fenomeno a interventi basati su consapevolezza e incentivi [6]. La tavola delle “canonical routes of cognition” che Shaw e Nave propongono è forse lo strumento analitico più immediatamente utile dell'intero paper. Identifica cinque percorsi cognitivi che costituisce una tassonomia utile a classificare i comportamenti osservabili e, potenzialmente, di progettare interventi mirati per ridirigerli (correggerli?) consapevolmente. Ciascuno dei percorsi vede un alternarsi di dominanza/conseguenza da parte di un sistema rispetto agli altri e nello specifico vengono definiti e descritti:

Percorso	Sistema
Intuizione	System 1 dominante
Deliberazione	System 2 dominante
Cognitive Offloading	System 3 usato strategicamente
Cognitive Surrender	System 3 usato acriticamente
Autopilot	Nessun sistema dominante (operatività routinaria)

2.3 L'intensificazione silente: quando l'AI ti fa lavorare di più

Su un piano completamente diverso dai primi due si colloca il contributo di Ranganathan e Ye su Harvard Business Review [13], e proprio per questo è indispensabile alla comprensione del fenomeno complessivo. Là dove System 0 e Tri-System Theory ragionano sulla cognizione individuale (cosa succede nella testa di chi usa l'AI) questo studio organizzativo di otto mesi in una tech company documenta le conseguenze organizzative e comportamentali dell'adozione dell'AI: cosa succede all'ambiente di lavoro, alle aspettative, ai ritmi, alle relazioni professionali. I risultati sfidano frontalmente la narrativa dell'AI come strumento di semplificazione, e lo fanno con una granularità che merita attenzione.

Il primo meccanismo documentato è l'**espansione dei compiti**: poiché l'AI consente di fare più cose, le aspettative su ciò che un professionista dovrebbe fare si espandono proporzionalmente. Non si tratta di un'espansione dichiarata o formalizzata: nessun manager dice “adesso che hai l'AI fai il doppio”. Succede in modo organico: compiti che prima erano considerati opzionali o “nice-to-have” diventano obbligatori così come deliverable normalmente accettabili in forma sintetica ora richiedono elaborazione completa. Il risultato è un'inflazione delle aspettative che si autoalimenta: ogni dimostrazione di capacità aumentata diventa la nuova baseline per le aspettative future.

Il secondo meccanismo è l'**erosione dei confini lavoro/vita** (qualora ci fosse bisogno di qualche altra meccanica o dinamica ad accelerarla). L'accessibilità permanente degli strumenti

AI rende il lavoro un fluido che si espande in ogni interstizio temporale disponibile. La bozza si può rifinire la sera, l'analisi si può completare nel weekend, il report si può generare durante il commuting e quella feature essenziale del nuovo sito o software va fatta (fare) immediatamente (ohhh come mi riconosco in questo profilo, finalmente qualcuno che ha messo nero su bianco la mia nuova vita AI assisted). La possibilità tecnica diventa aspettativa implicita, e l'aspettativa implicita diventa norma culturale.

Il terzo meccanismo è la **moltiplicazione del multitasking**. La possibilità di gestire più thread contemporaneamente (far generare codice all'AI mentre si rivede un documento, preparare una presentazione mentre si analizzano dati) non riduce il carico, lo frammenta e potenzialmente lo incrementa proprio per via della frammentazione. Le conseguenze sulla profondità del pensiero e sulla qualità decisionale sono documentate da decenni di ricerca sul *task-switching cost* [10], ma nel contesto AI assumono una dimensione nuova perché il multitasking non è più una scelta individuale ma una capacità abilitata (e quindi attesa) dallo strumento.

Il dato più rivelatore dello studio è probabilmente il più semplice: i lavoratori intervistati, nonostante percepissero un aumento della propria produttività, non riportavano una corrispondente riduzione del carico di lavoro. La spiegazione è strutturale, non contingente: il tempo “liberato” dall'AI viene immediatamente riassorbito in nuovi compiti, e il ciclo si autoalimenta perché l'organizzazione, vedendo maggiore output, alza le aspettative (pur non misurando, ad oggi, alcun reale vantaggio economico sostanziale). Ranganathan e Ye parlano di un “*self-reinforcing cycle*” dell'accelerazione, ma la formulazione potrebbe essere ancora più esplicita: si tratta di un meccanismo di feedback positivo in cui l'efficienza individuale produce intensificazione organizzativa, che produce pressione per maggiore efficienza, che produce ulteriore intensificazione. Mi trovo molto in linea con la proposta degli autori circa la costruzione di una “AI practice” organizzativa che governi intenzionalmente l'integrazione dell'AI nei processi di lavoro perché esattamente l'approccio che perseguo nei miei processi di “A(I)doption” (tanto nella pratica quanto nella forma). Trovo che però questa proposta manchi di un po' di praticità e di un raccordo esplicito con le dinamiche cognitive individuali documentate dagli altri due paper ragione per la quale mi avventuro in questo tentativo di colmare il gap (quanto meno sotto il profilo concettuale).

3 Lettura sinottica: dove convergono, dove divergono e cosa sembra mancare

Messi insieme, i tre contributi raccontano una storia che non si riesce altrimenti a delineare. Le convergenze sono significative: l'AI è visto come un agente attivo che ridisegna i processi cognitivi, non come uno strumento passivo documentando i rischi legati all'integrazione acritica suggerendo che la risposta richiede intenzionalità (anche perché con questi statement confermano ciò che la letteratura sull'automation bias documenta da decenni: la fiducia eccessiva nei sistemi automatizzati è un fenomeno robusto, resistente alla consapevolezza e agli incentivi, che tende a peggiorare nel tempo).

Le tensioni, però, sono altrettanto illuminanti secondo me. La prima è di natura topologica (erano anni che aspettavo il momento di rispolverare questa concettualità dal mio vissuto accademico): System 0 colloca l'AI prima della cognizione umana (come preprocessore), Tri-System Theory la colloca accanto (verrebbe da dire, per amore dei numeri, dopo ma in realtà è più efficace intesa come terzo sistema parallelo). A prima vista sembra una contraddizione, ma a ben guardare è una complementarità che dipende dal momento e dalla modalità d'uso. Quando un professionista chiede esplicitamente all'AI di risolvere un problema il modello opera come System 3, un sistema parallelo che si consulta e il cui output si valuta (o si dovrebbe valutare). Ma quando lo stesso professionista apre la giornata con una dashboard pre-compilata dall'AI, legge una sintesi generata automaticamente da un meeting oppure riceve ed accetta suggerimenti non sollecitati durante la scrittura, l'AI opera come System 0: plasma il campo informativo prima ancora che la cognizione deliberativa si attivi (in un modo, nella maggior parte dei casi, fastidioso soprattutto per quanto riguarda la versione 2025 di Clippy). La stessa tecnologia, dunque, può funzionare in entrambe le modalità, e spesso lo fa nello stesso stream di lavoro. Questa osservazione sta alla base del modello a fasi che propongo nella sezione successiva: la traiettoria della relazione cognitiva con l'AI è anche una migrazione graduale da un uso prevalentemente System 3 a un funzionamento prevalentemente System 0 (echi lontani degli utilizzi Centaurus e Cyborg cui la letteratura seria sulla AI della prima ora ci ha abituato).

La seconda tensione è temporale. System 0 e Tri-System Theory sono essenzialmente teorie statiche: descrivono una condizione, non una traiettoria od una direzione (e verso). Lo studio HBR ha una dimensione diacronica (otto mesi di osservazione) ma non la connette alla teoria cognitiva. Mancano le molto azzardate domande di come evolve la relazione cognitiva tra un individuo e l'AI nel tempo, se la cognitive surrender sia un punto di arrivo inevitabile, un rischio contingente, o una fase transitoria. La letteratura sull'automazione suggerirebbe che è una tendenza naturale che peggiora con l'esposizione prolungata [11], ma la specificità dell'AI generativa, che utilizzando il linguaggio naturale opera su domini cognitivi ad alta ambiguità, rende rischiosa qualsiasi estrapolazione diretta.

La terza tensione è di livello di analisi. I primi due contributi ragionano sull'individuo; il terzo ragiona sull'organizzazione. Il collegamento tra i due livelli resta implicito, e merita di essere esplicitato volendo capire, in ottica di adoption, come i comportamenti dei singoli condizionano le traiettorie dell'organizzazione. Le domande che mi sono fatto sono sostanzialmente se la cognitive surrender individuale alimenta l'intensificazione organizzativa (perché chi delega acriticamente produce più output, alzando il baseline per tutti), e se l'intensificazione organizzativa alimenta la cognitive surrender individuale (perché chi è sovraccarico ha meno tempo e meno risorse cognitive per la verifica critica). È un doppio ciclo di rinforzo (carpiato e con jete finale) che provo ad affrontare adesso.

4 Contributo speculativo formale e concettuale: un modello a fasi e una competenza da costruire

Preciso subito le coordinate epistemologiche di ciò che segue: si tratta di pura (se non becera) speculazione teorica informata. Non ho dati proprietari, non ho (ancora) condotto esperimenti, non ho validazione empirica diretta. Quello che propongo è un tentativo di integrare le evidenze e le intuizioni dei tre contributi precedenti con alcune evidenze empiriche a posteriori (cioè mie osservazioni ma mancanti di un modello di determinazione dei parametri a priori) in una cornice che li connetta e, possibilmente, li renda più utili per chi deve progettare programmi di adozione AI in contesti organizzativi reali. Quanto segue è pertanto una ipotesi di lavoro sulla quale tornerò penso molte volte (auspicabilmente non da solo... se qualcuno volesse contribuire), non come una teoria consolidata.

4.1 Le fasi della deriva cognitiva

La prima proposta nasce dal tentativo di risolvere la tensione temporale e la complementarità topologica che ho evidenziato nella lettura sinottica. Parto dall'assunto che la relazione cognitiva tra un individuo e l'AI si sviluppi attraverso una sequenza di fasi che, senza intervento intenzionale, tendono a seguire una traiettoria discendente (dai, cerchiamo di essere drammatici, chiamiamola "deriva cognitiva"). Le fasi che ipotizzo sono cinque, e per ciascuna propongo indicatori osservabili (per quanto ipotetici e provvisori) che potrebbero orientare una futura validazione empirica.




Figura 1: Le fasi della deriva cognitiva

1. Augmentation consapevole. L'individuo inizia a usare l'AI come strumento ausiliario, mantenendo piena consapevolezza della distinzione tra il proprio giudizio e l'output della macchina. Il cognitive offloading è strategico: si delega il compito, si verifica il risultato, si integra con il proprio sapere. L'AI opera prevalentemente come System 3 (consultazione esplicita).

Indicatori osservabili: il soggetto modifica sostanzialmente l'output dell'AI prima di utilizzarlo; è in grado di descrivere esplicitamente i criteri con cui valuta la qualità dell'output; mantiene modalità alternative di esecuzione del compito. Questa è la fase che nella letteratura sull'AI adoption è stata chiamata utilizzo Centauro. La metafora, resa popolare da Ethan Mollick e dai suoi studi sull'uso dell'AI nelle organizzazioni [9], descrive un modello in cui umano e AI operano in sequenza su compiti distinti, ciascuno nel proprio dominio di competenza, senza confusione di ruoli. Ed è anche la fase che, nella mia esperienza di consulente, dura meno di quanto ci si aspetti.

2. Offloading progressivo. L'individuo, avendo verificato ripetutamente che l'AI produce output di qualità accettabile, inizia a ridurre la frequenza e la profondità della verifica od a cambiare in modo sostanziale il meccanismo di ingaggio (partendo da qualcosa che esiste e che viene "condiviso"). È un comportamento perfettamente razionale dal punto di vista individuale gli economisti lo chiamerebbero un adattamento efficiente alle regolarità osservate. Il problema è che questa razionalità locale produce una conseguenza globale: la graduale atrofia della capacità di riconoscere i casi in cui il controllo sarebbe necessario. Il "comfort-growth paradox" di Riva [14] si materializza qui, e l'ironia dell'automazione di Bainbridge [1] pure.

Indicatori osservabili: la percentuale di output AI utilizzata senza modifiche aumenta nel tempo; il tempo dedicato alla revisione diminuisce; l'utilizzatore inizia a percepire la verifica come un costo più che come una precauzione e quindi si comporta da Cyborg (sempre nella tassonomia di Mollick), sfumando i confini tra il lavoro "umano" e quello "AI".

3. Cognitive Surrender incipiente. La linea tra offloading strategico e resa cognitiva diventa sfumata. L'individuo non decide più consapevolmente "delego questo compito all'AI e poi verifico": semplicemente usa l'output dell'AI come base di partenza (o come prodotto finito) senza un processo deliberativo esplicito sulla delega. È qui che l'AI compie la migrazione da System 3 a System 0: da sistema parallelo che si consulta, a preprocessore che plasma ciò che si considera. La transizione è insidiosa proprio perché soggettivamente invisibile: l'utilizzatore crede ancora di esercitare giudizio, ma il campo su cui il giudizio opera è già stato definito dall'AI.

Indicatori osservabili: il soggetto fatica a completare in tempi ragionevoli compiti che prima svolgeva senza assistenza; non ricorda l'ultima volta che ha rifiutato o riscritto completamente un output AI; percepisce l'AI come "generalmente affidabile" senza poter specificare su quali basi empiriche.

4. Normalizzazione. La cognitive surrender diventa il modo di lavorare standard, e si salda con i meccanismi di intensificazione organizzativa documentati da Ranganathan e Ye [13]. L'organizzazione ha adattato le proprie aspettative al nuovo livello di output (più, inteso come quantità, deliverable, velocità ampiezza) rendendo praticamente impossibile un ritorno alla modalità pre-AI: non c'è più tempo per fare le cose "a mano", perché il carico è stato calibrato

sulle capacità aumentate. Il doppio ciclo di rinforzo che ho descritto nella sezione precedente si stabilizza: la surrender alimenta l'intensificazione, l'intensificazione alimenta la surrender. Si crea quello che in ingegneria dei sistemi si chiama un *lock-in*: la dipendenza dal sistema non è più una scelta ma un vincolo strutturale.

Indicatori osservabili: l'organizzazione non prevede tempi di esecuzione senza assistenza AI; la rimozione temporanea dello strumento produce cali di produttività sproporzionati; nessuno mette più in discussione la qualità dell'output AI come prassi.

5. Biforcazione. Da un lato, la **dipendenza epistemica**: l'individuo e l'organizzazione non sono più in grado di operare efficacemente senza assistenza AI, non per mancanza di intelligenza ma per erosione delle competenze specifiche e dei pattern di pensiero indipendente. Dall'altro, il **nuovo equilibrio metacognitivo**: l'individuo o l'organizzazione riconosce la traiettoria, interviene intenzionalmente, e sviluppa una relazione matura con l'AI in cui la delega è calibrata, consapevole, e sottoposta a revisione periodica.

Cosa determina quale ramo della biforcazione si prende? Non ho una risposta, ma dalle prime osservazioni e la logica del modello suggeriscono alcuni possibili fattori discriminanti. Il primo è quello che potremmo chiamare un evento rivelatore: un fallimento dell'AI sufficientemente visibile e dotato di conseguenze tale da rendere percepibile la dipendenza che si era normalizzata. Questi eventi hanno il potere di rendere improvvisamente visibile una condizione che era diventata trasparente, e possono innescare una reazione di ricalibrazione. Il secondo fattore è l'intervento formativo esterno: qualcuno (un consulente/formatore o un collega particolarmente lucido) che interrompe il ciclo di normalizzazione ponendo le domande che il sistema, lasciato a sé stesso, non si pone più: "saresti in grado di fare questo lavoro senza AI? Quando è stata l'ultima volta che ci hai provato?" Il terzo, forse il più strutturale, è il design organizzativo intenzionale: organizzazioni che incorporano nei propri processi dei momenti obbligatori di verifica dell'autonomia cognitiva non come burocrazia difensiva, ma come manutenzione preventiva delle competenze, con la stessa logica con cui si programmano i test di emergenza nei sistemi critici. In assenza di almeno uno di questi fattori, la traiettoria naturale tende verso la dipendenza epistemica: il lock-in si consolida semplicemente perché nessuno lo mette in discussione.

Non è un mistero una certa analogia strutturale con il modello di elaborazione del lutto di Kübler-Ross (che peraltro uso spesso proprio per descrivere le risposte organizzative agli eventi di A(I)Doption): una sequenza di fasi, transizioni non lineari, e un esito che dipende dalla qualità con cui il processo viene attraversato. L'analogia regge come struttura ma diverge nel contenuto, ed è nelle divergenze che diventa interessante. Nella mia sequenza, la fase iniziale non è negazione dello strumento ma negazione della trasformazione: "lo uso, ma resto io a decidere, non mi cambia." L'offloading progressivo è una forma di negoziazione con sé stessi sui termini della delega ("le cose importanti le faccio io") che gradualmente sposta l'asticella di ciò che si considera "importante". Ma il punto più significativo è la fase 3, la cognitive surrender incipiente: in Kübler-Ross qui ci sarebbe la rabbia, il segnale emotivo che qualcosa è percepito come perdita. Nel mio modello, la rabbia non è "prevista" e la sua assenza è precisamente il problema, perché la transizione avviene senza che il soggetto ne sia consapevole. Non c'è perdita percepita, quindi

non c'è resistenza. La normalizzazione è poi una forma di accettazione passiva, più rassegnata che elaborata. La differenza più produttiva, però, è nella fase finale: Kübler-Ross converge su un unico esito (l'accettazione come integrazione della perdita), mentre il mio modello si biforca. La dipendenza epistemica è un'accettazione che non ha mai attraversato la consapevolezza; il nuovo equilibrio metacognitivo è un'accettazione attiva, intenzionale, che presuppone il riconoscimento di ciò che si è rischiato di perdere. In questo senso, ciò che nel modello di Kübler-Ross distingue un'elaborazione sana da una patologica (la capacità di attraversare consapevolmente le fasi) è esattamente ciò che provo a fare separando i due esiti della biforcazione.

Già mentre scrivevo queste righe mi sono apparsi evidenti tre grossi limiti di questo modello. Primo: non ho evidenza che queste fasi si verifichino in questa sequenza in tutti i contesti. È plausibile che la velocità di attraversamento vari enormemente tra domini professionali, livelli di expertise, e tipi di compito. Secondo: la sequenza potrebbe non essere lineare perché è possibile che individui particolarmente riflessivi o ben formati oscillino tra fasi diverse a seconda del contesto. Terzo: gli indicatori di misurazione che propongo sono provvisori e non validati empiricamente; servirebbero studi longitudinali con protocolli di osservazione strutturati per verificare se sono effettivamente discriminanti (ma questo vorrebbe dire che il mio lavoro ha smesso di essere quello con cui metto il pane in tavola ed è diventato invece quello che vorrei fare da sempre). Ho comunque una ragionevole fiducia nell'utilità euristica del modello perché è congruente con i meccanismi documentati dai tre paper e con la letteratura sull'automazione oltre che riconfermato da tutte le osservazioni fatte nel mio lavoro di consulenza e formazione in questi due ultimi anni dedicati praticamente in toto alla A(I)Doption.

4.2 La resa cognitiva qualificata come competenza e non difetto

La seconda proposta parte da un'osservazione che nel paper di Shaw e Nave rimane non completamente sviluppata: la cognitive surrender non è sempre irrazionale. Quando l'AI è accurata e il costo della verifica indipendente è elevato, seguire l'output dell'AI è la scelta economicamente e cognitivamente ottimale. Il problema non è la resa in sé; è la resa indiscriminata, cioè l'incapacità di distinguere i contesti in cui (af)fidarsi all'AI è saggio da quelli in cui è pericoloso. Vorrei pertanto sviluppare a partire da questa considerazione il concetto di **resa cognitiva qualificata** come competenza metacognitiva da sviluppare intenzionalmente. Non si tratta di "resistere all'AI" (posizione tanto romantica quanto antistorica ed impraticabile) ma di sviluppare la capacità di navigare consapevolmente il processo di delega tra autonomia cognitiva piena ed affidamento totale. Esiste una implicita circolarità al centro di questa proposta che sarebbe disonesto ignorare: se Shaw e Nave dimostrano che le persone non riescono a distinguere quando la delega è appropriata (nemmeno in presenza di incentivi economici) sto proponendo come soluzione una competenza la cui assenza è precisamente il problema. La circolarità è reale, e va affrontata con onestà intellettuale. La mia ipotesi è che la cognitive surrender documentata negli esperimenti di Shaw e Nave è un comportamento spontaneo in assenza di formazione specifica: i partecipanti non sono stati istruiti a calibrare la delega, dispongono solo della loro intuizione. Nella formazione

che conduco con professionisti e manager in contesti di AI adoption, ho osservato che sessioni strutturate di calibrazione della delega in cui i partecipanti analizzano ex post le proprie decisioni di accettazione o rifiuto dell'output AI, confrontandole con criteri espliciti di rischio producono nel breve periodo cambiamenti osservabili nei comportamenti di verifica: aumenta la frequenza del controllo sui task ad alta consequenzialità, e soprattutto emerge una consapevolezza dichiarata della propria tendenza alla surrender che prima era del tutto assente. Sono osservazioni aneddotiche, non dati sperimentali, ma suggeriscono che il fenomeno non è impermeabile all'intervento formativo. Il fatto che l'intuizione non basti non significa che la competenza non sia sviluppabile con interventi mirati (così come il fatto che le persone siano spontaneamente soggette a bias cognitivi non significa che il *debiasing* sia impossibile), ma solo che richiede tecniche specifiche e pratica deliberata [5, 8]. La questione, in ultima analisi, è empirica: la resa cognitiva qualificata può essere insegnata? A che costo? Con quale efficacia? Non ho la risposta, ma la domanda mi sembra importante.

Fatta questa premessa, la resa cognitiva qualificata si articola, nella mia visione, su tre capacità interconnesse.




Figura 2: Le fasi della deriva cognitiva

La prima è il **trriage cognitivo**: la capacità di valutare, per ogni compito specifico, il rapporto tra il costo della verifica indipendente e il rischio associato all'accettazione acritica dell'output AI. Non tutte le decisioni meritano lo stesso livello di scrutinio: una bozza di e-mail routinaria e un'analisi finanziaria che può supportare la decisione di procedere ad un investimento richiedono approcci radicalmente diversi alla delega. Questa osservazione è banale quando la si enuncia, ma la ricerca dimostra che nella pratica le persone non la applicano sistematicamente. Per renderla operativa, servirebbero tassonomie esplicite, condivise e periodicamente aggiornate, dei livelli di

rischio associati ai diversi tipi di compito assistito da AI (qualcosa che oggi non esiste in nessuna organizzazione che io conosca e che non è ancora previsto in alcun modello di A(I)Doption per quanto sofisticato come il mio).

La seconda capacità è il **monitoraggio della deriva**: la consapevolezza riflessiva della propria posizione lungo le fasi del modello descritto sopra, e la capacità di riconoscere i segnali di scivolamento dall'offloading strategico alla surrender acritica. Gli indicatori osservabili che ho proposto per ciascuna fase del modello potrebbero servire come base per strumenti di auto-valutazione tenendo sempre presente un caveat importante: il monitoraggio della propria deriva cognitiva è esso stesso un compito metacognitivo soggetto ai medesimi bias che si cerca di monitorare. Per questo motivo, probabilmente non può funzionare solo come pratica individuale: richiede meccanismi esterni (peer review e metriche organizzative) che forniscano feedback indipendente.

La terza capacità è l'**override deliberato**: la pratica intenzionale di completare periodicamente compiti senza assistenza AI, non per luddismo ma per mantenere attive le competenze cognitive che l'AI rischia di atrofizzare. L'analogia con l'allenamento fisico è immediata ma ha un limite importante che va riconosciuto: nell'allenamento fisico esistono metriche oggettive di forma (VO2max, tempi, carichi, ...), mentre nella cognizione professionale la misurazione dell'atrofia è molto più sfuggente. Come si misura se un analista sta perdendo la capacità di leggere un bilancio senza assistenza AI? Come si misura se un ingegnere sta perdendo la capacità di fare debug di codice senza copilot? Queste non sono domande retoriche: sono problemi di misurazione che qualsiasi implementazione seria dell'override deliberato dovrebbe affrontare, probabilmente attraverso prove periodiche strutturate il cui design è tutt'altro che banale.

5 Implicazioni e domande aperte

Penso che il merito del quadro disegnato (che ribadisco, è un'ipotesi, non un fatto) sia identificare che le implicazioni si distribuiscono su tre livelli.

A livello individuale, la questione centrale è lo sviluppo della consapevolezza metacognitiva sulla propria relazione con l'AI. Non si tratta di demonizzare lo strumento, ma di sviluppare quello che potremmo chiamare un'"igiene cognitiva" dell'era AI: sapere dove ci si trova nel continuum tra augmentation e dipendenza, avere strategie per mantenere l'autonomia cognitiva dove conta, e accettare la delega dove è razionale. Il fatto che i partecipanti agli esperimenti di Shaw e Nave non riescano a farlo spontaneamente nemmeno sotto incentivi economici ci dice che l'informazione da sola non basta: servono formazione deliberata e strutture di supporto.

A livello organizzativo, l'implicazione più importante riguarda il design dei programmi di adozione AI. La maggior parte delle organizzazioni che conosco approccia al tema dell'adozione dell'AI esclusivamente in termini di efficienza operativa: quante ore risparmiamo automatizzando e quanto output in più produciamo. Il quadro che emerge suggerisce che questa è una visione pericolosamente parziale. L'adozione va progettata anche in termini cognitivi: quali competenze rischiamo di atrofizzare? Quali decisioni non dovrebbero mai essere delegate senza supervisione?

L'AI practice di Ranganathan e Ye è un punto di partenza, ma necessita di una fondazione cognitiva: non basta governare i processi, bisogna governare la relazione tra le persone e lo strumento (o meglio la varietà degli strumenti che si stanno affollando).

A livello di policy e formazione, la questione è ancora più ampia. Se la cognitive surrender è un fenomeno robusto e resistente agli incentivi, allora i manifesti basati sulla semplice informazione “sappi che l'AI può sbagliare” sono probabilmente insufficienti, esattamente come i cartelli “attenzione” non bastano a prevenire l'automation bias in contesti critici. Servono programmi che includano pratica deliberata del triage cognitivo, esercitazioni periodiche senza assistenza AI, e feedback strutturato sulla qualità delle decisioni prese con e senza AI. In ambito accademico, dove insegno, questo significa ripensare non solo cosa si insegna sull'AI, ma anche e soprattutto come si insegna con l'AI.

Il modello e i concetti che ho proposto generano, infine, alcune domande (di ricerca) che vorrei trovare il modo di affrontare con una indagine sistematica. La sequenza delle fasi della deriva cognitiva è invariante o dipende dal dominio professionale, dal livello di expertise, dal tipo di AI utilizzata? Esistono “fattori protettivi” individuali o organizzativi che rallentano o arrestano la deriva? L'override deliberato produce effettivamente effetti misurabili sul mantenimento delle competenze, e se sì, con quale frequenza e intensità deve essere praticato? La resa cognitiva qualificata può essere insegnata con efficacia misurabile, e quali metodologie formative sono più efficaci? Quanto tempo ci vuole, in condizioni tipiche, per attraversare le fasi del modello? La risposta a queste domande richiede studi longitudinali con protocolli di osservazione strutturati, misurazioni ripetute delle competenze, e probabilmente disegni sperimentali con gruppi di controllo. Ambizioso, per me irrealizzabile ma, credo, necessario.

6 Conclusione

Torno alla domanda di apertura: cosa sta succedendo dentro la testa di chi usa l'AI? La risposta che emerge dalla lettura integrata dei tre contributi e dalla speculazione che ho costruito sopra è che sta succedendo qualcosa di più profondo e più sistematico di quanto la narrazione corrente suggerisca. Il paradosso che ho cercato di articolare è quello di un ciclo che si autoalimenta tra efficienza percepita, erosione cognitiva e intensificazione organizzativa. La buona notizia è che la traiettoria non è inevitabile: la biforcazione della quinta fase del modello esiste come possibilità reale, non solo come auspicio. Ma realizzarla richiede che individui, organizzazioni e istituzioni formative riconoscano il fenomeno per quello che è e decidano di governarlo, anziché lasciare che si governi da solo. Se il mio modello a fasi si rivelerà sbagliato nei dettagli, tanto meglio: significherà che qualcuno ha fatto la ricerca necessaria a confutarlo, e avremo imparato qualcosa. Se il concetto di resa cognitiva qualificata si rivelerà ingenuo, avremo almeno un nome per ciò che ci manca. In un campo che si muove alla velocità dell'AI, sbagliare in modo utile è un contributo che sono orgoglioso di poter di dare.

Bibliografia

Riferimenti bibliografici

- [1] Bainbridge, L. (1983). Ironies of automation. *Automatica*, 19(6), 775-779.
- [2] Chiriatti, M. et al. (2025). System 0: the role of AI as a cognitive pre-processor in decision-making. Working paper.
- [3] Cummings, M. L. (2004). Automation bias in intelligent time critical decision support systems. *AIAA 1st Intelligent Systems Technical Conference*.
- [4] Ebbatson, M., Harris, D., Huddleston, J., & Sears, R. (2010). The relationship between manual handling performance and recent flying experience in air transport pilots. *Ergonomics*, 53(2), 268-281.
- [5] Fischhoff, B. (1982). Debiasing. In D. Kahneman, P. Slovic, & A. Tversky (Eds.), *Judgment Under Uncertainty: Heuristics and Biases* (pp. 422-444). Cambridge University Press.
- [6] Goddard, K., Roudsari, A., & Wyatt, J. C. (2012). Automation bias: a systematic review of frequency, effect mediators, and mitigators. *Journal of the American Medical Informatics Association*, 19(1), 121-127.
- .
- [7] Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux
- [8] Larriek, R. P. (2004). Debiasing. In D. J. Koehler & N. Harvey (Eds.), *Blackwell Handbook of Judgment and Decision Making* (pp. 316-338). Blackwell Publishing.
- g.
- [9] Mollick, E. (2024). *Co-Intelligence: Living and Working with AI*. Portfolio/Penguin.
- [10] Monsell, S. (2003). Task switching. *Trends in Cognitive Sciences*, 7(3), 134-14
- [11] Parasuraman, R., & Manzey, D. (2010). Complacency and bias in human use of automation: an attentional integration. *Human Factors*, 52(3), 381-410.
- 10.
- [12] Parasuraman, R., Riley, V. (1997). Humans and automation: use, misuse, disuse, abuse. *Human Factors*, 39(2), 230-253.
- [13] Ranganathan, A., Ye, J. (2026). Research: AI May Not Make You More Productive. *Harvard Business Review*, febbraio 2026.
- [14] Riva, G. (2024). The comfort-growth paradox in AI-assisted cognition. *Cyberpsychology, Behavior, and Social Networking*.

- [15] Shaw, A., Nave, G. (2025). A Tri-System Theory of Human-AI Cognition: The Case of Cognitive Surrender. The Wharton School, University of Pennsylvania.