

Il paradosso dell'AI Literacy:

La conoscenza tecnica ostacola la consapevolezza metacognitiva?

Riccardo Bovetti

[LinkedIn](#) | [All you need is thought](#)

11 gennaio 2026

Indice

1	Introduzione al paradosso e alle sue radici linguistico-concettuali	3
2	La banalità dell'uso effettivo: quando la competenza tecnica incontra la poca significatività applicativa	4
3	Manifestazioni sistemiche del paradosso: evidenze dai contesti organizzativi	6
4	Il paradosso organizzativo: overconfidence sistemica e la crisi dell'ontologia delle competenza	7
5	L'amplificazione del paradosso attraverso l'engagement differenziale	8
6	Implicazioni per interventi educativi e organizzativi: oltre la literacy tecnica verso la consapevolezza metacognitiva	8
7	Conclusioni: verso una maturità epistemica nell'era dell'AI generativa (forse)	10
	Riferimenti bibliografici	11

1 Introduzione al paradosso e alle sue radici linguistico-concettuali

Era inevitabile che il cortocircuito, prima o poi, si verificasse. Era, statisticamente, solo questione di tempo.

Da quando è iniziata la “corsa all’oro” dell’adozione della AI in azienda (metafora che mi sembra rappresentare bene la situazione che stiamo vivendo: masse di persone che a fatica sanno distinguere la pirite dal rame ma che diventano esperte di ingegneria dei materiali “overnight”, attratte da faraoniche promesse a discapito di rischi e difficoltà della “ricerca”, reali benefici che stentano ad arrivare per tutti tranne che per chi vende pale, picconi e setacci) uno dei pochi capisaldi che mi sono sempre, in modo intellettualmente onesto, sentito di poter garantire come non solo utile ma necessario è stato quello della formazione.

Rendere le persone consapevoli di costi e benefici e dotarle di qualche “malizia” di base per poter quanto meno “gestire” se non comprendere gli strumenti che stavano entusiasticamente usando mi è sembrato sempre un imperativo morale più che un esercizio di business.

Mosso dalla convinzione dell’educatore che tra saperne e non saperne è sempre meglio la prima mi sono imbarcato in questa battaglia contro i mulini a vento che è convincere i decisori aziendali che, se per guidare una macchina serve una patente che si consegue con corsi di settimane di teoria e pratica, per poter evitare di fare danni con uno strumento costruito ad arte per convincerci con la plausibilità di una perfetta sintassi senza semantica, servissero almeno un paio di giornate di teoria e di pratica.

E siccome credo che la coerenza sia il valore più prezioso per chi fa un mestiere basato sulla fiducia, mi sono poi reso attore in prima persona del percorso formativo per, a contarli tutti, diverse centinaia di “studenti aziendali” con i quali ho avuto la possibilità di lavorare.

Anche al fine di poter portare, in questi scambi professionali, quanto più valore aggiunto possibile derivante anche dalle mie attività di ricerca accademica, mi sono poi lanciato in questo incessante percorso di lettura critica e differenziale dell’immenso volume di paper, ricerche, studi e saggi (equamente divisi tra autorevoli e seri e fuffa galattica) che mi ha portato nelle ultime settimane a questo cortocircuito ed ad una domanda alla quale ho sentito l’urgenza di provare a darmi una risposta: ma non è che, a differenza delle discipline (termine sovraesteso per indicare dalle tecnologie alle teorie) che hanno una dinamica di relazione tendenzialmente monodirezionale (ovverosia qualcuno capisce qualcosa rispetto ad un “fenomeno”, lo spiega, lo comprendo, lo assimilo, lo interiorizzo, lo uso) nelle quali lo studio è preconditione per lo sviluppo della consapevolezza metacognitiva, con queste discipline (sovraesteso nuovamente quanto “fenomeno”) che instaurano una relazione non monodirezionale (dire bi-direzionale mi pareva al tempo stesso troppo e troppo poco) funziona diversamente, persino al contrario?

Mi sono imbattuto, infatti, durante le mie ricerche, in un paper che riporta i risultati di uno studio empirico condotto da Fernandes e altri [3] che ha rivelato un fenomeno controintuitivo che sfida le assunzioni tradizionali sulla relazione tra competenza tecnica e capacità di autovalutazione: con specifico riferimento al tema dell’AI Generativa gli individui con maggiore AI literacy

dimostrano una minore accuratezza metacognitiva quando utilizzano sistemi di intelligenza artificiale generativa per compiti cognitivi complessi.

Questo paradosso si manifesta attraverso una dissociazione critica tra la confidenza percepita (che risulta significativamente aumentata) e la capacità effettiva non tanto di eseguire con efficienza, quanto di monitorare l'accuratezza delle proprie prestazioni (che invece risulta invariata o addirittura peggiorata).

Il paradosso risulta particolarmente pronunciato nella dimensione della comprensione tecnica, ovvero nella familiarità con aspetti procedurali quali il prompting (ma anche la configurazione di parametri e l'utilizzo di API), elementi che costituiscono il nucleo operativo dell'interazione con i modelli linguistici di grandi dimensioni.

Per provare a capirci di più ho cercato di condurre un'analisi che andasse oltre i soli meccanismi psicologici individuali, mettendo in qualche modo in discussione le fondamenta epistemologiche e linguistiche su cui si è costruito il discorso contemporaneo sull'intelligenza artificiale.

Come documentato da Floridi e Nobre [4] nel loro studio sul “prestito concettuale” (conceptual borrowing) (studio i cui elementi sono peraltro ripresi ed espansi nell'ultimo lavoro di Floridi [5]) tra l'Intelligenza Artificiale e le Scienze Cognitive, esiste un cortocircuito linguistico sistemico che precede e alimenta i fenomeni di confusione metacognitiva osservati negli utilizzatori variamente esperti di sistemi AI.

Questo cortocircuito si manifesta in una doppia direzione: da un lato, l'AI ha progressivamente adottato un vocabolario antropomorfo che attribuisce ai sistemi computazionali proprietà cognitive tipicamente umane (attenzione, apprendimento, memoria, ragionamento, comprensione), dall'altro, le neuroscienze cognitive hanno adottato un vocabolario derivato dalla teoria dell'informazione e dalle scienze computazionali per descrivere il cervello e la mente (encoding, processing, storage, retrieval, decoding).

Questa reciproca appropriazione linguistica non è meramente metaforica ma bensì sistemica e genera confusione concettuale con conseguenze pratiche significative, particolarmente evidenti proprio nel contesto dell'AI literacy e delle sue manifestazioni paradossali.

2 La banalità dell'uso effettivo: quando la competenza tecnica incontra la poca significatività applicativa

Mentre mi addentravo nell'approfondimento delle manifestazioni sistemiche del paradosso nei contesti organizzativi, sono inciampato in un altro dato empirico che amplifica drammaticamente le implicazioni del fenomeno studiato da Fernandes.

Analisi condotte su oltre un miliardo di messaggi inviati a ChatGPT tra maggio 2024 e giugno 2025 [1] rivelano un pattern tanto sorprendente quanto inquietante quando giustapposto al paradosso dell'AI literacy: l'utilizzo effettivo degli strumenti di AI generativa si concentra (va, ma mi sento di dire ancora), in larghissima parte, su applicazioni di basso valore cognitivo e limitata consequenzialità (intesa come generatrici di conseguenze o risultati) e tre categorie di casi d'uso

più frequenti (Practical Guidance, Writing, e Seeking Information) includono prevalentemente attività quali editing di testi forniti dall'utente, consigli generici su argomenti vari, ricerca di informazioni fattuali (abitudine peraltro deprecabile in presenza di una reale literacy sul modello di funzionamento della AIGen), e modifiche superficiali di contenuti esistenti.

Una significativa maggioranza delle conversazioni di Writing non riguardano la creazione di contenuto nuovo, ma piuttosto la modifica, critica, traduzione o riformulazione di testo già prodotto dall'utente (nel bene e nel male).

Questi pattern di utilizzo evidenziano un paradosso nel paradosso: se la statistica non è una opinione, anche gli individui con elevata AI literacy tecnica, che manifestano quindi maggiore confidenza nelle proprie capacità ma ridotta accuratezza metacognitiva quando utilizzano AI per compiti cognitivi complessi, impiegano comunque largamente questi strumenti per operazioni elementari che richiedono valutazione critica minima.

La dissociazione è profonda e sistemica. Da un lato, esistono individui che possiedono competenze tecniche nel prompting, nella configurazione di parametri, nell'utilizzo di API, nell'understanding del funzionamento dei transformer e dei meccanismi di attention, elementi che costituiscono il nucleo dell'AI literacy nella sua dimensione procedurale.

Dall'altro, anche questi stessi individui, almeno in quota parte, utilizzano tali competenze prevalentemente per task banali e solo una frazione estremamente ridotta (e quindi poco significativa in termini statistici) dei messaggi riguarda compiti sofisticati come programmazione informatica, ragionamenti matematici o analisi di dati, tutti ambiti dove la valutazione critica degli output richiede effettivamente expertise sostanziale e dove i rischi associati a errori non rilevati sono potenzialmente significativi.

La situazione diventa ulteriormente problematica quando si considera che questa configurazione di utilizzo (alta competenza tecnica applicata a task banali) potrebbe paradossalmente rafforzare piuttosto che mitigare i deficit metacognitivi ipotizzati ed empiricamente “dimostrati” dalla ricerca.

L'utilizzo ripetuto dell'AI per compiti a bassa consequenzialità crea condizioni ideali per lo sviluppo di quella che potremmo definire come una “metacognizione abitudinaria degradata”: gli utenti sviluppano routine di interazione fluide che generano output frequentemente adeguati (plausibili?) quando riferiti a task semplici, rafforzando la confidenza globale nelle proprie capacità di utilizzo dell'AI, senza però sviluppare le competenze di monitoraggio critico necessarie per task realmente complessi (ed alimentando peraltro anche quella causa di entropia che è la banalità concettuale).

Quando questi stessi utenti si trovano poi a utilizzare l'AI per task più complesse o potenzialmente “rischiose”, si comportano con una (over) confidenza calibrata su esperienze di successo in contesti banali applicandola acriticamente a situazioni che richiederebbero un livello significativamente superiore di vigilanza metacognitiva.

I dati di adozione organizzativa provenienti dal Wharton AI Adoption Report [2] completano questo quadro critico con evidenze complementari.

Quasi la metà dei leader aziendali utilizza AI generativa quotidianamente (con un incremento significativo rispetto all'anno precedente) e la stragrande maggioranza la impiega almeno settimanalmente, ma gli use case dominanti rimangono concentrati in aree di produttività individuale-procedurale che ricadono, nuovamente, nell'ambito di uso prevalente su menzionati.

Pertanto, il “modo d'uso prevalente” si estende oltre alla pratica personale ed “invade” anche i contesti lavorativi dove le conseguenze di errori sottovalutati (quando, finalmente, utilizzati per task più significativi) potrebbero essere sostanziali.

Emerge quindi una configurazione particolarmente insidiosa: individui (nell'uso diciamo personale) ed organizzazioni (intendendo gli individui che utilizzano l'AI in contesti professionali) sviluppano fluency tecnica e confidenza nell'uso dell'AI attraverso applicazioni prevalentemente banali, consolidando pattern di interazione che minimizzano il monitoraggio critico, per poi estendere (acriticamente?) questi stessi pattern (e la confidenza associata) a domini dove l'assenza di accuratezza metacognitiva può generare conseguenze significative.

Il paradosso dell'AI literacy evidenzia quindi vulnerabilità cognitiva individuale in situazioni isolate che diventa poi pattern sistemico rinforzato dalla struttura stessa dell'adozione tecnologica: la porta di ingresso all'AI generativa passa attraverso use case banali che mascherano la necessità di sviluppo di competenze metacognitive, creando una falsa sensazione di padronanza che viene poi trasferita inappropriatamente a contesti non privi di conseguenze.

3 Manifestazioni sistemiche del paradosso: evidenze dai contesti organizzativi

Mentre la ricerca di Fernandes e colleghi ha documentato il paradosso dell'AI literacy a livello di processi cognitivi individuali, e l'analisi degli use case effettivi ha rivelato la banalità prevalente delle applicazioni aziendali concrete, dati provenienti da indagini su larga scala condotte da uno dei player globali del recruiting su diverse migliaia di lavoratori e leader organizzativi in ventiquattro mercati globali rivelano sempre maggiormente che il fenomeno non è confinato alla dimensione psicologica individuale, ma si manifesta come vulnerabilità sistemica a livello organizzativo e sociale.

Il dato più interessante, a mio giudizio, di questo altro campo di indagine riguarda la dissociazione tra auto-percezione delle competenze AI e la (quantità e qualità) di formazione effettivamente ricevuta: mentre una parte considerevole dei lavoratori dichiara di credere che le competenze AI miglioreranno le proprie prospettive di carriera e promozione, solo una minoranza molto esigua riporta di aver ricevuto qualsiasi forma di training AI nell'ultimo anno.

Questa discrepanza drammatica tra aspettative e preparazione effettiva non è semplicemente una questione di domanda insoddisfatta di formazione, ma rappresenta una manifestazione del paradosso stesso a livello collettivo.

Gli individui esprimono confidenza nelle proprie capacità di navigare un futuro lavorativo dominato dall'AI nonostante l'assenza di preparazione formale, suggerendo che l'over-confidence

documentata a livello individuale (perchè in questo caso individuale e basata sull'esperienza d'uso "inconsapevole" è la fonte della literacy) da Fernandes e colleghi si replica a scala macro-sociale.

La padronanza superficiale nell'uso di strumenti AI consumer viene evidentemente confusa con una competenza genuina che prepara efficacemente per l'integrazione professionale dell'AI, esattamente come previsto dal meccanismo dell'illusione della profondità esplicativa operante a livello individuale.

La natura sistemica del paradosso emerge con particolare chiarezza quando si considera la distribuzione differenziale delle opportunità di formazione e della confidenza auto-riportata attraverso diverse distribuzioni demografiche: qui i bias metacognitivi e di self confidence sono assolutamente replica distributiva di quanto abbiamo già visto negli ultimi 20 anni in termini di gender e generazioni (overconfidenza maschile, maggiore resistenza nelle generazioni BabyBoomer rispetto alle GenZ e via discorrendo).

4 Il paradosso organizzativo: overconfidence sistemica e la crisi dell'ontologia delle competenza

Volendo estendere le considerazioni dal livello individuale a quello delle decisioni organizzative, vediamo il caratterizzarsi di una forma di sovraconfidenza sistemica che replica, a livello macro, i meccanismi di deficit metacognitivo osservati a livello individuale (a riprova dell'adagio che le aziende, alla fine, sono fatte di persone).

Una percentuale schiacciante dei leader aziendali concorda che l'adozione di tecnologie AI ha migliorato l'attrazione, l'engagement e la retention dei talenti ed esprime entusiasmo circa la proliferazione di AI, automazione e robotica nell'ambiente lavorativo.

Tuttavia, solo una minoranza molto limitata delle organizzazioni riporta di aver costruito una mappatura sistematica e strutturata (una ontologia, in pratica) delle competenze attese, trasformate e trasformande.

Le organizzazioni sembrano operare sotto l'assunzione implicita che l'adozione di tecnologie AI sarà automaticamente benefica e trasformativa, intendendo con adozione l'acquisto di una manciata di licenze del chatbot ritenuto più adeguato accompagnata (neanche sempre) da una spolverata di formazione (a volte anche solo asincrona con qualche video con la profondità di un TikTok), senza riconoscere che la realizzazione effettiva di questi benefici richiede una comprensione profonda e strutturata di quali competenze specifiche siano necessarie, come queste competenze si relazionino alle tecnologie AI, e come debbano essere sistematicamente identificate, sviluppate e validate.

La costruzione di una skills ontology non è semplicemente una "nice to have" da amministrazione del personale, ma rappresenta l'infrastruttura epistemologica che permette a un'organizzazione di avere consapevolezza metacognitiva delle proprie capacità effettive rispetto all'AI, esattamente come la calibrazione metacognitiva permette agli individui di riconoscere accuratamente i propri limiti e lacune: una sorta di "immunità di gregge" al qualunquismo da AI a tutti i costi.

Un’organizzazione che proclama trasformazione AI-driven senza costruire una skills ontology è l’equivalente sistemico di un individuo con elevata AI literacy tecnica ma bassa accuratezza metacognitiva: operativamente efficiente ma epistemicamente confuso circa la natura e i limiti delle proprie capacità.

5 L’amplificazione del paradosso attraverso l’engagement differenziale

Un ulteriore livello di complessità mi pare emergere dalla considerazione del paradosso dell’AI literacy in pattern di engagement differenziale con tecnologie AI.

Le ricerche empiriche identificano significative disparità nell’utilizzo dell’AI tra diverse categorie di lavoratori. I knowledge workers utilizzano l’AI con frequenza significativamente maggiore rispetto ai frontline workers. Similarmente, i lavoratori con educazione universitaria o post-universitaria utilizzano l’AI per attività lavorative con frequenza molto superiore rispetto ai lavoratori con solo educazione secondaria.

Questi pattern suggeriscono che l’esposizione all’AI, e quindi la probabilità di sviluppare sia fluency tecnica che potenziali deficit metacognitivi, possa essere distribuita in modo fortemente diseguale attraverso la forza lavoro, con implicazioni significative per l’equità e l’inclusione nell’era dell’AI.

Particolarmente preoccupante è il fenomeno dell’utilizzo “shadow” dell’AI che solleva questioni critiche circa la governance, la responsabilità e il rischio organizzativo.

Se gli individui con maggiore AI literacy tecnica sono anche quelli più vulnerabili a deficit metacognitivi, allora un ampio utilizzo non supervisionato di AI da parte di knowledge workers tecnicamente competenti ma potenzialmente overconfident rappresenta un rischio sistemico significativo.

Sembra un tema da social media, ma il timore della sostituzione è presente (anche perché mainstream come messaggio) e quindi la FOMO (fear of missing out) potrebbe generare esiti paradossali.

Da un lato esiste ed è presente (culturalmente nelle nostre aziende italiane forse più che altrove) la “AI shame” che porta a negare l’utilizzo anche palese. Dall’altro invece potrebbe creare incentivi perversi alla overconfidence: i lavoratori potrebbero essere motivati a proiettare sicurezza e competenza nell’uso dell’AI anche quando la loro comprensione effettiva fosse superficiale, per evitare di apparire obsoleti o inadeguati.

6 Implicazioni per interventi educativi e organizzativi: oltre la literacy tecnica verso la consapevolezza metacognitiva

E quindi, come prima parziale risposta alla mia fastidiosa domanda, posso iniziare a dire che gli approcci tradizionali alla formazione AI potrebbero essere non solo insufficienti, ma

potenzialmente controproducenti se non accompagnati da interventi esplicitamente mirati alla calibrazione metacognitiva e alla consapevolezza critica del vocabolario tecnico.

Lo stimolo che desumo e che andrò ad implementare nei miei modelli educativi sul tema è quello di incorporare esplicitamente tre componenti:

- Primo, formazione metacognitiva esplicita che insegni a discenti non solo come usare l'AI ma anche come monitorare e valutare criticamente la qualità dei propri processi di utilizzo e degli output generati. Questo attraverso pratiche strutturate di self ed etero explanation, prompts di riflessione metacognitiva integrati nei workflow, ed esercizi di calibrazione che aiutino gli individui a sviluppare una comprensione più accurata dei propri limiti e delle situazioni in cui è necessaria verifica esterna o terza.
- Secondo, formazione linguistico-critica che renda gli studenti consapevoli del vocabolario antropomorfo che permea il campo dell'AI e delle confusioni concettuali che questo vocabolario può generare. Chi partecipa ad un training sull'AI dovrebbe essere esplicitamente istruito sulla differenza tra uso computazionale e uso cognitivo-umano di termini come “attenzione”, “comprensione”, “ragionamento”, sviluppare l'abitudine di disambiguare sistematicamente tra questi sensi quando discutono di capacità AI.
- Terzo, formazione orientata alla validazione che insegni competenze pratiche di verifica, testing, e quality assurance appropriate per diversi tipi di output AI e contesti applicativi.

A livello organizzativo, le implicazioni del paradosso rafforza ancora maggiormente la necessità di ripensare fundamentalmente come le organizzazioni governano, monitorano e supportano l'utilizzo dell'AI da parte dei propri lavoratori.

Esiste un bisogno urgente di creare ambienti in cui l'uso dell'AI possa essere trasparente, supportato e appropriatamente supervisionato senza creare incentivi ad un uso “shadow”. Questo richiede un equilibrio delicato: da un lato, le organizzazioni devono implementare meccanismi di oversight che prevengano utilizzi rischiosi o disfunzionali dell'AI, dall'altro, devono evitare politiche troppo restrittive e tali da spingere l'utilizzo ancora più in ombra.

Stante che la psicodinamica cognitiva ci ha insegnato da anni che gli adulti consenzienti apprendono solo tramite il confronto tra peer, l'unico approccio possibile penso sia lo sviluppo di “AI champions” a livello organizzativo.

Individui con formazione specializzata non solo nell'uso tecnico dell'AI ma anche nei principi di calibrazione metacognitiva, validazione critica e consapevolezza linguistica. Questi champions devono fornire consulenza a richiesta ai colleghi che utilizzano AI per task rilevanti in termini di impatto, aiutandoli a identificare situazioni ad alto rischio dove la verifica esterna è essenziale, suggerendo strategie di validazione appropriate, e facilitando la riflessione critica sui propri processi di utilizzo.

Parallelamente, le organizzazioni potrebbero implementare “infrastrutture metacognitive” nei propri “Portali AI interni” (strumenti sempre più diffusi per raccogliere e condividere la conoscenza interna e le best practice locali) e nei workflow digitali, incorporando prompts strutturati che

incoraggino gli utenti a riflettere criticamente sulla qualità e affidabilità degli output AI prima di prendere decisioni basate su di essi.

7 Conclusioni: verso una maturità epistemica nell'era dell'AI generativa (forse)

Siamo nel mezzo di una transizione epistemologica (spinta dell'intelligenza artificiale generativa) caratterizzata da una tensione fondamentale tra la rapidità con cui evolviamo nella nostra capacità tecnica di creare e utilizzare sistemi sempre più sofisticati e la lentezza con cui la nostra (personale ed organizzativa) comprensione concettuale, epistemologica e metacognitiva si adatta a questa nuova realtà tecnologica.

Stiamo vivendo un momento storico in cui i confini tra cognizione umana e computazione artificiale stanno diventando progressivamente sfumati nel senso fenomenologico e linguistico dell'esperienza quotidiana di interazione con questi sistemi, anche se le differenze ontologiche rimangono profonde, e questa sfumatura crea condizioni ideali per confusione che possono avere conseguenze pratiche significative.

Solo attraverso uno sforzo coordinato e multidisciplinare che affronti esplicitamente questa transizione epistemologica nelle sue dimensioni cognitive, linguistiche, sociali, organizzative e tecnologiche e rifuggendo alle banalizzazioni marketing della “tecnologia a scaffale” sarà possibile trasformare una (empiricamente dimostrata) vulnerabilità in opportunità per lo sviluppo di forme mature, riflessive e criticamente informate di expertise umana nell'era dell'intelligenza artificiale generativa.

Riferimenti bibliografici

- [1] Handa, P., Brynjolfsson, E., Zhao, R., & Sharma, A. (2025). *How people use ChatGPT: Patterns, tasks, and implications*. OpenAI Working Paper Series.
- [2] Wharton Human-AI Research & GBK Collective. (2025). *Accountable acceleration: Gen AI fast-tracks into the enterprise*. Wharton AI Adoption Report 2025. University of Pennsylvania.
- [3] Fernandes, S., et al. (2025). *The AI literacy paradox: Technical knowledge and metacognitive accuracy in generative AI use*. Journal of Cognitive Science.
- [4] Floridi, L., & Nobre, A. C. (2024). *Anthropomorphising machines and computerising minds: The crosswiring of languages between Artificial Intelligence and Brain & Cognitive Sciences*. Centre for Digital Ethics (CEDE).
- [5] Floridi, L. (2025). *La differenza fondamentale*. Mondadori.