

Complessità e Sistemi di Senso

Riccardo Bovetti

Who am I? | [LinkedIn](#) | [All you need is thought](#)

Marzo 2026/Giugno 2026

Indice

I	Le coordinate	5
1	From God to Google (passando per Goodenough): genealogia del principio di autorità nell'era digitale	7
1.1	Mappa infografica del capitolo	8
1.2	Come definire il principio di autorità?	8
1.3	Prima fase: il Verbo e i suoi intermediari	9
1.4	Seconda fase: la razionalità come nuovo assoluto	10
1.5	Terza fase: Dal Se(lf) al Se(lfie), l'autorità dell'io ipertrofico	11
1.6	Quarta fase: l'algoritmo come nuovo oracolo	12
1.7	La struttura ricorrente: cosa cambia e cosa resta	14
1.8	Cambiare le domande	14
2	Novità vs. innovazione: un primo tentativo di debunking all'hype dell'AI generalista	17
2.1	Mappa infografica del capitolo	18
2.2	Una confusione che viene da lontano	18
2.3	Il presente che conferma la diagnosi	19
2.4	La distinzione che conta	20
2.5	Due rivoluzioni, una direzione	21
3	ConcrEthica: la bussola etica che forse ancora non abbiamo	23
3.1	Mappa infografica del capitolo	24
3.2	Il quarto spintone: l'invenzione che decentra più della scoperta	24
3.3	Quando lo strumento smette di essere neutro	25
3.4	Leggi, governance, compliance, etica: insieme che si sfuggono e non si contengono	27
3.5	La catena del valore digitale come mappa delle questioni etiche	28
3.6	I cinque principi fondativi della Digital Ethics	31
3.7	ConcrEthica: la bussola dell'agire	33

II	Le rivoluzioni (quelle vere)	35
III	L'umano al centro (ma quale umano, e quale centro?)	37
IV	Governare la complessità	39
	Bibliografia	41

Parte I

Le coordinate

Capitolo 1

From God to Google (passando per Goodenough): genealogia del principio di autorità nell'era digitale

Sono sempre stato affascinato dal potere delle connessioni e dalla possibilità che viene offerta, al prezzo accettabile di un po' di fatica per utilizzare metodi sufficientemente rigorosi, di costruire a posteriori correlazioni che spiegano (e in qualche misura giustificano) quasi qualsiasi evento, accadimento, stravolgimento o trasformazione (il famigerato “senno di poi”). E questa fascinazione mi porta, a volte, a chiedermi da un lato che cosa resterà, nella lettura a posteriori, di tutto il dibattito attorno alla *disruption* digitale che sta polarizzando l'attenzione di una gran parte della letteratura professionale (e che sembra avere date di scadenza più ravvicinate del latte fresco), dall'altro se non sia possibile (almeno provare ad) anticipare alcune delle letture tendenziali che necessariamente emergeranno come spiegazioni (a posteriori) di questo eccezionale periodo storico. Di sicuro il dibattito attorno alle *disruption*, e in particolare quella digitale, ha una caratteristica che lo distingue da quelli che lo hanno storicamente preceduto: i tempi tra l'avvenimento che ha generato la discontinuità, la narrazione del cambiamento e la previsione del futuro si sono accorciati notevolmente, sia in termini di reazione che di orizzonte temporale. Quando Copernico “spostò” la Terra dal centro del sistema solare, ci vollero generazioni prima che questa verità diventasse parte del senso comune. Quando la Scienza moderna sconfisse la malaria con il chinino, ci vollero decenni prima che il cambio di paradigma epistemologico fosse metabolizzato. Quando l'AI generativa ha reso improvvisamente capace qualsiasi utente di produrre testi, immagini e codice (con un grado di plausibilità tale da farli intendere per “veri”, qualsiasi cosa significhi) a partire da istruzioni in linguaggio naturale, il tempo trascorso tra l'evento (novembre 2022, il lancio su larga scala di ChatGPT 3.5 in quel fantastico esperimento sociale a fini meramente economici di cui avremo modo e tempo di parlare ampiamente) e la saturazione del dibattito è stato di qualche mese. La velocità stessa con cui si narrano le *disruption* è, essa stessa e se vogliamo essere romantici, una discontinuità. Questa è la ragione per la quale ho ritenuto utile, come primo passo di questa mia passeggiata in questi futuri e presenti giardini mentali, rileggere accadimenti passati, remoti e molto meno remoti, costruendovi attorno un qualcosa, dal punto di vista concettuale, che provasse a integrare etica, tecnologia e storia. Per farlo ho voluto concentrare l'attenzione su un concetto che attraversa tutta la storia

dell'umanità e che mi sembra illuminare il presente meglio di qualsiasi disamina tecnica delle caratteristiche dei modelli linguistici: il principio di autorità, ovvero la questione di chi o cosa, in una data epoca, detiene il diritto riconosciuto di fornire una risposta (in prima stesura avevo scritto rispondere, ma penso che l'atto possa essere disgiunto dal risultato) alle domande più importanti.

1.1 Mappa infografica del capitolo




Figura 1.1: Mappa logica del Capitolo 1

1.2 Come definire il principio di autorità?

Per principio di autorità intendo, con una certa libertà definitoria che mi concedo, quell'insieme di condizioni e di elementi che consentono a qualcuno o qualcosa di assumere un ruolo di predominio nelle attività di ricevere e accogliere le domande (per lo più di carattere etico, nel senso più ampio: chi sono, dove vado, perché), dispensare risposte e precetti, comminare giudizi e pene e guidare verso comportamenti e pensieri conformi. Questa definizione, volutamente operativa più che filosoficamente rigorosa, trova una corrispondenza precisa in una delle griglie analitiche più potenti della sociologia moderna, quella elaborata da Max Weber nelle sue riflessioni sui tipi di dominio legittimo [1]. Egli identificava tre forme di autorità:

- **Autorità tradizionale:** fondata sull'immutabilità di ciò che è sempre stato (il Re per grazia di Dio, il sacerdote per tradizione apostolica);

- **Autorità carismatica:** fondata sul riconoscimento di qualità straordinarie in un individuo (il profeta, il condottiero, il capo di stato (sic!) o il fondatore di startup con la visione rivoluzionaria);
- **Autorità razionale-legale:** fondata su regole impersonali e procedure codificate (il funzionario statale, il tecnico esperto, la norma giuridica).

La storia con la quale iniziamo il nostro viaggio è, in buona sostanza, la storia del progressivo spostamento tra queste tre forme storiche, con l'elemento di disturbo aggiuntivo costituito da un quarto tipo che Weber non aveva potuto anticipare: quello che potremmo chiamare autorità algoritmica, fondata su correlazioni statistiche tra dati in quantità tale da rendere strutturalmente opaco il processo che conduce al risultato.

Utile strabismo interpretativo penso sia anche il contributo di Michel Foucault con il suo concetto di “regime di verità” [2, 3]. Foucault osservava che ogni società ha un suo regime di verità, ovvero un insieme di meccanismi e istituzioni che consentono di distinguere le affermazioni vere da quelle false, e che attribuiscono un valore speciale (in quanto diversamente riconosciuto) alle prime rispetto alle seconde. Chi controlla questo meccanismo detiene un potere che non è semplicemente quello della forza, ma qualcosa di ancora più rilevante: il potere di definire cosa è reale, cosa conta, cosa merita di essere detto. In questa prospettiva, il principio di autorità non è solo una questione di gerarchia sociale, ma diventa pienamente una questione epistemologica... il passaggio dall'autorità della divinità all'autorità dell'algoritmo non è solo un cambiamento di chi comanda, è un cambiamento di cosa vuol dire sapere.

1.3 Prima fase: il Verbo e i suoi intermediari

“In principio era il Verbo [...] e il Verbo era Dio.” — (Giovanni, 1.1)

Si può dare per fatto storico, dove per storia si intende qualcosa di più della mera elencazione di accadimenti, ma l'accezione più ampia di storia dell'uomo, della cultura e del pensiero, che al principio di ogni narrazione ci sia la divinità. A prescindere da quale tradizione e da quale specifica cosmogonia si voglia considerare, il principio di autorità è stato, per gran parte della storia antica, attribuito a una dimensione trascendente. Un dio, o un pantheon di divinità, al quale ci si rivolgeva, per tramite di umanissime interfacce (intermediate o disintermediate a seconda dei casi e delle preferenze culturali), per porre domande, cercare spiegazioni e sperare in risposte, attivando, con curiosa similitudine con più recenti sistemi informatici ugualmente complessi, una serie di protocolli per fare interagire tra loro e con il richiedente una varietà di entità. Superstizione come antidoto alla mancanza di risposte: un sistema, in fondo in fondo, che è sempre stato efficientemente funzionale al suo scopo. Sulla scorta del principio di necessità hanno prosperato generazioni di sacerdoti, mistici, vestali e ogni altra sorta di umana interfaccia con la divinità, entità così assoluta e assolutamente distante da permettere la contemporanea autoassoluzione continua rispetto all'ignoranza e l'esercizio di un potere altrettanto assoluto e assolutamente concreto. Il punto cruciale, che Bruno Latour aveva intravisto con grande lucidità nei suoi lavori sulla mediazione [4, 5], è che ogni sistema di autorità funziona attraverso catene di mediatori che traducono l'inaccessibile in accessibile. La divinità non è un'eccezione, è il prototipo. Il sacerdote non comanda, nel senso ordinario del termine; egli traduce (con gradi di opacità che sono propri della tradizione culturale e sociale a cui ci si riferisce ed introducendo nella traduzione, come sempre, qualcosa che appartiene al traduttore). Questa architettura di sistema, con un'entità originaria di cui si conosce il risultato

ma non il meccanismo, con interfacce umane che mediano l'accesso, con protocolli rituali che codificano le modalità di interrogazione e di risposta, con un codice esoterico accessibile solo agli iniziati, ha una parentela strutturale molto stretta con quella di un certo tipo di intelligenza artificiale contemporanea. La divinità conservava gelosamente il suo sapere e lo dispensava solo in forme esoteriche. La convinzione che basti una “s” (un token in più, quindi) per trasformarla in forma essoterica nella nostra condizione presente è un errore concettuale sul quale torneremo. Sarebbe però sbagliato leggere questa prima fase come una semplice era di oscurantismo superata dalla ragione. La struttura dell'autorità teocratica aveva caratteristiche di efficienza che ancora oggi ricerchiamo primariamente: rispondeva al bisogno di certezza di fronte all'ignoto fornendo un sistema di valori condivisi che consentiva la coesione sociale e delegava a istituzioni riconoscibili il compito di gestire le domande esistenziali. Quello che rendeva questo sistema vulnerabile non era la sua irrazionalità, era la sua rigidità. Quando le domande sono cambiate, il sistema non era in grado di cambiare le risposte.

(Nota: uno spirito geneticamente illuminista e orientato al futuro con una malcelata speranza, più ancora che la necessità di rappresentare l'evoluzione delle fasi in una prospettiva temporale, mi ha spinto a coniugare al tempo passato le riflessioni sull'autorità teocratica. Purtroppo la correttezza del tempo verbale è data solo in alcune fortunate geografie e non in altre, nelle quali invece il tempo presente è ancora disperatamente quello proprio).

1.4 Seconda fase: la razionalità come nuovo assoluto

“Ultimo viene il corvo”, ma prima viene l'uomo — Italo Calvino, 1949

Il progresso della Scienza in tutte le sue forme (medicina, matematica, filosofia naturale, fisica, chimica) e l'aumento della sua diffusione per tramite delle invenzioni che hanno reso possibile la vera divulgazione, dalla stampa di Gutenberg in poi, costituiscono la prima grande discontinuità che ha assestato un colpo importante, anche se non definitivo, all'asse di equilibrio del principio di autorità. Il processo che Max Weber ha descritto con il termine *Entzauberung*, che si traduce solitamente come “disincantamento del mondo”, è esattamente questo: il progressivo declino delle spiegazioni magico-religiose dei fenomeni naturali e sociali, sostituite da spiegazioni causali che fanno riferimento a leggi, meccanismi, forze descrivibili e misurabili. D'un tratto, in un processo che ha richiesto anni, decenni e secoli, ma che per l'orizzonte temporale della storia costituisce comunque una discontinuità, si è affacciato sul palco dell'autorità un attore nuovo, in grado di dare, se non tutte, almeno alcune risposte nuove e alternative agli interrogativi che affliggevano l'umanità: la razionalità incarnata (per natura) nella specie umana. L'uomo collettivo, l'intelligenza e la razionalità espresse per tramite di quel bipede al (quasi) vertice della catena alimentare che, ponendosi le domande, è stato in grado di costruire una strada per trovarne anche le risposte. Questa capacità ha fatto fiorire quella fiducia quasi incrollabile nelle capacità umane che ha caratterizzato l'Umanesimo e poi, in forme più strutturate e istituzionalizzate, l'Illuminismo. Uomo inteso come entità espressione di intelligenza collettiva, ma con un riferimento al singolo che diventa sempre più marcato a mano a mano che si afferma, non in antitesi, ma in completamento dell'essere umano collettivo, l'“umano essere” individuale (quasi “essente” nella sua composita unicità). A partire dalla fine dei secoli “bui” è stato possibile iniziare, senza più imbarazzo, a fare domande alla Scienza e ascoltare le risposte dal Sé, e viceversa, abbandonando progressivamente quel

ricorso all'irrazionale per spiegare l'ignoto e sostituendolo con una fiducia crescente nella capacità umana di comprendere, misurare, prevedere (che, a giudicare dai fatti, sembra malriposta, ma questo è un altro tema).

È importante però notare ciò che questa transizione non ha fatto: non ha eliminato la struttura del principio di autorità, l'ha semplicemente spostata. L'autorità della Scienza non è meno assoluta, nelle sue forme consolidate, dell'autorità della religione, arrivando nelle sue manifestazioni a "sostituirla". Il rapporto con i suoi intermediari (scienziati, esperti, tecnici) replica strutturalmente il rapporto con i sacerdoti: la maggioranza della popolazione non ha accesso diretto ai meccanismi che producono la conoscenza scientifica e si fida dei risultati in forza dell'istituzione, non della comprensione diretta. Quello che Weber chiamava "autorità razionale-legale" non è razionale nel senso che chi la esercita sia sempre comprensibile a chi la riceve: è razionale nel senso che poggia su procedure codificate e astratte, non su tradizioni o carismi personali. La sequenza che Foucault chiamerebbe "regime di verità" si è semplicemente aggiornata: non più il testo sacro come criterio di verità, ma il metodo sperimentale, la peer review, la statistica. Chi controlla questi processi detiene il potere di definire cosa è reale. E la Scienza, come tutte le istituzioni, è stata storicamente controllata da attori specifici con interessi specifici (oggi molto semplificati nella loro decodifica: il denaro, punto), il che non ne invalida i risultati, ma dovrebbe rendere più cauta la nostra fede nella sua neutralità. È anche in questo contesto che va letto il decentramento progressivo dell'uomo descritto da Copernico, da Darwin e da Freud, i tre "spintoni cosmologici" che qualsiasi testo che voglia dirsi fondamentale del pensiero etico contemporaneo richiama come precedenti storici dell'AI. Ciascuno di questi spostamenti ha sottratto all'uomo una certezza sulla propria centralità (nel cosmo, nella catena del vivente, nella propria psiche), ma ognuno di essi ha paradossalmente rafforzato l'autorità della razionalità umana come unico strumento disponibile per indagare questa condizione. Anche quando la Scienza ci dice che non siamo al centro, lo fa attraverso un processo che è integralmente umano e umanamente scientifico.

1.5 Terza fase: Dal Se(lf) al Se(lfie), l'autorità dell'io ipertrofico

Il moto centripeto che aveva fatto rompere tangenzialmente le orbite dell'autorità dal divino all'umano ha subito un'ulteriore e inattesa accelerazione grazie, o a causa, di due delle *disruption* che hanno caratterizzato la fine del secolo scorso: le batterie agli ioni di litio (John Goodenough, 1980, Nobel per la Chimica nel 2019) e il Walkman della Sony (1979). Due invenzioni che oramai sembrano parte di una quotidianità storica e che invece hanno rimodellato molto più profondamente di altre la topologia dell'autorità. Per poter concentrare ulteriormente su di sé la referenza e l'autorità, l'uomo come essere collettivo aveva bisogno di strumenti che gli consentissero di affermarsi come essere individuale. Ovverosia di strumenti che gli consentissero di ignorare selettivamente (ovunque volesse) e consapevolmente (ogni qual volta ne avesse necessità) l'esistenza degli altri suoi simili e di poterlo fare per un tempo sufficientemente lungo perché gli altri si rassegnassero all'idea di essere ignorati. La combinazione di Walkman e batterie portatili ha reso possibile esattamente questo: uno spazio acustico privato in un contesto pubblico, la possibilità di abitare un mondo interiore mentre si è fisicamente presenti in quello esteriore. Lo sviluppo tecnologico successivo, dai videogiochi agli mp3 agli smartphone, che altro non sono se non sofisticate varianti sul tema del Walkman, ha ulteriormente focalizzato questo moto verso l'interiorità ipertrofica. E pertanto dal Se(lf) siamo arrivati al Se(lfie) come apoteosi di espressione solipsistica di un'autorità assoluta, assolutamente autoreferenziale, che ancora confonde la presenza con la partecipazione, nonostante questa sia proprio una delle cose che il digitale consente di separare senza perdita di significato. Non è una coincidenza che il termine "selfie" sia entrato nell'**Oxford**

English Dictionary nel 2013, nello stesso periodo in cui gli smartphone avevano raggiunto una diffusione di massa sufficiente a rendere la fotografia di sé stessi una pratica quotidiana per centinaia di milioni di persone. Christopher Lasch aveva già descritto, nel 1979, con straordinaria lucidità anticipatoria in *The Culture of Narcissism* [6], i processi sociali che avrebbero prodotto questo esito, molto prima che gli smartphone li rendessero visibili e misurabili. Il narcisismo di massa non è un prodotto della tecnologia portatile: è un prodotto di dinamiche culturali profonde che la tecnologia portatile ha semplicemente amplificato e reso esplicito. Il *selfie* è la manifestazione visibile di un processo di concentrazione dell'autorità sull'io che aveva radici molto più antiche. Il rischio di questa fase, come anticipatoriamente identificato da Eli Pariser che ne aveva colto il meccanismo nel 2011 con il concetto di “filter bubble” [7], è che l'algoritmo delle piattaforme digitali abbia completato il lavoro iniziato dal Walkman: se il Walkman isolava acusticamente, l'algoritmo delle piattaforme isola epistemicamente. Non senti più le voci degli altri, ma soprattutto non incontri più le idee degli altri. L'autorità dell'io ipertrofico viene paradossalmente amplificata da un sistema algoritmico che seleziona le informazioni in funzione di ciò che l'utente ha già dimostrato di apprezzare o a cui si è, anche in modo inconsapevole, dichiarato interessato, creando un circolo virtuoso (per il gestore della piattaforma) e vizioso (per la qualità epistemica dell'individuo) che porta l'io a confondersi sempre più con il tutto.

1.6 Quarta fase: l'algoritmo come nuovo oracolo

In onore di al-Khuwārizmī — Muhammad ibn Musa al-Khwarizmi (c. 780 – c. 850)

Algoritmo, sì. Digitale, sì. Perché alla fine sempre lì si arriva. Quello che ci ha sottratto l'effimero piacere di essere diventati, in qualche modo, dispensatori e fruitori di un'autorità da noi stessi espressa è proprio il fatto che l'evoluzione digitale ha di nuovo spostato al di fuori di noi il principio stesso di quella autorità. Al di fuori di noi e forse ancora più lontano di dove era collocato all'origine del percorso. Perché se all'inizio la divinità conservava gelosamente il suo sapere e lo dispensava solo in forme esoteriche, oggi l'algoritmo mette tutta la conoscenza a disposizione in modo completamente essoterico. In un modo talmente abituale che le risposte, anche a problemi etici oltre che pratici e medici, le cerchiamo su Google e, oggi, le chiediamo a modelli linguistici che nel tempo impiegato a leggere questa frase producono migliaia di token su qualsiasi argomento. In un modo talmente naturale che lo sviluppo già concretamente in corso dei sensori biometrici potrebbe presto permetterci di chiedere all'algoritmo “come sto?”, ricevendo da esso una risposta più attendibile di quella che riceveremmo chiedendolo a noi stessi o a un medico. Questo spostamento ha una caratteristica che lo distingue da tutti i precedenti: per la prima volta nella storia, il sistema-autorità è stato costruito dall'uomo, ma non è immediatamente comprensibile e compreso dall'uomo. Frank Pasquale, nel suo *The Black Box Society* (2015) [8], aveva identificato con precisione il meccanismo: l'opacità degli algoritmi non è accidentale né temporanea, è strutturale. Sappiamo cosa producono, conosciamo i risultati, possiamo osservare gli effetti. Ma il processo che conduce dal dato al risultato è, nella maggior parte dei casi di interesse pratico, non direttamente comprensibile dall'essere umano. Questo è esattamente il pattern della divinità. La divinità produceva risultati (pioggia, vittoria, guarigione) e noi conoscevamo i rituali per richiederli (preghiera, sacrificio, offerta). Ma il meccanismo interno della divinità era, per definizione, inaccessibile all'umano. La distanza tra input e output era così grande che si chiamava miracolo. Con l'AI la distanza tra input (il prompt che scriviamo) e output (la risposta del modello) è altrettanto grande, ma non

la chiamiamo miracolo: la chiamiamo “intelligenza artificiale emergente” o “proprietà del sistema”, espressioni che funzionano esattamente come il miracolo nel senso che nominano (e denominano) ciò che non capiamo senza spiegarlo.

La differenza cruciale, e qui la parentela con la divinità si interrompe, è che l'AI non pretende di avere un'intenzione. Il dio aveva intenzioni, giudicava, premiava e puniva in funzione di un piano che aveva un senso e una coerenza “interna”, anche se non decifrabile. L'algoritmo non ha intenzioni, produce correlazioni. Ma questa assenza di intenzione dichiarata non risolve il problema dell'autorità: di fatto le correlazioni dell'algoritmo diventano norme di comportamento, guide per la decisione, criteri di giudizio. L'algoritmo che decide chi ottiene un mutuo, quale notizia appare nel feed, quale curriculum viene scartato, quale prezzo viene mostrato, esercita una forma di autorità normativa senza avere, formalmente, alcuna autorità legittima nel senso weberiano del termine. Volendo proseguire idealmente il lavoro di Bruno Latour, potremmo descrivere questa situazione come un caso estremo di mediazione: l'uomo ha costruito un mediatore così potente da essere diventato il mediato. Non è più l'uomo che usa l'algoritmo per accedere alla conoscenza, è l'algoritmo che accede all'uomo attraverso il suo comportamento, le sue preferenze, le sue interazioni, per produrre un modello dell'uomo stesso che poi viene usato per influenzarlo. L'ago della bussola dell'autorità ha completato un giro completo: dal dio che guida l'uomo attraverso intermediari umani, all'uomo che si guida da sé, all'uomo che si fa guidare da un sistema che lui stesso ha costruito, ma non controlla.

Bello, eh?

Tabella 1.1: La genealogia del principio di autorità: quattro fasi a confronto

Fase	Detentore dell'autorità	Tipo weberiano	Comprensibilità del meccanismo	Velocità della transizione
Teocratica	Divinità (mediata da sacerdoti, profeti, oracoli)	Tradizionale	Nulla per il laico; esoterica per gli iniziati	Millenaria
Razionalista	Scienza e ragione umana collettiva	Razionale-legale	Alta in linea di principio; mediata in pratica	Secolare
Individualista	Il Sé (l'io ipertrofico, l'individuo digitalmente isolato)	Carismatica autoreferenziale	Completa in apparenza; illusoria in profondità (Freud)	Generazionale
Algoritmica	L'algoritmo (e chi lo detiene e lo addestra)	Nessun tipo weberiano applicabile; richiede una quarta categoria	Nulla, incluso per i costruttori stessi	Decennale e in accelerazione

Tre osservazioni a margine:

- Le fasi non si sostituiscono, si stratificano. Oggi (purtroppo) ancora convivono autorità teocratiche, razionaliste, individualiste e algoritmiche, spesso in conflitto tra loro e spesso nella mente della stessa persona, talvolta nello stesso momento. La genealogia non è una freccia, è un sedimento.
- La colonna “comprensibilità del meccanismo” non misura la qualità dell'autorità, ma la sua *governabilità*. Un sistema di autorità il cui meccanismo è comprensibile è, almeno in linea di principio, criticabile, riformabile, responsabilizzabile. Un sistema di autorità il cui meccanismo è opaco non lo è, indipendentemente dalla qualità dei risultati che produce.
- La velocità crescente delle transizioni non è una legge naturale, ma un dato empirico della storia recente. È precisamente questa velocità a rendere urgente il tipo di lavoro che questo libro si propone di fare.

1.7 La struttura ricorrente: cosa cambia e cosa resta

Rileggendo questa genealogia, emerge con una certa nitidezza una struttura che vale la pena di rendere esplicita, perché è questo pattern che fa di questo capitolo qualcosa di più di una storia curiosa e che lo rende, si spera, una cornice utile per tutto ciò che segue. Le domande restano le stesse attraverso le fasi e attraverso i secoli. *Chi sono? Dove vado? Perché? Come stare bene? Come fare la cosa giusta? Come sapere cosa è vero?* Queste domande le poneva l'uomo che interrogava l'oracolo di Delfi, le poneva il filosofo illuminista che sfidava l'autorità della tradizione, le pone oggi chi chiede a un modello linguistico di aiutarlo a capire una diagnosi medica (da cui l'appello dell'OMS che nel 2025 implorava l'umanità di smetterla di caricare sui chatbot le proprie analisi del sangue, cosa che, sono sicuro, abbiamo fatto tutti) o a prendere una decisione professionale difficile. La struttura della domanda è rimasta straordinariamente stabile. Quello che cambia è a chi si pone la domanda, perché ci si fida della risposta e con quale grado di comprensione del meccanismo che produce la risposta. Su questo terzo elemento, la comprensibilità del meccanismo, la genealogia disegna una curva interessante. La divinità aveva un meccanismo del tutto incomprensibile, accessibile solo in via mediata e attraverso codici esoterici. La Scienza moderna ha introdotto un meccanismo in linea di principio trasparente: il metodo sperimentale, per essere tale, deve essere replicabile, verificabile e, dove necessario, opponibile e falsificabile. Chiunque abbia le competenze necessarie deve poter, almeno in principio, ripercorrere il ragionamento ottenendo gli stessi risultati. L'individuo come autorità suprema ha un meccanismo completamente trasparente a sé stesso, anche se spesso illusoriamente: l'io si crede trasparente a sé stesso, Freud ci ha mostrato che non è esattamente così e le neuroscienze ci spiegano (anche con riferimenti biologici) il perché. L'algoritmo ha un meccanismo di nuovo opaco, ma con una caratteristica inedita rispetto alla divinità: è opaco anche ai suoi programmatori, non solo ai suoi utilizzatori.

C'è poi un elemento di velocità che non va trascurato. I tempi di transizione tra le fasi si sono sistematicamente accorciati. Millenni ha impiegato il principio di autorità a spostarsi dalla divinità alla ragione. Secoli ha impiegato a spostarsi dalla ragione collettiva all'individuo. Decenni ha impiegato a spostarsi dall'individuo all'algoritmo. E questa accelerazione ha una conseguenza pratica molto importante: il tempo disponibile per adattare le istituzioni, il diritto, la cultura, l'etica alle nuove strutture di autorità si riduce a ogni transizione. Quando la Scienza ha sfidato la religione, la Chiesa ha avuto secoli per rispondere e ha risposto (con il Concilio di Trento, con l'adattamento progressivo, con l'assorbimento di molte conquiste scientifiche nel proprio sistema di pensiero). Quando l'algoritmo sfida la razionalità umana, le istituzioni hanno anni, se va bene hanno mesi.

Questo è precisamente il problema che mi propongo di affrontare: non (solo) come funziona l'AI (ci sono infinite risorse più autorevoli e infinite anche meno per quello), ma come governare la transizione di autorità che l'AI sta producendo, con strumenti adeguati ai tempi di questa transizione.

1.8 Cambiare le domande

Aspettando Go(d)ot — Samuel Beckett, 1952

Quale sarà la prossima discontinuità e quali conseguenze avrà sull'equilibrio del principio di autorità? Imprimerà un'accelerazione in quale direzione? Nessuno può saperlo. Come recita un famoso adagio attribuito a Niels Bohr, “è difficile fare previsioni, soprattutto sul futuro”. Quello che è certo è che, quale che sia

l'entità alla quale le domande fondamentali saranno rivolte, l'uomo continuerà a formularle, perché sono parte fondamentale di come esso costruisce la sua immagine e rappresentazione nel mondo. La metafora epigrafica di Beckett non è casuale. In "Aspettando Godot", i due protagonisti attendono passivamente l'arrivo di un'entità che non capiscono, di cui non conoscono le intenzioni e che non arriva mai. L'attesa è l'unica loro attività. C'è qualcosa di *beckettianamente* inquietante nell'idea di aspettare che l'algoritmo ci dica come vivere, cosa scegliere, cosa pensare, mentre continuiamo a interrogarci su chi siamo e dove andiamo. L'alternativa che credo sia opportuno proporre non è romantica, né luddista, né tantomeno semplicemente regolamentare. È metodologica. Se il problema è che stiamo attribuendo all'algoritmo un'autorità epistemica, normativa (e anche tecnica) che non sappiamo governare, la risposta non è togliergli quell'autorità (un'impresa impraticabile, oltre che probabilmente non desiderabile), ma cambiare le domande. Non "cosa può fare l'AI?", ma "a cosa è opportuno che risponda?". Non "l'AI è intelligente?" ma "quale tipo di autorità le stiamo attribuendo e con quali meccanismi di controllo?". Non "come si usa l'AI?" ma "come si governa la relazione tra l'uomo e un sistema che esercita un'autorità di tipo nuovo?".

E se fosse giunto il momento di cambiare domande, giusto così, per vedere cosa succede?

Capitolo 2

Novità vs. innovazione: un primo tentativo di debunking all'hype dell'AI generalista

C'è un'estate, nella vita di ogni osservatore del presente, in cui le cose già viste tornano con la forza a confondere le cose nuove. L'estate del 2025 ha avuto per me questa caratteristica: settimane di letture sull'AI, decine di articoli, ricerche, dichiarazioni di intenti, e alla fine la sensazione di aver già percorso quella strada, non parlando e pensando strettamente e solamente all'AI, ma a qualcos'altro di, quanto meno, affine. Il ragionamento che mi è tornato in mente lo avevo scritto nel 2019, in un contesto completamente diverso, quando l'AI generativa non era ancora nei titoli dei giornali e il dibattito sull'innovazione riguardava IoT, blockchain, e le prime effettive incursioni del machine learning nelle practice aziendali. Lo avevo intitolato “Critica alla contemporanea ambiguità semantica del termine innovazione”, che è esattamente il tipo di titolo che si dà a un testo quando si vuole celare dietro una apparente aria composta un furore crescente. Il ragionamento di allora, riletto oggi, calza perfettamente. Forse troppo perfettamente.

2.1 Mappa infografica del capitolo




Figura 2.1: Mappa logica del Capitolo 2

2.2 Una confusione che viene da lontano

"Se vogliamo che tutto rimanga com'è, bisogna che tutto cambi." — G. Tomasi di Lampedusa, *Il Gattopardo*. 1958

Quando scrissi quel pamphlet (ho sempre adorato il termine, ne ho sempre adorato i fini, ho sempre aspettato di potermi riferire ad un qualche mio "delirio" con quel nome) il fastidio era che in ogni evento, presentazione e documento aziendale i termini "innovazione", "trasformazione" e "disruption" venissero usati come sinonimi intercambiabili, e quasi sempre con una polarizzazione semantica acriticamente ottimistica. L'innovazione era sempre positiva, sempre necessaria, sempre imminente (quando non immanente). Nessuno si fermava a chiedersi il significato delle parole che stava utilizzando, se quindi le stesse usando nel modo corretto, e soprattutto nessuno sembrava interessato a farlo.

La prima contraddizione che avevo rimarcato (dico rimarcato perché, come tutto, la mia altro non era che la rielaborazione di concetti che avevo già sentito) era quella tra innovazione e miglioramento. I due termini non sono né sinonimi linguistici né equivalenti logici. Innovazione si riferisce a qualcosa di esistente, di realizzato, di oggettivo. Miglioramento è un'espressione di valori, e come tale relativa per definizione: l'equivalenza non regge perché se è vero che per migliorare bisogna cambiare, non è affatto detto che un

cambiamento sia necessariamente apportatore di miglioramento. La storia dell'innovazione umana è costellata di trasformazioni anche epocali che hanno mostrato un lato oscuro e prodotto, nell'uso, conseguenze negative significative. La scrittura, per esempio, è stata una delle prime disruption nella storia dell'umanità: ha costituito un supporto esterno alla memoria, ma proprio per questa sua caratteristica ha contribuito all'atrofia delle capacità mnemoniche non supportate tecnologicamente. La stampa ha permesso la diffusione della cultura con una velocità e un'ampiezza prima inimmaginabili, ma lo ha fatto così in fretta da superare la velocità della produzione culturale stessa, che, innescando una sorta di meccanismo di conservazione del volume complessivo della cultura, ha ridotto la profondità per allargarne la base (e lo stesso si potrebbe dire, ad esempio, della differenza tra scattare le fotografie con un cellulare o scontrandosi con le limitazioni oggettive e fisiche del rullino, dello sviluppo, della stampa e dei costi connessi).

La seconda contraddizione era ancora più rilevante per il tema che ci interessa: ciò che chiamiamo innovazione spesso non è una novità. Molto spesso l'innovazione non è altro che l'applicazione di qualcosa di noto o di abituale al perseguimento di un obiettivo differente da quello originario. Altre volte è semplicemente l'evoluzione tecnologica di base a rendere praticabili innovazioni già preconizzate ma fino ad allora irrealizzabili per ragioni di costo, di scala o di maturità infrastrutturale. La cosiddetta Rivoluzione Copernicana, che teorizza in modo scientifico il sistema eliocentrico, era in nuce da almeno duemila anni: era stata preconizzata da Aristarco di Samo, ed era nota anche a Tolomeo, la cui visione geocentrica è logicamente equivalente a quella copernicana dal punto di vista della descrizione del moto dei pianeti. Quello che cambia è il punto di osservazione, non la scoperta del fenomeno. Lo stesso calcolatore elettronico, quando fu teorizzato da Turing nel 1936, aveva già quasi un secolo di storia "non applicata" nel lavoro di Babbage: la vera innovazione fu la disponibilità di tecnologie elettroniche sufficientemente efficienti da renderlo costruibile, non l'idea in sé.

La terza contraddizione, quella più scomoda, è che spesso facciamo precedere l'adozione all'uso: adottiamo tecnologie prima che si sia stabilizzato un modello condiviso di come usarle responsabilmente. I social network sono l'esempio più recente e bruciante di questa corsa all'(ab)uso adozione. Abbiamo costruito piattaforme di scala globale prima di porre seriamente le questioni sulla privacy, sull'uso dei dati, sul diritto all'oblio, sull'impatto sui processi democratici. Abbiamo adottato strumenti potenti convinti che il percorso di evoluzione tecnologica fosse inarrestabile e giusto "di per sé", e quella convinzione ci ha distratti dal compito di definirne i limiti prima di averne fatto un'infrastruttura cognitiva di massa.

Poi avevo aggiunto una nota finale sul tema della velocità e dell'accelerazione, che mi sembra ancora oggi la distinzione più sottovalutata nell'intero dibattito sulla trasformazione tecnologica: forse dovremmo smettere di preoccuparci tanto della rapidità con cui i cambiamenti avvengono, ovverosia la velocità istantanea, e cominciare a prestare attenzione all'accelerazione impressa da questi cambiamenti all'ambiente circostante. Possiamo adattarci all'alta velocità, e la nostra esperienza di abitanti di questo pianeta ce lo dimostra quotidianamente. Ma siamo molto meno equipaggiati a gestire anche marginali accelerazioni che modificano le leggi di riferimento con cui interpretiamo il contesto. Riletto oggi, questo testo sembra scritto per descrivere esattamente ciò che sta accadendo con l'AI generativa. Le tre contraddizioni sono presenti, amplificate e su scala globale. Il problema non è cambiato: è semplicemente diventato più urgente.

2.3 Il presente che conferma la diagnosi

"Ma l'imperatore è nudo!" — Hans Christian Andersen, *I vestiti nuovi dell'imperatore*, 1837

Da settembre del 2022 ho fatto dell'AI generativa il mio principale tema di ricerca e approfondimento, sia accademico che professionale. E da quando seguo questo argomento ho potuto rilevare che il dibattito pubblico ha sempre oscillato tra entusiasmo incontrollato e preoccupazione diffusa, con una narrazione quasi sempre polarizzata e concentrata sui modelli di AI generalista: chatbot sempre più sofisticati, capacità conversazionali in grado di imitare l'interazione umana, strumenti capaci di produrre testi, immagini e codice in pochi secondi anche grazie a crescenti attitudini “agentiche” (e quindi di una limitata autonomia che concediamo). Questo racconto, per quanto suggestivo, rischia di far passare in secondo piano sia le necessarie considerazioni tecniche per comprendere potenzialità e limiti, sia trasformazioni molto più profonde e strutturali.

La conferma empirica più strutturata che ho trovato di questa diagnosi è la ricerca del 2025 del MIT NANDA Project, che ha misurato con precisione quello che ha chiamato “GenAI Divide” [9]. Il dato è netto: la quasi totalità delle organizzazioni ottiene ancora oggi zero o near ROI misurabile dai propri progetti di AI (soprattutto quando questi sono, in realtà, distribuzioni a pioggia acritiche di manciate di licenze di ChatBot a supporto di attività individuali marginali e non sono accompagnate da vere trasformazioni). Solo una minima parte dei progetti AI realmente integrati arriva effettivamente in produzione. Non si tratta di aziende che hanno fallito l'implementazione tecnica. Si tratta di aziende che hanno adottato la novità, convinte che la novità e l'innovazione fossero la stessa cosa. Hanno fatto esattamente ciò che le tre contraddizioni descrivono: hanno equiparato innovazione a miglioramento automatico, hanno scambiato la novità di uno strumento per un cambiamento strutturale, e hanno adottato prima di capire come usare. Il GenAI Divide non è un fallimento tecnologico: è un fallimento semantico ed epistemologico. È la conseguenza misurabile di una confusione concettuale che dura da decenni e che l'AI generativa ha semplicemente reso più visibile e più costosa.

2.4 La distinzione che conta

“La storia non si ripete, ma spesso fa rima.” — Attribuita a Mark Twain (1835-1930)

Il momento per tornare sul punto è quindi più che mai oggi: è fondamentale distinguere tra “novità” e “innovazione”. I due termini non sono equivalenti né intercambiabili.

La novità è ciò che appare nuovo in un dato momento: per l'AI in questi anni è stato il lancio di un modello più grande, un'interfaccia più intuitiva, una capacità agentiche meno ancora supervisionata od un'applicazione inedita. Ogni nuova release di GPT, Claude o Gemini è una novità, spesso ragguardevole sul piano tecnico. L'innovazione, invece, è qualcosa che implica un cambiamento sostanziale nel modo in cui pensiamo, agiamo o organizziamo i processi: modifica strutture, abitudini, metriche e, in ultima analisi, i risultati economici e i meccanismi con cui il valore viene creato e distribuito.

Nel campo dell'AI, gran parte di ciò che oggi viene celebrato come innovativo rientra in realtà nella categoria della novità: importante, certo, e talvolta impressionante, ma ancora un'evoluzione incrementale di concetti già noti. Schumpeter aveva formalizzato questa distinzione nell'ambito dell'economia nel 1942, distinguendo tra invenzione (la produzione di un'idea nuova), innovazione (la sua prima applicazione economica) e imitazione (la sua diffusione) [10]. In questa triade, la maggior parte di ciò che passa per innovazione nel dibattito corrente sull'AI è in realtà imitazione: l'adozione diffusa di strumenti già esistenti, senza che questo adozione cambi i meccanismi attraverso cui le organizzazioni creano valore.

Un'azienda che usa un chatbot per redigere le email è un'azienda che ha acquisito una novità (peraltro di impatto tendenzialmente marginale). Un'azienda che ha ridisegnato il proprio processo decisionale integrando modelli addestrati sui propri dati proprietari, con metriche di successo misurate sui propri KPI di business, sta perseguendo qualcosa che ha il profilo dell'innovazione nel senso schumpeteriano. Questa distinzione non è pedanteria terminologica. Ha conseguenze dirette sulle scelte strategiche, sulle aspettative di ritorno, e sulla capacità di valutare lucidamente se ciò che si sta acquistando o implementando risolve un problema reale o soltanto ne allontana la percezione.

Gli incentivi strutturali al confondere le due cose sono potenti e non sono casuali. I fornitori di modelli e strumenti hanno tutto l'interesse a presentare ogni aggiornamento come una rivoluzione, perché è così che si giustificano prezzi crescenti e cicli di rinnovo brevi. Chi cerca disperatamente di rientrare di investimenti (sbagliati) offrendo servizi o prodotti che invecchiano come le fragole al sole hanno interesse a mantenere alta la percezione di urgenza, perché l'urgenza scoraggia la riflessione e accelera la firma. I media specializzati sopravvivono sull'attenzione, e l'attenzione si cattura con l'insolito, il primo, il più grande, il più veloce. In questo ecosistema, la novità è strutturalmente sovrarappresentata e l'innovazione strutturalmente sottorappresentata, non per malevolenza ma per incentivi di carattere meramente economico. La distorsione produce una asimmetria informativa a danno delle organizzazioni che devono decidere: chi compra decide in un mercato che sistematicamente esagera i benefici delle novità e sottostima il lavoro organizzativo necessario per trasformarle in innovazione. Il GenAI Divide non è un'anomalia: è il risultato prevedibile di questo sistema di incentivi applicato a scala industriale.

2.5 Due rivoluzioni, una direzione

In questo contesto distorto, emergono tuttavia due prospettive che si collocano, a mio giudizio totalmente sindacabile, oltre il perimetro della novità per entrare a pieno titolo nel dominio dell'innovazione, nel senso che modificano strutture, meccanismi e metriche, non solo strumenti.

La prima riguarda il passaggio da un uso passivo dell'AI, quello tipico dell'“AI user” che consuma output generalisti, a un approccio proattivo di creazione di valore. È la transizione che separa chi usa un chatbot “assistant” per le email da chi ha costruito sistemi intelligenti ed, in alcuni casi (estremi), agentici radicati nei propri dati proprietari, nei propri processi, nella propria conoscenza tacita. Questa transizione è la prima rivoluzione vera: non è una questione di strumenti più sofisticati, ma di un cambio di paradigma nel rapporto tra l'organizzazione e la tecnologia. Il come di questa transizione, le tecniche, le figure organizzative, le metriche, è materia di un successivo capitolo.

La seconda prospettiva riguarda orizzonti più lunghi e richiede, per ora, solo di essere nominata: la convergenza tra AI, capacità computazionali avanzate e robotica è un processo già in atto, che accorcia i cicli decisione-azione e apre possibilità di automazione intelligente che ridisegneranno interi settori. Per le organizzazioni di medie dimensioni, il punto non è sapere quando questa convergenza raggiungerà la maturità commerciale, ma capire che le fondamenta che si costruiscono oggi sulla prima rivoluzione determineranno la capacità di sfruttarla quando arriverà. Le due rivoluzioni hanno un tratto comune che vale la pena di rendere esplicito, perché è la conclusione pratica dell'intero ragionamento di questo capitolo: entrambe spostano il focus dall'adozione acritica di strumenti “alla moda” alla costruzione di un ecosistema di valore. Non vincerà chi possiede il modello più aggiornato o chi è stato il primo ad adottare ogni nuova versione. Vincerà chi saprà costruire il valore più proprio (volevo scrivere più intimo ma mi sono trattenuto), più radicato nella propria

realtà operativa (e soprattutto sui propri dati, che costituiscono veramente l'asset intangibile del presente), e più difficile da replicare da chiunque disponga degli stessi strumenti generalisti. In un mercato dove gli strumenti si commoditizzano velocemente, il vantaggio competitivo si sposta sui dati, sui processi, sulla conoscenza e sulla disciplina con cui tutto questo viene integrato. La gara non è di potenza: è di pertinenza e di rilevanza contro la mera plausibilità.

Non è (più) solo un gioco per “grandi”. Non servono i budget delle grandi multinazionali per competere nell'era dell'AI. Serve la chiarezza strategica per distinguere ciò che è novità da ciò che è innovazione, e il coraggio di dire no alle prime per investire nelle seconde. In un contesto dove la velocità è importante ma la direzione è decisiva, questa distinzione può fare la differenza tra essere spettatori passivi del cambiamento o protagonisti consapevoli della propria evoluzione. Nel seguito, prima di addentrarci nelle rivoluzioni vere, è necessario fermarsi sulla domanda con cui tutta questa trasformazione deve fare i conti: con quali strumenti morali intendiamo governarla?

Capitolo 3

ConcrEthica: la bussola etica che forse ancora non abbiamo

Che un informatico di formazione accademica, il cui “day job” è fare il partner di una grande società di consulenza, si avventuri nel terreno dell’etica e della filosofia, sebbene relativamente e limitatamente alla loro applicazione alla sua materia di competenza, potrebbe far storcere il naso a più di qualcuno. Me ne farò una ragione, auspicando che, sulla medesima linea di sensibilità intellettuale, analoga scelta sia condivisa dai lettori. La ragione per cui questo capitolo esiste, tuttavia, non è l’ambizione di contribuire in modo necessariamente originale al dibattito filosofico sull’etica dell’AI, che è già ricco e articolato e non ha bisogno di principianti (perchè già tanti ve ne sono). La ragione è più semplice e più urgente: dopo aver affrontato nel Capitolo 1 lo spostamento verso l’algoritmo del principio di autorità, ed aver osservato (nel Capitolo 2) la sistematica confusione tra novità e innovazione, ci si trova di fronte a una domanda che non è possibile rimandare ulteriormente. Con quali strumenti morali intendiamo governare questa transizione? E la risposta, a mio giudizio, è che gli strumenti che abbiamo a disposizione, pur necessari, non sono sufficienti.

3.1 Mappa infografica del capitolo



Figura 3.1: Mappa logica del Capitolo 3

3.2 Il quarto spintone: l'invenzione che decentra più della scoperta

"Le macchine mi sorprendono molto di frequente." — Alan Turing, *Macchine calcolatrici e intelligenza* (1950)

L'umanità ha affrontato, nel suo percorso storico, almeno tre grandi trasformazioni che hanno contribuito a ridisegnare, a volte radicalmente, la percezione della propria centralità e il proprio modo di vedere il mondo e se stessa. Prima è venuto Copernico, che ci ha resi consapevoli del fatto che la Terra non fosse al centro dell'universo ma orbitasse attorno al Sole, scardinando l'idea della nostra centralità rispetto al cosmo e ridimensionando la nostra posizione nell'universo (come già detto riprendendo ed aggiornando teorie pre-esistenti). In seguito Darwin ha rivelato che l'uomo è il frutto di un lungo processo evolutivo, condividendo le sue origini con altre specie e infrangendo l'illusione di essere centro e apice unico della vita sulla Terra in termini, quanto meno, di regno "animale". Nel secolo scorso Freud ha messo in dubbio la nostra idea di essere completamente padroni delle nostre azioni e dei nostri pensieri, rivelando una complessità interiore inaspettata e sottraendoci la comodità di un'autoconsapevolezza integra e "finita". Queste tre rivoluzioni hanno progressivamente decentrato l'essere umano rispetto al cosmo, alla biologia e alla propria psiche, spingendoci a confrontarci con nuove verità e a rivedere il nostro rapporto con il mondo.

Luciano Floridi [15]: ha identificato, a completamento di questa sequenza, il pattern di ciò che chiama “quarta rivoluzione”: la digitalizzazione, e in particolare l’intelligenza artificiale, costituisce un quarto e per certi versi più radicale decentramento, perché mette in discussione il primato cognitivo, forse l’ultimo baluardo dell’auto-affermata centralità umana. Volendo, per mimesi, conservare l’associazione a un personaggio storico, potremmo ricondurre questa quarta trasformazione a Turing, anche se la forzatura è evidente: Turing non ha scoperto una verità scomoda sull’uomo, bensì ha progettato e dimostrato (in via teorica, per lo meno) la possibilità di simulare gli esiti del pensiero con una macchina. Ed è proprio questa differenza, apparentemente tecnica, che porta con sé le conseguenze filosoficamente più dirompenti. C’è infatti una differenza fondamentale tra i quattro spostamenti che vale la pena di rendere esplicita, perché è da questa differenza che nascono le questioni etiche più urgenti. Le prime tre rivoluzioni erano scoperte: Copernico, Darwin e Freud ci hanno detto qualcosa che era già vero e che non sapevamo. Il quarto è invece il prodotto di un’invenzione: siamo noi ad aver costruito la tecnologia che ora mette in discussione la nostra centralità cognitiva. Chi è causa dei suoi mali, si potrebbe dire, con l’ironia che si riserva alle situazioni in cui la lucidità sulla radice del problema non aiuta a risolverlo. Questa distinzione non è soltanto filosoficamente interessante: risulta eticamente decisiva. Di fronte a una scoperta, possiamo solo adattare la nostra postura. La Terra orbitava già attorno al Sole prima che Copernico lo dimostrasse finalmente, e continuerà a farlo indipendentemente da ciò che decidiamo. Di fronte a un’invenzione, invece, possiamo, e dobbiamo, scegliere. La questione non è se sviluppare l’AI, una domanda alla quale la storia ha già risposto con velocità ed irreversibilità proporzionali solo agli investimenti effettuati. La questione è come, con quali intenzioni, con quali salvaguardie, con quali meccanismi di correzione e, soprattutto, con quale consapevolezza delle implicazioni che stiamo producendo.

Ed è precisamente su questo “come” che gli strumenti concettuali e istituzionali di cui disponiamo mostrano le loro insufficienze.

Paolo Benanti ha descritto questo momento come un “cambio d’epoca” [18], distinguendolo con cura da un’epoca di cambiamenti. Non stiamo assistendo a trasformazioni quantitative all’interno di un quadro stabile: stiamo assistendo al ridisegno del quadro stesso. Le categorie con cui abbiamo pensato la tecnologia, il lavoro, l’identità, la conoscenza e la responsabilità sono tutte, in misura diversa, in discussione simultaneamente. E questa simultaneità è, di per sé, una sfida etica, perché le istituzioni che producono ed applicano norme (i parlamenti, i tribunali, le università, le amministrazioni, persino i regimi) operano per definizione con tempi più lunghi della velocità con cui le sfide emergono. La forbice tra la velocità del cambiamento tecnologico e la velocità delle istituzioni normative è uno dei principali generatori di vuoto etico con cui ci troviamo a convivere.

3.3 Quando lo strumento smette di essere neutro

“Plasmiamo i nostri strumenti e poi i nostri strumenti plasmano noi.” — John Culkin 1967

L’uomo, animale “naturalmente tecnologico”, si è tradizionalmente rapportato alla tecnologia con l’obiettivo prevalente di efficientare attività e azioni da svolgere, partendo da una base di conoscenza circa le attività da effettuare derivata dalla propria esperienza. In questo senso ha sempre privilegiato valutazioni legate all’incremento della performance nello sviluppo e nell’innovazione degli strumenti per mezzo dei quali ha trasformato il mondo che abita. La sega elettrica è un esempio paradigmatico: un’innovazione altamente

efficiente di una tecnologia non nuova, che sfrutta una evoluzione tecnologica di base (l'energia elettrica) per rendere possibile aumentare la quantità di lavoro svolto nell'unità di tempo. Vista in questa prospettiva, il lavoro da fare (il *Job To Be Done*, per dirla con Ethan Mollick) non cambia. Cambia invece, a volte anche radicalmente, il modo con il quale decidiamo di svolgerlo. In questa classe di tecnologie, la valutazione morale riguarda esclusivamente l'uso che se ne fa: la sega elettrica è moralmente neutra in sé, e sono le intenzioni e le azioni di chi la usa a portare valore morale (che è compito umano definire come positivo o negativo). Le tecnologie digitali con le quali ci troviamo a confrontarci oggi, invece, perseguono non solo l'obiettivo di efficienza ma vi affiancano, a volte in modo prevalente, quello dell'efficacia, nel senso che rendono possibili cose che sarebbero semplicemente impossibili senza di esse. Si pensi alla separazione tra la presenza fisica e la partecipazione che il digitale permette con le videochiamate e i meeting remoti: non si tratta di fare più velocemente qualcosa che si faceva già (efficienza), ma di fare qualcosa di strutturalmente diverso (efficacia). Ed in molti casi lo si può fare per la prima volta (imprenditorialità). I risultati prodotti da queste tecnologie, visti dal di fuori, possono sembrare talmente indistinguibili da quelli prodotti da esseri umani da trasformare il nostro stesso rapporto con la tecnologia. In presenza di tecnologie in grado di rispondere in modo efficace ed efficiente alle domande che vengono loro poste, il ruolo dell'uomo si trasforma necessariamente da portatore di risposte a decisore circa quali domande sono rilevanti e prioritarie. In questa trasformazione si riverbera anche quella, più generale, del nostro tempo: da un'epoca dell'accumulo e della memorizzazione (performativo assoluto misurabile in efficienza) a un'epoca della selezione e dell'eliminazione (performativo relativo misurabile in efficacia). La distinzione non è soltanto tecnica: è una distinzione sulla natura del valore umano nel processo produttivo e decisionale. Questo spostamento ha una conseguenza etica diretta che raramente viene nominata con la chiarezza che merita. Quando uno strumento cessa di essere puramente orientato all'efficienza attraverso l'amplificazione delle capacità umane (condizione che relega le considerazioni etiche al solo impiego che dello strumento viene fatto) e produce risultati che vanno nella direzione dell'efficacia e lo fa in modo imprenditoriale (ovverosia per la prima volta), la tecnologia inizia ad assumere una sorta di intenzionalità che può indirizzare l'uomo verso determinati comportamenti. Questa classe di soluzioni tecnologiche cessa di essere moralmente neutrale, dove per neutrale si intende passiva, e assume un valore morale che si esprime e dipende dai comportamenti verso i quali essa indirizza. Un esempio quotidiano per illustrare questa dinamica con immediatezza. Lo smartwatch che "sollecita" certi comportamenti ritenuti positivi, raggiunto il quale siamo già all'interno di un territorio dove qualcuno ha deciso cosa è positivo per noi: un insieme di intenzioni (quelle dei progettisti ad esempio) che si è reso concreto in un oggetto tecnologico e che opera silenziosamente sull'orientamento delle nostre abitudini quotidiane. Chi ha stabilito le soglie? Con quale criterio? In funzione di quale modello od obiettivo di salute e di vita? Non appena queste domande vengono sollevate, si rivela quanto il confine tra strumento e indirizzo morale sia sottile. E siamo già, mani e piedi, dentro il dominio dell'etica. Un esempio più estremo ed esteso (e purtroppo attualissimo, nell'intera sua declinazione di livelli) è quello della fissione nucleare: strumento ineguagliabile di efficienza nella generazione di energia elettrica che, trasformata in armamento, diventa strumento di deterrenza e, costituendo la tecnologia attorno alla quale si sono organizzati e polarizzati i due grandi schieramenti del Novecento, finisce per diventare un'espressione culturale e definitoria dell'intera specie umana (che può esistere o non esistere in funzione di essa). In questo caso, la tecnologia non è più un mezzo neutro che l'uomo usa: è diventata il contesto entro il quale l'uomo definisce le sue alleanze, le sue paure ed i suoi equilibri di potere in vista ed in funzione di fini esistenziali.

Al livello più radicale di questa evoluzione, siccome ogni cultura si manifesta attraverso gli artefatti e i manufatti tecnologici che crea, la tecnologia, quando pervade integralmente l'agire di una comunità, diventa il

modo e il senso attorno al quale la comunità stessa si organizza.

Dobbiamo quindi chiederci se, nel momento storico in cui ci troviamo, gli strumenti concettuali, culturali e filosofici di cui disponiamo siano adeguati agli impatti che questi nuovi strumenti digitali, e in particolare l'intelligenza artificiale, hanno nel quotidiano. Siamo preparati a rispondere alle domande etiche proprie di un mondo che si organizza attorno a manufatti tecnologici il cui funzionamento non siamo in grado di spiegare fino in fondo, almeno non nel modo deterministico in cui ci siamo abituati a spiegare le cose tecniche? La risposta onesta fatica ad essere altro che “no”. L'essere umano tecnologicamente supportato è sorretto da cause che comprende, e quando i risultati sono spiegabili in termini di causa-effetto, le categorie morali tradizionali reggono bene. Ma quando ci troviamo di fronte alle nuove tecnologie digitali e ai comportamenti che producono e inducono, e questi non possono essere più semplicemente spiegati come effetti di cause note, ci vengono a mancare delle categorie concettuali che dobbiamo interamente ridefinire (anche in termini ontologici, anzi innanzitutto in questi termini). La responsabilità di chi? La causalità di cosa? L'intenzionalità di chi ha scritto l'algoritmo, o di chi ha raccolto i dati? Questi interrogativi non sono accademici: sono le domande pratiche a cui un giudice, un regolatore, un manager o anche solo un individuo “utilizzatore” devono già oggi saper rispondere, e per le quali gli strumenti esistenti si rivelano sistematicamente inadeguati.

3.4 Leggi, governance, compliance, etica: insieme che si sfuggono e non si contengono

“Corruptissima re publica plurimae leges.” — Publio Cornelio Tacito, *Annales* (117 d.C.)

L'urgenza di rispondere a queste sfide giustificerebbe, da sola, la ricerca e la spinta verso una nuova interpretazione morale, sia nell'agire delle tecnologie sia nella postura da assumere nei loro confronti. La confusione sorge però quando la convinzione di aver già fatto “tutto quello che era necessario” (come ad esempio mettere qualche bel filtro sul firewall per bloccare accessi a chatbot, riflesso pavloviano di ogni IT manager medio(cre)) si scontra con la consapevolezza che qualcosa manca ancora. Il problema è frequente nelle organizzazioni: si produce un documento di policy sull'uso responsabile dell'AI, magari si nomina un comitato etico, si dichiara l'adesione a qualche framework internazionale, si chiude qualche rubinetto e si ritiene di aver assolto l'obbligo. Questo equivoco nasce dalla mancata distinzione tra quattro insieme che spesso vengono trattati come sinonimi, e che invece sono profondamente diversi per natura, meccanismi di enforcement, scopo (e fine) nonché ambito di applicazione.

Le leggi sono istituti fondamentali di una società che regolano i comportamenti per assicurare ordine e giustizia, istituendo nel contempo meccanismi sanzionatori per i comportamenti che violano gli indirizzi normativi. La legge dice cosa non si può fare (e talvolta cosa si deve fare), e prevede conseguenze in caso di violazione. È il livello della coercizione esplicita, e la sua efficacia dipende dalla chiarezza delle fattispecie e dalla capacità degli organi preposti di applicare le sanzioni.

La governance è un insieme di regole tramite le quali un'organizzazione, o una porzione di società, gestisce se stessa. Si ispira ed è guidata dalle leggi (una porzione organizzata della società non può darsi regole contraddittorie rispetto alle leggi che governano il tutto), ma non avendo istituti formali che ne assicurino il rispetto, dispone di strumenti limitati per garantirne l'applicazione interna.

La compliance rappresenta l'intersezione necessaria ma insufficiente tra leggi e governance: assicura che un comportamento normato da una legge sia recepito anche nella governance aziendale e che non vi siano contraddizioni, ma non copre il territorio dell'etica.

L'etica, infine, è l'insieme dei principi morali che regolano i comportamenti in funzione di un principio di giusto e sbagliato. Per sua natura, inerendo a valutazioni qualitative che non si prestano a formalizzazione coercitiva, non può essere codificata in istituti sanzionatori. È sempre insufficiente come strumento di governo, ma forse anche per questo indispensabile come bussola.

Questi quattro insiemi si intersecano senza sovrapporsi completamente, e la loro non-coincidenza è la radice strutturale del problema. Non possiamo aspettarci che da un complesso di leggi o regolamenti emergano, da sole, indicazioni e prescrizioni di carattere etico: la legge vieta, l'etica orienta. Sono operazioni logicamente distinte, e confonderle produce o un eccesso di legalismo (l'idea che rispettare la norma esaurisca il dovere morale) o un eccesso di eticismo astratto (l'idea che enunciare principi equivalga a praticarli - in altri contesti questo è il desiderismo .. quando speriamo che per fare accadere qualcosa basti deciderlo o volerlo). Sebbene l'Europa abbia adottato un impianto normativo apprezzabile, dal GDPR fino all'AI Act (Regolamento UE 2024/1689), per il momento il più articolato e completo nel panorama globale, questo da solo non surroga il bisogno di una riflessione etica più estesa e profonda. L'AI Act incorpora alcuni principi etici irrinunciabili nella nascente relazione tra l'uomo e queste tecnologie, ma l'assenza di una visione complessiva globale e la mancanza di meccanismi attuativi concreti rischiano di rendere quella norma, e quelle che eventualmente da essa si gemmeranno, un vuoto esercizio di stile. La battuta che gli i miei colleghi a stelle e strisce amano ripetere, secondo cui “gli americani inventano, i cinesi copiano e gli europei proibiscono”, va accolta non come critica ma come stimolo: il fatto che l'Europa sia l'unica (o quanto meno la prima) ad aver tentato una regolamentazione organica è già un merito, ma il tentativo non basta a sé stesso. Paolo Benanti, nel suo lavoro sull'algor-etica [17], ha articolato con precisione perché la sola regolamentazione giuridica sia strutturalmente insufficiente: un'etica dell'AI che si limiti a vietare i comportamenti peggiori senza orientare positivamente lo sviluppo è come una medicina che curi i sintomi senza affrontare la malattia. La proposta di Benanti, che richiama esplicitamente la tradizione del pensiero cristiano-sociale, è che il “human in the loop” non sia solo una clausola tecnica dei sistemi di AI, ma una postura epistemologica e morale: la supervisione umana sulle decisioni algoritmiche non è un optional di buona prassi, è una condizione necessaria per il mantenimento della responsabilità morale nel ciclo decisionale. Detto in modo più diretto: se tolgo l'umano dal loop, non tolgo solo una funzione tecnica surrogabile, tolgo il soggetto morale. E senza soggetto morale, la responsabilità si dissolve, non perché nessuno abbia fatto nulla, ma perché le strutture concettuali che la fondano non trovano più un agente cui attenersi. Il che ci porta a chiedersi: dove, esattamente, nella catena che va dai dati alle decisioni, le questioni etiche emergono con più urgenza? E questa domanda richiede, prima di poter rispondere con utilità pratica, di capire con sufficiente precisione come quella catena funziona.

3.5 La catena del valore digitale come mappa delle questioni etiche

“La mappa non è il territorio.” — Alfred Korzybski (1931)

In soccorso di una visione più pragmatica può venire una comprensione dei meccanismi logici e tecnici che sottendono al funzionamento di questa classe di soluzioni digitali. Proviamo a srotolare la “catena del valore” che il digitale esprime e realizza, partendo, per una volta, dal fondo anziché dall’inizio, seguendo il verso del ragionamento invece di quello della narrazione.



Figura 3.2: Data Value Chain

Iper-semplificando, possiamo dire con buona approssimazione che gli esseri umani adottano soluzioni tecnologiche principalmente come supporto alle decisioni, manageriali o quotidiane, che devono prendere. Sulla base del supporto che ricevono, prendono decisioni che modificano il mondo in cui vivono (quello reale, sia esso fisico o virtuale). Assumono queste scelte basandosi sulla conoscenza che viene loro messa a disposizione dai tool che usano, conoscenza è prodotta a partire dalle informazioni di cui il tool dispone, che a loro volta sono il frutto di un processo di sintesi analitica dei dati raccolti e organizzati dal sistema informativo. I dati raccolti, organizzati e trattati sono una mappa, ovverosia una rappresentazione necessariamente approssimata della realtà di riferimento (proprio quella realtà che tramite le azioni conseguenti andremo a modificare).

Vale la pena ora di percorrere questa catena anche nell’altra direzione, dall’inizio alla fine, soffermandosi sugli elementi trasformativi introdotti a ogni passaggio, in modo da identificare con precisione dove e come si inseriscono le questioni etiche (spoiler: in ogni dove).

Il punto di partenza (e di arrivo) è sempre uno solo: la realtà. Per tramite di tecniche di acquisizione e sensorizzazione viene prodotta una mappa che approssima la realtà. Ogni datificazione di un fenomeno che avviene nel “continuo” implica sempre una certa imprecisione: le carte geografiche sono mappe (im)perfette che rappresentano la realtà pur non essendola, e lo stesso vale per ogni dato che rappresenta la realtà.

Questi dati hanno caratteristiche oggi mnemonicamente identificabili nelle cinque “V”:

volume (la mole di informazione raccolta è di gran lunga superiore alla capacità di analisi tradizionale),

velocità (la frequenza di aggiornamento è in molti casi pressoché real-time),

variabilità (le fonti sono eterogenee e i formati non standardizzati),

veridicità (non tutti i dati raccolti sono accurati e affidabili)

valore (non tutti i dati raccolti portano informazione utile).

Sono, in sintesi, tanti, troppi e complicati, e devono essere organizzati, resi confrontabili, gestibili, memorizzati e trattati, pur sapendo che non portano necessariamente contenuto informativo diretto. I dati, entità informativamente neutre (non ontologicamente inerti, ma questo è altro discorso), possono esprimere contenuto quando ad essi si applichi un processo di sintesi analitica che li classifica, seleziona e arricchisce progressivamente di connotazioni che sintetizziamo in tre dimensioni: struttura, significato e valore semantico. La struttura identifica l'insieme di caratteristiche che un dato deve esprimere per rappresentare un'informazione. Il significato disambigua in modo univoco il contesto di riferimento al quale il dato appartiene. Il valore semantico certifica l'esistenza di quel significato nel contesto di riferimento e, soprattutto, la sua coerenza con la rappresentazione del mondo reale al quale si riferisce.

Un esempio può essere d'aiuto, per quanto necessariamente incompleto e tirato per capelli od ogni altra appendice tricotica. Il numero 30 e il numero 30.000.000 sono inequivocabilmente dati, ma non portano, di per se, informazione che vada oltre la loro esistenza concettuale in quanto numerali a rappresentazione di numeri. Se aggiungo una struttura (ad esempio il simbolo “°”) ottengo 30° e 30.000.000°: dati con struttura, ma ancora ambigui nel significato: non ci inequivocabilmente dicono di cosa stiamo parlando. Solo quando disambiguo ulteriormente il contesto (non angoli, ma temperature Celsius) faccio un passo avanti verso l'informazione. E infine: 30°C è un'informazione sensata, mentre 30.000.000°C non lo è, perché il dato strutturato e significante non ha valore semantico nel contesto di verità nel quale viene letto (la temperatura stimata del nucleo del Sole è circa 15.000.000°C, e quindi 30.000.000°C non è né vero né falso: non ha semplicemente senso come informazione sul mondo che conosciamo e rappresentiamo).

Potremmo quindi dire che il dato con struttura è informazione “come il reale”; il dato con struttura e significato è informazione “per il reale” (una serie limitata di istruzioni per l'uso); il dato con struttura, significato e valore semantico è informazione “sul reale”, ovvero sia è una proposizione che può essere valutata come vera o falsa nel mondo a cui si riferisce. Solo i dati che superino questo sbarramento logico portano valore informativo e possono essere utilizzati per costruire conoscenza. La disponibilità strutturata di informazioni non significa conoscenza, ma permette di derivarla tramite processi correlativi, ovvero processi logici e matematici basati su probabilità e statistica (nota bene, non probabilità o statistica, ma proprio probabilità e statistica). Nel caso dell'AI discriminativa e generativa, tramite algoritmi molto sofisticati basati su reti neurali e deep learning, ma il *job to be done* non cambia: si cercano semplicemente correlazioni su nature diverse di dati (numeri, pezzi di parole in linguaggi naturali) usando strumenti di ricerca molto più potenti. La conoscenza che generiamo, adeguatamente presentata, ci permette di prendere decisioni che, una volta agite, modificheranno il mondo che ci circonda. Questo mondo trasformato sarà poi nuovamente datificato, rientrando nel circolo che abbiamo descritto.

Vorrei concentrare l'attenzione su due snodi centrali di questa catena per rimarcare la portata del cambio di “specie” che stiamo osservando, quanto meno in relazione al rapporto con le tecnologie. Il primo snodo è

quello tra dati e informazioni: la raccolta, classificazione e trasformazione dei dati in informazioni riposa sul principio dell'approssimazione selettiva, il che significa che i dati che trattiamo sono ancora “riferiti”, per quanto in modo molto approssimato e decisamente “imperfetto”, direttamente al reale da cui scaturiscono. Il secondo snodo è quello tra informazioni e conoscenza: quando trasformiamo le informazioni in conoscenza, perdiamo il legame con il “reale”, perché la conoscenza è espressione sintetica di una correlazione statistica e probabilistica. Non è più una rappresentazione approssimata del reale: è un'astrazione che ne cattura i pattern ma non le singole istanze.

In altri termini: *prendiamo decisioni che modificano il nostro mondo reale partendo da dati generati da algoritmi probabilistici (ai quali nel caso dell'AI generativa forniamo noi stessi lo strato semantico necessario a rendere il risultato qualcosa di sensato e non solo plausibile), e che si poggiano su una sintesi di dati che approssimano grossolanamente la realtà*. La distanza tra il risultato prodotto e la realtà cui si riferisce non è soltanto tecnica: è una distanza epistemologica che, non essendo più visibile nella forma del risultato (l'AI generativa produce testo fluente, immagini verosimili, ragionamenti articolati), tende sistematicamente a essere sottovalutata. Che sia urgente l'esigenza di sviluppare un'etica nuova per governare questa nascente complessità dovrebbe essere, a questo punto, fuori discussione.

3.6 I cinque principi fondativi della Digital Ethics

“Il vero problema non è se le macchine pensano, ma se gli uomini lo fanno.” — Burrhus Frederic Skinner (1969)

Come molto di quanto scritto fino a qui, ciò che segue non è originale: è la miglior definizione disponibile, formulata da chi del tema ha fatto la propria ricerca principale. La filosofia utile, quella che parla delle cose del mondo e del tempo in cui viene sviluppata, è chiamata non solo a formulare le domande ma anche, laddove è possibile, a indirizzare le risposte. E il modo in cui ci si può avvicinare responsabilmente a questo tentativo è di non fare mai domande delle quali non si conosca già la risposta: il mantra che viene somministrato agli studenti delle facoltà di Legge negli Stati Uniti il primo giorno di lezione, e che nel nostro contesto significa non enunciare principi che non si sia già in grado di tradurre in indicazioni operative. La Digital Ethics, secondo Floridi [14], è *“un nuovo ramo dell'etica che studia e valuta i problemi morali legati ai dati (compresa la generazione, registrazione, cura, elaborazione, diffusione, condivisione ed uso), agli algoritmi (inclusi intelligenza artificiale, agenti artificiali, apprendimento automatico e robot), e alle relative pratiche e infrastrutture (inclusi l'innovazione responsabile, la programmazione, l'hacking, i protocolli e i codici professionali), al fine di formulare e sostenere soluzioni moralmente corrette”*.

Ciò che colpisce immediatamente di questa definizione è l'estensione e la portata dell'ambito di interesse che abbraccia. Non si parla solo di dati e algoritmi, ma anche dei metodi per il trattamento e il governo degli stessi, le infrastrutture sulle quali i dati risiedono e vengono elaborati, e persino i risultati fruiti, il che comporta considerazioni etiche che riguardano l'hardware stesso (cosa trovo particolarmente affascinante: pensare alla *moralità* di un hard disk, ovvero di un oggetto fisico che contiene rappresentazioni digitali di persone reali, con tutto ciò che ne consegue in termini di responsabilità sulla conservazione, l'accesso, la cancellazione). È chiaro che, dovendo attraversare trasversalmente tutte le tecnologie, non vi è altro modo di incorporare l'etica nell'ecosistema se non *by design*: dall'inizio, dalla progettazione. Illudersi di poter

correggere il tiro una volta disegnato, implementato e rilasciato un componente, un algoritmo o una soluzione è una pia illusione, non perché non si possa tecnicamente intervenire, ma perché a quel punto i comportamenti indotti, i *bias* incorporati e le asimmetrie di potere generate hanno già prodotto effetti reali. Floridi propone cinque principi fondamentali che devono guidare ogni atto di progettazione e sviluppo di ogni elemento della catena del valore digitale. Vale la pena menzionarli e provare ad applicarli esplicitamente ai livelli della catena che abbiamo descritto, non come esercizio accademico ma come tentativo di rendere la loro applicazione concreta e tracciabile.

La non maleficenza , ovvero non causare danno e prevenirlo laddove possibile, si applica con priorità al livello della datificazione. Nei processi di acquisizione, conservazione e trattamento dei dati dobbiamo rispondere a tre domande: i sistemi sono sicuri rispetto ad accessi non autorizzati? La privacy degli individui è rispettata, non solo formalmente in sede di consenso, ma sostanzialmente nel modo in cui i dati vengono poi utilizzati e combinati? Il consenso è stato ottenuto in modo genuinamente informato, oppure si è nascosta la reale portata del trattamento dietro l'opacità delle condizioni di servizio? Questi non sono interrogativi astratti: ogni violazione di dati, ogni caso di uso improprio di informazioni personali, ogni sistema di profilazione non trasparente è una violazione concreta del principio di non maleficenza applicato al livello della datificazione.

La benevolenza , ovvero contribuire positivamente allo sviluppo umano, si applica al livello della generazione dell'informazione. Nei processi in cui attribuiamo struttura, significato e valore semantico ai dati, dobbiamo assicurarci di curare l'interpretazione, identificare i bias sistematici e verificare l'integrità delle fonti. I *bias* nei dati di addestramento dei modelli di AI sono la manifestazione più evidente della violazione di questo principio: un sistema addestrato su dati storici che riflettono discriminazioni consolidate (in ambito lavorativo, di genere, di condizione sociale ad es creditizio, sanitario) produrrà sistematicamente raccomandazioni che perpetuano quelle discriminazioni, indipendentemente dalle intenzioni dei suoi progettisti. La benevolenza richiede un intervento attivo, non una mera astensione dal danno.

L'autonomia , ovvero rispettare l'autonomia umana e riservare sempre all'umano la facoltà di scegliere (o di rifiutare), si applica al livello della generazione della conoscenza. Nei processi correlativi dobbiamo assicurare l'accessibilità e la controllabilità del procedimento, per evitare (limitare, forse è più appropriato) le correlazioni spurie che sono sempre in agguato quando si lavora con trasformazioni statistiche dei dati, e verificare che gli strati semantici siano costruiti sulla base di rilevanze statistiche significative. Al decrescere di questa significatività, il fenomeno delle cosiddette "allucinazioni" dei modelli linguistici diventa un rischio inaccettabile, non soltanto perché produce risultati errati, ma perché produce risultati errati in forma plausibile, ovvero in una forma che rende difficile all'utente non esperto riconoscerne l'errore. L'autonomia del soggetto umano è violata non solo quando gli si impedisce di scegliere se utilizzare o no strumenti di questo genere (ad esempio incorporandoli come funzione di base non "deselezionabile"), ma anche quando gli si forniscono conoscenze false in forma credibile.

La giustizia , ovvero contribuire a una equa distribuzione dei rischi e dei benefici, si applica al livello delle decisioni e delle azioni. Dobbiamo mantenere il primato dell'etica sociale anche a scapito della pura ragione economica, il che significa chiedersi, per ogni sistema di AI che produce decisioni, chi beneficia e chi sopporta i rischi, e se questa distribuzione sia equa. Questo è il principio più scomodo da applicare,

perché è quello che entra più direttamente in conflitto con gli incentivi di mercato: i benefici dell'AI tendono a concentrarsi nei soggetti che possiedono i dati e le infrastrutture computazionali (poche grandi imprese tecnologiche), mentre i rischi (dalla potenziale perdita del lavoro alla sicura erosione della privacy ed a tutti gli effetti negativi dell'amplificazione delle disuguaglianze) tendono a distribuirsi più ampiamente.

L'esplicabilità, ovvero garantire la comprensibilità dei modelli di funzionamento ed evitare l'opacità dell'effetto black-box, è trasversale all'intera catena. È anche il principio che l'AI Act recepisce in modo più lacunoso (anche per via delle limitazioni tecniche che rendono questo principio, di fatto...): il diritto alla spiegazione delle decisioni algoritmiche è formalmente presente nel regolamento, ma i meccanismi attuativi sono ancora largamente inapplicati nella pratica. Il problema dell'esplicabilità non è soltanto tecnico (spiegare come funziona un transformer con centinaia di miliardi di parametri è genuinamente difficile): è anche epistemologico. Una spiegazione che sia comprensibile a un non esperto richiede necessariamente una semplificazione, e ogni semplificazione introduce distorsione. Il bilanciamento tra accuratezza della spiegazione e accessibilità della medesima è esso stesso una scelta etica.

3.7 ConcrEthica: la bussola dell'agire

“L'etica non è esattamente la dottrina di come renderci felici, ma di come dovremmo renderci degni della felicità.” — Immanuel Kant

Quando ho battezzato questa sintesi e rielaborazione concettuale “ConcrEthica” avevo una ambizione precisa: fare percepire questo insieme “normativo” non come una buffa astratta da proclamare nelle policy aziendali e poi dimenticare nei comportamenti quotidiani, ma una filosofia pragmatica da dimostrare in ogni singola scelta di progettazione, in ogni decisione su quali dati raccogliere, in ogni valutazione su quale correlazione è accettabile e quale non lo è. La differenza tra un “estetico annuncio” di voler fare la cosa giusta e un “etico agire” è esattamente la differenza tra dichiarare di aderire ai principi e applicarli livello per livello nella catena del valore. Questa distinzione non è retorica. Le organizzazioni che pubblicano documenti di AI Ethics policy aderendo a codici di condotta internazionali, magari anche istituendo comitati etici senza modificare alcunché nei processi di sviluppo, di raccolta e gestione dei dati è un atto prevalentemente comunicativo a fini marketing, non un atto etico. Peggio: stanno producendo un'immunizzazione contro la critica (“abbiamo già un'etica policy”) che rende più difficile l'identificazione e la correzione dei problemi reali. Il termine tecnico in letteratura è “ethics washing”, e il fenomeno è sufficientemente diffuso da aver generato una letteratura critica specifica. Come si traduce, allora, ConcrEthica in pratica? Non esiste una risposta unica, e sarei intellettualmente disonesto se proponessi un framework in n passi con tanto di checklist a risoluzione di un problema strutturale. Ciò che è possibile indicare sono alcune posture, alcune domande e alcune condizioni organizzative che rendono più probabile che l'etica entri davvero nei processi decisionali.

La prima postura è quella della **trasparenza attiva** verso se stessi prima che verso l'esterno. Un'organizzazione che si interroghi onestamente su quali dati utilizza, da dove provengono, chi li ha raccolti e con quale consenso, quali bias sistemici potrebbero essere presenti, e chi sopporta le conseguenze delle decisioni prodotte dal modello, sta già compiendo un atto etico concreto, indipendentemente dalla risposta che trova.

Il problema non è avere le risposte giuste: è aver smesso di fare le domande. E nelle organizzazioni sotto pressione competitiva e di time-to-market, smettere di fare le domande scomode è la deriva più comune e più pericolosa.

La seconda postura è quella della **progettazione inclusiva** delle considerazioni etiche, che significa incorporare la valutazione etica non come audit ex-post sul prodotto finito, ma come elemento costitutivo del processo di design (o di scelta). È questa la ragione per cui Floridi insiste sul “by design”: non come slogan, ma come constatazione pratica che l’etica inserita o verificata tardivamente non funziona.

La terza postura, forse la più difficile, è quella del **disagio come segnale positivo**. Convivere con il disagio della sfocatura dei confini tra il mondo digitale, dove le decisioni vengono prese, e il mondo reale, nel quale le conseguenze delle azioni si riverberano, non è un problema da risolvere: è la condizione normale di chi opera responsabilmente in un contesto di complessità genuina. L’assenza di disagio è, nella maggior parte dei casi, un indicatore che le domande difficili non vengono poste, non che siano state risolte.

Comportarsi eticamente in entrambi i mondi, quello digitale e quello reale, non è un obiettivo che si raggiunge una volta per tutte: è una pratica continuamente rinnovata, esattamente come lo è qualsiasi altra forma di rigore professionale. Ciascuno (organizzazione o singoli) di noi deve costruire la sua bussola etica, perché le mappe che abbiamo, ovvero leggi, governance e compliance, siano necessarie ma non sufficienti per usarla. La bussola senza le mappe è inutile, ma le mappe senza la bussola sono pericolose: indicano la posizione, non la direzione. In tutto il prosieguo di questo lavoro l’etica non sarà più capitolo o paragrafo separato: diventa la condizione di intelligibilità di tutto il resto. Senza di essa, la complessità rimane complessità; con essa, diventa sistema di significato.

Parte II

Le rivoluzioni (quelle vere)

Parte III

L'umano al centro (ma quale umano, e
quale centro?)

Parte IV

Governare la complessità

Bibliografia

Capitolo 1

- [1] Weber, Max. *Wirtschaft und Gesellschaft*. Mohr Siebeck, Tübingen, 1922. (Traduzione italiana: *Economia e società*, Edizioni di Comunità, Milano, 1961).
- [2] Foucault, Michel. *L'ordre du discours*. Gallimard, Paris, 1970. (Traduzione italiana: *L'ordine del discorso*, Einaudi, Torino, 1972).
- [3] Foucault, Michel. *Surveiller et punir. Naissance de la prison*. Gallimard, Paris, 1975. (Traduzione italiana: *Sorvegliare e punire. Nascita della prigione*, Einaudi, Torino, 1976).
- [4] Latour, Bruno. *Science in Action: How to Follow Scientists and Engineers Through Society*. Harvard University Press, Cambridge, MA, 1987.
- [5] Latour, Bruno. *Nous n'avons jamais été modernes*. La Découverte, Paris, 1991. (Traduzione italiana: *Non siamo mai stati moderni*, Elèuthera, Milano, 1995).
- [6] Lasch, Christopher. *The Culture of Narcissism: American Life in an Age of Diminishing Expectations*. W. W. Norton & Company, New York, 1979.
- [7] Pariser, Eli. *The Filter Bubble: What the Internet Is Hiding from You*. Penguin Press, New York, 2011.
- [8] Pasquale, Frank. *The Black Box Society: The Secret Algorithms That Control Money and Information*. Harvard University Press, Cambridge, MA, 2015.

Capitolo 2

- [9] Challapally, Sid, Gabriella Pease, Ramesh Raskar e Arnav Chari. *The GenAI Divide: State of AI in Business 2025*. Tech report, MIT NANDA Project, 2025. Disponibile all'indirizzo: <https://nanda.media.mit.edu>
- [10] Schumpeter, Joseph A. *Capitalism, Socialism and Democracy*. Harper & Brothers, New York, 1942. (Traduzione italiana: *Capitalismo, socialismo e democrazia*, Etas, Milano, 2001)[cite: 259].
- [11] LeGrande, Craig e Venky Lakshminarayanan. *AI-Driven Value Management: How AI Can Help Bridge the Gap Across the Enterprise to Achieve Customer Success*. John Wiley & Sons, Hoboken, NJ, 2025.

- [12] Thomas, Rob, Paul Zikopoulos e Kate Soule. *AI Value Creators: Beyond the Generative AI User Mindset*. O'Reilly Media, Sebastopol, CA, 2025.
- [13] Musiol, Martin. *Generative AI: Navigating the Course to the Artificial General Intelligence Future*. John Wiley & Sons, Hoboken, NJ, 2024.

Capitolo 3

- [14] Floridi, Luciano. *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford University Press, Oxford, 2023.
- [15] Floridi, Luciano. *The Fourth Revolution: How the Infosphere is Reshaping Human Reality*. Oxford University Press, Oxford, 2014.
- [16] Floridi, Luciano. *Digital Philosophy and Ethics*. Corso a.a. 2023-2024, Bologna Lectures, YouTube.
- [17] Benanti, Paolo. *Human in the Loop. Decisioni umane e intelligenze artificiali*. Mondadori Università, Milano, 2023.
- [18] Benanti, Paolo. *Digital Age. Teoria del cambio d'epoca. Persona, famiglia e società*. Edizioni San Paolo, 2020.
- [19] Benanti, Paolo. *La grande invenzione. Il linguaggio come tecnologia, dalle pitture rupestri al GPT-3*. Edizioni San Paolo, 2021.