

Complessità e Sistemi di Senso

Riccardo Bovetti

Who am I? | [LinkedIn](#) | [All you need is thought](#)

Marzo 2026/Giugno 2026

Indice

Quello che questo libro non è (e perché esiste lo stesso)	5
I Le coordinate	7
Dove siamo e perché non è dove pensiamo di essere	8
1 From God to Google (passando per Goodenough): genealogia del principio di autorità nell'era digitale	10
1.1 Mappa infografica del capitolo	11
1.2 Come definire il principio di autorità?	11
1.3 Prima fase: il Verbo e i suoi intermediari	13
1.4 Seconda fase: la razionalità come nuovo assoluto	14
1.5 Terza fase: Dal Se(lf) al Se(lfie), l'autorità dell'io ipertrofico	15
1.6 Quarta fase: l'algoritmo come nuovo oracolo	16
1.7 La struttura ricorrente: cosa cambia e cosa resta	18
1.8 Cambiare le domande	19
2 Novità vs. innovazione: un primo tentativo di debunking all'hype dell'AI generalista	20
2.1 Mappa infografica del capitolo	21
2.2 Una confusione che viene da lontano	21
2.3 Il presente che conferma la diagnosi	22
2.4 La distinzione che conta	23
2.5 La rivoluzione, il suo terreno ed il suo orizzonte	24
3 ConcrEthica: la bussola etica che forse ancora non abbiamo	26
3.1 Mappa infografica del capitolo	27
3.2 Il quarto spintone: l'invenzione che decentra più della scoperta	27
3.3 Quando lo strumento smette di essere neutro	28
3.4 Leggi, governance, compliance, etica: insieme che si sfuggono e non si contengono	30
3.5 La catena del valore digitale come mappa delle questioni etiche	31
3.6 I cinque principi fondativi della Digital Ethics	34
3.7 ConcrEthica: la bussola dell'agire	36

II La rivoluzione (quella vera) 38

Cosa cambia e perché non è (solo) quello che pensiamo 39

4 Da “AI User” a “AI Value Creator”: la rivoluzione dell’AI Generativa 42

4.1	Mappa infografica del capitolo	43
4.2	Adottare e creare: una differenza che non è lessicale o sintattica	43
4.3	Le dimensioni (non) contano (più)	44
4.4	Il processo, molto più che l’evento	46
4.5	Il cuore è organizzativo, lo stomaco è tecnologico	46
4.6	La questione dei dati, i dati questionabili	47
4.7	Misurare il valore con le metriche giuste, evitare l’AI-Washing e superare la retorica	48
4.8	Una partita di pertinenza	49

5 I dati come asset strategico: il vero campo di battaglia dell’AI aziendale 50

5.1	Mappa infografica del capitolo	51
5.2	Il dato come fattore cogente ed urgente	51
5.3	È una questione di qualità (e di nuovo meno di quantità di quanto si possa pensare)	53
5.4	Del cambio di natura: il passaggio dal fattuale al plausibile	54
5.5	Tassonomia, ontologia ed epistemologia di contesto	55
5.7	Governance dei dati nell’era dell’AI: chi decide cosa, e perché	56

6 L’illusione dell’AI agantica: concetti base, limiti e rischi resi evidenti dal confronto con la teoria dell’agenzia 62

6.1	Mappa infografica del capitolo	63
6.2	Qualche nozione storica, perché la storia è sempre il miglior consulente	63
6.3	La Agency Theory: la matematica senza tempo del disallineamento	64
6.4	Cosa significa (davvero) “agente” nel contesto dell’IA	65
6.5	Agency senza intelligenza: il paradosso che nessuno vuole nominare	67
6.6	La teoria dell’Agenzia applicata agli Agenti AI	68
6.7	Come le aziende si riorganizzano per accogliere (e governare) gli Agenti	70
6.8	Rischi emergenti e opportunità latenti	71
6.9	Superare l’hype, verso un’adozione consapevole	72

III L’umano al centro (ma quale umano, e quale centro?) 73

Siamo ancora convinti di stare soltanto “usando” uno strumento? 74

7 Il paradosso dell’AI Literacy: quando sapere di più fa capire di meno 77

7.1	Mappa infografica del capitolo	79
7.2	La banalità dell’uso effettivo: quando la competenza tecnica incontra la poca significatività applicativa	79
7.3	Dal singolo al sistema: organizzazioni, ontologie mancanti, accesso ineguale	80

7.4	Centauro e Cyborg: una grammatica delle posture (prima che diventi una traiettoria)	81
7.5	Implicazioni per interventi educativi e organizzativi: oltre la literacy tecnica verso la consapevolezza metacognitiva	83
7.6	Conclusioni: verso una maturità epistemica nell'era dell'AI generativa (forse)	84
8	Pensa per noi, ci fa lavorare di più, e continua a sembrarci pure una buona idea	85
8.1	Mappa infografica del capitolo	86
8.2	Tre lenti per mettere a fuoco lo stesso fenomeno	86
8.2.1	System 0: l'AI che pensa prima di te	86
8.2.2	Tri-System Theory: l'AI che pensa con te (o al posto tuo)	87
8.2.3	L'intensificazione silente: quando l'AI ti fa lavorare di più	87
8.3	Lettura sinottica: dove convergono, dove divergono e cosa sembra mancare	88
8.4	Un modello a fasi e una competenza da costruire	89
8.4.1	Le fasi della deriva cognitiva	89
8.4.2	La resa cognitiva qualificata come competenza e non difetto	91
8.5	Implicazioni e livelli di impatto	93
8.6	Conclusione	93
9	Cybernetic teammates: ripensare la collaborazione nell'era dell'AI	94
9.1	Mappa infografica del capitolo	96
9.2	Riconfigurazione del lavoro in team: il superamento necessario dei paradigmi tradizionali . . .	96
9.3	L'AI come tecnologia sociale: applicazioni ed approfondimenti teorici	98
9.4	Cognizione distribuita e AI: ripensare i confini della "conoscenza" tra umano e non-umano . .	100
9.5	Verso un nuovo modello teorico: il framework del "CyberMate"	102
9.6	Implicazioni pratiche nella progettazione organizzativa	103
9.7	Come il collega sintetico si imbriglia in un nodo etico	104
10	Ontoetica della collaborazione: quando la filosofia diventa necessità operativa	105
10.1	Mappa infografica del capitolo	106
10.2	Dalla teoria alla filosofia: l'ontologia dell'informazione e il "CyberMate"	107
10.3	Etica dell'informazione e responsabilità distribuita	108
10.4	Ontoetica e trasformazione del lavoro collaborativo	110
10.5	Verso un'etica della collaborazione umano-AI	111
10.6	Dalla bussola etica alla pratica della collaborazione	112
IV	Governare la complessità	113
	Bibliografia	115

Quello che questo libro non è (e perché esiste lo stesso)

Quando la quantità di cose che uno non sa o non capisce supera visibilmente la quantità di cose che sa, ci sono solo due possibili reazioni: lo scoramento e il farsi passivamente sopraffare dall'igno(to)ranza, oppure far diventare questa sproporzione la ragione stessa per scrivere. Questo lavoro è nato esattamente in quel momento e con la consapevolezza che dichiararlo apertamente è forse la forma più onesta per stabilire un rapporto "concettuale" con il lettore (eventuale). Questo **non** è un libro sull'intelligenza artificiale, almeno non nel senso in cui la maggior parte dei libri che portano quelle due parole nel titolo intende il termine. Non contiene definizioni di transformer, spiegazioni dettagliate di come funziona un Large Language Model, confronti tra architetture, benchmark di performance tra modelli concorrenti. Non perché queste cose non siano importanti (lo sono, enormemente), ma perché esistono risorse migliori per quello, scritte da persone più competenti di me, e soprattutto perché la *shelf life* di qualunque informazione tecnica sui modelli di AI è oggi così breve da essere strutturalmente incompatibile con il formato libro. Qualunque cifra, qualunque confronto, qualunque affermazione sullo stato dell'arte che scrivessi oggi sarebbe probabilmente obsoleta prima di raggiungere il primo lettore. Invece è una riflessione frammentata ma articolata su cosa succede quando un fenomeno tecnologico di questa portata attraversa le organizzazioni, le persone, le istituzioni e i modi in cui pensiamo. È un tentativo di condividere le coordinate che nel tempo ho costruito per orientarmi nel fenomeno, non nel prodotto. Di capire non come funziona l'AI (nella speranza che questo non rimanga, per mia colpa, un'ignoranza), ma cosa fa a noi, alle nostre strutture di autorità, ai nostri modi di creare valore, ai nostri strumenti etici, ai nostri processi cognitivi, alla nostra capacità di governare la complessità senza ridurla a slogan di marketing. La domanda che attraversa tutto il percorso, che sicuramente non troverà una risposta definitiva in queste pagine, è quella che dà il titolo all'intera "iniziativa": è possibile trasformare la complessità in sistemi di senso? Il testo **non** cerca modi di eliminare la complessità, che sarebbe un'ambizione tanto vana quanto pericolosa, ma di costruire strutture di significato che la rendano navigabile, governabile, e forse anche generativa (di valore, per lo meno). Chi scrive **non** è un filosofo, **non** è un ingegnere dell'AI e **nemmeno** un neuroscienziato. Chi scrive è invece qualcuno che si muove nel territorio di intersezione tra epistemologia, etica e pratica organizzativa con la consapevolezza dei propri limiti e la convinzione, forse ottimista ma non priva di fondamento empirico, che quel territorio di confine sia esattamente quello dove si producono le connessioni più utili. Questo libro nasce da un corpus di articoli, ricerche, interventi e lezioni scritti negli ultimi dieci anni. Questa origine è visibile nel testo e voluta: non si tratta di un trattato sistematico costruito a tavolino, ma della cristallizzazione di un pensiero che si è sviluppato nel tempo, con le sue ricorrenze, le sue evoluzioni e le sue ostinate insistenze su temi che, a ben vedere, in alcuni casi si possono considerare già risolti o non ancora urgenti. Alcune idee che sembravano premature sono diventate ovvietà quotidiane, altre che sembravano urgenti si sono rivelate meno centrali di quanto apparissero. Il libro riflette questo percorso senza nascondere, perché la traiettoria di un pensiero è secondo me informativa quanto le sue conclusioni.

Il percorso è organizzato in quattro parti che corrispondono a quattro domande diverse, non a quattro risposte.

- La prima parte, **Le coordinate**, stabilisce dove siamo: nella genealogia del principio di autorità che si è spostato dalla divinità all'algoritmo, nella confusione sistematica tra novità e innovazione, e nella necessità di una bussola etica che le norme da sole non possono fornire. Sono tre risposte parziali che mi hanno permesso di scoprire, con vari gradi di disagio, che non è dove pensavamo di essere.

- La seconda parte, **La rivoluzione (quella vera)**, affronta ciò che sta effettivamente cambiando: una trasformazione strutturale che merita il nome di rivoluzione, il terreno dei dati su cui si gioca, e l'illusione agentica che promette la prossima rivoluzione senza averla ancora completamente consegnata alla realtà.
- La terza parte, **L'umano al centro (ma quale umano, e quale centro?)**, si occupa di ciò che succede nelle persone quando il rapporto con l'AI diventa quotidiano: il paradosso dell'AI literacy, la deriva cognitiva, la collaborazione uomo-macchina e le sue implicazioni ontoetiche.
- La quarta parte, **Governare la complessità**, propone strumenti per chi deve prendere decisioni: un framework per l'integrazione organizzativa, l'impatto sulla didattica, e una guida pratica per chi vuole passare dalla teoria all'azione senza perdersi nel tragitto.
- **Due appendici**, infine, si concedono il lusso della divagazione: una per esplorare come le radici religiose e culturali possano influenzare e guidare gli atteggiamenti verso l'AI, l'altra sulla relazione tra AI e processi creativi. Sono le connessioni che non ho la pretesa che siano indispensabili ma che sono convinto arricchiscano il percorso speculativo "laterale" sulla materia.

Una nota di metodo, prima di procedere. L'approccio che governa questa mia (inspiegabile) fatica non è quello di chi propone risposte definitive a domande aperte (un'ambizione che non avrei la competenza di perseguire e, francamente, nemmeno la presunzione di annunciare), ma quello di chi ritiene che formulare le domande giuste sia già, di per sé, un contributo non trascurabile. La complessità del presente non si risolve con la velocità delle risposte: si governa con la qualità delle domande. E se alla fine ci troveremo tutti con più domande di quante ne avessimo all'inizio, beh, avremo fatto un buon lavoro.

Parte I

Le coordinate

Dove siamo e perché non è dove pensiamo di essere

Il vero viaggio di scoperta non consiste nel cercare nuove terre, ma nell'avere nuovi occhi. — Marcel Proust,
La Prisonnière (1923)

Penso che si dovrebbe sempre avere la buona creanza di dichiarare le proprie intenzioni in anticipo, anche (soprattutto) quando si sa di non poterle mantenere tutte. La prima parte di questo lavoro che (sinceramente non so perché) ho deciso di intraprendere ha un compito che potrebbe sembrare modesto ma che, a ben vedere, è il più ambizioso dell'intero percorso: esplicitare le coordinate di riferimento per il nostro viaggio. Non le coordinate di un territorio già mappato, nel qual caso il lavoro sarebbe quello, tutto sommato confortevole, del geometra che verifica i confini, ma le coordinate di un paesaggio che si sta ridisegnando (ad una velocità abbagliante) mentre lo attraversiamo, con la conseguenza che qualsiasi mappa rischia di essere già obsoleta nel momento in cui la si consegna alle stampe (o, più realisticamente, alle e-stampe). La domanda che attraversa questi tre capitoli (che sono sicuro riemergerà in forme diverse in tutto il resto del libro) è semplice nella formulazione e vertiginosa nelle implicazioni: a chi o a cosa stiamo delegando il diritto di rispondere alle domande che contano? Non le domande tecniche, quelle hanno risposte che si possono verificare, misurare e confutare con i metodi della scienza e dell'ingegneria. Le domande che contano sono le altre: chi sono, dove vado, cosa è giusto o meno fare, cosa è vero e cosa è soltanto plausibile. Per millenni queste domande sono state rivolte alla divinità, poi alla ragione, poi all'individuo, ed ora sistemi algoritmici il cui funzionamento è opaco persino a chi li ha costruiti. Questa sequenza, che nel Capitolo 1 viene ricostruita come genealogia del principio di autorità, non è una storia lineare di progresso o di decadenza: è una storia di spostamenti di senso e di fiducia e di immutabili ricorrenze che cambiano protagonista senza cambiare copione. Se la prima coordinata è storica (da dove veniamo, nella nostra relazione con chi o cosa detiene l'autorità di rispondere), la seconda è semantica e pertanto più difficile ed importante. Il Capitolo 2 si occupa di una (minima) parte della confusione che permea il dibattito contemporaneo sull'intelligenza artificiale: la sistematica (erronea) pretesa di equivalenza tra novità e innovazione. Una equivalenza che non regge meno che mai logicamente e che tuttavia viene riprodotta con entusiasmo acritico ad ogni ciclo tecnologico. Il fastidio che questa confusione genera non è estetico ma piuttosto economico e strategico: le organizzazioni che scambiano l'adozione di uno strumento nuovo per un cambiamento strutturale (e che poi si stupiscono di ottenere risultati trascurabili) stanno pagando il prezzo di un errore epistemologico prima ancora che gestionale. La terza coordinata è etica, nel senso più operativo e meno proclamatorio del termine (considerando il pulpito dal quale proviene). Posta

la questione dell'autorità ed indirizzata la confusione tra novità e innovazione, resta la domanda che non è possibile rimandare ulteriormente: con quali strumenti morali intendiamo governare tutto questo? Il Capitolo 3 tenta una risposta che non si accontenta della pur necessaria dimensione normativa (le leggi ci sono, e l'AI Act europeo è probabilmente il tentativo regolatorio più articolato e completo esistente al momento di questa stesura), ma che prova a distinguere, con una certa ostinazione, tra il fare la cosa giusta e il (solo) dichiarare di volerla fare. ConcrEthica (nel richiamo a quel pragmatismo che penso debba permeare anche la filosofia), il nome che ho dato a questa sintesi, nasce precisamente dalla convinzione che l'etica dell'intelligenza artificiale debba essere incorporata nel modo in cui si progettano i sistemi, si raccolgono i dati, si valutano le correlazioni e si prendono le decisioni, per non essere mero esercizio di comunicazione che immunizza contro la critica senza modificare i comportamenti. Tre coordinate, dunque: storica, semantica, etica. Tre modi di rispondere alla domanda "dove siamo" scoprendo con vari gradi di disagio che non è dove pensavamo di essere. Il principio di autorità non è dove lo avevamo lasciato (nel dominio dell'umano razionale e consapevole). L'innovazione non è dove la narrazione dominante la colloca (nella novità tecnologica di per sé). L'etica non è dove le policy aziendali la dichiarano (nei documenti di compliance e nei comitati variegati). E questa tripla delocalizzazione, che potrebbe sembrare scoraggiante, è in realtà la premessa necessaria per orientarsi con qualche speranza di lucidità nel resto del percorso.

Capitolo 1

From God to Google (passando per Goodenough): genealogia del principio di autorità nell'era digitale

Sono sempre stato affascinato dal potere delle connessioni e dalla possibilità che viene offerta, al prezzo accettabile di un po' di fatica per utilizzare metodi sufficientemente rigorosi, di costruire a posteriori correlazioni che spiegano (e in qualche misura giustificano) quasi qualsiasi evento, accadimento, stravolgimento o trasformazione (il famigerato “senno di poi”). E questa fascinazione mi porta, a volte, a chiedermi da un lato che cosa resterà, nella lettura a posteriori, di tutto il dibattito attorno alla *disruption* digitale che sta polarizzando l'attenzione di una gran parte della letteratura professionale (e che sembra avere date di scadenza più ravvicinate del latte fresco), dall'altro se non sia possibile (almeno provare ad) anticipare alcune delle letture tendenziali che necessariamente emergeranno come spiegazioni (a posteriori) di questo eccezionale periodo storico. Di sicuro il dibattito attorno alle *disruption*, e in particolare quella digitale, ha una caratteristica che lo distingue da quelli che lo hanno storicamente preceduto: i tempi tra l'avvenimento che ha generato la discontinuità, la narrazione del cambiamento e la previsione del futuro si sono accorciati notevolmente, sia in termini di reazione che di orizzonte temporale. Quando Copernico “spostò” la Terra dal centro del sistema solare, ci vollero generazioni prima che questa verità diventasse parte del senso comune. Quando la Scienza moderna sconfisse la malaria con il chinino, ci vollero decenni prima che il cambio di paradigma epistemologico fosse metabolizzato. Quando l'AI generativa ha reso improvvisamente capace qualsiasi utente di produrre testi, immagini e codice (con un grado di plausibilità tale da farli intendere per “veri”, qualsiasi cosa significhi) a partire da istruzioni in linguaggio naturale, il tempo trascorso tra l'evento (novembre 2022, il lancio su larga scala di ChatGPT 3.5 in quel fantastico esperimento sociale a fini meramente economici di cui avremo modo e tempo di parlare ampiamente) e la saturazione del dibattito è stato di qualche mese. La velocità stessa con cui si narrano le *disruption* è, essa stessa e se vogliamo essere romantici, una discontinuità. Questa è la ragione per la quale ho ritenuto utile, come primo passo di questa mia passeggiata in questi futuri e presenti giardini mentali, rileggere accadimenti passati, remoti e molto meno remoti, costruendovi attorno un qualcosa, dal punto di vista concettuale, che provasse a integrare etica, tecnologia e storia. Per farlo ho voluto concentrare l'attenzione su un concetto che attraversa tutta la storia

dell'umanità e che mi sembra illuminare il presente meglio di qualsiasi disamina tecnica delle caratteristiche dei modelli linguistici: il principio di autorità, ovvero la questione di chi o cosa, in una data epoca, detiene il diritto riconosciuto di fornire una risposta (in prima stesura avevo scritto rispondere, ma penso che l'atto possa essere disgiunto dal risultato) alle domande più importanti.

1.1 Mappa infografica del capitolo




Figura 1.1: Mappa logica del Capitolo 1

1.2 Come definire il principio di autorità?

Per principio di autorità intendo, con una certa libertà definitoria che mi concedo, quell'insieme di condizioni e di elementi che consentono a qualcuno o qualcosa di assumere un ruolo di predominio nelle attività di ricevere e accogliere le domande (per lo più di carattere etico, nel senso più ampio: chi sono, dove vado, perché), dispensare risposte e precetti, comminare giudizi e pene e guidare verso comportamenti e pensieri conformi. Questa definizione, volutamente operativa più che filosoficamente rigorosa, trova una corrispondenza precisa in una delle griglie analitiche più potenti della sociologia moderna, quella elaborata da Max Weber nelle sue riflessioni sui tipi di dominio legittimo [1]. Egli identificava tre forme di autorità:

- **Autorità tradizionale:** fondata sull'immutabilità di ciò che è sempre stato (il Re per grazia di Dio, il sacerdote per tradizione apostolica);

- **Autorità carismatica:** fondata sul riconoscimento di qualità straordinarie in un individuo (il profeta, il condottiero, il capo di stato (sic!) o il fondatore di startup con la visione rivoluzionaria);
- **Autorità razionale-legale:** fondata su regole impersonali e procedure codificate (il funzionario statale, il tecnico esperto, la norma giuridica).

La storia con la quale iniziamo il nostro viaggio è, in buona sostanza, la storia del progressivo spostamento tra queste tre forme storiche, con l'elemento di disturbo aggiuntivo costituito da un quarto tipo che Weber non aveva potuto anticipare: quello che potremmo chiamare autorità algoritmica, fondata su correlazioni statistiche tra dati in quantità tale da rendere strutturalmente opaco il processo che conduce al risultato.

Utile strabismo interpretativo penso sia anche il contributo di Michel Foucault con il suo concetto di “regime di verità” [2, 3]. Foucault osservava che ogni società ha un suo regime di verità, ovvero un insieme di meccanismi e istituzioni che consentono di distinguere le affermazioni vere da quelle false, e che attribuiscono un valore speciale (in quanto diversamente riconosciuto) alle prime rispetto alle seconde. Chi controlla questo meccanismo detiene un potere che non è semplicemente quello della forza, ma qualcosa di ancora più rilevante: il potere di definire cosa è reale, cosa conta, cosa merita di essere detto. In questa prospettiva, il principio di autorità non è solo una questione di gerarchia sociale, ma diventa pienamente una questione epistemologica... il passaggio dall'autorità della divinità all'autorità dell'algoritmo non è solo un cambiamento di chi comanda, è un cambiamento di cosa vuol dire sapere.

È a mio avviso utile, prima di avventurarci nelle quattro fasi della genealogia, esplicitare il modo in cui queste tre prospettive (Weber, Foucault, Latour) si compongono in una griglia analitica unitaria (in un reticolo, come ho sentito chiamare per la prima volta un file Excel da un cliente questa settimana), perché è precisamente questa composizione, e non ciascuna prospettiva isolata, a rendere leggibile il percorso che segue. *Weber* ci offre una tassonomia delle forme di legittimazione: l'autorità esiste in quanto riconosciuta come legittima, e le ragioni di questo riconoscimento cambiano storicamente. La sua tripartizione (tradizionale, carismatica, razionale-legale) è una mappa dei fondamenti su cui l'autorità poggia, non dei meccanismi attraverso cui opera. In questo snodo/questione interviene invece **Foucault**, il cui contributo non riguarda la forma della legittimazione ma il meccanismo della produzione della materia della stessa: la verità. Il **regime di verità** non si chiede chi comanda, si chiede come viene costruito ciò che conta come vero, attraverso quali istituzioni, quali procedure, quali criteri di inclusione e di esclusione. La domanda weberiana è *perché gli obbediamo?*; la domanda foucaultiana è *come hanno costruito il mondo in cui obbedire sembra razionale?*. Sono domande complementari, non alternative, e la loro sovrapposizione illumina aspetti che ciascuna, da sola, lascerebbe in ombra. Il terzo vertice di questo triangolo analitico è quello di **Latour**, che sposta l'attenzione dalla struttura dell'autorità e dal meccanismo della verità alla catena di mediazioni attraverso cui entrambe si rendono operative. Per Latour, nessun sistema di autorità funziona per contatto diretto tra il detentore e il destinatario: funziona sempre attraverso catene di mediatori, ciascuno dei quali traduce, trasforma e, inevitabilmente, aggiunge qualcosa di proprio al messaggio che trasmette [4, 5]. Il sacerdote traduce la parola divina, lo scienziato traduce il dato sperimentale in conclusione pubblicabile, il giornalista traduce la conclusione scientifica in notizia comprensibile, l'algoritmo traduce il comportamento dell'utente in raccomandazione personalizzata. In ciascun passaggio, la mediazione è costitutiva e non neutra. Ciò che arriva al destinatario non è mai l'originale, è sempre un prodotto, una rielaborazione ed a volte un cascame della catena. Se si compongono queste tre lenti, la lettura delle transizioni storiche che seguono diventa considerevolmente più ricca. Per ciascuna fase sarà possibile chiedersi, simultaneamente: su quale forma di

legittimazione si regge l'autorità di quel periodo (Weber)? Attraverso quali meccanismi istituzionali viene prodotta e certificata la verità (Foucault)? E quali catene di mediazione rendono operative sia l'autorità sia la verità, con quali gradi di opacità e con quali effetti di trasformazione (Latour)? La genealogia che segue è il tentativo di applicare sistematicamente questa triplice interrogazione a ciascuna delle quattro fasi che, a mio giudizio, scandiscono il rapporto tra l'umanità e le proprie fonti di autorità.

1.3 Prima fase: il Verbo e i suoi intermediari

“In principio era il Verbo [...] e il Verbo era Dio.” — (Giovanni, 1.1)

Si può dare per fatto storico, dove per storia si intende qualcosa di più della mera elencazione di accadimenti, ma l'accezione più ampia di storia dell'uomo, della cultura e del pensiero, che al principio di ogni narrazione ci sia la divinità. A prescindere da quale tradizione e da quale specifica cosmogonia si voglia considerare, il principio di autorità è stato, per gran parte della storia antica, attribuito a una dimensione trascendente. Un dio, o un pantheon di divinità, al quale ci si rivolgeva, per tramite di umanissime interfacce (intermediate o disintermediate a seconda dei casi e delle preferenze culturali), per porre domande, cercare spiegazioni e sperare in risposte, attivando, con curiosa similitudine con più recenti sistemi informatici ugualmente complessi, una serie di protocolli per fare interagire tra loro e con il richiedente una varietà di entità. Superstizione come antidoto alla mancanza di risposte: un sistema, in fondo in fondo, che è sempre stato efficientemente funzionale al suo scopo. Sulla scorta del principio di necessità hanno prosperato generazioni di sacerdoti, mistici, vestali e ogni altra sorta di umana interfaccia con la divinità, entità così assoluta e assolutamente distante da permettere la contemporanea autoassoluzione continua rispetto all'ignoranza e l'esercizio di un potere altrettanto assoluto e assolutamente concreto. Il punto cruciale, che Bruno Latour aveva intravisto con grande lucidità nei suoi lavori sulla mediazione [4, 5], è che ogni sistema di autorità funziona attraverso catene di mediatori che traducono l'inaccessibile in accessibile. La divinità non è un'eccezione, è il prototipo. Il sacerdote non comanda, nel senso ordinario del termine; egli traduce (con gradi di opacità che sono propri della tradizione culturale e sociale a cui ci si riferisce ed introducendo nella traduzione, come sempre, qualcosa che appartiene al traduttore). Questa architettura di sistema, con un'entità originaria di cui si conosce il risultato ma non il meccanismo, con interfacce umane che mediano l'accesso, con protocolli rituali che codificano le modalità di interrogazione e di risposta, con un codice esoterico accessibile solo agli iniziati, ha una parentela strutturale molto stretta con quella di un certo tipo di intelligenza artificiale contemporanea. La divinità conservava gelosamente il suo sapere e lo dispensava solo in forme esoteriche. La convinzione che basti una “s” (un token in più, quindi) per trasformarla in forma essoterica nella nostra condizione presente è un errore concettuale sul quale torneremo. Sarebbe però sbagliato leggere questa prima fase come una semplice era di oscurantismo superata dalla ragione. La struttura dell'autorità teocratica aveva caratteristiche di efficienza che ancora oggi ricerchiamo primariamente: rispondeva al bisogno di certezza di fronte all'ignoto fornendo un sistema di valori condivisi che consentiva la coesione sociale e delegava a istituzioni riconoscibili il compito di gestire le domande esistenziali. Quello che rendeva questo sistema vulnerabile non era la sua irrazionalità, era

la sua rigidità. Quando le domande sono cambiate, il sistema non era in grado di cambiare le risposte.¹

1.4 Seconda fase: la razionalità come nuovo assoluto

“Ultimo viene il corvo”, ma prima viene l'uomo — Italo Calvino, 1949

Il progresso della Scienza in tutte le sue forme (medicina, matematica, filosofia naturale, fisica, chimica) e l'aumento della sua diffusione per tramite delle invenzioni che hanno reso possibile la vera divulgazione, dalla stampa di Gutenberg in poi, costituiscono la prima grande discontinuità che ha assestato un colpo importante, anche se non definitivo, all'asse di equilibrio del principio di autorità. Il processo che Max Weber ha descritto con il termine *Entzauberung*, che si traduce solitamente come “disincantamento del mondo”, è esattamente questo: il progressivo declino delle spiegazioni magico-religiose dei fenomeni naturali e sociali, sostituite da spiegazioni causali che fanno riferimento a leggi, meccanismi, forze descrivibili e misurabili. D'un tratto, in un processo che ha richiesto anni, decenni e secoli, ma che per l'orizzonte temporale della storia costituisce comunque una discontinuità, si è affacciato sul palco dell'autorità un attore nuovo, in grado di dare, se non tutte, almeno alcune risposte nuove e alternative agli interrogativi che affliggevano l'umanità: la razionalità incarnata (per natura) nella specie umana. L'uomo collettivo, l'intelligenza e la razionalità espresse per tramite di quel bipede al (quasi) vertice della catena alimentare che, ponendosi le domande, è stato in grado di costruire una strada per trovarne anche le risposte. Questa capacità ha fatto fiorire quella fiducia quasi incrollabile nelle capacità umane che ha caratterizzato l'Umanesimo e poi, in forme più strutturate e istituzionalizzate, l'Illuminismo. Uomo inteso come entità espressione di intelligenza collettiva, ma con un riferimento al singolo che diventa sempre più marcato a mano a mano che si afferma, non in antitesi, ma in completamento dell'essere umano collettivo, l'“umano essere” individuale (quasi “essente” nella sua composita unicità). A partire dalla fine dei secoli “bui” è stato possibile iniziare, senza più imbarazzo, a fare domande alla Scienza e ascoltare le risposte dal Sé, e viceversa, abbandonando progressivamente quel ricorso all'irrazionale per spiegare l'ignoto e sostituendolo con una fiducia crescente nella capacità umana di comprendere, misurare, prevedere (che, a giudicare dai fatti, sembra malriposta, ma questo è un altro tema).

È importante però notare ciò che questa transizione non ha fatto: non ha eliminato la struttura del principio di autorità, l'ha semplicemente spostata. L'autorità della Scienza non è meno assoluta, nelle sue forme consolidate, dell'autorità della religione, arrivando nelle sue manifestazioni a “sostituirla”. Il rapporto con i suoi intermediari (scienziati, esperti, tecnici) replica strutturalmente il rapporto con i sacerdoti: la maggioranza della popolazione non ha accesso diretto ai meccanismi che producono la conoscenza scientifica e si fida dei risultati in forza dell'istituzione, non della comprensione diretta. Quello che Weber chiamava “autorità razionale-legale” non è razionale nel senso che chi la esercita sia sempre comprensibile a chi la riceve: è razionale nel senso che poggia su procedure codificate e astratte, non su tradizioni o carismi personali. La sequenza che Foucault chiamerebbe “regime di verità” si è semplicemente aggiornata: non più il testo sacro come criterio di verità, ma il metodo sperimentale, la peer review, la statistica. Chi controlla questi processi detiene il potere di definire cosa è reale. E la Scienza, come tutte le istituzioni, è stata storicamente controllata

¹Uno spirito geneticamente illuminista e orientato al futuro, con una malcelata speranza più ancora che la necessità di rappresentare l'evoluzione delle fasi in una prospettiva temporale, mi ha spinto a coniugare al tempo passato le riflessioni sull'autorità teocratica. Purtroppo la correttezza del tempo verbale è data solo in alcune fortunate geografie e non in altre, nelle quali invece il tempo presente è ancora disperatamente quello proprio.

da attori specifici con interessi specifici (oggi molto semplificati nella loro decodifica: il denaro, punto), il che non ne invalida i risultati, ma dovrebbe rendere più cauta la nostra fede nella sua neutralità. È anche in questo contesto che va letto il decentramento progressivo dell'uomo descritto da Copernico, da Darwin e da Freud, i tre “spintoni cosmologici” che qualsiasi testo che voglia dirsi fondamentale del pensiero etico contemporaneo richiama come precedenti storici dell'AI. Ciascuno di questi spostamenti ha sottratto all'uomo una certezza sulla propria centralità (nel cosmo, nella catena del vivente, nella propria psiche), ma ognuno di essi ha paradossalmente rafforzato l'autorità della razionalità umana come unico strumento disponibile per indagare questa condizione. Anche quando la Scienza ci dice che non siamo al centro, lo fa attraverso un processo che è integralmente umano e umanamente scientifico.

1.5 Terza fase: Dal Se(lf) al Se(lfie), l'autorità dell'io ipertrofico

Il moto centripeto che aveva fatto rompere tangenzialmente le orbite dell'autorità dal divino all'umano ha subito un'ulteriore e inattesa accelerazione grazie, o a causa, di due delle *disruption* che hanno caratterizzato la fine del secolo scorso: le batterie agli ioni di litio (John Goodenough, 1980, Nobel per la Chimica nel 2019) e il Walkman della Sony (1979). Due invenzioni che oramai sembrano parte di una quotidianità storica e che invece hanno rimodellato molto più profondamente di altre la topologia dell'autorità. Per poter concentrare ulteriormente su di sé la referenza e l'autorità, l'uomo come essere collettivo aveva bisogno di strumenti che gli consentissero di affermarsi come essere individuale. Ovverosia di strumenti che gli consentissero di ignorare selettivamente (ovunque volesse) e consapevolmente (ogni qual volta ne avesse necessità) l'esistenza degli altri suoi simili e di poterlo fare per un tempo sufficientemente lungo perché gli altri si rassegnassero all'idea di essere ignorati. La combinazione di Walkman e batterie portatili ha reso possibile esattamente questo: uno spazio acustico privato in un contesto pubblico, la possibilità di abitare un mondo interiore mentre si è fisicamente presenti in quello esteriore. Lo sviluppo tecnologico successivo, dai videogiochi agli mp3 agli smartphone, che altro non sono se non sofisticate varianti sul tema del Walkman, ha ulteriormente focalizzato questo moto verso l'interiorità ipertrofica. E pertanto dal Se(lf) siamo arrivati al Se(lfie) come apoteosi di espressione solipsistica di un'autorità assoluta, assolutamente autoreferenziale, che ancora confonde la presenza con la partecipazione, nonostante questa sia proprio una delle cose che il digitale consente di separare senza perdita di significato. Non è una coincidenza che il termine “selfie” sia entrato nell'**Oxford English Dictionary** nel 2013, nello stesso periodo in cui gli smartphone avevano raggiunto una diffusione di massa sufficiente a rendere la fotografia di sé stessi una pratica quotidiana per centinaia di milioni di persone. Christopher Lasch aveva già descritto, nel 1979, con straordinaria lucidità anticipatoria in *The Culture of Narcissism* [6], i processi sociali che avrebbero prodotto questo esito, molto prima che gli smartphone li rendessero visibili e misurabili. Il narcisismo di massa non è un prodotto della tecnologia portatile: è un prodotto di dinamiche culturali profonde che la tecnologia portatile ha semplicemente amplificato e reso esplicito. Il *selfie* è la manifestazione visibile di un processo di concentrazione dell'autorità sull'io che aveva radici molto più antiche. Il rischio di questa fase, come anticipatoriamente identificato da Eli Pariser che ne aveva colto il meccanismo nel 2011 con il concetto di “filter bubble” [7], è che l'algoritmo delle piattaforme digitali abbia completato il lavoro iniziato dal Walkman: se il Walkman isolava acusticamente, l'algoritmo delle piattaforme isola epistemicamente. Non senti più le voci degli altri, ma soprattutto non incontri più le idee degli altri. L'autorità dell'io ipertrofico viene paradossalmente amplificata da un sistema algoritmico che seleziona le informazioni in funzione di ciò che l'utente ha già dimostrato di apprezzare o a cui si è, anche in

modo inconsapevole, dichiarato interessato, creando un circolo virtuoso (per il gestore della piattaforma) e vizioso (per la qualità epistemica dell'individuo) che porta l'io a confondersi sempre più con il tutto.

1.6 Quarta fase: l'algoritmo come nuovo oracolo

In onore di al-Khuwārizmī — Muhammad ibn Musa al-Khwarizmi (c. 780 – c. 850)

Algoritmo, sì. Digitale, sì. Perché alla fine sempre lì si arriva. Quello che ci ha sottratto l'effimero piacere di essere diventati, in qualche modo, dispensatori e fruitori di un'autorità da noi stessi espressa è proprio il fatto che l'evoluzione digitale ha di nuovo spostato al di fuori di noi il principio stesso di quella autorità. Al di fuori di noi e forse ancora più lontano di dove era collocato all'origine del percorso. Perché se all'inizio la divinità conservava gelosamente il suo sapere e lo dispensava solo in forme esoteriche, oggi l'algoritmo mette tutta la conoscenza a disposizione in modo completamente essoterico. In un modo talmente abituale che le risposte, anche a problemi etici oltre che pratici e medici, le cerchiamo su Google e, oggi, le chiediamo a modelli linguistici che nel tempo impiegato a leggere questa frase producono migliaia di token su qualsiasi argomento. In un modo talmente naturale che lo sviluppo già concretamente in corso dei sensori biometrici potrebbe presto permetterci di chiedere all'algoritmo “come sto?”, ricevendo da esso una risposta più attendibile di quella che riceveremmo chiedendolo a noi stessi o a un medico. Questo spostamento ha una caratteristica che lo distingue da tutti i precedenti: per la prima volta nella storia, il sistema-autorità è stato costruito dall'uomo, ma non è immediatamente comprensibile e compreso dall'uomo. Frank Pasquale, nel suo *The Black Box Society* (2015) [8], aveva identificato con precisione il meccanismo: l'opacità degli algoritmi non è accidentale né temporanea, è strutturale. Sappiamo cosa producono, conosciamo i risultati, possiamo osservare gli effetti. Ma il processo che conduce dal dato al risultato è, nella maggior parte dei casi di interesse pratico, non direttamente comprensibile dall'essere umano. Questo è esattamente il pattern della divinità. La divinità produceva risultati (pioggia, vittoria, guarigione) e noi conoscevamo i rituali per richiederli (preghiera, sacrificio, offerta). Ma il meccanismo interno della divinità era, per definizione, inaccessibile all'umano. La distanza tra input e output era così grande che si chiamava miracolo. Con l'AI la distanza tra input (il prompt che scriviamo) e output (la risposta del modello) è altrettanto grande, ma non la chiamiamo miracolo: la chiamiamo “intelligenza artificiale emergente” o “proprietà del sistema”, espressioni che funzionano esattamente come il miracolo nel senso che nominano (e denominano) ciò che non capiamo senza spiegarlo.

La differenza cruciale, e qui la parentela con la divinità si interrompe, è che l'AI non pretende di avere un'intenzione. Il dio aveva intenzioni, giudicava, premiava e puniva in funzione di un piano che aveva un senso e una coerenza “interna”, anche se non decifrabile. L'algoritmo non ha intenzioni, produce correlazioni. Ma questa assenza di intenzione dichiarata non risolve il problema dell'autorità: di fatto le correlazioni dell'algoritmo diventano norme di comportamento, guide per la decisione, criteri di giudizio. L'algoritmo che decide chi ottiene un mutuo, quale notizia appare nel feed, quale curriculum viene scartato, quale prezzo viene mostrato, esercita una forma di autorità normativa senza avere, formalmente, alcuna autorità legittima nel senso weberiano del termine. Volendo proseguire idealmente il lavoro di Bruno Latour, potremmo descrivere questa situazione come un caso estremo di mediazione: l'uomo ha costruito un mediatore così potente da essere diventato il mediato. Non è più l'uomo che usa l'algoritmo per accedere alla conoscenza, è l'algoritmo che

accede all'uomo attraverso il suo comportamento, le sue preferenze, le sue interazioni, per produrre un modello dell'uomo stesso che poi viene usato per influenzarlo. L'ago della bussola dell'autorità ha completato un giro completo: dal dio che guida l'uomo attraverso intermediari umani, all'uomo che si guida da sé, all'uomo che si fa guidare da un sistema che lui stesso ha costruito, ma non controlla.

Bello, eh?

Tabella 1.1: La genealogia del principio di autorità: quattro fasi a confronto

Fase	Detentore dell'autorità	Tipo weberiano	Comprensibilità del meccanismo	Velocità della transizione
Teocratica	Divinità (mediata da sacerdoti, profeti, oracoli)	Tradizionale	Nulla per il laico; esoterica per gli iniziati	Millenaria
Razionalista	Scienza e ragione umana collettiva	Razionale-legale	Alta in linea di principio; mediata in pratica	Secolare
Individualista	Il Sé (l'io ipertrofico, l'individuo digitalmente isolato)	Carismatica autoreferenziale	Completa in apparenza; illusoria in profondità (Freud)	Generazionale
Algoritmica	L'algoritmo (e chi lo detiene e lo addestra)	Nessun tipo weberiano applicabile; richiede una quarta categoria	Nulla, incluso per i costruttori stessi	Decennale e in accelerazione

Tre osservazioni a margine:

- Le fasi non si sostituiscono, si stratificano. Oggi (purtroppo) ancora convivono autorità teocratiche, razionaliste, individualiste e algoritmiche, spesso in conflitto tra loro e spesso nella mente della stessa persona, talvolta nello stesso momento. La genealogia non è una freccia, è un sedimento.
- La colonna “comprensibilità del meccanismo” non misura la qualità dell'autorità, ma la sua *governabilità*. Un sistema di autorità il cui meccanismo è comprensibile è, almeno in linea di principio, criticabile, riformabile, responsabilizzabile. Un sistema di autorità il cui meccanismo è opaco non lo è, indipendentemente dalla qualità dei risultati che produce.
- La velocità crescente delle transizioni non è una legge naturale, ma un dato empirico della storia recente. È precisamente questa velocità a rendere urgente il tipo di lavoro che questo libro si propone di fare.
- La quarta fase non trova collocazione in nessuno dei tipi weberiani. Per tentare una formalizzazione provvisoria (provvisoria perché si tratta di una fotografia necessariamente mossa, visto che il soggetto è in movimento) possiamo definire l'**autorità algoritmica** come una forma di dominio legittimato dalla performance predittiva, fondato su correlazioni statistiche tra dati in quantità e complessità tali da rendere strutturalmente opaco il processo che conduce al risultato, il cui meccanismo di legittimazione opera non per riconoscimento esplicito (come nel tipo tradizionale o carismatico) né per adesione razionale a procedure codificate (come nel tipo razionale-legale), ma per assuefazione funzionale (quella che più avanti chiamerò anche la resa cognitiva): ci si affida all'algoritmo non perché se ne comprenda il funzionamento, e nemmeno perché un'istituzione ne garantisca l'affidabilità, ma perché il risultato che produce è sufficientemente utile, plausibile e comodo da rendere il non-uso più costoso dell'uso. La legittimazione, in altri termini, è performativa e abitudinaria, non deliberativa. Questa forma di autorità ha almeno tre condizioni di vulnerabilità distintive. La prima è l'assenza di un soggetto morale responsabile del risultato: l'algoritmo non risponde, nel senso etico del termine, delle proprie raccomandazioni. La seconda è l'opacità strutturale, non contingente, del meccanismo: a differenza

della Scienza, il cui metodo è in linea di principio replicabile, l'output di un modello di deep learning con centinaia di miliardi di parametri non è ricostruibile da chi lo riceve, e spesso nemmeno da chi lo ha addestrato. La terza è la velocità con cui questa forma di autorità si è diffusa, che non ha consentito lo sviluppo di anticorpi istituzionali e culturali comparabili a quelli che le transizioni precedenti, pur con tempi molto più lunghi, avevano comunque prodotto.

1.7 La struttura ricorrente: cosa cambia e cosa resta

Rileggendo questa genealogia, emerge con una certa nitidezza una struttura che vale la pena di rendere esplicita, perché è questo pattern che fa di questo capitolo qualcosa di più di una storia curiosa e che lo rende, si spera, una cornice utile per tutto ciò che segue. Le domande restano le stesse attraverso le fasi e attraverso i secoli. *Chi sono? Dove vado? Perché? Come stare bene? Come fare la cosa giusta? Come sapere cosa è vero?* Queste domande le poneva l'uomo che interrogava l'oracolo di Delfi, le poneva il filosofo illuminista che sfidava l'autorità della tradizione, le pone oggi chi chiede a un modello linguistico di aiutarlo a capire una diagnosi medica (da cui l'appello dell'OMS che nel 2025 implorava l'umanità di smetterla di caricare sui chatbot le proprie analisi del sangue, cosa che, sono sicuro, abbiamo fatto tutti) o a prendere una decisione professionale difficile. La struttura della domanda è rimasta straordinariamente stabile. Quello che cambia è a chi si pone la domanda, perché ci si fida della risposta e con quale grado di comprensione del meccanismo che produce la risposta. Su questo terzo elemento, la comprensibilità del meccanismo, la genealogia disegna una curva interessante. La divinità aveva un meccanismo del tutto incomprensibile, accessibile solo in via mediata e attraverso codici esoterici. La Scienza moderna ha introdotto un meccanismo in linea di principio trasparente: il metodo sperimentale, per essere tale, deve essere replicabile, verificabile e, dove necessario, opponibile e falsificabile. Chiunque abbia le competenze necessarie deve poter, almeno in principio, ripercorrere il ragionamento ottenendo gli stessi risultati. L'individuo come autorità suprema ha un meccanismo completamente trasparente a sé stesso, anche se spesso illusoriamente: l'io si crede trasparente a sé stesso, Freud ci ha mostrato che non è esattamente così e le neuroscienze ci spiegano (anche con riferimenti biologici) il perché. L'algoritmo ha un meccanismo di nuovo opaco, ma con una caratteristica inedita rispetto alla divinità: è opaco anche ai suoi programmatori, non solo ai suoi utilizzatori.

C'è poi un elemento di velocità che non va trascurato. I tempi di transizione tra le fasi si sono sistematicamente accorciati. Millenni ha impiegato il principio di autorità a spostarsi dalla divinità alla ragione. Secoli ha impiegato a spostarsi dalla ragione collettiva all'individuo. Decenni ha impiegato a spostarsi dall'individuo all'algoritmo. E questa accelerazione ha una conseguenza pratica molto importante: il tempo disponibile per adattare le istituzioni, il diritto, la cultura, l'etica alle nuove strutture di autorità si riduce a ogni transizione. Quando la Scienza ha sfidato la religione, la Chiesa ha avuto secoli per rispondere e ha risposto (con il Concilio di Trento, con l'adattamento progressivo, con l'assorbimento di molte conquiste scientifiche nel proprio sistema di pensiero). Quando l'algoritmo sfida la razionalità umana, le istituzioni hanno anni, se va bene hanno mesi.

Questo è precisamente il problema che mi propongo di affrontare: non (solo) come funziona l'AI (ci sono infinite risorse più autorevoli e infinite anche meno per quello), ma come governare la transizione di autorità che l'AI sta producendo, con strumenti adeguati ai tempi di questa transizione.

1.8 Cambiare le domande

Aspettando Go(d)ot — Samuel Beckett, 1952

Quale sarà la prossima discontinuità e quali conseguenze avrà sull'equilibrio del principio di autorità? Imprimerà un'accelerazione in quale direzione? Nessuno può saperlo. Come recita un famoso adagio attribuito a Niels Bohr, “è difficile fare previsioni, soprattutto sul futuro”. Quello che è certo è che, quale che sia l'entità alla quale le domande fondamentali saranno rivolte, l'uomo continuerà a formularle, perché sono parte fondamentale di come esso costruisce la sua immagine e rappresentazione nel mondo. La metafora epigrafica di Beckett non è casuale. In “Aspettando Godot”, i due protagonisti attendono passivamente l'arrivo di un'entità che non capiscono, di cui non conoscono le intenzioni e che non arriva mai. L'attesa è l'unica loro attività. C'è qualcosa di *beckettianamente* inquietante nell'idea di aspettare che l'algoritmo ci dica come vivere, cosa scegliere, cosa pensare, mentre continuiamo a interrogarci su chi siamo e dove andiamo. L'alternativa che credo sia opportuno proporre non è romantica, né luddista, né tantomeno semplicemente regolamentare. È metodologica. Se il problema è che stiamo attribuendo all'algoritmo un'autorità epistemica, normativa (e anche tecnica) che non sappiamo governare, la risposta non è togliergli quell'autorità (un'impresa impraticabile, oltre che probabilmente non desiderabile), ma cambiare le domande. Non “cosa può fare l'AI?”, ma “a cosa è opportuno che risponda?”. Non “l'AI è intelligente?” ma “quale tipo di autorità le stiamo attribuendo e con quali meccanismi di controllo?”. Non “come si usa l'AI?” ma “come si governa la relazione tra l'uomo e un sistema che esercita un'autorità di tipo nuovo?”.

E se fosse giunto il momento di cambiare domande, giusto così, per vedere cosa succede?

Capitolo 2

Novità vs. innovazione: un primo tentativo di debunking all'hype dell'AI generalista

C'è un'estate, nella vita di ogni osservatore del presente, in cui le cose già viste tornano con la forza a confondere le cose nuove. L'estate del 2025 ha avuto per me questa caratteristica: settimane di letture sull'AI, decine di articoli, ricerche, dichiarazioni di intenti, e alla fine la sensazione di aver già percorso quella strada, non parlando e pensando strettamente e solamente all'AI, ma a qualcos'altro di, quanto meno, affine. Il ragionamento che mi è tornato in mente lo avevo scritto nel 2019, in un contesto completamente diverso, quando l'AI generativa non era ancora nei titoli dei giornali e il dibattito sull'innovazione riguardava IoT, blockchain, e le prime effettive incursioni del machine learning nelle practice aziendali. Lo avevo intitolato "Critica alla contemporanea ambiguità semantica del termine innovazione", che è esattamente il tipo di titolo che si dà a un testo quando si vuole celare dietro una apparente aria composta un furore crescente. Il ragionamento di allora, riletto oggi, calza perfettamente. Forse troppo perfettamente.

2.1 Mappa infografica del capitolo



Figura 2.1: Mappa logica del Capitolo 2

2.2 Una confusione che viene da lontano

“Se vogliamo che tutto rimanga com’è, bisogna che tutto cambi.” — G. Tomasi di Lampedusa, *Il Gattopardo*.

1958

Quando scrissi il succitato pamphlet (ho sempre adorato il termine, ne ho sempre adorato i fini, ho sempre aspettato di potermi riferire ad un qualche mio “delirio” con quel nome) il fastidio era che in ogni evento, presentazione e documento aziendale i termini “innovazione”, “trasformazione” e “disruption” venissero usati come sinonimi intercambiabili, e quasi sempre con una polarizzazione semantica acriticamente ottimistica. L’innovazione era sempre positiva, sempre necessaria, sempre imminente (quando non immanente). Nessuno si fermava a chiedersi il significato delle parole che stava utilizzando, se quindi le stesse usando nel modo corretto, e soprattutto nessuno sembrava interessato a farlo.

La prima contraddizione che avevo rimarcato (dico rimarcato perché, come tutto, la mia altro non era che la rielaborazione di concetti che avevo già sentito) era quella tra innovazione e miglioramento. I due termini non sono né sinonimi linguistici né equivalenti logici. Innovazione si riferisce a qualcosa di esistente, di realizzato, di oggettivo. Miglioramento è un’espressione di valori, e come tale relativa per definizione: l’equivalenza non regge perché se è vero che per migliorare bisogna cambiare, non è affatto detto che un

cambiamento sia necessariamente apportatore di miglioramento. La storia dell'innovazione umana è costellata di trasformazioni anche epocali che hanno mostrato un lato oscuro e prodotto, nell'uso, conseguenze negative significative. La scrittura, per esempio, è stata una delle prime disruption nella storia dell'umanità: ha costituito un supporto esterno alla memoria, ma proprio per questa sua caratteristica ha contribuito all'atrofia delle capacità mnemoniche non supportate tecnologicamente. La stampa ha permesso la diffusione della cultura con una velocità e un'ampiezza prima inimmaginabili, ma lo ha fatto così in fretta da superare la velocità della produzione culturale stessa, che, innescando una sorta di meccanismo di conservazione del volume complessivo della cultura, ha ridotto la profondità per allargarne la base (e lo stesso si potrebbe dire, ad esempio, della differenza tra scattare fotografie con un cellulare e farle facendo i conti con le limitazioni oggettive e fisiche del rullino, dello sviluppo, della stampa e dei costi connessi).

La seconda contraddizione era ancora più rilevante per il tema che ci interessa: ciò che chiamiamo innovazione spesso non è una novità. Molto spesso l'innovazione non è altro che l'applicazione di qualcosa di noto o di abituale al perseguimento di un obiettivo differente da quello originario. Altre volte è semplicemente l'evoluzione tecnologica di base a rendere praticabili innovazioni già preconizzate ma fino ad allora irrealizzabili per ragioni di costo, di scala o di maturità infrastrutturale. La cosiddetta Rivoluzione Copernicana, che teorizza in modo scientifico il sistema eliocentrico, era in nuce da almeno duemila anni: era stata preconizzata da Aristarco di Samo, ed era nota anche a Tolomeo, la cui visione geocentrica è logicamente equivalente a quella copernicana dal punto di vista della descrizione del moto dei pianeti. Quello che cambia è il punto di osservazione, non la scoperta del fenomeno. Lo stesso calcolatore elettronico, quando fu teorizzato da Turing nel 1936, aveva già quasi un secolo di storia “non applicata” nel lavoro di Babbage: la vera innovazione fu la disponibilità di tecnologie elettroniche sufficientemente efficienti da renderlo costruibile, non l'idea in sé.

La terza contraddizione, quella più scomoda, è che spesso facciamo precedere l'adozione all'uso: adottiamo tecnologie prima che si sia stabilizzato un modello condiviso di come usarle responsabilmente. I social network sono l'esempio più recente e bruciante di questa corsa all'(ab)uso adozione. Abbiamo costruito piattaforme di scala globale prima di porre seriamente le questioni sulla privacy, sull'uso dei dati, sul diritto all'oblio, sull'impatto sui processi democratici. Abbiamo adottato strumenti potenti convinti che il percorso di evoluzione tecnologica fosse inarrestabile e giusto “di per sé”, e quella convinzione ci ha distratti dal compito di definirne i limiti prima di averne fatto un'infrastruttura cognitiva di massa.

Poi avevo aggiunto una nota finale sul tema della velocità e dell'accelerazione, che mi sembra ancora oggi la distinzione più sottovalutata nell'intero dibattito sulla trasformazione tecnologica: forse dovremmo smettere di preoccuparci tanto della rapidità con cui i cambiamenti avvengono, ovverosia la velocità istantanea, e cominciare a prestare attenzione all'accelerazione impressa da questi cambiamenti all'ambiente circostante. Possiamo adattarci all'alta velocità, e la nostra esperienza di abitanti di questo pianeta ce lo dimostra quotidianamente. Ma siamo molto meno equipaggiati a gestire anche marginali accelerazioni che modificano le leggi di riferimento con cui interpretiamo il contesto. Riletto oggi, questo testo sembra scritto per descrivere esattamente ciò che sta accadendo con l'AI generativa. Le tre contraddizioni sono presenti, amplificate e su scala globale. Il problema non è cambiato: è semplicemente diventato più urgente.

2.3 Il presente che conferma la diagnosi

“Ma l'imperatore è nudo!” — Hans Christian Andersen, I vestiti nuovi dell'imperatore, 1837

Da settembre del 2022 ho fatto dell'AI generativa il mio principale tema di ricerca e approfondimento, sia accademico che professionale. E da quando seguo questo argomento ho potuto rilevare che il dibattito pubblico ha sempre oscillato tra entusiasmo incontrollato e preoccupazione diffusa, con una narrazione quasi sempre polarizzata e concentrata sui modelli di AI generalista: chatbot sempre più sofisticati, capacità conversazionali in grado di imitare l'interazione umana, strumenti capaci di produrre testi, immagini e codice in pochi secondi anche grazie a crescenti attitudini “agentiche” (e quindi di una limitata autonomia che concediamo). Questo racconto, per quanto suggestivo, rischia di far passare in secondo piano sia le necessarie considerazioni tecniche per comprendere potenzialità e limiti, sia trasformazioni molto più profonde e strutturali.

La conferma empirica più strutturata che ho trovato di questa diagnosi è la ricerca del 2025 del MIT NANDA Project, che ha misurato con precisione quello che ha chiamato “GenAI Divide” [9]. Il dato è netto: la quasi totalità delle organizzazioni ottiene ancora oggi zero o near ROI misurabile dai propri progetti di AI (soprattutto quando questi sono, in realtà, distribuzioni a pioggia acritiche di manciate di licenze di ChatBot a supporto di attività individuali marginali e non sono accompagnate da vere trasformazioni). Solo una minima parte dei progetti AI realmente integrati arriva effettivamente in produzione. Non si tratta di aziende che hanno fallito l'implementazione tecnica. Si tratta di aziende che hanno adottato la novità, convinte che la novità e l'innovazione fossero la stessa cosa. Hanno fatto esattamente ciò che le tre contraddizioni descrivono: hanno equiparato innovazione a miglioramento automatico, hanno scambiato la novità di uno strumento per un cambiamento strutturale, e hanno adottato prima di capire come usare. Il GenAI Divide non è un fallimento tecnologico: è un fallimento semantico ed epistemologico. È la conseguenza misurabile di una confusione concettuale che dura da decenni e che l'AI generativa ha semplicemente reso più visibile e più costosa.

2.4 La distinzione che conta

“La storia non si ripete, ma spesso fa rima.” — Attribuita a Mark Twain (1835-1930)

Il momento per tornare sul punto è quindi più che mai oggi: è fondamentale distinguere tra “novità” e “innovazione”. I due termini non sono equivalenti né intercambiabili.

La novità è ciò che appare nuovo in un dato momento: per l'AI in questi anni è stato il lancio di un modello più grande, un'interfaccia più intuitiva, una capacità agantica meno ancora supervisiona(bile)ta od un'applicazione inedita. Ogni nuova release di GPT, Claude o Gemini è una novità, spesso ragguardevole sul piano tecnico. L'innovazione, invece, è qualcosa che implica un cambiamento sostanziale nel modo in cui pensiamo, agiamo o organizziamo i processi: modifica strutture, abitudini, metriche e, in ultima analisi, i risultati economici e i meccanismi con cui il valore viene creato e distribuito.

Nel campo dell'AI, gran parte di ciò che oggi viene celebrato come innovativo rientra in realtà nella categoria della novità: importante, certo, e talvolta impressionante, ma ancora un'evoluzione incrementale di concetti già noti. Schumpeter aveva formalizzato questa distinzione nell'ambito dell'economia nel 1942, distinguendo tra invenzione (la produzione di un'idea nuova), innovazione (la sua prima applicazione economica) e imitazione (la sua diffusione) [10]. In questa triade, la maggior parte di ciò che passa per innovazione nel dibattito corrente sull'AI è in realtà imitazione: l'adozione diffusa di strumenti già esistenti, senza che questo adozione cambi i meccanismi attraverso cui le organizzazioni creano valore.

Un'azienda che usa un chatbot per redigere le email è un'azienda che ha acquisito una novità (peraltro di impatto tendenzialmente marginale). Un'azienda che ha ridisegnato il proprio processo decisionale integrando modelli addestrati sui propri dati proprietari, con metriche di successo misurate sui propri KPI di business, sta perseguendo qualcosa che ha il profilo dell'innovazione nel senso schumpeteriano. Questa distinzione non è pedanteria terminologica. Ha conseguenze dirette sulle scelte strategiche, sulle aspettative di ritorno, e sulla capacità di valutare lucidamente se ciò che si sta acquistando o implementando risolve un problema reale o soltanto ne allontana la percezione. Questa lettura schumpeteriana trova conferma convergente in contributi recenti provenienti da prospettive diverse. LeGrande e Lakshminarayanan, nel loro lavoro sull'AI-Driven Value Management [11], osservano che la maggior parte delle organizzazioni utilizza l'AI come strumento di ottimizzazione incrementale all'interno di processi invariati, senza mai interrogarsi su come la tecnologia potrebbe ridisegnare la catena di creazione del valore per il cliente. Thomas, Zikopoulos e Soule [12] spingono la distinzione ancora oltre, introducendo il concetto di "AI Value Creator" in esplicita contrapposizione con quello di "Generative AI User", documentando come le organizzazioni che hanno superato la soglia dell'imitazione schumpeteriana siano quelle che hanno ricostruito i propri processi decisionali attorno ai dati proprietari, non attorno agli strumenti generalisti (queste letture peraltro saranno utili per la seconda parte, in particolare per il capitolo 4 di questo lavoro). Musiol [13], in una prospettiva più orientata alla traiettoria tecnologica, avverte che la confusione tra novità incrementale e innovazione strutturale è particolarmente pericolosa nel contesto dell'AI generativa, proprio perché l'immediatezza scenografica dell'output (testi, immagini, codice ...) maschera l'assenza di un cambiamento nei meccanismi sottostanti. D'altro canto gli incentivi strutturali al confondere le due cose sono potenti e non sono casuali. I fornitori di modelli e strumenti hanno tutto l'interesse a presentare ogni aggiornamento come una rivoluzione, perché è così che si giustificano prezzi crescenti e cicli di rinnovo brevi. Chi cerca disperatamente di rientrare di investimenti (sbagliati) offrendo servizi o prodotti che invecchiano come le fragole al sole hanno interesse a mantenere alta la percezione di urgenza, perché l'urgenza scoraggia la riflessione e accelera la firma. I media specializzati sopravvivono sull'attenzione, e l'attenzione si cattura con l'insolito, il primo, il più grande, il più veloce. In questo ecosistema, la novità è strutturalmente sovrarappresentata e l'innovazione strutturalmente sottorappresentata, non per malevolenza ma per incentivi di carattere meramente economico. La distorsione produce una asimmetria informativa a danno delle organizzazioni che devono decidere: chi compra decide in un mercato che sistematicamente esagera i benefici delle novità e sottostima il lavoro organizzativo necessario per trasformarle in innovazione. Il GenAI Divide non è un'anomalia: è il risultato prevedibile di questo sistema di incentivi applicato a scala industriale.

2.5 La rivoluzione, il suo terreno ed il suo orizzonte

In questo contesto distorto, emerge tuttavia una prospettiva che si colloca, a mio giudizio totalmente sindacabile, oltre il perimetro della novità per entrare a pieno titolo nel dominio dell'innovazione, nel senso che modifica strutture, meccanismi e metriche, non solo strumenti. Essa riguarda il passaggio da un uso passivo dell'AI, quello tipico dell'"AI user" che consuma output generalisti, a un approccio proattivo di creazione di valore. È la transizione che separa chi usa un chatbot "assistant" per le email da chi ha costruito sistemi intelligenti ed, in alcuni casi (estremi), agentici radicati nei propri dati proprietari, nei propri processi, nella propria conoscenza tacita. Questa transizione è la prima rivoluzione vera: non è una questione di strumenti più sofisticati, ma di un cambio di paradigma nel rapporto tra l'organizzazione e la tecnologia. Il come di questa transizione, le tecniche, le figure organizzative, le metriche, è materia di un successivo capitolo.

Su un orizzonte temporale (leggermente) più lungo, e proprio perché il suo essere "in divenire" la rende a questo punto più nominata che sviluppata, si affaccia lo scenario di una sempre maggiore convergenza tra AI, capacità computazionali avanzate e robotica software e hardware (di fatto è un processo già in atto), che accorcia i cicli decisione-azione e apre possibilità di automazione intelligente che ridisegneranno interi settori. Non la chiamo seconda rivoluzione, perché il suo grado di maturità oggi non lo consente ancora, ma è l'orizzonte verso cui la rivoluzione attuale prepara il terreno. Ho scritto molto sul tema dell'automazione e dell'automazione intelligente, ma non sono ancora sicuro se dedicherò a questa seconda traiettoria un capitolo autonomo, perché il suo grado di maturità e la velocità con cui il panorama si trasforma renderebbero qualsiasi trattazione sistematica obsoleta prima ancora di terminarne la scrittura. Sicuramente continuerò a rilevarne le manifestazioni concrete là dove esse emergono (in particolare nella discussione sugli agenti AI e sull'illusione agentica che ne accompagna la narrazione), senza la pretesa di una mappatura esaustiva di un territorio ancora troppo in formazione. Per le organizzazioni, il punto non è sapere quando questa convergenza raggiungerà la maturità commerciale, ma capire che le fondamenta che si costruiscono oggi sulla prima rivoluzione determineranno la capacità di sfruttarla quando arriverà. La rivoluzione e il suo orizzonte di evoluzione condividono un tratto che vale la pena di rendere esplicito, perché è la conclusione pratica dell'intero ragionamento di questo capitolo: entrambe spostano il focus dall'adozione acritica di strumenti "alla moda" alla costruzione di un ecosistema di valore. Non vincerà chi possiede il modello più aggiornato o chi è stato il primo ad adottare ogni nuova versione. Vincerà chi saprà costruire il valore più proprio (volevo scrivere più intimo ma mi sono trattenuto), più radicato nella propria realtà operativa (e soprattutto sui propri dati, che costituiscono veramente l'asset intangibile del presente), e più difficile da replicare da chiunque disponga degli stessi strumenti generalisti. In un mercato dove gli strumenti si commoditizzano velocemente, il vantaggio competitivo si sposta sui dati, sui processi, sulla conoscenza e sulla disciplina con cui tutto questo viene integrato. La gara non è di potenza: è di pertinenza e di rilevanza contro la mera plausibilità. Non è (più) solo un gioco per "grandi". Non servono i budget delle grandi multinazionali per competere nell'era dell'AI. Serve la chiarezza strategica per distinguere ciò che è novità da ciò che è innovazione, e il coraggio di dire no alle prime per investire nelle seconde. In un contesto dove la velocità è importante ma la direzione è decisiva, questa distinzione può fare la differenza tra essere spettatori passivi del cambiamento o protagonisti consapevoli della propria evoluzione. Nel seguito, prima di addentrarci nelle rivoluzioni vere, è necessario fermarsi sulla domanda con cui tutta questa trasformazione deve fare i conti: con quali strumenti morali intendiamo governarla?

Capitolo 3

ConcrEthica: la bussola etica che forse ancora non abbiamo

Che un informatico di formazione accademica, il cui “day job” è fare il partner di una grande società di consulenza, si avventuri nel terreno dell’etica e della filosofia, sebbene relativamente e limitatamente alla loro applicazione alla sua materia di competenza, potrebbe far storcere il naso a più di qualcuno. Me ne farò una ragione, auspicando che, sulla medesima linea di sensibilità intellettuale, analoga scelta sia condivisa dai lettori. La ragione per cui questo capitolo esiste, tuttavia, non è l’ambizione di contribuire in modo necessariamente originale al dibattito filosofico sull’etica dell’AI, che è già ricco e articolato e non ha bisogno di principianti (perché già tanti ve ne sono). La ragione è più semplice e più urgente: dopo aver affrontato nel Capitolo 1 lo spostamento verso l’algoritmo del principio di autorità, ed aver osservato (nel Capitolo 2) la sistematica confusione tra novità e innovazione, ci si trova di fronte a una domanda che non è possibile rimandare ulteriormente. Con quali strumenti morali intendiamo governare questa transizione? E la risposta, a mio giudizio, è che gli strumenti che abbiamo a disposizione, pur necessari, non sono sufficienti.

3.1 Mappa infografica del capitolo




Figura 3.1: Mappa logica del Capitolo 3

3.2 Il quarto spintone: l'invenzione che decentra più della scoperta

*“Le macchine mi sorprendono molto di frequente.” — Alan Turing, *Macchine calcolatrici e intelligenza* (1950)*

L'umanità ha affrontato, nel suo percorso storico, almeno tre grandi trasformazioni che hanno contribuito a ridisegnare, a volte radicalmente, la percezione della propria centralità e il proprio modo di vedere il mondo e se stessa. Prima è venuto Copernico, che ci ha resi consapevoli del fatto che la Terra non fosse al centro dell'universo ma orbitasse attorno al Sole, scardinando l'idea della nostra centralità rispetto al cosmo e ridimensionando la nostra posizione nell'universo (come già detto riprendendo ed aggiornando teorie pre-esistenti). In seguito Darwin ha rivelato che l'uomo è il frutto di un lungo processo evolutivo, condividendo le sue origini con altre specie e infrangendo l'illusione di essere centro e apice unico della vita sulla Terra in termini, quanto meno, di regno “animale”. Nel secolo scorso Freud ha messo in dubbio la nostra idea di essere completamente padroni delle nostre azioni e dei nostri pensieri, rivelando una complessità interiore inaspettata e sottraendoci la comodità di un'autoconsapevolezza integra e “finita”. Queste tre rivoluzioni hanno progressivamente decentrato l'essere umano rispetto al cosmo, alla biologia e alla propria psiche, spingendoci a confrontarci con nuove verità e a rivedere il nostro rapporto con il mondo.

Luciano Floridi [15]: ha identificato, a completamento di questa sequenza, il pattern di ciò che chiama “quarta rivoluzione”: la digitalizzazione, e in particolare l’intelligenza artificiale, costituisce un quarto e per certi versi più radicale decentramento, perché mette in discussione il primato cognitivo, forse l’ultimo baluardo dell’auto-affermata centralità umana. Volendo, per mimesi, conservare l’associazione a un personaggio storico, potremmo ricondurre questa quarta trasformazione a Turing, anche se la forzatura è evidente: Turing non ha scoperto una verità scomoda sull’uomo, bensì ha progettato e dimostrato (in via teorica, per lo meno) la possibilità di simulare gli esiti del pensiero con una macchina. Ed è proprio questa differenza, apparentemente tecnica, che porta con sé le conseguenze filosoficamente più dirompenti. C’è infatti una differenza fondamentale tra i quattro spostamenti che vale la pena di rendere esplicita, perché è da questa differenza che nascono le questioni etiche più urgenti. Le prime tre rivoluzioni erano scoperte: Copernico, Darwin e Freud ci hanno detto qualcosa che era già vero e che non sapevamo. Il quarto è invece il prodotto di un’invenzione: siamo noi ad aver costruito la tecnologia che ora mette in discussione la nostra centralità cognitiva. Chi è causa dei suoi mali, si potrebbe dire, con l’ironia che si riserva alle situazioni in cui la lucidità sulla radice del problema non aiuta a risolverlo. Questa distinzione non è soltanto filosoficamente interessante: risulta eticamente decisiva. Di fronte a una scoperta, possiamo solo adattare la nostra postura. La Terra orbitava già attorno al Sole prima che Copernico lo dimostrasse finalmente, e continuerà a farlo indipendentemente da ciò che decidiamo. Di fronte a un’invenzione, invece, possiamo, e dobbiamo, scegliere. La questione non è se sviluppare l’AI, una domanda alla quale la storia ha già risposto con velocità ed irreversibilità proporzionali solo agli investimenti effettuati. La questione è come, con quali intenzioni, con quali salvaguardie, con quali meccanismi di correzione e, soprattutto, con quale consapevolezza delle implicazioni che stiamo producendo.

Ed è precisamente su questo “come” che gli strumenti concettuali e istituzionali di cui disponiamo mostrano le loro insufficienze.

Paolo Benanti ha descritto questo momento come un “cambio d’epoca” [18], distinguendolo con cura da un’epoca di cambiamenti. Non stiamo assistendo a trasformazioni quantitative all’interno di un quadro stabile: stiamo assistendo al ridisegno del quadro stesso. Le categorie con cui abbiamo pensato la tecnologia, il lavoro, l’identità, la conoscenza e la responsabilità sono tutte, in misura diversa, in discussione simultaneamente. E questa simultaneità è, di per sé, una sfida etica, perché le istituzioni che producono ed applicano norme (i parlamenti, i tribunali, le università, le amministrazioni, persino i regimi) operano per definizione con tempi più lunghi della velocità con cui le sfide emergono. La forbice tra la velocità del cambiamento tecnologico e la velocità delle istituzioni normative è uno dei principali generatori di vuoto etico con cui ci troviamo a convivere.

3.3 Quando lo strumento smette di essere neutro

“Plasmiamo i nostri strumenti e poi i nostri strumenti plasmano noi.” — John Culkin 1967

L’uomo, animale “naturalmente tecnologico”, si è tradizionalmente rapportato alla tecnologia con l’obiettivo prevalente di efficientare attività e azioni da svolgere, partendo da una base di conoscenza circa le attività da effettuare derivata dalla propria esperienza. In questo senso ha sempre privilegiato valutazioni legate all’incremento della performance nello sviluppo e nell’innovazione degli strumenti per mezzo dei quali ha trasformato il mondo che abita. La sega elettrica è un esempio paradigmatico: un’innovazione altamente

efficiente di una tecnologia non nuova, che sfrutta una evoluzione tecnologica di base (l'energia elettrica) per rendere possibile aumentare la quantità di lavoro svolto nell'unità di tempo. Vista in questa prospettiva, il lavoro da fare (il *Job To Be Done*, per dirla con Ethan Mollick) non cambia. Cambia invece, a volte anche radicalmente, il modo con il quale decidiamo di svolgerlo. In questa classe di tecnologie, la valutazione morale riguarda esclusivamente l'uso che se ne fa: la sega elettrica è moralmente neutra in sé, e sono le intenzioni e le azioni di chi la usa a portare valore morale (che è compito umano definire come positivo o negativo). Le tecnologie digitali con le quali ci troviamo a confrontarci oggi, invece, perseguono non solo l'obiettivo di efficienza ma vi affiancano, a volte in modo prevalente, quello dell'efficacia, nel senso che rendono possibili cose che sarebbero semplicemente impossibili senza di esse. Si pensi alla separazione tra la presenza fisica e la partecipazione che il digitale permette con le videochiamate e i meeting remoti: non si tratta di fare più velocemente qualcosa che si faceva già (efficienza), ma di fare qualcosa di strutturalmente diverso (efficacia). Ed in molti casi lo si può fare per la prima volta (imprenditorialità). I risultati prodotti da queste tecnologie, visti dal di fuori, possono sembrare talmente indistinguibili da quelli prodotti da esseri umani da trasformare il nostro stesso rapporto con la tecnologia. In presenza di tecnologie in grado di rispondere in modo efficace ed efficiente alle domande che vengono loro poste, il ruolo dell'uomo si trasforma necessariamente da portatore di risposte a decisore circa quali domande sono rilevanti e prioritarie. In questa trasformazione si riverbera anche quella, più generale, del nostro tempo: da un'epoca dell'accumulo e della memorizzazione (performativo assoluto misurabile in efficienza) a un'epoca della selezione e dell'eliminazione (performativo relativo misurabile in efficacia). La distinzione non è soltanto tecnica: è una distinzione sulla natura del valore umano nel processo produttivo e decisionale. Questo spostamento ha una conseguenza etica diretta che raramente viene nominata con la chiarezza che merita. Quando uno strumento cessa di essere puramente orientato all'efficienza attraverso l'amplificazione delle capacità umane (condizione che relega le considerazioni etiche al solo impiego che dello strumento viene fatto) e produce risultati che vanno nella direzione dell'efficacia e lo fa in modo imprenditoriale (ovverosia per la prima volta), la tecnologia inizia ad assumere una sorta di intenzionalità che può indirizzare l'uomo verso determinati comportamenti. Questa classe di soluzioni tecnologiche cessa di essere moralmente neutrale, dove per neutrale si intende passiva, e assume un valore morale che si esprime e dipende dai comportamenti verso i quali essa indirizza. Un esempio quotidiano per illustrare questa dinamica con immediatezza. Lo smartwatch che "sollecita" certi comportamenti ritenuti positivi, raggiunto il quale siamo già all'interno di un territorio dove qualcuno ha deciso cosa è positivo per noi: un insieme di intenzioni (quelle dei progettisti ad esempio) che si è reso concreto in un oggetto tecnologico e che opera silenziosamente sull'orientamento delle nostre abitudini quotidiane. Chi ha stabilito le soglie? Con quale criterio? In funzione di quale modello od obiettivo di salute e di vita? Non appena queste domande vengono sollevate, si rivela quanto il confine tra strumento e indirizzo morale sia sottile. E siamo già, mani e piedi, dentro il dominio dell'etica. Un esempio più estremo ed esteso (e purtroppo attualissimo, nell'intera sua declinazione di livelli) è quello della fissione nucleare: strumento ineguagliabile di efficienza nella generazione di energia elettrica che, trasformata in armamento, diventa strumento di deterrenza e, costituendo la tecnologia attorno alla quale si sono organizzati e polarizzati i due grandi schieramenti del Novecento, finisce per diventare un'espressione culturale e definitoria dell'intera specie umana (che può esistere o non esistere in funzione di essa). In questo caso, la tecnologia non è più un mezzo neutro che l'uomo usa: è diventata il contesto entro il quale l'uomo definisce le sue alleanze, le sue paure ed i suoi equilibri di potere in vista ed in funzione di fini esistenziali.

Al livello più radicale di questa evoluzione, siccome ogni cultura si manifesta attraverso gli artefatti e i manufatti tecnologici che crea, la tecnologia, quando pervade integralmente l'agire di una comunità, diventa il

modo e il senso attorno al quale la comunità stessa si organizza.

Dobbiamo quindi chiederci se, nel momento storico in cui ci troviamo, gli strumenti concettuali, culturali e filosofici di cui disponiamo siano adeguati agli impatti che questi nuovi strumenti digitali, e in particolare l'intelligenza artificiale, hanno nel quotidiano. Siamo preparati a rispondere alle domande etiche proprie di un mondo che si organizza attorno a manufatti tecnologici il cui funzionamento non siamo in grado di spiegare fino in fondo, almeno non nel modo deterministico in cui ci siamo abituati a spiegare le cose tecniche? La risposta onesta fatica ad essere altro che “no”. L'essere umano tecnologicamente supportato è sorretto da cause che comprende, e quando i risultati sono spiegabili in termini di causa-effetto, le categorie morali tradizionali reggono bene. Ma quando ci troviamo di fronte alle nuove tecnologie digitali e ai comportamenti che producono e inducono, e questi non possono essere più semplicemente spiegati come effetti di cause note, ci vengono a mancare delle categorie concettuali che dobbiamo interamente ridefinire (anche in termini ontologici, anzi innanzitutto in questi termini). La responsabilità di chi? La causalità di cosa? L'intenzionalità di chi ha scritto l'algoritmo, o di chi ha raccolto i dati? Questi interrogativi non sono accademici: sono le domande pratiche a cui un giudice, un regolatore, un manager o anche solo un individuo “utilizzatore” devono già oggi saper rispondere, e per le quali gli strumenti esistenti si rivelano sistematicamente inadeguati.

3.4 Leggi, governance, compliance, etica: insieme che si sfuggono e non si contengono

“Corruptissima re publica plurimae leges.” — Publio Cornelio Tacito, *Annales* (117 d.C.)

L'urgenza di rispondere a queste sfide giustificerebbe, da sola, la ricerca e la spinta verso una nuova interpretazione morale, sia nell'agire delle tecnologie sia nella postura da assumere nei loro confronti. La confusione sorge però quando la convinzione di aver già fatto “tutto quello che era necessario” (come ad esempio mettere qualche bel filtro sul firewall per bloccare accessi a chatbot, riflesso pavloviano di ogni IT manager medio(cre)) si scontra con la consapevolezza che qualcosa manca ancora. Il problema è frequente nelle organizzazioni: si produce un documento di policy sull'uso responsabile dell'AI, magari si nomina un comitato etico, si dichiara l'adesione a qualche framework internazionale, si chiude qualche rubinetto e si ritiene di aver assolto l'obbligo. Questo equivoco nasce dalla mancata distinzione tra quattro insieme che spesso vengono trattati come sinonimi, e che invece sono profondamente diversi per natura, meccanismi di enforcement, scopo (e fine) nonché ambito di applicazione.

Le leggi sono istituti fondamentali di una società che regolano i comportamenti per assicurare ordine e giustizia, istituendo nel contempo meccanismi sanzionatori per i comportamenti che violano gli indirizzi normativi. La legge dice cosa non si può fare (e talvolta cosa si deve fare), e prevede conseguenze in caso di violazione. È il livello della coercizione esplicita, e la sua efficacia dipende dalla chiarezza delle fattispecie e dalla capacità degli organi preposti di applicare le sanzioni.

La governance è un insieme di regole tramite le quali un'organizzazione, o una porzione di società, gestisce se stessa. Si ispira ed è guidata dalle leggi (una porzione organizzata della società non può darsi regole contraddittorie rispetto alle leggi che governano il tutto), ma non avendo istituti formali che ne assicurino il rispetto, dispone di strumenti limitati per garantirne l'applicazione interna.

La compliance rappresenta l'intersezione necessaria ma insufficiente tra leggi e governance: assicura che un comportamento normato da una legge sia recepito anche nella governance aziendale e che non vi siano contraddizioni, ma non copre il territorio dell'etica.

L'etica, infine, è l'insieme dei principi morali che regolano i comportamenti in funzione di un principio di giusto e sbagliato. Per sua natura, inerendo a valutazioni qualitative che non si prestano a formalizzazione coercitiva, non può essere codificata in istituti sanzionatori. È sempre insufficiente come strumento di governo, ma forse anche per questo indispensabile come bussola.

Questi quattro insiemi si intersecano senza sovrapporsi completamente, e la loro non-coincidenza è la radice strutturale del problema. Non possiamo aspettarci che da un complesso di leggi o regolamenti emergano, da sole, indicazioni e prescrizioni di carattere etico: la legge vieta, l'etica orienta. Sono operazioni logicamente distinte, e confonderle produce o un eccesso di legalismo (l'idea che rispettare la norma esaurisca il dovere morale) o un eccesso di eticismo astratto (l'idea che enunciare principi equivalga a praticarli - in altri contesti questo è il desiderismo .. quando speriamo che per fare accadere qualcosa basti deciderlo o volerlo). Sebbene l'Europa abbia adottato un impianto normativo apprezzabile, dal GDPR fino all'AI Act (Regolamento UE 2024/1689), per il momento il più articolato e completo nel panorama globale, questo da solo non surroga il bisogno di una riflessione etica più estesa e profonda. L'AI Act incorpora alcuni principi etici irrinunciabili nella nascente relazione tra l'uomo e queste tecnologie, ma l'assenza di una visione complessiva globale e la mancanza di meccanismi attuativi concreti rischiano di rendere quella norma, e quelle che eventualmente da essa si gemmeranno, un vuoto esercizio di stile. La battuta che gli i miei colleghi a stelle e strisce amano ripetere, secondo cui “gli americani inventano, i cinesi copiano e gli europei proibiscono”, va accolta non come critica ma come stimolo: il fatto che l'Europa sia l'unica (o quanto meno la prima) ad aver tentato una regolamentazione organica è già un merito, ma il tentativo non basta a sé stesso. Paolo Benanti, nel suo lavoro sull'algor-etica [17], ha articolato con precisione perché la sola regolamentazione giuridica sia strutturalmente insufficiente: un'etica dell'AI che si limiti a vietare i comportamenti peggiori senza orientare positivamente lo sviluppo è come una medicina che curi i sintomi senza affrontare la malattia. La proposta di Benanti, che richiama esplicitamente la tradizione del pensiero cristiano-sociale, è che il “human in the loop” non sia solo una clausola tecnica dei sistemi di AI, ma una postura epistemologica e morale: la supervisione umana sulle decisioni algoritmiche non è un optional di buona prassi, è una condizione necessaria per il mantenimento della responsabilità morale nel ciclo decisionale. Detto in modo più diretto: se tolgo l'umano dal loop, non tolgo solo una funzione tecnica surrogabile, tolgo il soggetto morale. E senza soggetto morale, la responsabilità si dissolve, non perché nessuno abbia fatto nulla, ma perché le strutture concettuali che la fondano non trovano più un agente cui attenersi. Il che ci porta a chiedersi: dove, esattamente, nella catena che va dai dati alle decisioni, le questioni etiche emergono con più urgenza? E questa domanda richiede, prima di poter rispondere con utilità pratica, di capire con sufficiente precisione come quella catena funziona.

3.5 La catena del valore digitale come mappa delle questioni etiche

“La mappa non è il territorio.” — Alfred Korzybski (1931)

Prima di proseguire, un avvertimento unita ad una dichiarazione di intenti. Le pagine che seguono rappresentano il passaggio più tecnico di questa prima parte del libro, e il cambio di registro rispetto alle riflessioni filosofiche che precedono è consapevole e deliberato (e financo necessario). La ragione è semplice: non è possibile parlare di etica dell'AI con un minimo di credibilità senza aver prima compreso, almeno nelle sue linee essenziali, la catena di trasformazioni che conduce dal dato grezzo alla decisione operativa. È in questa catena che le questioni etiche si annidano concretamente pertanto vale la pena di percorrerla con un grado di dettaglio che è da considerarsi come un investimento (breve, promesso) di attenzione con rendimento differito.

In soccorso di una visione più pragmatica può venire una comprensione dei meccanismi logici e tecnici che sottendono al funzionamento di questa classe di soluzioni digitali. Proviamo a srotolare la “catena del valore” che il digitale esprime e realizza, partendo, per una volta, dal fondo anziché dall’inizio, seguendo il verso del ragionamento invece di quello della narrazione.

MAPPA DEL VALORE DEI DATI: DAL REALE ALLA CONOSCENZA




Figura 3.2: Data Value Chain

Iper-semplificando, possiamo dire con buona approssimazione che gli esseri umani adottano soluzioni tecnologiche principalmente come supporto alle decisioni, manageriali o quotidiane, che devono prendere. Sulla base del supporto che ricevono, prendono decisioni che modificano il mondo in cui vivono (quello reale, sia esso fisico o virtuale). Assumono queste scelte basandosi sulla conoscenza che viene loro messa a disposizione dai tool che usano, conoscenza è prodotta a partire dalle informazioni di cui il tool dispone, che a loro volta sono il frutto di un processo di sintesi analitica dei dati raccolti e organizzati dal sistema informativo. I dati raccolti, organizzati e trattati sono una mappa, ovverosia una rappresentazione necessariamente approssimata della realtà di riferimento (proprio quella realtà che tramite le azioni conseguenti andremo a modificare).

Vale la pena ora di percorrere questa catena anche nell'altra direzione, dall'inizio alla fine, soffermandosi sugli elementi trasformativi introdotti a ogni passaggio, in modo da identificare con precisione dove e come si inseriscono le questioni etiche (spoiler: in ogni dove).

Il punto di partenza (e di arrivo) è sempre uno solo: la realtà. Per tramite di tecniche di acquisizione e sensorizzazione viene prodotta una mappa che approssima la realtà. Ogni datificazione di un fenomeno che avviene nel "continuo" implica sempre una certa imprecisione: le carte geografiche sono mappe (im)perfette che rappresentano la realtà pur non essendola, e lo stesso vale per ogni dato che rappresenta la realtà.

Questi dati hanno caratteristiche oggi mnemonicamente identificabili nelle cinque "V":

volume (la mole di informazione raccolta è di gran lunga superiore alla capacità di analisi tradizionale),

velocità (la frequenza di aggiornamento è in molti casi pressoché real-time),

variabilità (le fonti sono eterogenee e i formati non standardizzati),

veridicità (non tutti i dati raccolti sono accurati e affidabili)

valore (non tutti i dati raccolti portano informazione utile).

Sono, in sintesi, tanti, troppi e complicati, e devono essere organizzati, resi confrontabili, gestibili, memorizzati e trattati, pur sapendo che non portano necessariamente contenuto informativo diretto. I dati, entità informativamente neutre (non ontologicamente inerti, ma questo è altro discorso), possono esprimere contenuto quando ad essi si applichi un processo di sintesi analitica che li classifica, seleziona e arricchisce progressivamente di connotazioni che sintetizziamo in tre dimensioni: struttura, significato e valore semantico. La struttura identifica l'insieme di caratteristiche che un dato deve esprimere per rappresentare un'informazione. Il significato disambigua in modo univoco il contesto di riferimento al quale il dato appartiene. Il valore semantico certifica l'esistenza di quel significato nel contesto di riferimento e, soprattutto, la sua coerenza con la rappresentazione del mondo reale al quale si riferisce.

Un esempio può essere d'aiuto, per quanto necessariamente incompleto e tirato per capelli od ogni altra appendice tricotica. Il numero 30 e il numero 30.000.000 sono inequivocabilmente dati, ma non portano, di per se, informazione che vada oltre la loro esistenza concettuale in quanto numerali a rappresentazione di numeri. Se aggiungo una struttura (ad esempio il simbolo "°") ottengo 30° e 30.000.000°: dati con struttura, ma ancora ambigui nel significato: non ci inequivocabilmente dicono di cosa stiamo parlando. Solo quando disambiguo ulteriormente il contesto (non angoli, ma temperature Celsius) faccio un passo avanti verso l'informazione. E infine: 30°C è un'informazione sensata, mentre 30.000.000°C non lo è, perché il dato strutturato e significativo non ha valore semantico nel contesto di verità nel quale viene letto (la temperatura stimata del nucleo del Sole è circa 15.000.000°C, e quindi 30.000.000°C non è né vero né falso: non ha semplicemente senso come informazione sul mondo che conosciamo e rappresentiamo).

Potremmo quindi dire che il dato con struttura è informazione "come il reale"; il dato con struttura e significato è informazione "per il reale" (una serie limitata di istruzioni per l'uso); il dato con struttura, significato e valore semantico è informazione "sul reale", ovvero sia è una proposizione che può essere valutata come vera o falsa nel mondo a cui si riferisce. Solo i dati che superino questo sbarramento logico portano valore informativo e possono essere utilizzati per costruire conoscenza. La disponibilità strutturata di informazioni non significa conoscenza, ma permette di derivarla tramite processi correlativi, ovvero processi logici e matematici basati su probabilità e statistica (nota bene, non probabilità o statistica, ma proprio probabilità

e statistica). Nel caso dell'AI discriminativa e generativa, tramite algoritmi molto sofisticati basati su reti neurali e deep learning, ma il *job to be done* non cambia: si cercano semplicemente correlazioni su nature diverse di dati (numeri, pezzi di parole in linguaggi naturali) usando strumenti di ricerca molto più potenti. La conoscenza che generiamo, adeguatamente presentata, ci permette di prendere decisioni che, una volta agite, modificheranno il mondo che ci circonda. Questo mondo trasformato sarà poi nuovamente datificato, rientrando nel circolo che abbiamo descritto.

Vorrei concentrare l'attenzione su due snodi centrali di questa catena per rimarcare la portata del cambio di "specie" che stiamo osservando, quanto meno in relazione al rapporto con le tecnologie. Il primo snodo è quello tra dati e informazioni: la raccolta, classificazione e trasformazione dei dati in informazioni riposa sul principio dell'approssimazione selettiva, il che significa che i dati che trattiamo sono ancora "riferiti", per quanto in modo molto approssimato e decisamente "imperfetto", direttamente al reale da cui scaturiscono. Il secondo snodo è quello tra informazioni e conoscenza: quando trasformiamo le informazioni in conoscenza, perdiamo il legame con il "reale", perché la conoscenza è espressione sintetica di una correlazione statistica e probabilistica. Non è più una rappresentazione approssimata del reale: è un'astrazione che ne cattura i pattern ma non le singole istanze.

In altri termini: *prendiamo decisioni che modificano il nostro mondo reale partendo da dati generati da algoritmi probabilistici (ai quali nel caso dell'AI generativa forniamo noi stessi lo strato semantico necessario a rendere il risultato qualcosa di sensato e non solo plausibile), e che si poggiano su una sintesi di dati che approssimano grossolanamente la realtà*. La distanza tra il risultato prodotto e la realtà cui si riferisce non è soltanto tecnica: è una distanza epistemologica che, non essendo più visibile nella forma del risultato (l'AI generativa produce testo fluente, immagini verosimili, ragionamenti articolati), tende sistematicamente a essere sottovalutata. Che sia urgente l'esigenza di sviluppare un'etica nuova per governare questa nascente complessità dovrebbe essere, a questo punto, fuori discussione.

3.6 I cinque principi fondativi della Digital Ethics

"Il vero problema non è se le macchine pensano, ma se gli uomini lo fanno." — Burrhus Frederic Skinner (1969)

Come molto di quanto scritto fino a qui, ciò che segue non è originale: è la miglior definizione disponibile, formulata da chi del tema ha fatto la propria ricerca principale. La filosofia utile, quella che parla delle cose del mondo e del tempo in cui viene sviluppata, è chiamata non solo a formulare le domande ma anche, laddove è possibile, a indirizzare le risposte. E il modo in cui ci si può avvicinare responsabilmente a questo tentativo è di non fare mai domande delle quali non si conosca già la risposta: il mantra che viene somministrato agli studenti delle facoltà di Legge negli Stati Uniti il primo giorno di lezione, e che nel nostro contesto significa non enunciare principi che non si sia già in grado di tradurre in indicazioni operative. La Digital Ethics, secondo Floridi [14], è *"un nuovo ramo dell'etica che studia e valuta i problemi morali legati ai dati (compresa la generazione, registrazione, cura, elaborazione, diffusione, condivisione ed uso), agli algoritmi (inclusi intelligenza artificiale, agenti artificiali, apprendimento automatico e robot), e alle relative pratiche e infrastrutture (inclusi l'innovazione responsabile, la programmazione, l'hacking, i protocolli e i codici professionali), al fine di formulare e sostenere soluzioni moralmente corrette"*.

Ciò che colpisce immediatamente di questa definizione è l'estensione e la portata dell'ambito di interesse che abbraccia. Non si parla solo di dati e algoritmi, ma anche dei metodi per il trattamento e il governo degli stessi, le infrastrutture sulle quali i dati risiedono e vengono elaborati, e persino i risultati fruiti, il che comporta considerazioni etiche che riguardano l'hardware stesso (cosa trovo particolarmente affascinante: pensare alla *moralità* di un hard disk, ovvero di un oggetto fisico che contiene rappresentazioni digitali di persone reali, con tutto ciò che ne consegue in termini di responsabilità sulla conservazione, l'accesso, la cancellazione). È chiaro che, dovendo attraversare trasversalmente tutte le tecnologie, non vi è altro modo di incorporare l'etica nell'ecosistema se non *by design*: dall'inizio, dalla progettazione. Illudersi di poter correggere il tiro una volta disegnato, implementato e rilasciato un componente, un algoritmo o una soluzione è una pia illusione, non perché non si possa tecnicamente intervenire, ma perché a quel punto i comportamenti indotti, i *bias* incorporati e le asimmetrie di potere generate hanno già prodotto effetti reali. Floridi propone cinque principi fondamentali che devono guidare ogni atto di progettazione e sviluppo di ogni elemento della catena del valore digitale. Vale la pena menzionarli e provare ad applicarli esplicitamente ai livelli della catena che abbiamo descritto, non come esercizio accademico ma come tentativo di rendere la loro applicazione concreta e tracciabile.

La non maleficenza , ovvero non causare danno e prevenirlo laddove possibile, si applica con priorità al livello della datificazione. Nei processi di acquisizione, conservazione e trattamento dei dati dobbiamo rispondere a tre domande: i sistemi sono sicuri rispetto ad accessi non autorizzati? La privacy degli individui è rispettata, non solo formalmente in sede di consenso, ma sostanzialmente nel modo in cui i dati vengono poi utilizzati e combinati? Il consenso è stato ottenuto in modo genuinamente informato, oppure si è nascosta la reale portata del trattamento dietro l'opacità delle condizioni di servizio? Questi non sono interrogativi astratti: ogni violazione di dati, ogni caso di uso improprio di informazioni personali, ogni sistema di profilazione non trasparente è una violazione concreta del principio di non maleficenza applicato al livello della datificazione. I principi sono formulati da Floridi in [14]; mi prendo invece la responsabilità della loro declinazione specifica ai livelli datificazione, informazione, conoscenza e decisione.

La benevolenza , ovvero contribuire positivamente allo sviluppo umano, si applica al livello della generazione dell'informazione. Nei processi in cui attribuiamo struttura, significato e valore semantico ai dati, dobbiamo assicurarci di curare l'interpretazione, identificare i bias sistematici e verificare l'integrità delle fonti. I *bias* nei dati di addestramento dei modelli di AI sono la manifestazione più evidente della violazione di questo principio: un sistema addestrato su dati storici che riflettono discriminazioni consolidate (in ambito lavorativo, di genere, di condizione sociale ad es creditizio, sanitario) produrrà sistematicamente raccomandazioni che perpetuano quelle discriminazioni, indipendentemente dalle intenzioni dei suoi progettisti. La benevolenza richiede un intervento attivo, non una mera astensione dal danno.

L'autonomia , ovvero rispettare l'autonomia umana e riservare sempre all'umano la facoltà di scegliere (o di rifiutare), si applica al livello della generazione della conoscenza. Nei processi correlativi dobbiamo assicurare l'accessibilità e la controllabilità del procedimento, per evitare (limitare, forse è più appropriato) le correlazioni spurie che sono sempre in agguato quando si lavora con trasformazioni statistiche dei dati, e verificare che gli strati semantici siano costruiti sulla base di rilevanze statistiche significative. Al

decrescere di questa significatività, il fenomeno delle cosiddette “allucinazioni” dei modelli linguistici diventa un rischio inaccettabile, non soltanto perché produce risultati errati, ma perché produce risultati errati in forma plausibile, ovvero in una forma che rende difficile all’utente non esperto riconoscerne l’errore. L’autonomia del soggetto umano è violata non solo quando gli si impedisce di scegliere se utilizzare o no strumenti di questo genere (ad esempio incorporandoli come funzione di base non “deselezionabile”), ma anche quando gli si forniscono conoscenze false in forma credibile.

La giustizia , ovvero contribuire a una equa distribuzione dei rischi e dei benefici, si applica al livello delle decisioni e delle azioni. Dobbiamo mantenere il primato dell’etica sociale anche a scapito della pura ragione economica, il che significa chiedersi, per ogni sistema di AI che produce decisioni, chi beneficia e chi sopporta i rischi, e se questa distribuzione sia equa. Questo è il principio più scomodo da applicare, perché è quello che entra più direttamente in conflitto con gli incentivi di mercato: i benefici dell’AI tendono a concentrarsi nei soggetti che possiedono i dati e le infrastrutture computazionali (poche grandi imprese tecnologiche), mentre i rischi (dalla potenziale perdita del lavoro alla sicura erosione della privacy ed a tutti gli effetti negativi dell’amplificazione delle disuguaglianze) tendono a distribuirsi più ampiamente.

L’esplicabilità , ovvero garantire la comprensibilità dei modelli di funzionamento ed evitare l’opacità dell’effetto black-box, è trasversale all’intera catena. È anche il principio che l’AI Act recepisce in modo più lacunoso (anche per via delle limitazioni tecniche che rendono questo principio, di fatto [... frase lasciata appesa volontariamente]): il diritto alla spiegazione delle decisioni algoritmiche è formalmente presente nel regolamento, ma i meccanismi attuativi sono ancora largamente inapplicati nella pratica. Il problema dell’esplicabilità non è soltanto tecnico (spiegare come funziona un transformer con centinaia di miliardi di parametri è genuinamente difficile): è anche epistemologico. Una spiegazione che sia comprensibile a un non esperto richiede necessariamente una semplificazione, e ogni semplificazione introduce distorsione. Il bilanciamento tra accuratezza della spiegazione e accessibilità della medesima è esso stesso una scelta etica.

3.7 ConcrEthica: la bussola dell’agire

“L’etica non è esattamente la dottrina di come renderci felici, ma di come dovremmo renderci degni della felicità.” — Immanuel Kant

Quando ho battezzato questa sintesi e rielaborazione concettuale “ConcrEthica” avevo una ambizione precisa: fare percepire questo insieme “normativo” non come una buffa astratta da proclamare nelle policy aziendali e poi dimenticare nei comportamenti quotidiani, ma una filosofia pragmatica da dimostrare in ogni singola scelta di progettazione, in ogni decisione su quali dati raccogliere, in ogni valutazione su quale correlazione è accettabile e quale non lo è. La differenza tra un “estetico annuncio” di voler fare la cosa giusta e un “etico agire” è esattamente la differenza tra dichiarare di aderire ai principi e applicarli livello per livello nella catena del valore. Questa distinzione non è retorica. Le organizzazioni che pubblicano documenti di AI Ethics policy aderendo a codici di condotta internazionali, magari anche istituendo comitati etici senza modificare alcunché nei processi di sviluppo, di raccolta e gestione dei dati è un atto prevalentemente

comunicativo a fini marketing, non un atto etico. Peggio: stanno producendo un'immunizzazione contro la critica ("abbiamo già un'etica policy") che rende più difficile l'identificazione e la correzione dei problemi reali. Il termine tecnico in letteratura è "ethics washing", e il fenomeno è sufficientemente diffuso da aver generato una letteratura critica specifica. Ad esempio Jobin, Ienca e Vayena [20], in una mappatura sistematica di 84 documenti di principi etici per l'AI pubblicati a livello globale, hanno documentato la significativa convergenza retorica dei principi dichiarati e, al contempo, la sistematica divergenza nelle modalità di implementazione, concludendo che la proliferazione di linee guida non si traduce automaticamente in pratica etica. Hagedorff [21] ha rafforzato questa diagnosi mostrando come la grande maggioranza dei framework etici per l'AI non preveda alcun meccanismo di enforcement, configurandosi come strumenti di legittimazione più che di governo. Come si traduce, allora, ConcrEthica in pratica? Non esiste una risposta unica, e sarei intellettualmente disonesto se proponessi un framework in n passi con tanto di checklist a risoluzione di un problema strutturale. Ciò che è possibile indicare sono alcune posture, alcune domande e alcune condizioni organizzative che rendono più probabile che l'etica entri davvero nei processi decisionali.

La prima postura è quella della **trasparenza attiva** verso se stessi prima che verso l'esterno. Un'organizzazione che si interroghi onestamente su quali dati utilizza, da dove provengono, chi li ha raccolti e con quale consenso, quali bias sistemici potrebbero essere presenti, e chi sopporta le conseguenze delle decisioni prodotte dal modello, sta già compiendo un atto etico concreto, indipendentemente dalla risposta che trova. Il problema non è avere le risposte giuste: è aver smesso di fare le domande. E nelle organizzazioni sotto pressione competitiva e di time-to-market, smettere di fare le domande scomode è la deriva più comune e più pericolosa.

La seconda postura è quella della **progettazione inclusiva** delle considerazioni etiche, che significa incorporare la valutazione etica non come audit ex-post sul prodotto finito, ma come elemento costitutivo del processo di design (o di scelta). È questa la ragione per cui Floridi insiste sul "by design": non come slogan, ma come constatazione pratica che l'etica inserita o verificata tardivamente non funziona.

La terza postura, forse la più difficile, è quella del **disagio come segnale positivo**. Convivere con il disagio della sfocatura dei confini tra il mondo digitale, dove le decisioni vengono prese, e il mondo reale, nel quale le conseguenze delle azioni si riverberano, non è un problema da risolvere: è la condizione normale di chi opera responsabilmente in un contesto di complessità genuina. L'assenza di disagio è, nella maggior parte dei casi, un indicatore che le domande difficili non vengono poste, non che siano state risolte.

Comportarsi eticamente in entrambi i mondi, quello digitale e quello reale, non è un obiettivo che si raggiunge una volta per tutte: è una pratica continuamente rinnovata, esattamente come lo è qualsiasi altra forma di rigore professionale. Ciascuno (organizzazione o singoli) di noi deve costruire la sua bussola etica, perché le mappe che abbiamo, ovvero leggi, governance e compliance, siano necessarie ma non sufficienti per usarla. La bussola senza le mappe è inutile, ma le mappe senza la bussola sono pericolose: indicano la posizione, non la direzione. In tutto il prosieguo di questo lavoro l'etica non sarà più capitolo o paragrafo separato: diventa la condizione di intelligibilità di tutto il resto. Senza di essa, la complessità rimane complessità; con essa, diventa sistema di significato.

Se l'etica è la condizione di intelligibilità, e se la bussola ha la forma che abbiamo definito allora siamo pronti ad orientarla verso le trasformazioni concrete che stanno ridisegnando il rapporto tra le organizzazioni e la tecnologia. La prima, e forse la più urgente, riguarda una transizione che si fatica ancora a riconoscere come tale: il passaggio da consumatori passivi di AI generalista a creatori attivi di valore attraverso l'AI. È di questo che mi occuperò a partire dal capitolo seguente.

Parte II

La rivoluzione (quella vera)

Cosa cambia e perché non è (solo) quello che pensiamo

“Non c’è nulla di più pratico di una buona teoria.” — Kurt Lewin (1890–1947)

Nella prima parte di questo lavoro (sulla motivazione che mi ha spinto ad iniziarlo non finirò mai di interrogarmi) ho cercato di fare ciò che chiunque affronti un viaggio a tappe dovrebbe provare a fare prima della partenza di una nuova tappa: verificare la posizione sulla mappa, accertarsi che la bussola funzioni e, quando è il caso, accettare con garbo la scoperta che il punto in cui ci si trova non corrisponde a quello in cui si pensava di essere. Le tre coordinate che ne sono emerse, storica, semantica ed etica, avevano precisamente questa funzione: non fornire risposte, ma rendere le domande successive meno scontate. Se il principio di autorità si è spostato dalla divinità all’algoritmo senza che la struttura profonda della delega cambiasse granché, se la confusione tra novità e innovazione continua a produrre investimenti privi di rendimento strutturale, e se l’etica rimane troppo spesso confinata nei documenti di compliance anziché incorporata nelle architetture decisionali, allora la domanda che sarebbe opportuno porsi adesso non è più “dove siamo” ma “cosa sta effettivamente cambiando” e cosa invece è solo una mistificazione percettiva. La seconda parte prova a rispondere a questa domanda con un cambio di registro per il quale mi sono concesso (d’altra parte sono io che scrivo, deciderò ben cosa mi concedo, no?) un certo coraggio terminologico: parlare di rivoluzione in un contesto dove la parola è stata inflazionata fino alla perdita di significato (quante “rivoluzioni” ci sono state negli ultimi cinque anni?) è un rischio che mi assumo dopo averlo calcolato. Accetto il rischio perché penso che la trasformazione in atto riguardi effettivamente le strutture, i meccanismi e le metriche con cui le organizzazioni creano e distribuiscono valore (efficacia), e non semplicemente gli strumenti con cui svolgono attività che svolgevano già prima, magari un po’ più velocemente e con qualche interfaccia più accattivante (efficienza). L’ipotesi (perché le certezze, le tesi ed i teoremi sono ad altri destinati) che attraversa i tre capitoli è una sola: l’adozione dell’AI di per se non è la rivoluzione ma costituisce il prerequisito perché si verifichi. La rivoluzione vera è infatti la transizione da utilizzatori semi-passivi di strumenti altrui a “costruttori” di sistemi basati su dati propri, cioè il passaggio da ciò che chiamo “AI User” ad “AI Value Creator”. È una distinzione che potrebbe sembrare lessicale e che invece è strutturale, perché separa chi usa in un modo “quasi avulso dal contesto” una tecnologia di diffusione comune (e ne subisce i ritmi, le evoluzioni ed i limiti decisi da altri) da chi costruisce sui propri dati e sulle proprie competenze un asset che accumula valore nel tempo precisamente perché riflette ciò che l’organizzazione ha di più caratteristico e non replicabile.

Il **Capitolo 4** si occupa di questa transizione nella sua dimensione strategica e organizzativa. Non è un

capitolo sulla tecnologia (i RAG, gli SLM, il fine-tuning compaiono come strumenti di base, quasi sullo sfondo e non come protagonisti), ma sulla scelta fondamentale che separa le organizzazioni che investono (spesso a caso) in licenze da quelle che investono in proprietà intellettuale. Emerge qui un paradosso che ci accompagna dalla prima parte: la rivoluzione non chiede di vincere una gara di potenza computazionale, chiede di giocare una partita di pertinenza, dove conta la chiarezza strategica, la cura dei dati e la disciplina organizzativa molto più del numero di parametri del modello. Il cuore della trasformazione, si scopre, non è tecnologico ma organizzativo, e lo stomaco, che è tecnologico, funziona solo se il cuore pompa nella direzione giusta.

Ogni rivoluzione ha un terreno su cui si combatte, e il terreno viene prima della battaglia. Il **Capitolo 5** affronta la questione dei dati partendo da una osservazione empirica oggetto di studi molto blasonati (che ha anche un sapore quasi liberatorio): la maggior parte dei progetti AI fallisce non perché i modelli non funzionano, ma perché i dati che li alimentano non sono adeguati, e non lo sono per ragioni che precedono l'AI di almeno vent'anni. Anagrafiche duplicate, codici incoerenti tra sistemi, documentazione dispersa in cartelle personali, fogli di calcolo che vivono al di fuori di qualunque governance: tutto questo era il rumore di fondo tollerabile dell'informatica aziendale finché il consumatore del dato era un essere umano dotato di buon senso e capacità di discriminazione semantica. Ora che il consumatore è un modello linguistico che produce risposte sbagliate con la sicurezza di chi non sa di sbagliare, quel rumore è diventato un costo visibile e misurabile. Proveremo ad entrare nella distinzione cruciale tra il fattuale e il plausibile, puntando il dito su quel punto della catena del valore digitale in cui il dato perde il suo ancoraggio alla realtà e diventa costruzione probabilistica. Sapere in quale punto di quella catena ci si trova in ogni momento, e calibrare di conseguenza il grado di fiducia, è forse la competenza più importante che un decisore deve acquisire in questa fase storica.

Il **Capitolo 6**, infine, si occupa di quello che ci serve per “agire” (combattere, in questo periodo, è un verbo che trovo pesante usare in questi contesti) ovvero sia l'AI agentica, intesa come sistemi capaci di agire con una qualche forma di autonomia perseguendo obiettivi anziché eseguendo istruzioni. È il capitolo che invecchierà peggio perché, di tutta la Parte II, è quello dove il debunking è più esplicito, ma ovviamente incardinato sulla realizzabilità odierna e non su quella dell'immediato futuro. Per mettermi almeno un po' al riparo da questa inevitabile obsolescenza ho provato ad analizzare la questione non dal punto di vista della tecnologia ma da quello della teoria dell'agenzia, un corpus teorico che da cinquant'anni studia esattamente ciò che l'hype agentico pretenderebbe di aver inventato: i problemi che nascono quando si delega a qualcuno (o a qualcosa) l'esecuzione di compiti in condizioni di informazione asimmetrica e interessi potenzialmente divergenti. Il parallelo tra i fattori della Compagnia Olandese delle Indie Orientali che sfruttavano i ritardi di comunicazione con Amsterdam e un agente AI che ottimizza una funzione obiettivo senza comprenderne il contesto è un espediente retorico (del quale peraltro vado immeritatamente fiero) ma è anche la dimostrazione che il problema della delega non è nuovo, che la sua matematica è irrisolta da secoli e che pretendere di averla risolta semplicemente cambiando la natura dell'agente (da umano a algoritmico) è (nella migliore delle ipotesi) un'ingenuità costosa.

Tre capitoli per tre dimensioni della stessa trasformazione (scritto così mi ricorda il “Sette spose per sette fratelli” di S. Donen): il valore che si può creare, il terreno (i dati) su cui lo si costruisce, e l'illusione (l'agenzia autonoma) che promette di accelerare tutto senza aver ancora fatto i conti con i vincoli che la realtà impone. Il filo che li tiene insieme è la convinzione (al momento non ancora confutata dalla realtà), che la distanza tra la narrazione dominante sull'AI e la realtà operativa delle organizzazioni sia ancora enorme e che ridurla richieda non più entusiasmo o investimenti a casaccio (cioè spese), ma più rigore e un numero maggiore di domande giuste. Se la prima parte ha detto dove siamo (scoprendo che non era dove pensavo di

essere), questa seconda parte prova a dire cosa sta cambiando, scoprendo che la rivoluzione c'è, ma non è (solo) quella che pensavo che fosse e non (sempre) sta nel modello più grande, nell'adozione più rapida e nella maggiore o minore autonomia dell'agente di turno. È nella capacità, molto meno sexy e molto più faticosa, di trasformare i propri dati, i propri processi e le proprie competenze in sistemi organizzati che generano valore misurabile e difendibile. A trasformare la complessità (ed anche la complicazione) in sistemi di senso.

Capitolo 4

Da “AI User” a “AI Value Creator”: la rivoluzione dell’AI Generativa

I tre capitoli precedenti hanno provato ad assolvere la funzione di parte introduttiva collocando la fenomenologia (non la tecnologia) dell’AI nella genealogia lunga del principio di autorità, separando il rumore della novità dal segnale dell’innovazione e abbozzando una bussola etica, primo strumento pratico per orientare le scelte in assenza di altre, più robuste, precondizioni. Erano coordinate, non volevano assurgere a cattedre assiomatiche né tanto meno a istruzioni. Servivano (a me, quanto meno) per ricordarmi dove ci si trova, prima di decidere cosa fare. La Seconda Parte deve registrare un cambio di registro, perché vorrei che desse visibilità a quella che, con un certo coraggio terminologico soprattutto per via dell’instabilità dello scenario, ho scelto di chiamare “la rivoluzione vera”: le trasformazioni (conseguenti ad adozione e uso) che, quanto meno a mio giudizio (pertanto sindacabile), modificano effettivamente le strutture, i meccanismi e le metriche con cui le organizzazioni creano e distribuiscono valore. Ho anticipato, nella sezione precedente, questa trasformazione come direzione di marcia: la transizione da AI User a AI Value Creator. È il tema di questo capitolo e ora proviamo a svilupparla operativamente.

4.1 Mappa infografica del capitolo




Figura 4.1: Mappa logica del Capitolo 4

4.2 Adottare e creare: una differenza che non è lessicale o sintattica

“L’immaginazione è l’inizio della creazione.” — George Bernard Shaw (1856–1950)

Nella prima ondata di trasformazione guidata dall’AI (ancora in corso perché fortemente dipendente dalla maturità organizzativa dei soggetti coinvolti) ci si è focalizzati, nei casi migliori, sui processi di adozione. Era ed è una necessità cogente dettata dalla diffusa impreparazione a un cambiamento di questa portata. Le organizzazioni che hanno completato questa prima fase si trovano però oggi sulla soglia di un cambiamento di magnitudo ancora più rilevante, quello che permetterà di (iniziare a) parlare di “creazione” (di valore). La differenza, qui, è tutt’altro che sintattica. Adottare significa utilizzare qualcosa di “diffusione comune”, che esiste perché altri necessariamente detengono il controllo dei suoi ritmi evolutivi e dei suoi meccanismi (e ne ottengono per questo, generalmente, il beneficio in termini di valore). Creare, al contrario, significa costruire un asset (sia esso intangibile, virtuale o anche solo concettuale), un bene economico che accumula valore nel tempo perché sta sulle fondamenta di ciò che l’organizzazione che lo crea ha di più caratteristico e peculiare: i dati, i processi, il know-how (tacito ed esplicito) delle persone e delle competenze, le decisioni che l’organizzazione prende tutti i giorni in condizioni di vincoli e incertezze specifiche. La prima vera rivoluzione dell’AI nel mondo del lavoro e delle imprese, quella che separa i “semplici utilizzatori” (per quanto sia già “tanta roba” averne

anche solo di semplici utilizzatori esperti) dai “creatori di valore”, consiste esattamente in questo spostamento di baricentro: la costruzione di sistemi proprietari (più o meno intelligenti) basati sull’utilizzo esteso degli strumenti generalisti con tecniche evolute (come il “vibe coding” o la Retrieval Augmented Generation, RAG, su conoscenza proprietaria, anche se stiamo parlando di piani ontologici completamente diversi) oppure, in casi specifici e probabilmente limitati, sul fine-tuning di Small Language Models (SLM) su basi informative interne.

4.3 Le dimensioni (non) contano (più)

“La semplicità è l’ultima sofisticazione.” — Leonardo da Vinci (1452–1519)

Per comprendere perché questa rivoluzione sia possibile oggi, e perché sia particolarmente rilevante per le imprese di qualsiasi dimensione, conviene liberarsi del pregiudizio che il potenziale dell’AI dipenda soprattutto dalla “dimensione” del modello, con una relazione assolutistica del tipo “più parametri, più qualità”. Questa è una correlazione che ha funzionato nella fase pionieristica; sta diventando una semplificazione pericolosa nella fase di industrializzazione. Negli ultimi tempi si sono affermati approcci che prevedono, tramite l’adozione estensiva di modelli generalisti interrogati con prompt strutturati e ripetitivi e con basi documentali trattate opportunamente, con funzionalità “agentiche” sempre più sofisticate, tramite le funzionalità di AI embedded, o anche tramite lo sviluppo e il training di RAG mirati, con footprint computazionale contenuto, che hanno dimostrato di superare i modelli generalisti in attività di dominio.

Perché un RAG o un SLM (gli oggetti sono concettualmente e praticamente molto differenti nella struttura, nel “costo”, nelle finalità e nelle modalità di utilizzo, lo so... ma rientrano per lo meno logicamente nel cluster che voglio rappresentare e pertanto utilizzerò, a sproposito, come equivalenti di soluzione, lasciando a un approfondimento a fine sezione qualche dettaglio tecnico) costruito sui dati dell’impresa diventa un asset e non solo un’ennesima licenza software? Per almeno tre ragioni.

La prima è la **specificità**. Un modello che ha “digerito” dizionari tecnici, manualistica interna, casi storici, listini, distinte base, clausole contrattuali, codici guasto, note post-vendita, conosce il linguaggio e l’onomastica dell’azienda esattamente come la conoscono i suoi esperti. Questo riduce drasticamente la distanza tra “output plausibile” e “output utilizzabile”, cioè tra ciò che un modello può scrivere e ciò che l’azienda può davvero eseguire o firmare.

La seconda è l’**integrazione**. Un RAG costruito sui dati aziendali oppure un SLM “proprietario” non vive nell’isolamento, ma accede, con i permessi corretti e tramite uno strato non necessariamente troppo complesso di automazione, ai sistemi transazionali, agli ERP, ai PLM, ai CRM, ai repository documentali, alle API dei software operativi. È questa contiguità funzionale, molto più che l’effetto “wow” linguistico, a spostare i risultati: il modello non genera testi generici, governa azioni e suggerisce decisioni allineate con i vincoli reali e, nell’ipotesi di essere nella fattispecie di casi d’uso che lo ammettono (quei casi d’uso per i quali ci interessa il risultato generato a prescindere dal processo utilizzato per generarlo) lo può fare con una certa dose di autonomia propria dell’approccio agentico.

La terza è la **difendibilità**. Anche un concorrente con lo stesso modello di base non può replicare gli stessi risultati senza i medesimi dati, le stesse tassonomie, le stesse policy, gli stessi feedback degli utenti e la stessa documentazione degli (o/e)rrori pregressi. Qui nasce il vero vantaggio competitivo: nell’accoppiamento

stretto tra modello e patrimonio informativo-operativo dell’impresa in un processo generativo di un asset intangibile solo nella forma.

Approfondimento — RAG ed SLM con Fine-Tuning: anatomia di una transizione (o di come smettere di rincorrere l’hype)

Un rischio nel quale sistematicamente inciampano i decisori aziendali quando decidono di passare dalla fase di *adozione* a quella di *creazione* di valore, è la convinzione (alimentata ad arte dai vendor) che la soluzione risieda sempre nel “modello più grande” oppure nella soluzione “flagship” del vendor di turno. I dati, testardi come sempre, ci dicono un’altra cosa: mentre la quasi totalità delle organizzazioni dichiara di sperimentare con l’AI generativa (ed a volte pensa che comprare qualche licenza base di un chatbot corrisponda a farlo), appena una frazione sopravvive al cosiddetto “purgatorio dei Pilot” per arrivare a una messa a terra in produzione su larga scala. Il vero GenAI Divide si consuma qui: nell’incapacità di scegliere l’architettura corretta per il *job to be done*. Quando un’azienda decide di mettere a valore il proprio patrimonio informativo (la vera ed unica miniera d’oro che possiede, nell’infoeconomia), il dibattito si polarizza solitamente su due acronimi, che rispondono a domande ontologicamente diverse:

- **RAG (Retrieval-Augmented Generation) — Cambiare *cosa* il modello vede.** Non è una scorciatoia, è la soluzione pragmatica per una larga parte dei problemi aziendali. Si tratta di un insegnamento mirato al modello (fatto fornendo documenti specifici e limitando molto l’utilizzo della conoscenza “generale” nella produzione degli output) gli si fornisce la capacità di “pescare” la risposta esatta dai documenti aziendali un attimo prima di generare l’output. E’ aggiornabile in tempo “quasi” reale (se cambia una procedura, basta aggiornare il database, non riaddestrare l’AI), consente di utilizzare diversi approcci tecnologici (ad oggi è possibile implementare sia RAG con architetture dedicate che imitarne il comportamento utilizzando funzioni, ad esempio “project” di Claude o “NotebookLM” di Google) e mitiga drasticamente quell’arte divinatoria algoritmica che chiamiamo elegantemente “allucinazione”.
 - **SLM (Small Language Models) — Cambiare *quale* modello eseguiamo.** La rivincita della specificità sulla *hybris* onnisciente dei modelli generalisti. Sotto i 10 miliardi di parametri, questi modelli possono girare localmente, garantendo privacy assoluta sui dati e costi infrastrutturali marginali. Non scriveranno sonetti shakespeariani o difficilmente genereranno meme di gattini, ma se utilizzati a dovere estraggono entità da un contratto o instradano ticket di assistenza in modo impeccabile purchè correttamente “fine-tunati”. Il **Fine-tuning** è l’equivalente ingegneristico di un trapianto di personalità. Modifica in modo permanente i pesi interni del modello. Costa molto, richiede moli di dati estremamente puliti (e ne richiede in quantità industriale) ed è giustificato solo quando serve impartire un tono di voce specifico, un formato di output rigoroso o quando la latenza deve essere ridotta all’osso. Per la stragrande maggioranza delle casistiche d’uso, inseguire il fine-tuning al giorno zero è semplicemente un feticcio tecnologico prematuro.
-

4.4 Il processo, molto più che l’evento

*“Il genio è per l’un per cento ispirazione e per il novantanove per cento sudore.” — Thomas Edison
(1847–1931)*

Purtroppo questi anni di approcci superficiali e qualunquisti (o massimalisti, per essere più radicali) ci hanno bombardato di messaggi tipo per “addestrare un modello” è sufficiente “scaricare un dataset (da dove? Boh) e premere start”. La costruzione di un RAG (o in casi estremi e limitati ma non inesistenti) il fine tuning di un SLM che crei valore è un processo. Ed in quanto processo ha ben chiaro uno step di “start” che in questo caso è costituito da una domanda scomoda e liberatoria: quali decisioni ricorrenti, decisive per margini, qualità, tempi, rischio, sono oggi prese con informazioni frammentate, conoscenza dispersa o tacita (od erronea) e scarsa o nulla tracciabilità? Quando questa domanda viene posta senza feticci tecnologici, le aree ad alto impatto affiorano con chiarezza: configurazione tecnico-economica delle offerte complesse, classificazione e routing di richieste post-vendita in supply chain caratterizzate da numerose e peculiari varianti, generazione di istruzioni operative aderenti a macchine e impianti con una storia di modifiche stratificate che le rendono anni luce distanti dai “manuali operativi” della messa in produzione, consultazione normativa e contrattuale per casi non standard. In tutti questi contesti, un modello snello ma educato sui dati e integrato nei sistemi dell’azienda può comprimere tempi decisionali, uniformare qualità, ridurre errori, e, al tempo stesso, “insegnare” le prassi e le pratiche a chi entra oggi in ruoli che ieri richiedevano anni di affiancamento. Non servono decine di use case per ribaltare l’equazione del valore: ne bastano due o tre ben scelti, purché siano “pane quotidiano” costruito sul valore, non demo da convegno. Tutto il resto (cioè tutti gli use case “non strategici” in termini di valore) richiedono soluzioni tecnologiche molto meno “s sofisticate” e quindi sono considerate da tutti meno interessanti... chissà poi perché).

4.5 Il cuore è organizzativo, lo stomaco è tecnologico

“L’organizzazione è ciò che fai prima di fare qualcosa, affinché quando la fai non sia tutto confuso.” — A.A. Milne (1882–1956)

Il focus della rivoluzione Value Creator non è tecnico (e curiosamente, quando si parla di tecnologia quasi mai lo è) bensì organizzativo e passa per tramite della ricostruzione di una catena che da anni si è spezzata: quella che unisce chi conosce il cliente e il prodotto, chi governa i dati, chi fa architettura applicativa, chi disegna i processi e chi misura il valore. La figura che deve orchestrare questa catena non è necessariamente un tecnico AI od un data scientist puro; è un “product owner” dell’AI capace di tradurre risultati di business in specifiche modellistiche o rappresentazioni delle stesse e quest’ultime in metriche economiche. Questa figura ibrida, che dovrà trovare collocazione organizzativa in ambiti business e non necessariamente IT, è la persona che decide che cosa il modello deve “sapere” davvero, quali sorgenti informative sono affidabili, quali feedback contano e come si gestisce, governa e risolve l’ambiguità. In molte imprese, questa figura non esiste ancora formalmente; eppure il suo lavoro lo stanno già facendo, a spizzichi e bocconi, i migliori responsabili di funzione, gli ingegneri di processo, i controller che hanno imparato a parlare con IT e operations.

Formalizzarne il ruolo, darle tempo e mandato, è spesso la discriminante che separa i progetti che vivono da quelli che evaporano. Spesso per evitare lo “sforzo organizzativo” si cerca la soluzione “a scaffale” (che esiste solo nelle intenzioni di chi la vende) e si citano a volte addirittura i dati delle ricerche [22] per giustificarlo: i progetti con forti partnership esterne hanno tassi di successo del 67% contro il 33% di quelli che prevedono sviluppi interamente interni. La lettura corretta non è quella di un invito acritico all’esternalizzazione, anzi. Il significato di questo dato è che le organizzazioni che attraversano con successo il “divide” non competono (solo) sui budget ma sulla capacità di personalizzazione process-specific e sulla valutazione puntuale basato su outcome operativi. Le partnership esterne sono indispensabili per garantire quel livello di innovazione continua e competenza verticale che all’interno dell’organizzazione sarebbe quasi impossibile sviluppare. Ma funzionano solo quando esiste, all’interno dell’organizzazione, una controparte forte capace di tradurre tra il linguaggio del fornitore e il linguaggio del business ed anche di prendersi in carico, in modo crescente, componenti anche dello sviluppo e distribuzione di soluzioni. L’obiettivo dovrebbe essere decentralizzare una parte dell’attività implementativa mantenendone una quota (magari quella relativa ai casi applicativi più semplici) ma preservando una accountability chiara, evitando la dipendenza totale da fornitori disconnessi dalle operation quotidiane.

4.6 La questione dei dati, i dati questionabili

“Senza dati sei solo un’altra persona con un’opinione.” — W. Edwards Deming (1900–1993)

C’è poi la questione dei dati, che da molte parti si continua a trattare come un rifornimento generico: “servono più dati”. No, non servono più dati. Servono dati buoni, in assoluto migliori. Meglio meno, ma meglio .. diceva qualcuno. Servono i dati che spiegano gli esiti che vogliamo migliorare. La qualità non è un parametro astratto, ma la rispondenza all’uso: in questo contesto la qualità attribuisce semantica al dato trasformandolo in informazione. Un log di produzione “rumoroso” può essere prezioso se anticipa anomalie rilevanti; un documento perfettamente scritto ma non aderente alle pratiche aziendali può essere dannoso se induce il modello a “normalizzare” proprio ciò che rende l’azienda differente dai competitor. La pratica vincente non è la stanca “bonifica una volta per tutte”, ma la curation continua sui domini che contano: si parte stretto, si arricchisce a spirale, si eliminano ridondanze e si versiona la conoscenza come si versiona il software: tassonomia ed ontologia sono le parole chiave che dovremmo iniziare a frequentare. Disegnare la tassonomia dei dati (come chiamiamo le cose, con quali attributi e come li mettiamo in relazione), curare l’ontologia (come questi dati rappresentano in modo univoco e non equivoco un dominio) e trovare il modo di esplicitare la conoscenza implicita (ciò che sta nella testa degli esperti) significa creazione di capitale intellettuale e semantico, non svolgere in modo pedissequo un compito da documentaristi. La creazione di asset dati locali, curati e proprietari sblocca, anche in contesti regolati (sanità, finanza, energia), use case che i modelli generalisti cloud-only non potrebbero affrontare proprio per l’assenza di questa “località del controllo”, riduce il rischio operativo, rende gli audit sostenibili, aumenta la confidenza del management. Lungi dal rallentare, una governance dati ben disegnata abilita: definisce confini chiari entro cui si può sperimentare senza paura. Mi voglio occupare in seguito, nello specifico e nel dettaglio del tema dei dati che sono il terreno sul quale si combatte questa rivoluzione, per ora basti il principio: senza un investimento serio e continuativo sui dati, qualunque progetto di transizione a Value Creator resta un esercizio di stile.

4.7 Misurare il valore con le metriche giuste, evitare l’AI-Washing e superare la retorica

“Misura ciò che è misurabile, e rendi misurabile ciò che non lo è.” — Galileo Galilei (1564–1642)

L’evoluzione nella direzione dell’AI Value Creator cambia anche le metriche con le quali dobbiamo misurare le iniziative: una volta adottata l’AI all’interno dell’azienda contare utenti attivi o prompt generati diventa rapidamente irrilevante dal punto di vista economico: bisogna misurare margini e rischi. Una modello che confeziona un’offerta tecnicamente corretta e finanziariamente sostenibile vale di più di cento draft “creativi” di una email. Una riduzione stabile del tempo di attraversamento di un processo, che si traduce in rotazione di magazzino o in puntualità di consegna, ha valore monetario misurabile così come l’abbattimento dell’errore in documenti tecnici o in compliance evita costi occulti e reputazionali. La fase di transizione richiede che le metriche vengano progettate a monte, incorporate nei sistemi evoluti (come già detto anche per l’etica) e non inseguite a valle: un modello cieco ai parametri economico-operativi produrrà sicuramente testi persuasivi ma non risultati. Per questo i KPI dell’AI dovranno sempre più essere sviluppati a partire da quelli di business: time-to-quote, tasso di first-time-right, incidenza scarti, lead-time reale, DSO, NPS, costo della non qualità, esposizione a penali. Il modello dovrebbe “vedere” questi numeri e tenere conto della loro ottimizzazione nel formulare gli output, permettendo all’AI di smettere di essere una forma di intrattenimento e diventare una “nuova” disciplina gestionale. Per fare seriamente questa trasformazione si parte da uno (o poco più di uno) use case ben riconoscibile, con tre caratteristiche: alta frequenza (così il modello impara), alto valore marginale (così l’unità di miglioramento paga), disponibilità di feedback “veri” (così si chiude il loop). Non serve comprare infrastrutture monumentali: serve scegliere bene dove l’AI “tocca” il business, costruire quello che serve, integrarlo nei processi e misurare con prosaica testardaggine. Due o tre iterazioni riuscite generano spesso un effetto valanga: l’organizzazione vede benefici concreti, i team chiedono di portare il modello in altre pieghe del lavoro quotidiano, la diffidenza cala, la conversazione smette di essere astratta. Nella prima fase “post adozione” (ripeto, dove l’adozione c’è stata ... ovvero non ovunque) la maggioranza degli investimenti sono andati su use case sales & marketing, anche se i payback più rapidi vengono ancora oggi dall’automazione (magari con strumenti limitatamente “intelligenti”) dei back-office e dalle funzioni operative [22].

Come è ovvio (ed anche giusto) questa fase di trasformazione si scontra con la retorica della sostituzione delle persone. Che però deve cessare di essere retorica ed aprirsi al confronto della realtà, cedendo il passo alla pratica della complementarità. Un RAG consultabile come un “collega anziano” non “tolgono” il lavoro agli esperti: tolgono loro la fatica di ripetere l’ovvio, di cercare fra varianti, di spiegare per la centesima volta. Liberano tempo e attenzione per ciò che non è codificabile e proprio per questo non sostituibile: la negoziazione, l’eccezione che conferma la regola, la relazione con il cliente (interno ed esterno). Questo scambio chiede contestuali nuove responsabilità: documentare ciò che finora era implicito, restituire feedback strutturati al modello, accettare che “come si è sempre fatto” non basta più come giustificazione per mantenere profili di efficienza minori di quelli possibili. La trasformazione deve essere vissuta come una palestra di maturazione professionale e manageriale, non solo un’adozione tecnologica, soprattutto nelle organizzazioni medie, dove i ruoli sono meno compartimentati e le distanze fra chi decide, chi fa e chi misura sono ridotte. E’ interessante il cortocircuito: le aziende che hanno ottenuto maggiori risultati “economici” dall’adozione dell’AI pare li abbiano ottenuti riducendo BPO e fornitori esterni anziché tagliando staff interno, investendo (in tecnologia)

proprio a favore del proprio personale. Ma questo è meno “sensazionalistico” e notiziabile di un annuncio di riduzione di organico in dovuto all’adozione dell’ AI. Certo è che, latente, rimane (e sarà compito di una parte successiva provare a dare qualche preliminare risposta) una serie di domande: cosa cambia, nelle persone e nelle organizzazioni, quando il rapporto quotidiano con l’AI diventa la norma e non l’eccezione?

4.8 Una partita di pertinenza

Questa è, in sostanza, la vera rivoluzione: spostare il focus dall’uso “basico” allo sviluppo di valore, facendo dei modelli variamente addestrati su dati proprietari non un gadget di produttività individuale, ma un pilastro operativo che si rafforza a ogni ciclo di utilizzo. È una rivoluzione alla portata di tutte le imprese perché non chiede di vincere una gara di potenza, ma di giocare una partita di pertinenza: incorporare nel modello l’identità dell’azienda, i suoi dati e i suoi vincoli, i suoi obiettivi economici e i suoi standard professionali. Quale che sia la dimensione del modello, perché qui conta la chiarezza strategica, la cura dei dati e la disciplina esecutiva (e organizzativa) che accompagna la trasformazione. Chi parte oggi (dopo aver fatto un percorso consapevole di adozione diffusa e organizzativa), con poche scelte nette e ben presidiate, costruisce un vantaggio che domani non si compra a scaffale.

Capitolo 5

I dati come asset strategico: il vero campo di battaglia dell'AI aziendale

Spinti dalla necessità di trovare metafore ad effetto o locuzioni memorabili che ancorino un concetto a una frase che possa richiamarlo senza doverlo esprimere, abbiamo tutti, prima o dopo, affermato (senza interrogarci a fondo su quel significato di quell'affermazione) che “i dati sono il carburante dell'AI”. Sarà che l'attuale situazione mondiale rende problematico riferirsi senza doppiosensismi ai carburanti e ai loro precursori; però vorrei provare ad offrire una lettura diversa e suggerire una metafora alternativa: i dati sono il *terreno* su cui la rivoluzione si gioca, e la qualità di quel terreno determina se quella trasformazione produce valore o solo macerie elegantemente formulate. Nella prima parte avevamo introdotto la catena del valore digitale come strumento epistemologico ed etico per localizzare dove, nella sequenza che va dal dato grezzo alla decisione operativa supportata dalla conoscenza, le questioni etiche emergono con più urgenza [14, 17]. Qui riuso quella stessa catena come strumento operativo chiedendomi “dove si spezza nella pratica?”. La risposta, nella maggior parte delle organizzazioni che mi è capitato di assistere in questi anni, è brutale e semplice: si spezza al primo anello, perché i dati (se ci sono) non sono adeguati e “pronti”.

5.1 Mappa infografica del capitolo



Figura 5.1: Mappa logica del Capitolo 5

5.2 Il dato come fattore cogente ed urgente

“Meglio meno, ma meglio.” — Vladimir Il'ič Ulyanov (Lenin), Pravda (1923)

Il rapporto delle organizzazioni (e delle persone, più in generale) con i propri dati è sempre stato un rapporto complicato. Problemi di qualità, disponibilità, frammentazione e governance sono evidenti a chiunque abbia lavorato su un progetto di adozione o evoluzione di un sistema ERP, sull'implementazione di una business intelligence, su un'integrazione tra sistemi o anche solo su un report di fine mese. Problemi spesso ritenuti tollerabili, vissuti con rassegnazione, giustificati nel quotidiano “abbiamo sempre fatto così”. Anagrafiche duplicate, codici prodotto incoerenti tra sistemi, documentazione tecnica salvata in cartelle personali senza naming convention, i fogli Excel (o reticoli, per gli amici) che vivono al di fuori di qualunque governance con macro che presentano stratificazioni storiche che fanno invidia al Grand Canyon; tutto questo è ancora oggi il rumore di fondo dell'informatica aziendale. Ci si convive perché il costo della sua inadeguatezza è diffuso, invisibile e ormai incorporato nei processi, mentre il costo della sanatoria è a volte incalcolabile.

Il problema oggi è che l'AI ha reso quel costo visibile e misurabile, perché ora esiste una tecnologia che promette di estrarre valore dai dati proprietari: peccato che, molto più che con altre soluzioni informatiche (il concetto di “merd-in ... merd-out” non è certo stato inventato oggi), la qualità dell'output dipende

radicalmente dalla qualità dei dati in ingresso. Tra le tante ricerche fa gioco citare quella di Gartner che predice (predica?) che le organizzazioni che non dispongono di dati “AI-ready” abbandoneranno il 60% dei propri progetti AI entro il 2026 [27, 28]. I silos informativi, i legacy systems e le barriere culturali alla condivisione delle informazioni non sono problemi creati dall'AI, ma il loro impatto è stato amplificato dall'AI. Quando le incoerenze tra anagrafiche erano un fastidio visibile e gestibile a martellate sul reporting mensile, ce ne facevamo una ragione. Quando un RAG deve supportare la risposta a una domanda su un cliente attingendo a dati che arrivano da CRM, ERP, email, contratti e note post-vendita, quelle stesse incoerenze anagrafiche diventano la causa diretta di risposte sbagliate formulate in modo convincente, il che è peggio di un errore visibile, perché genera una fiducia ingiustificata.

La frammentazione informativa spesso è caratteristica strutturale, non accidentale. Nasce dalla storia stessa delle organizzazioni: crescite per acquisizioni successive in cui ogni azienda acquisita ha portato con sé il proprio sistema gestionale, il proprio piano dei conti, le proprie anagrafiche, le proprie convenzioni. Sistemi informativi stratificati nel tempo, in cui il gestionale dei primi anni 2000 convive con il CRM implementato nel 2015 e con i sistemi di collaboration implementati durante la pandemia senza che nessuno dei tre parli la stessa lingua. Sistemi implementati per funzione anziché per processo con ogni reparto concentrato sui propri dati ma senza una visione trasversale che spesso è demandata all'IT. Aggravante è sicuramente un fenomeno culturale che raramente viene nominato nella letteratura: la proprietà del dato come strumento di potere informale. In molte organizzazioni controllare un'informazione significa controllare un pezzo del processo decisionale, e condividere quell'informazione significa perdere un vantaggio posizionale. Questo non è cinismo: è la conseguenza razionale di un'organizzazione in cui la governance dei dati non è formalizzata e in cui, di conseguenza, chi detiene l'informazione detiene un potere che non gli viene riconosciuto formalmente ma che esercita quotidianamente (spesso a scapito dell'efficienza e dell'efficacia complessiva). Qualunque progetto AI che ignori questa dinamica è destinato a scontrarsi con resistenze che non hanno nulla di tecnico. Il paradosso si esacerba nelle imprese medie che sono troppo grandi per il foglio Excel e culturalmente troppo distanti (o che si percepiscono troppo piccole) per un approccio strutturato a una data platform. Non hanno la sensibilità per comprendere la necessità di investire in infrastrutture di dati *enterprise-grade*, pur avendo una complessità operativa che rende insufficienti gli strumenti artigianali. Spesso la resistenza è prima di tutto dovuta al fatto che vengono proposte (prevalentemente da consulenti *incapaci* o poco sensibili alla realtà) architetture ultra-sofisticate (che hanno pesanti impatti organizzativi prima ancora che tecnologici e che richiedono risorse che probabilmente non avranno mai un ritorno adeguato) quando la soluzione sta nel fare bene le cose semplici: naming coerente, versioning dei documenti, metadati che descrivano cosa contiene ogni file e da quando è valido, tassonomie condivise tra le funzioni, un master data management che, almeno sulle anagrafiche critiche (clienti, prodotti, fornitori), garantisca unicità e coerenza.

La pratica vincente non è la “bonifica una volta per tutte”, mito che consuma budget senza produrre risultati duraturi perché il giorno dopo la bonifica il dato ricomincia a degradarsi. La pratica vincente è la *curation* continua sui domini che contano: si parte stretti, su un perimetro ridotto (il catalogo prodotti di una linea, i contratti di una tipologia di cliente o la documentazione tecnica di una famiglia di macchine, accettando il fatto che non si possa fare tutto subito, per ieri), si arricchisce progressivamente, si eliminano ridondanze, si versiona la conoscenza con la stessa disciplina con cui una volta si versionava il software (no, versionare correttamente non significa giustapporre al nome del file suffissi del tipo “finale”, “finale-2”, “finale_ultimo”, “definitivo”, “definitivo_finale_pippo”). Due o tre domini ben curati sui quali innestare da subito processi *AI-assisted* che permettano di estrarre valore valgono più di una bonifica massiva che tocca tutto, scontenti

tutti e non sistema nulla. Serve però una nozione condivisa di qualità tramite la quale orientarsi nelle scelte.

5.3 È una questione di qualità (e di nuovo meno di quantità di quanto si possa pensare)

“Non tutto ciò che può essere contato conta, e non tutto ciò che conta può essere contato.” — William Bruce Cameron (1963)

Mi pare di aver già argomentato che la qualità non è un parametro statico e astratto, ma la rispondenza all'uso, l'aderenza alla finalità [26]. Sicuramente è una formulazione pragmatica e meno da manuale di data management ma lo è per una ragione precisa: il concetto stesso di qualità dei dati cambia significativamente quando il consumatore del dato non è più un fruitore umano che lo legge (discriminandolo con un bagaglio semantico inconsciamente attivato) ma un modello linguistico che lo incorpora in una risposta. Il framework **DAMA-DMBOK 2.0** [25] costituisce uno standard internazionale di riferimento per la gestione dei dati ed identifica diverse dimensioni tramite le quali esprimere il concetto di qualità: accuratezza, validità, completezza, integrità, unicità (o possibilità algoritmica di deduplicazione), tempestività, ragionevolezza, coerenza e, nella revisione del 2024, anche la “currency” (l'attualità del dato rispetto al momento dell'uso). Sono dimensioni utili e ben codificate, ma vanno riformulate quando il contesto d'uso è l'AI generativa perché cambiano (a volte radicalmente) i pesi relativi.

L'*accuratezza*, per esempio, resta fondamentale: un dato errato produce un'informazione errata, e un RAG che attinge a un dato errato produce una risposta errata con la sicurezza linguistica di chi non sa di sbagliare. Ma la *completezza* assume, nel contesto della fruizione algoritmica, un significato diverso: un dato incompleto può essere più utile di un dato “completo” ma generico, perché il modello riesce a lavorare con informazioni parziali purché siano pertinenti al dominio. Un log di produzione “rumoroso”, pieno di timestamp irregolari e annotazioni semi-strutturate, può essere prezioso per un sistema di manutenzione predittiva che cerca pattern di anomalia tanto quanto una heatmap di Strava ci dice di più su “chi corre” su un certo percorso specifico (pensate, ad esempio, a una mappa riferita a un territorio su cui è presente una base militare) in presenza di relativamente pochi dati rispetto a quanto ci dica la stessa mappa posizionata su Milano. La dimensione più critica nel contesto AI, ed è anche quella meno presente nei framework tradizionali, è il già citato “valore semantico”, ovvero la rispondenza del dato al contesto di verità in cui viene letto. Un dato può essere accurato, completo, coerente e tempestivo, e tuttavia non avere senso (non “esistere veramente”) nel contesto in cui il modello lo utilizza. La triade struttura-significato-valore semantico che abbiamo introdotto in precedenza diventa qui operativa: prima di alimentare un RAG o un SLM con i propri dati, un'organizzazione dovrebbe chiedersi se quei dati hanno attraversato tutti e tre i livelli e se il contesto in cui il modello li leggerà è coerente con il contesto in cui sono stati prodotti, nonché se questo rappresenti il “modello di verità” che volevamo descrivere. Il problema, però, sta proprio nel concetto di rappresentazione tramite i dati: cosa rappresentiamo e come.

5.4 Del cambio di natura: il passaggio dal fattuale al plausibile

“Ci sono tre tipi di bugie: le bugie, le sfacciate bugie, e le statistiche.” — Attribuita a Benjamin Disraeli / Mark Twain

C'è un punto nella catena del valore digitale in cui si verifica una trasformazione di natura più che di livello, ed essere consapevoli di cosa avviene in quello snodo è, a mio avviso, la competenza più importante che un decisore deve acquisire nell'era dell'AI. Il punto è il passaggio da informazione a conoscenza, ovvero il momento in cui i processi correlativi (siano essi analytics tradizionali, machine learning o AI generativa) trasformano dati e informazioni in qualcosa di qualitativamente diverso. Prima di quello snodo, per quanto approssimato e impreciso, il dato mantiene un ancoraggio alla realtà fattuale dalla quale è stato derivato (ad esempio tramite sensori) o dalla quale è stato generato (ad esempio un dato di transazione come “il cliente X ha ordinato Y pezzi il 15 marzo”). Il dato “grezzo” è fattuale. Può essere registrato male o incompleto, può mancare di contesto, ma si riferisce a qualcosa che è accaduto nel mondo. Dopo quello snodo, la conoscenza prodotta dai processi correlativi di tipo probabilistico e statistico perde completamente quel legame. La conoscenza, nell'ambito della catena del valore digitale, è una pura costruzione probabilistica su una correlazione statistica, un pattern che il sistema ha trovato nei dati ma che non necessariamente corrisponde ad alcuna relazione causale nel mondo reale. La progressione attraverso i tre livelli di analytics rende visibile questo distacco con una chiarezza che merita di essere esplicitata, perché ciascun livello segna una tacca nella misura dell'allontanamento dal fattuale.

- **L'analitico di tipo descrittivo** parte da quel sottoinsieme di dati grezzi che è qualificabile come informazione e prova a rispondere alla domanda “cosa è successo?” guardando indietro, organizzando e visualizzando dati storici e cercando di identificare una correlazione tra le variazioni tra insiemi di dati spiegando queste variazioni in termini probabilistici e/o statistici.
- **L'analitico predittivo** compie un ulteriore salto “qualitativo”. Nel rispondere alla domanda “cosa potrebbe succedere?” applica modelli statistici ai dati “esistenti” per proiettare tendenze. Il legame con il reale, che era già stato disintermediato dalla funzione di probabilità, diventa labile in modo strutturale, perché la predizione è una stima probabilistica basata sull'assunzione che i pattern del passato (che abbiamo intercettato) si ripeteranno nel futuro, assunzione tanto più fragile quanto più il contesto è volatile. Il modello descrittivo non ipotizza correlazioni, quello predittivo ipotizza il futuro secondo l'assunzione che questo si verifichi rispettando la distribuzione statistica del passato.
- **L'analitico prescrittivo** compie il salto definitivo. Prova a rispondere alla domanda “cosa dovremmo fare per fare accadere questo?” combinando predizioni con funzioni di ottimizzazione che suggeriscono azioni. Qui il distacco dal reale è più che completo, perché l'output non è più una distribuzione descrittiva di qualcosa che esiste o che potrebbe esistere: è una raccomandazione generata da un algoritmo che ha ottimizzato una funzione obiettivo: in pratica è una sua opinione. Un'opinione costruita su correlazioni, ottimizzata su una funzione scelta, presentata con la stessa neutralità grafica con cui si presentano i fatti.

Il punto problematico è che gli output dei tre modelli arrivano nella stessa forma e sostanza di quelli fattuali e l'AI generativa esacerba questo distacco fino al suo punto terminale, perché produce output in forma

di linguaggio naturale (o in altre forme di codifica basate su di esso, siano esse audio o visuali), appropriandosi della sua capacità di persuasione e mostrando in apparenza un ragionamento e una comprensione che sono in realtà generati interamente da correlazioni statistiche tra sequenze di token (assimilabili, in italiano, ai morfemi, come mi ha fatto notare recentemente una docente di Italiano correggendomi sul fatto che io solitamente usavo “lessema” a sproposito) [33, 34]. Il risultato non è conoscenza nel senso epistemologico del termine: è plausibilità linguistica che, dal punto di vista cognitivo, appare quasi indistinguibile dalla verità per un utilizzatore non educato, ragione per cui il principio dell'autonomia di Floridi (discusso nel Capitolo 3 e che prescrive di rispettare la facoltà umana di scegliere in modo informato) diventa tassativo e critico in questo snodo della catena.

Chi usa strumenti basati su processi “analitici” o generativi ha l'obbligo (morale, purtroppo ancora soprattutto quello) di sapere in quale punto della catena si trova in ogni momento, e calibrare di conseguenza il grado di fiducia e il tipo di supervisione che applica, perché al crescere di “livello” l'effetto di amplificazione della distanza dal reale non è lineare ma geometrico. Governare i dati, nell'era dell'AI, significa anche (e soprattutto) governare la consapevolezza di questo snodo. La governance dei dati deve includere la tracciabilità del “livello di astrazione” di ogni output, non solo la tracciabilità della fonte. Sapere da dove viene un dato è necessario ma non sufficiente: bisogna sapere anche quante trasformazioni probabilistiche ha attraversato prima di arrivare nelle mani di chi decide.

5.5 Tassonomia, ontologia ed epistemologia di contesto

“Che cosa c'è in un nome? Ciò che chiamiamo rosa, anche con un altro nome conserverebbe il suo profumo.”

— William Shakespeare, *Romeo e Giulietta*

Un tema che rimane sullo sfondo della discussione attorno ai dati e all'AI (forse perché è un tema organizzativo e semantico, con conseguenze tecniche dirette ma non tecnico in senso stretto) è quello del design delle tassonomie e della gestione (codifica simbolica, cura, trattamento

dots

usate voi il termine preferito) della conoscenza implicita.

- La **tassonomia** è il modo in cui un'organizzazione o un individuo (perché, alla fine, le organizzazioni altro non sono che collezioni spesso patologiche di individui) chiama le cose. Non è una questione informatica: è un'attività e un'attitudine organizzativa che predetermina cosa il sistema deve o può trovare e cosa no. Se il codice prodotto nel CRM non corrisponde al codice prodotto nel gestionale di magazzino, nessun RAG al mondo potrà rispondere correttamente a una domanda che attraversa i due sistemi. Se la stessa macchina si chiama “linea 3” nel sistema di produzione, “asset 4712” nella contabilità cespiti e “la vecchia Comau” nelle conversazioni degli operatori, il modello non sa che si tratta dello stesso oggetto e produce risposte incoerenti. La tassonomia è l'atto fondativo della governabilità dei dati e spesso è il prodotto di stratificazioni storiche non coordinate, acquisizioni non integrate e convenzioni personali (il lessico familiare dell'azienda, per dirlo con la Ginzburg) mai formalizzate.
- L'**ontologia**, quantomeno nell'accezione informatica del termine, si riferisce a come mettiamo in relazione le cose. Un'ontologia di dominio definisce un “ordine” negli elementi della tassonomia (ad

esempio l'appartenenza di un “cliente” a un “segmento”, che quel “segmento” ha un “margine target”, che quel “margine target” dipende dal “mix prodotto”, e così via). Quando un RAG dispone di un'ontologia strutturata, le sue risposte acquisiscono una coerenza che non è possibile ottenere con la sola indicizzazione vettoriale (procedimento “tecnico” di base) dei documenti. L'ontologia non è un lusso o un desiderio di utilizzare parole difficili a tutti i costi (cosa che, conoscendomi, si potrebbe anche sospettare): è il modo in cui si passa da “il modello trova le parole giuste” a “il modello costruisce le relazioni giuste tra gli oggetti”.

Forse però il tema più importante (e forse più specifico e peculiare nel contesto italiano delle imprese medie) è quello della **conoscenza tacita** [29]. Ogni organizzazione con una storia operativa significativa ha accumulato nel tempo una quantità enorme di conoscenza che non è formalizzata in nessun documento, che non è codificata in nessun sistema informativo, perché vive esclusivamente nella testa delle persone. L'esperto senior che sa perché quella macchina vibra in quel modo e cosa fare quando succede, o il commerciale che sa riconoscere i segnali che precedono la perdita di un cliente. Il controller che sa quali numeri del report mensile sono affidabili e quali vanno interpretati con cautela, e il tecnico post-vendita che ha sviluppato nel tempo una mappa mentale dei difetti ricorrenti per lotto di produzione, fino all'imprenditore che sa mettere insieme tutte queste cose in un modo che, a volte, anche con il senno di poi non si riesce a spiegare (nella prima stesura di questo capitolo il tema dell'imprenditore non era ancora emerso, ma nel corso delle ultime settimane mi sono trovato più volte a discutere con alcuni clienti e colleghi proprio sulla possibilità (?) di fare, in modo *AI-assisted*, un *dump* della memoria e del *savoir faire* imprenditoriale in ottica di supporto al cambio generazionale ... e quindi mi è parso opportuno almeno citarlo). Questa conoscenza è esattamente ciò che rende proprietario, non replicabile e difendibile un sistema AI costruito sui dati dell'impresa. Portarla fuori dalla testa delle persone e dentro il sistema (sotto forma di documenti strutturati, annotazioni sui dati, regole di business, FAQ interne, casi storici documentati, glossari di dominio, video, registrazioni audio ecc.) è creazione di capitale semantico-intellettuale nel senso più pieno del termine. Spesso viene percepito come un compito formale, quasi da documentaristi, e per questo delegato ai livelli più bassi della *catena alimentare aziendale*; invece, è il compito più strategico che un'organizzazione possa intraprendere nell'era dell'AI. Spesso, soprattutto dai detrattori di ogni forma d'ordine, viene usato come opposizione a questo approccio un potenziale rischio (peraltro reale ed insidioso al quale bisogna trovare una soluzione sistematica): la normalizzazione distrugge il valore. Un modello addestrato su documenti “perfetti” che non riflettono le pratiche patologiche reali produrrà output generici, indistinguibili da quelli che qualunque concorrente potrebbe ottenere con lo stesso modello di base. Il valore sta nelle eccezioni, nelle varianti, nei “come si fa davvero qui”, non nella versione idealizzata dei processi che si presenta in sede di un assessment o di un audit. Un RAG che conosce la differenza tra la procedura ufficiale e la procedura effettiva (con le sue ragioni, i suoi vincoli, le sue scorciatoie giustificate dall'esperienza) è un RAG che produce risposte utili, non solo corrette, ma anche utilizzabili. Organizzare, ordinare, qualificare, curare. In pratica gestire e governare. Questa è una competenza da sviluppare e a cui rendere giustizia anche organizzativa.

5.7 Governance dei dati nell'era dell'AI: chi decide cosa, e perché

“Una cattiva organizzazione del lavoro farà fallire anche le persone migliori.” — W. Edwards Deming

Governare l'asset intangibile e strategico dei dati in azienda non significa (solo) formulare una policy. Significa definire ruoli, responsabilità, processi e metriche, in pratica un Modello Operativo. Questa affermazione può sembrare ovvia eppure contrasta con le pratiche diffuse nelle organizzazioni (in particolare quelle medie), dove la “data governance” si esaurisce spesso in un documento di principi generali (quando esiste) approvato (a volte formalmente) e poi ignorato nei comportamenti quotidiani, in una dinamica che ricorda da vicino tutti i vari processi di *washing* (green, ethic, AI...) che affliggono questi tempi in cui la rappresentazione esterna di un fenomeno è considerata più rilevante del fenomeno stesso. Una seria data governance nel contesto dell'adozione dell'AI richiede almeno tre figure organizzative bene definite, con mandati distinti e non intercambiabili. Il **data owner** è il responsabile del “cosa”: decide quali dati servono, con quale qualità, per quale scopo, e risponde della loro pertinenza al business. Non è una figura tecnica o IT: è una persona di business che conosce il processo e che può giudicare se un dato è utile o no. Il **data steward** è il custode del “come”: cura naming, versioning, metadati, permessi, e garantisce che le regole definite dal data owner vengano applicate nella pratica. Il **product owner AI** invece traduce i requisiti di business in specifiche per il modello e viceversa, e ha bisogno del contributo dei primi due per poter essere efficace. In media oggi queste tre figure raramente esistono (soprattutto nelle aziende medie) come ruoli formalizzati. Il lavoro ci si aspetta spesso che lo faccia l'IT che, se va bene, può contare sull'aiuto, prevalentemente su base volontaristica, dei più esperti responsabili di funzione, dei controller curiosi, degli ingegneri di organizzazione o di processo che hanno capito che il dato è il vero bottleneck per le iniziative di trasformazione [30]. Formalizzare questi ruoli, anche solo parzialmente e senza stravolgere l'organigramma, è il primo passo concreto e necessario di una data governance che funzioni.

Dove non arriva l'organizzazione spesso arriva il legislatore: l'AI Act (Regolamento UE 2024/1689) impone obblighi di trasparenza e tracciabilità che la maggior parte delle organizzazioni non è in grado di soddisfare con le pratiche attuali. Il diritto alla spiegazione delle decisioni algoritmiche, la documentazione tecnica dei sistemi ad alto rischio, la tracciabilità delle fonti utilizzate dal modello: sono tutti requisiti che presuppongono una governance dei dati strutturata. Volendo andare più sul filosofico anche la connessione con la nostra **bussola etica** è diretta: il principio di non maleficenza applicato al livello della datificazione richiede esattamente questo: sapere chi raccoglie i dati, con quale consenso, quali bias sono incorporati nelle scelte di cosa raccogliere e cosa no e chi sopporta le conseguenze delle decisioni prodotte su quella base. Una data governance ben disegnata abilita e non rallenta i processi di adozione perché definisce confini chiari entro cui si può sperimentare senza paura, riduce il rischio di errori costosi, aumenta la fiducia del management e dei team legali, e rende gli audit sostenibili. Le organizzazioni che l'hanno capito non trattano la governance come un costo di compliance bensì come un investimento in velocità perché rende chiaro fino a che punto il processo che ha trasformato i dati in conoscenza merita la fiducia di chi li usa per decidere. Chi non si prepara in questa direzione continuando a convivere con i silos e le incoerenze sperando che il modello “se la cavasse comunque” (ahimè, ho sentito alcuni miei clienti dire convinti che oggi non vale più la pena strutturare i dati perché tanto l'intelligenza artificiale è in grado di capire tutto), chi ha investito tutto nel modello (comprato ovviamente a scaffale da qualche farabutto che prometteva magie *plug and play*) e nulla nei dati, chi ha trattato la governance come un ulteriore esercizio burocratico anziché come un atto di governo e di consapevolezza si troveranno con un arsenale di strumenti potentissimi e ritorni trascurabili [22].

Ecco perché i dati sono il terreno su cui si combatte questa rivoluzione: e il terreno viene prima della battaglia e prima anche dell'orizzonte.

Approfondimento — Distant Reading potenziato da LLM: quando i dati testuali diventano conoscenza (e quando no)

Il **distant reading** è un approccio sviluppato nell'ambito degli studi letterari e delle digital humanities, nei lavori di Franco Moretti [31]. In contrapposizione alla tradizionale *close reading* (lettura ravvicinata) di pochi testi, la lettura distante analizza grandi collezioni di testi attraverso metodi computazionali, facendo emergere schemi, tendenze e caratteristiche quantitative che sfuggono all'analisi testuale manuale. Ad esempio, applicando tecniche di distant reading alla produzione narrativa è possibile studiare migliaia di romanzi in termini di frequenza di parole, ricorrenza di temi o evoluzione di generi letterari, senza dover leggere integralmente ogni opera. Questo cambio di prospettiva, dal particolare al generale, ha aperto nuove strade nella ricerca permettendo di esplorare il “grande non letto”, inteso come l'insieme vasto e variegato di testi mai esaminati approfonditamente dai critici. Consapevole della modalità di funzionamento di entrambi gli approcci (e dell'irresistibile tentazione di far dialogare cose che sembrano non c'entrare nulla l'una con l'altra), ho ritenuto impossibile che i modelli linguistici di grandi dimensioni non potessero offrire nuove possibilità per potenziare, eventualmente trasformandolo, il distant reading [32]. I grandi modelli linguistici sono capaci di “comprendere” (l'antropomorfizzazione delle caratteristiche di queste sequenze di 0 e 1 processate da pezzi di silicio alimentati a corrente continua è la misura della nostra fondamentale incapacità di adattarci veramente al nuovo) e generare linguaggio in modo coerente (sintatticamente perfetto, semanticamente non pervenuto), avendo *letto* in termini computazionali miliardi di token provenienti da libri, articoli, siti web e altre fonti testuali. Il risultato del processo di addestramento è una sorta di conoscenza distribuita delle strutture linguistiche e dei contenuti presenti nel linguaggio naturale. Durante la fase di addestramento, gli LLM effettuano di fatto una forma estrema e automatizzata di distant reading: il modello non legge con l'intento cosciente di comprendere (e peraltro, come potrebbe avere questo intento?), ma assorbe pattern linguistici e informativi dall'intero insieme di testi. La differenza cruciale è che nel distant reading classico le mappe dei pattern sono esplicite e interpretate dallo studioso, mentre nel LLM sono implicite nei miliardi di parametri della rete neurale.

La pratica: una storia personale di tentativi, fallimenti e calici di vino

Per quanto non abbia mai condotto progetti di Distant Reading propriamente detti, mi sono trovato, nel corso degli ultimi due anni, a rivoluzionare il mio approccio alla lettura e alla “meta-ricerca” in ambito professionale e accademico (chi mi legge sa che per rispetto di quelli che fanno veramente lavoro di ricerca preferisco schermirmi dietro a un “meta”, che come un “dottò” a Napoli non si nega a nessuno) adottando laddove possibile strumenti di AI a supporto. La ragione è presto detta: la mole di testi, articoli, studi che leggo annualmente per supportare la mia ridicola produzione è importante e, dovendo io “negoziare” il tempo per questa attività con il mio “day job”, la considero da sempre un limite alla varietà dei miei studi. Per riuscire a perseguire i miei obiettivi ho dovuto sviluppare un approccio “bizzarro” alla lettura dei testi (specialmente quelli, e sono la maggior parte, di provenienza accademica anglosassone): siccome molti dei testi accademici concentrano nella parte centrale e finale i concetti “salienti” (lasciando ai capitoli introduttivi quella che descrivo come “la storia di Adamo ed Eva”) io di solito parto dal fondo e non dall'inizio. Leggo l'introduzione o l'abstract, poi vado all'ultimo capitolo, lo leggo segnandomi le cose che non capisco e poi procedo a ritroso capitolo per capitolo finché la lista delle cose “incomprensibili” non ha trovato piena spiegazione. A quel punto

mi fermo, perché i capitoli che stanno tra l'abstract e l'ultimo concetto spiegato di solito non contengono cose indimenticabili.

La storia dei miei tentativi di applicare l'AI a questo processo merita di essere raccontata, non per valore scientifico ma come documento di un percorso che ha molte analogie con gli approcci di trial and error che caratterizzano l'AI adoption nelle aziende ed è soprattutto rappresentativo degli impatti dell'evoluzione tecnologica sui modi d'uso (fermo restando che il caso d'uso, il *job to be done*, è sempre lo stesso).

- **Luglio 2023.** Volendo dedicare parte significativa delle vacanze d'agosto a un tema di ricerca, mi sono procurato un vasto database di articoli e pubblicazioni e ho provato a usare ChatGPT-4 per avere sintesi, confronti e cross-reference lavorando esclusivamente sui prompt. Risultato: impatto rilevante in termini di efficienza, trascurabile in termini di efficacia perché l'attendibilità era molto limitata soprattutto sui testi lunghi. Al netto di alcuni articoli che sono riuscito a “scartare” (ma che avrei scartato anche solo leggendone l'abstract), l'esperienza è stata poco significativa.
- **Luglio 2024.** Stesso contesto, diverso argomento, diversi strumenti, consapevolezza e approccio. Le performance erano radicalmente migliori con ChatGPT-4o, ma la performance e l'attendibilità del risultato sintetico tendevano a degradare, nei testi lunghi, verso la fine del testo, cosa in totale contrasto con la mia metodologia di lettura (e con il paradossale effetto di avere più informazioni sulla storia di “Adamo ed Eva” che sul contenuto distintivo del documento). Ho pertanto provato a sviluppare un GPT istruendolo in modo strutturato per procedere nella lettura come avrei fatto io. La non perfetta capacità di identificare la struttura dei testi ha reso il risultato molto meno efficace di quanto teoricamente avrei potuto aspettarmi, tanto che, intestardendomi su questo tentativo, sono stato obbligato a usare una tecnica di forza bruta: ho scaricato un LLM locale, costruito un RAG via tonnellate di codice Python (scritte, manco a dirlo, in co-design con l'AI in qualche calda serata tra autan, zanzare e un discreto numero di calici di vino), strutturato un metodo di “chunking” del file e fatto “lavorare” il modello secondo il mio perverso metodo di lettura. Risultato: accettabile in termini di attendibilità, discutibile l'impatto sull'efficienza se si considera il tempo/costo dei vari tentativi e dello sviluppo della soluzione. Sulla lunga distanza, ancora più discutibile per il fatto che, oggi, lo stesso GPT costruito dieci mesi fa, senza alcuna modifica, ha prestazioni comparabili o superiori alla mia *usine à gaz* programmata con cazzuolate di codice.
- **Primo semestre 2025.** Per alcuni degli ultimi articoli ho sperimentato un'ulteriore modalità operativa: costruirmi liste di lettura usando strumenti come Perplexity, sfruttando diversi modelli in modalità “deep research” e facendoli cooperare con me e tra loro a partire dalle mie ricerche, integrando con testi e contenuti letti in modo efficiente sia *forward* che *backward*, in una modalità operativa che, in ossequio al maestro **Ethan Mollick** ho chiamato “modalità Cyborg”. Risultato: se devo considerare innanzitutto l'impatto “emotivo”, rilevo un significativo aumento della mia produttività in senso lato. Avendo la possibilità di sottoporre a uno screening preventivo “cautamente affidabile” una grande mole di testi, mi sono trovato spesso a lanciarmi nella ricerca di connessioni bizzarre che avevo da molto tempo in testa senza avere fisicamente il tempo di completare anche solo il percorso di individuazione delle fonti.
- **Dal 2026 in avanti.** L'utilizzo è ormai sistematico e il livello di “affidabilità” è decisamente elevato. Sono cambiati gli strumenti e, necessariamente, gli approcci “tecnici”, anche se le modalità operative restano simili. Le tecniche che descrivo in seguito sono diventate skill (di Claude o di ChatGPT), il lavoro

è fatto in “locale” su cartelle tramite Codex, Cowork oppure Claude Code o anche una combinazione dei tre.

Le tecniche: chunking, overlap e lettura gerarchica

Da questo percorso sono emerse alcune tecniche operative che, al netto della loro artigianalità, si sono dimostrate efficaci e che condivido nella speranza che qualcuno, sperimentandole, produca a sua volta qualcosa di non indimenticabile così da far dimenticare rapidamente le mie già non indimenticabili produzioni.

La preparazione del corpus. Se la collezione di testi è ampia (decine o centinaia di documenti), è necessario suddividerla in *chunk* gestibili, tenendo conto dei limiti di contesto dei modelli. Ogni documento lungo va segmentato in parti più piccole (sezioni, paragrafi, capitoli, senza pretendere che la nostra comprensione e nozione di “capitolo” sia implicitamente compresa dal modello) che l’LLM possa leggere singolarmente. Idealmente i chunk dovrebbero avere una dimensione massima leggermente inferiore a quella massima gestibile dai singoli prompt (regola del pollice: 80%) e prevedere sempre una certa sovrapposizione tra parti adiacenti, così da non perdere contesto ai “bordi” di ciascun segmento.

La gestione degli overlap. Questa è, per esperienza personale, l’unico modo di garantire che la focalizzazione “fetta per fetta” sia sulla parte centrale ma che esista nella memoria dello strumento la sequenzialità logica del procedere. Ho trovato efficace l’utilizzo del tagging XML per segnalare questi elementi di overlap (forse è efficace perché mi rassicura con il suo composto ordine logico più che da un reale valore aggiunto in termini di performance, ma tant’è). La struttura che uso è:

```
<OVERLAPFROMCHAPTERn-1>...</OVERLAPFROMCHAPTERn-1>
<CHAPTERn>...</CHAPTERn>
<OVERLAPTOCHAPTERn+1>...</OVERLAPTOCHAPTERn+1>
```

dove il contenuto dell’overlap “from” del chunk M è identico all’overlap “to” del chunk M-1, e le istruzioni specificano che le operazioni sono da compiere sul contenuto del <CHAPTERn> ma tenendo in considerazione l’intero contesto. Questo garantisce continuità semantica tra chunk adiacenti senza duplicazione del lavoro analitico.

Il prompting gerarchico (MapReduce). Una strategia particolarmente efficace è organizzare l’elaborazione in più fasi gerarchiche, secondo un approccio che chi ha familiarità con i paradigmi di programmazione distribuita riconoscerà come *MapReduce*. In un primo step (*Map*), l’LLM analizza separatamente ogni documento o ogni chunk, generando un output intermedio (il riassunto di ciascun testo, l’estrazione di determinate informazioni chiave da quel segmento). In un secondo step (*Reduce*), si riaggregano e sintetizzano i risultati di tutti i chunk, chiedendo al modello di fornire una visione d’insieme mantenendo coerenza tra le relazioni implicite ed esplicite nei testi analizzati. Questo approccio gerarchico può essere implementato iterativamente: prima a livello di singolo documento, poi a livello di insieme di documenti. Si può istruire l’LLM a leggere ciascun articolo di un corpus e a produrre per ognuno un breve abstract; successivamente, si forniscono all’LLM tutti gli abstract generati chiedendo di stilare una sintesi unificata, evidenziando temi comuni e differenze. Questo *prompting a livelli successivi* (paragrafo → documento → collezione) consente una sorta di *reading sintetico progressivo*: l’LLM costruisce insight passo dopo passo, evitando di perdere dettagli importanti e mantenendo coerenza anche su corpora estesi, ed è particolarmente efficace se si è in grado di preparare il corpus con tutti i necessari overlap sopra citati.

L’integrazione con RAG. Per insiemi di contenuti particolarmente vasti o eterogenei, resta una soluzione costosa ma largamente efficiente l’integrazione tra LLM e tecniche di Retrieval-Augmented Generation. Lo

schema prevede che i documenti vengano indicizzati tramite tecniche di *embedding* vettoriali: ogni chunk di testo è rappresentato come un vettore numerico in uno spazio di “contesto semantico”. Quando si effettua un’analisi, questa viene tradotta in una ricerca di similarità tra i vettori per recuperare solo i passaggi più rilevanti (in termini probabilistici e statistici, come ormai dovrebbe essere chiaro al lettore che ha attraversato la sezione 5.4 di questo capitolo). Si passano poi all’LLM generalista *solo* questi chunk selezionati, chiedendo un’elaborazione limitata ad essi. In tal modo l’LLM opera su una conoscenza semanticamente contestuale mirata, riducendo al minimo sia il rumore di fondo che il rischio di superare i limiti di contesto. L’approccio RAG è particolarmente utile per implementare la mia bizzarra modalità di revisione della letteratura: invece di tentare di far leggere all’LLM centinaia di articoli per intero, si possono preparare estrazioni dai paper solo delle sezioni pertinenti (abstract, conclusioni, e i diversi capitoli come oggetti separati di contenuto) facendoli sintetizzare al modello generalista nell’ordine preferito.

L’avvertimento epistemologico

L’avvertimento è lo stesso che attraversa tutto questo capitolo e che ci portiamo dietro come un filo rosso da quando abbiamo introdotto la catena del valore digitale e in particolare lo snodo tra il fattuale e il plausibile della sezione precedente: il modello non garantisce l’affidabilità delle sue sintesi, può mescolare contesti diversi, e produce correlazioni che hanno la forma della conoscenza senza averne la sostanza fattuale. Il modello che analizza il mio corpus “describe” i miei testi senza averli pensati, senza conoscere il contesto in cui li ho scritti, senza sapere che quella parentesi ironica era una risposta a un commento ricevuto la mattina stessa. È interessante notare, peraltro, che gli LLM stessi possono diventare *oggetto* di distant reading. Così come uno studioso analizza un corpus letterario per capire la cultura di un’epoca, altri studiosi iniziano ad analizzare il comportamento linguistico di modelli come GPT per capire cosa “hanno imparato” dalla mole di testi. Analizzando le associazioni che il modello fa tra certi concetti, o studiando sistematicamente dove il modello sbaglia, si può ottenere una sorta di mappa delle conoscenze e dei bias incorporati. Questo è un distant reading di secondo livello: leggere attraverso l’LLM ciò che esso ha assorbito dalla letteratura. Tale ricerca incrocia informatica, linguistica e scienze cognitive, e rappresenta un nuovo fronte in cui la metodologia umanistica (interpretare pattern linguistici) si applica a un artefatto tecnologico frutto a sua volta di un distant reading automatizzato. L’evoluzione del distant reading “boosted” dagli LLM rappresenta di sicuro una frontiera affascinante a patto che l’uomo e la macchina continuino il balletto che li vede operare in sinergia: la macchina per la sua potenza di calcolo e di lettura su larga scala, l’uomo per la capacità di attribuire significato, valore e direzione all’analisi prodotta in forza bruta. Avendo sempre chiaro a chi spetta il senso critico e la responsabilità interpretativa. Almeno ancora per un po’.

Capitolo 6

L'illusione dell'AI agentica: concetti base, limiti e rischi resi evidenti dal confronto con la teoria dell'agenzia

Nel corso dell'ultimo anno si è diffuso un entusiasmo crescente attorno al concetto di “AI agentica”, ovvero sistemi di intelligenza artificiale capaci di agire con una qualche forma di autonomia perseguendo obiettivi, più che eseguendo un processo avente questo fine. Un recente report di Wharton [35] sintetizza testualmente questo nuovo hype: “l'AI agentica è la nuova frontiera” e ormai “ogni discussione tra executive finisce per toccare il tema degli agenti AI”. Ma a fronte di questo interesse, mi sorge spontanea una domanda provocatoria: quanti di quelli che usano questo termine hanno riflettuto, davvero, su cosa significa “agente”, su quali origini abbia il termine e quali trappole si nascondano dietro il suo utilizzo (oltremodo) disinvolto? Voglio prendermi questo spazio per analizzare criticamente il concetto di AI agentica, discutendone i limiti teorici e pratici (chiedendomi, appunto, cosa significhi davvero “agente” in ambito IA, almeno cosa significhi al momento di questa stesura), mettendolo a confronto con la tradizionale Agency Theory che si studia ed insegna in ambito economico-aziendale (Jensen & Meckling, Eisenhardt, Ross, ecc. [36, 37, 38]). L'idea di fondo è quella di portare in luce i rischi della delega decisionale “on behalf”, cioè per conto del lavoratore e dell'azienda, a un sistema AI, con implicazioni organizzative, informative e reputazionali, anche prendendo in considerazione il ruolo delle norme emergenti, con un riferimento particolare all'AI Act europeo e alle istanze di governance etica dell'IA che avevamo esplorato nel Capitolo 3 sotto il nome di ConcrEthica [15, 14, 18, 17].

6.1 Mappa infografica del capitolo




Figura 6.1: Mappa logica del Capitolo 6

6.2 Qualche nozione storica, perché la storia è sempre il miglior consulente

“Coloro che non ricordano il passato sono condannati a ripeterlo.” — George Santayana (1863–1952)

I fattori della *Compagnia Olandese delle Indie Orientali* che operavano nella Batavia del XVII secolo avevano imparato molto presto a sfruttare i ritardi di comunicazione che potevano arrivare fino a 18 mesi con i direttori di Amsterdam, creando un'asimmetria informativa che rendeva il monitoraggio del loro operato effettivamente impossibile. In questo modo gli agenti si dedicavano al commercio privato, appropriandosi delle opportunità dell'azienda mentre i direttori non potevano verificare i rapporti su prezzi, qualità o condizioni di mercato. Il risultato: appesantita dal contrabbando, dalla corruzione e dai crescenti costi amministrativi (la compliance è tra noi da illo tempore, o meglio, proprio da allora) la Compagnia delle Indie fallì nel 1799 dopo soli due secoli dalla sua concezione e nascita. Quello che nello scorso secolo venne chiamato “problema di agenzia” distrusse letteralmente quella che era stata la più grande azienda del mondo. Similmente, i manager della *Compagnia Inglese delle Indie Orientali* esercitavano poteri quasi governativi in India lontano dalla supervisione di Londra, accettando tangenti, manipolando gli acquisti di merci per profitto personale e usando l'esercito della Compagnia per scopi privati, sguazzando in orizzonti temporali divergenti che incoraggiavano

l'estrazione (di valore, o meglio di beni di valore) a breve termine piuttosto che la creazione di valore a lungo termine.

6.3 La Agency Theory: la matematica senza tempo del disallineamento

“Le persone rispondono agli incentivi. Il resto è un commento.” — Steven Landsburg

Nella pratica economica (ed in particolare nell'ambito della ingegneria gestionale e dell'economia applicata) la Teoria dell'Agenzia (*Agency Theory*) emerse dall'osservazione di un pattern ripetuto attraverso i secoli e relativo ai problemi che nascono quando un principale delega a un agente l'esecuzione di un compito o una decisione, in presenza d'informazioni asimmetriche e interessi potenzialmente divergenti. Il fondamento teorico (nell'accezione moderna) del fenomeno si può far risalire agli studi di **Stephen Ross** che nel 1973 [38] definì formalmente la dinamica delle relazioni in cui “una parte agisce per, per conto di, o come rappresentante dell'altra in un particolare dominio di problemi decisionali.” Ross formulò la teoria in forma di embrionale “sfida matematica” che ancora oggi rimane irrisolta: quando gli agenti massimizzano la propria utilità piuttosto che il benessere del principale, ed i principali non possono osservare perfettamente le azioni degli agenti, una certa perdita residua è inevitabile anche con meccanismi ottimali di monitoraggio e *bonding*. Il lavoro successivo di **Jensen & Meckling** (1976) [36] che definiva l'agenzia come “un contratto in cui una o più persone (il principale) incaricano un'altra persona (l'agente) di svolgere un servizio per loro conto, delegandole un certo potere decisionale” rese questo fondamento matematico maggiormente netto e preciso. I costi di agenzia equivalgono alle spese di monitoraggio più le spese di *bonding* più la perdita residua, la riduzione irriducibile del benessere derivante dalla delega imperfetta. **Joseph Stiglitz** condivise il Premio Nobel 2001 per aver analizzato i mercati con informazione asimmetrica, dimostrando che ogni volta che l'informazione è imperfetta e distribuita asimmetricamente (e questo avviene, essenzialmente, sempre) le economie non sono “Pareto efficienti”. La sua teoria dello screening mostrò come le parti non informate progettano contratti per indurre le parti informate a rivelare informazioni private attraverso l'autoselezione. La sfida si intensifica quando gli agenti possiedono sia informazioni superiori sulle circostanze, che la capacità di intraprendere azioni nascoste che influenzano i risultati. La Agency Theory ha formalizzato diverse categorie di problemi che sorgono in queste relazioni di delega. I principali, che tratto ampiamente nei miei corsi universitari di Management Control dove le componenti “comportamentali” risultano per me importanti quanto quelle “tecniche”, meritano di essere richiamati perché ciascuno troverà un parallelo sorprendentemente coerente nel rapporto tra organizzazione e AI.

- La *Adverse Selection* (selezione avversa) è un problema pre-contrattuale, che si verifica prima della chiusura dell'accordo tra principale e agente. È dovuto all'informazione asimmetrica ex ante: l'agente possiede informazioni private sulla propria qualità, capacità o intenzioni che il principale non conosce, e ciò può portare a una scelta sfavorevole dell'agente. In pratica chi “compra” o ingaggia qualcuno può trovarsi con la parte “scadente” del mercato se non riesce a distinguere ex ante la qualità. Nel contesto del lavoro, un esempio di selezione avversa è assumere un candidato che sembra perfetto ma che ha abilmente occultato lacune o cattive attitudini durante il processo di selezione (o millantato titoli, cosa

che sarebbe sempre meglio non fare soprattutto se si mira a cariche istituzionali da esercitare poi in tempi di pandemie globali).

- Il *Moral Hazard* (azzardo morale) è un problema post-contrattuale, che insorge dopo l'inizio del rapporto di agenzia. Qui l'asimmetria informativa riguarda le azioni dell'agente una volta contrattualizzato: l'agente potrebbe comportarsi in modo opportunistico o diverso da quanto atteso, sfruttando il fatto che il principale non può osservarlo o controllarlo direttamente (o quanto meno continuativamente). Nel mondo aziendale, moral hazard è il manager che prende decisioni eccessivamente rischiose perché il costo di eventuali perdite sarà sostenuto dagli azionisti, mentre lui potrebbe comunque trarne benefici (bonus, stock option) se le cose vanno bene. In sintesi, l'agente è tentato ad adottare "shirk behavior" (con un neologismo potremmo dire "fannullonare") o di agire in modo non diligente, sapendo che il principale fatica a monitorare ogni sua mossa.
- Gli *incentivi disallineati* (*misalignment*) sono all'origine di molti conflitti di agenzia: la divergenza negli obiettivi o nei criteri di determinazione del successo tra principale e agente. Se il principale valuta la performance in base a certe metriche, l'agente cercherà di ottimizzare le proprie ricompense anche se ciò non coincide con il massimo beneficio per il principale. Ad esempio, se un venditore fosse pagato solo a provvigione sul venduto, potrebbe essere tentato di realizzare vendite a qualunque costo, perché il suo incentivo sarebbe solo chiudere contratti, mentre l'azienda avrebbe interesse a relazioni di lungo termine con clienti soddisfatti. Jensen e Murphy (1990) discussero ampiamente il tema dell'allineamento degli incentivi, sottolineando come sistemi di compenso mal disegnati possano peggiorare i problemi di agenzia invece di risolverli.
- I *costi di monitoraggio e controllo* completano il quadro: per mitigare i problemi di cui sopra, il principale deve investire in meccanismi di monitoraggio delle azioni dell'agente (controlli, reportistica, audit) e in contratti che leghino la retribuzione dell'agente ai risultati desiderati. L'agente, dal canto suo, potrebbe sostenere costi di bonding (ovverossia di garanzia), cioè spese per segnalare il proprio impegno o assicurare il principale. Anche rispettando queste misure, generalmente nell'equazione resta una perdita residua perché non si può azzerare del tutto il conflitto di interessi senza costi proibitivi.

La storia del management e della filosofia morale ci ricordano che perseguire un fine e seguire un processo che renda legittimo quel fine non sono la stessa cosa perché esiste una profonda differenza tra una razionalità del risultato e una razionalità della condotta. La prima risponde alla domanda "come massimizzo l'output?", la seconda a "quali azioni sono ammissibili per ottenerlo?", ed un'antica legge organizzativa recita: l'ottimizzazione cieca del fine produce distorsioni. In altre parole, un agente può avere razionalità strumentale senza avere razionalità procedurale. Un buon agente non è quindi solo quello che raggiunge lo scopo, ma quello che lo persegue rispettando il processo legittimo per farlo, perché è il processo che dà forma, trasparenza e responsabilità al risultato.

6.4 Cosa significa (davvero) "agente" nel contesto dell'IA

"La saggezza inizia con la definizione dei termini." — Attribuita a Socrate

Il termine “agentico” applicato all’IA è spesso usato in modo ambiguo e generico. Nel linguaggio comune dell’industria tech, un AI agent evoca l’idea di un programma autonomo che, dato un obiettivo, può pianificare e agire indipendentemente per raggiungerlo, eventualmente interagendo con l’ambiente e altri sistemi. Tuttavia, come nota anche Ethan Mollick [41], “agente” rimane un termine sfumato: c’è stato molto buzz sugli agenti negli ultimi mesi, ma ancora (troppa) poca tecnologia che funzioni davvero bene. In altre parole, il concetto è di moda, ma la sua concretizzazione pratica è ancora embrionale e mal definita. Bisogna quindi chiarire i fondamenti del termine prima ancora di provare ad applicarlo all’AI per evitare di farci tirare in mezzo in modo acritico dall’Iper-Hype: d’altro canto si sa, quando le definizioni divergono, vince il marketing.

Il termine **agente** porta significati radicalmente diversi a seconda delle discipline alle quali si applica, creando confusione concettuale che il marketing tende a sfruttare sistematicamente. In economia (o più ampiamente nel “management”), gli agenti sono massimizzatori di utilità che operano sotto vincoli. Il mai abbastanza citato lavoro di **Herbert Simon** del 1955 [42] sulla razionalità limitata (per me, ma non solo per me ovviamente, il testo seminale della AI, quanto meno dal punto di vista sociale ancora più che organizzativo) riconobbe che gli agenti reali “soddisfano” piuttosto che ottimizzare a causa di limiti cognitivi e costi informativi, ma la razionalità rimane puramente procedurale ed esterna. Gli agenti economici non necessitano di essere coscienti o autonomi, semplicemente ottimizzano entro vincoli. In filosofia, invece, l’agenzia richiede intenzionalità (come specificato con il termine “aboutness” degli stati mentali di Brentano), coscienza, autonomia come auto-governo e responsabilità morale. La manipolazione sintattica di simboli è insufficiente per la comprensione semantica: gli algoritmi possiedono solo intenzionalità indiretta, “derivata” dai progettisti, non intenzionalità intrinseca radicata nella coscienza (e come non citare a difesa di questo postulato, che sembra sempre più “labile”, l’argomento della Stanza Cinese di Searle del 1980).

Tradizionalmente, nella letteratura sull’Intelligenza Artificiale classica, un agente è qualunque entità in grado di percepire l’ambiente ed eseguire azioni su di esso. Sotto questa definizione estremamente ampia (fornita da **Russell e Norvig** nel 1995, tanto per ricordarci che stiamo sempre parlando di cose che hanno già ampiamente l’età per votare anche al Senato), persino un termostato può essere considerato un agente, poiché “percepisce” la temperatura e “agisce” accendendo o spegnendo il riscaldamento. Ovviamente, nel contesto odierno, popolato da AI generative, con il concetto di AI agentica si intende qualcosa di molto più sofisticato. Una prospettiva contemporanea enfatizza l’autonomia decisionale: un agente AI come “un sistema che utilizza un Large Language Model per decidere autonomamente il flusso di controllo di un’applicazione”, dunque capace di prendere decisioni senza istruzioni passo-passo umane. In termini pratici, la differenza tra un AI tool (od un AI Workflow propriamente detto) ed un AI agent sta nel grado di autonomia: un tool esegue funzioni predefinite su comando, mentre un agente può pianificare, ragionare e svolgere compiti complessi indipendentemente. Conviene qui richiamare una distinzione che abbiamo già incontrato in precedenza nel contesto dei dati e degli analytics, perché illumina la questione agentica da un punto di vista inusuale o forse inatteso. L’AI discriminativa o analitica rappresenta l’IA tradizionale focalizzata su analisi di dati, classificazione, previsione o decisioni basate su regole e modelli predefiniti: è l’IA dei sistemi di business intelligence e dei modelli predittivi, quella che nel capitolo dedicato ai dati avevamo descritto nei suoi tre livelli (descrittivo, predittivo, prescrittivo) con il progressivo (seppur immediato) distacco dal fattuale. L’AI generativa invece è la famiglia di tecniche che creano nuovi contenuti: testi, immagini, audio, codice, elaborando output originali basati sui pattern appresi dai dati di addestramento. In pratica, l’IA discriminativa analizza e spiega i dati, mentre l’IA generativa produce qualcosa di nuovo. Molti cosiddetti agenti AI oggi integrano componenti sia analitiche sia generative, il che significa che operano simultaneamente nei due domini, con

le fragilità epistemologiche di entrambi. Oggi quando si parla di AI agantica si fa tipicamente riferimento a sistemi costruiti utilizzando modelli generativi ai quali si dà la possibilità di interagire con strumenti esterni (API, database, applicazioni) e prendere iniziative per raggiungere un certo obiettivo dichiarato. In soldoni, questi agenti, a partire da un goal provano a suddividere il compito in azioni, eseguirle iterativamente e auto-migliorarsi in loop (dandosi in modo molto divertente istruzioni in linguaggio naturale e, a volte, anche autogratificandosi o autocomplimentandosi, quando il risultato viene raggiunto, in questo il browser di OpenAI è inarrivabile per qualità e quantità dell'automotivazione). Questo paradigma ha acceso l'immaginazione di molti, facendo pensare a software in grado di svolgere autonomamente interi flussi di lavoro complessi, fungendo da "colleghi" artificiali, a volte sottostimando due elementi fondazionali prettamente umani che costituiscono un limite all'agentificazione: la poca "fantasia" organizzativa (ovverosia la limitata capacità di identificare quali casi applicativi perseguire) e l'abituale molta "confusione" organizzativa che porta spesso ad avere processi non documentati, basati su eccezioni più che su regole e fortemente ancorati e dipendenti dal giudizio umano.

Anche se in questi ultimi mesi gli sviluppi sono stati, come d'abitudine, esponenziali la realtà finora non ha mantenuto le promesse più audaci. Molte implementazioni pratiche di agenti AI hanno mostrato limiti sostanziali. Spesso, e per fortuna, questi agenti richiedono ancora un forte intervento umano ("human in the loop") per correggere errori, fornire feedback o autorizzare certe azioni. Non siamo ancora di fronte, per fortuna, a veri agenti pienamente autonomi: quelli attuali sono più vicini a strumenti estesi (magari percepiti come maggiormente user-friendly grazie alla possibilità di interagirvi in linguaggio naturale) che ad agenti con reale iniziativa propria.

6.5 Agency senza intelligenza: il paradosso che nessuno vuole nominare

"Non c'è niente di più spaventoso dell'ignoranza in azione." — Johann Wolfgang von Goethe (1749–1832)

Un'IA può davvero avere "agency"? In filosofia, agency indica la capacità di un'entità di agire in modo intenzionale e autonomo, prendendo decisioni e assumendosi la responsabilità delle proprie azioni. Attribuire agency ad un'IA è un tema ampiamente dibattuto, perché implica considerare l'IA capace di scelte intenzionali e volontà propria. Il filosofo **Luciano Floridi** [32] osserva che i sistemi di IA odierni mostrano "una forma di agency in domini specifici, potendo svolgere compiti o prendere decisioni entro parametri predefiniti, ma hanno zero intelligenza". In pratica l'IA può esibire comportamenti agentici (*goal-oriented*), quali risolvere problemi con successo in vista di un obiettivo, senza però possedere le proprietà cognitive che normalmente associamo a qualcuno che agisce in modo intelligente: comprensione, coscienza, intenzionalità.

Questa "agency senza intelligenza" comporta diversi limiti pratici. I modelli di AI generativa come i Large Language Model sono noti per l'illusione di competenza che riescono a creare in assenza di conoscenze che possano attribuire il vestito semantico a quel perfetto scheletro sintattico che viene computato. Sono estremamente efficaci nel produrre output plausibili e coerenti e di "illusorio" senso compiuto, dando l'impressione di "sapere" ciò di cui parlano. In realtà, come sottolineano le linguiste Emily M. Bender e Timnit Gebru [33] (autrici del famosissimo e forse per questo contestatissimo e contrastatissimo paper "Stochastic Parrots"),

questi modelli stanno semplicemente rielaborando in modo probabilistico i pattern del linguaggio assorbiti dai dati di addestramento, senza alcuna comprensione del significato. Un modello di linguaggio avanzato può generare con sicumera una frase perfettamente formattata e plausibile, ma priva di veridicità, “senza alcuna consapevolezza dell’errore”. I sistemi LLM non hanno un modello del mondo sottostante distinto dal sottoinsieme di testi in linguaggio naturale sui quali sono stati addestrati, né un meccanismo intrinseco per distinguere vero e falso. È lo stesso snodo epistemologico che abbiamo analizzato in precedenza parlando del passaggio dal fattuale al plausibile: l’AI genera plausibilità linguistica, non conoscenza fattuale, e il problema si amplifica quando a quella plausibilità si aggiunge la capacità di agire nel mondo. La mancanza di comprensione e di *common sense* comporta fragilità nell’autonomia. Un agire umano, anche se imperfetto, possiede buon senso e un modello causale del mondo, che lo aiutano a evitare azioni autodistruttive o insensate durante il perseguimento di un obiettivo. Gli odierni agenti AI, invece, possono trovarsi bloccati da contraddizioni logiche, ingannati da input fuorvianti o portati a tentare azioni inadeguate non avendo modo di “capire” il contesto. Il risultato è che senza una supervisione, difficilmente completano compiti complessi in modo affidabile. L’imprenditore Gary Marcus, critico noto dell’IA odierna, insiste sul fatto che non abbiamo ancora dotato le macchine di quella robusta base di buon senso e ragionamento che sarebbe necessaria per agenti autonomi davvero efficaci; quell’“ancora” a me fa un “ancora” un po’ paura.

Da quando mi occupo di Information Technology in modo professionale (se conto gli anni dell’università sono quasi trentacinque, oramai) mi sono sempre interessato al discorso attorno alla antropomorfizzazione delle tecnologie digitali, nei confronti della quale ho sempre avuto posizioni molto critiche (sia contro le detrattrici del tasto “ENTER” sia contro gli spacciatori di attribuzione di comportamenti peculiarmente umani a dei pezzi di sabbia silicica cotta alimentati a corrente continua). Con l’AI c’è stato un salto di “qualità” in questa perversione. Quello dell’agire è solo l’ultimo degli ambiti della cognizione umana che sono stati oggetto di overlap terminologico da parte dei sistemi digitali (intelligenza, apprendimento, visione, comprensione, la lista sarebbe lunga). Quando il marketing mainstream parla di Agenti AI, mescola intenzionalmente (si spera almeno intenzionalmente) tutti i significati (e le cose mescolate, non shakerate, tendenzialmente sono buone solo da bere). Promettono l’agenzia filosofica (autonomia, comprensione, intenzionalità) per giustificare la delega mentre forniscono agenzia informatica (automazione delle azioni entro vincoli). L’antropomorfizzazione sfrutta dei bias cognitivi che la psicodinamica e le neuroscienze hanno dimostrato ampiamente: è dal 1944, grazie alla ricerca di Heider-Simmel, che abbiamo scoperto che gli umani attribuiscono intenzionalità a qualsiasi cosa mostri comportamento orientato agli obiettivi. Il linguaggio del “digital employee” e degli “agenti che si uniscono alla forza lavoro” costituisce antropomorfizzazione strategica progettata per normalizzare la delega senza esame. Se l’IA è semplicemente un altro lavoratore, perché preoccuparsi di supervisione, verifiche o limiti? La metafora occulta differenze critiche: i dipendenti umani possiedono comprensione contestuale, giudizio morale e responsabilità legale. I sistemi di IA possiedono ottimizzazione statistica senza comprensione, azioni senza coscienza e capacità senza responsabilità.

6.6 La teoria dell’Agenzia applicata agli Agenti AI

“Il più grande pericolo in tempi di turbolenza non è la turbolenza, ma agire con la logica di ieri.” — Peter Drucker (1909–2005)

Tenendo a mente i limiti intrinseci succitati esaminiamo l'idea di considerare l'IA come “agente” nel senso economico-organizzativo del termine, ossia un soggetto che agisce per conto di un principale (l'azienda o il manager) e vediamo come i concetti classici della Agency Theory, analogamente o per contrasto, si applicano al caso di agenti non umani.

La *selezione avversa* nell'adozione di AI si manifesta quando un'azienda sceglie di implementare un sistema: c'è asimmetria informativa ex ante perché i venditori di soluzioni AI conoscono bene i propri modelli, ma l'azienda acquirente fatica a valutarne a fondo l'affidabilità, i bias nascosti, le limitazioni tecniche. Ogni fornitore dipinge il proprio prodotto come efficiente e sicuro, ma in mancanza di metriche standard e trasparenza, il rischio è di adottare un sistema non adeguato alle proprie esigenze o addirittura controproducente. Molte aziende potrebbero essere sedotte dall'hype e acquistare un “AI agent” per il customer service venduto come plug-and-play, per poi scoprire che richiede enormi quantità di dati di qualità (quelli di cui abbiamo parlato nel Capitolo 5) e continui aggiustamenti che non sono in grado di fornire efficientemente. Senza parametri chiari, l'azienda (che nel rapporto di agenzia gioca il ruolo del principale) non sa distinguere i buoni sistemi AI da quelli scadenti o non etici.

L'*azzardo morale* con un agente non umano può sembrare curiosamente paradossale considerando che un agente algoritmico, per definizione, non dovrebbe avere morale quanto meno intenzionale (anche se sull'assenza o sulla presenza di uno strato etico e morale nelle tecnologie votate all'efficacia penso di aver speso già più di qualche parola precedentemente). Tuttavia, se definiamo *moral hazard* come la situazione in cui l'agente, dopo essere stato investito del potere di agire, compie azioni che espongono il principale a rischi eccessivi perché egli (l'agente) non ne subisce le conseguenze, allora certe dinamiche con l'AI vi assomigliano. Un agente AI, infatti, non subisce direttamente il costo dei propri errori: se un sistema automatizzato prende una decisione sbagliata, le ripercussioni le affronta l'azienda, non certo il software, che continua a funzionare finché qualcuno non lo disattiva. Questa mancanza di accountability intrinseca può portare l'IA a perseguire l'obiettivo assegnato senza ponderare rischi collaterali che un umano invece considererebbe. Questo scenario non è puramente teorico: nel 2010 il cosiddetto Flash Crash di Wall Street (crollo improvviso poi recuperato in pochi minuti) fu amplificato da algoritmi di trading automatico che operavano senza comprendere il contesto, vendendo a valanga e poi riacquistando. Quegli algoritmi seguirono le loro regole ottimizzando probabilmente una qualche funzione profitto a brevissimo termine, incuranti del caos che stavano generando nel mercato: l'agente software non pativa direttamente il danno.

Gli *incentivi disallineati* tra principale e agente AI sono forse il problema meno evidente (più subdolo) e più impattante: l'AI farà esattamente ciò che le diciamo di fare, non necessariamente ciò che intendiamo. Un agente AI configurato per massimizzare il numero di ticket risolti potrebbe chiuderli senza risolverli, perché la sua funzione obiettivo non cattura la differenza tra “chiuso” e “risolto”. Un agente per il pricing potrebbe ottimizzare il margine unitario a scapito della relazione con il cliente, se nessuno ha codificato nella funzione obiettivo il valore della relazione a lungo termine. Siamo di fronte alla traduzione algoritmica di quello che la Agency Theory descrive da cinquant'anni: quando gli incentivi sono mal disegnati, l'agente ottimizza la metrica sbagliata con grande efficienza. Definire gli incentivi di un agente AI è l'equivalente contemporaneo del drafting contrattuale: bisogna codificare nei dati e negli obiettivi ciò che un tempo si negoziava a parole, e un algoritmo addestrato su obiettivi incompleti porta a esiti inattesi esattamente come un contratto incompleto porta a liti.

I *costi di monitoraggio* dell'AI completano il parallelo. Distribuire agenti AI in azienda non elimina i costi di controllo, se va bene li trasforma ma di sicuro almeno inizialmente può aumentarli, perché ora servono

competenze e strutture per monitorare i sistemi AI. Un modello di machine learning o, peggio ancora, di AI non è trasparente per “definizione”: bisogna investire in audit algoritmici, dashboard per tracciare le decisioni, team di validazione dei dati e output, test periodici per assicurarsi che le prestazioni rimangano nel previsto. Sempre occorre (e speriamo a lungo ancora) affiancare un “human-in-the-loop” in applicazioni sensibili. Per contro, se non si pone alcun monitoraggio umano, l'azienda si espone a rischi potenzialmente molto gravi.

Possiamo dunque dire che, concettualmente, l'uso di AI agentiche ricrea molte dinamiche tipiche del rapporto di agenzia: c'è un principale (l'organizzazione, i suoi leader) e un agente (il sistema AI) con informazione asimmetrica (il sistema diventa una sorta di scatola nera difficile da interpretare dall'esterno), con possibili comportamenti opportunistici (non intenzionali ma effettivi) e la necessità di riallinearlo e controllarlo. Non a caso, un articolo della California Management Review del 2025 [39] suggerisce di guardare agli AI agents come “lavoratori intelligenti al servizio di umani”, (io userei l'aggettivo “diversamente intelligenti” ma è un problema mio) il che aiuta a porsi le domande giuste su ruoli, funzioni e governance di questi sistemi. Si tratta di considerare l'agente AI come un intermediario che bilancia autonomia e rispetto degli obiettivi organizzativi, operando entro vincoli stabiliti dai suoi “datori di lavoro” umani. Questa prospettiva impone di esplicitare meccanismi di oversight, simili a quelli che useremmo con dipendenti od outsourcer: linee guida chiare, monitoraggio della performance, feedback e correzioni continue.

6.7 Come le aziende si riorganizzano per accogliere (e governare) gli Agenti

“L'organizzazione è semplicemente il mezzo per moltiplicare le forze degli individui.” — Peter Drucker

Che ci piaccia o no, gli “Agenti AI” sono tra noi e vanno gestiti (dopo averli capiti). Nelle organizzazioni ad alta intensità digitale si sta affermando sempre più un modello organizzativo abitualmente indicato come *Hub & Spoke*. In questo modello, si centralizzano in un hub le attività a basso valore aggiunto, altamente standardizzabili e automatizzabili, mentre le unità periferiche (spoke) si specializzano in attività a maggior valore, mantenendo però un forte collegamento orizzontale con l'hub per condividere informazioni e dati. L'hub svolge compiti transazionali nel modo più efficiente possibile (spesso con il supporto massiccio di sistemi digitali e AI). Le spoke sono invece team specializzati (per funzione o competenza), che utilizzano i dati e i servizi forniti dall'hub per produrre analisi, prendere decisioni strategiche ed innovare. Nel nostro contesto, un modello *hub & spoke* può essere un approccio per implementare l'AI agentica con maggiore controllo: si potrebbe concentrare un “cervello digitale” nell'hub che esegue decisioni comuni (pricing, allocazione risorse) sotto stretta supervisione centrale, mentre le unità spoke (umane) nei vari dipartimenti interagiscono con l'hub, ne validano gli output e si focalizzano su eccezioni o su attività non automatizzabili. Questo garantirebbe una certa standardizzazione ed un governo centralizzato (riducendo costi di agenzia, perché l'AI hub è unico e monitorabile) ma anche adattamento locale tramite le spoke.

Credo fermamente che le organizzazioni dovrebbero puntare (almeno inizialmente) su collezioni di agenti specializzati che collaborano come un team di professionisti, ciascuno con compiti ristretti e facilmente monitorabili. Ciò faciliterebbe il controllo (ogni micro-agente è più prevedibile) consentendo di sfruttare intelligenza collettiva uomo-macchina. Ad esempio, in supply chain potremmo avere un agente AI per la

previsione della domanda, uno per l'ottimizzazione delle scorte, uno per la schedulazione della produzione, tutti coordinati e con esseri umani pronti a intervenire per le decisioni critiche. Come ha recentemente notato Yoshua Bengio, “usare sistemi non agentici per controllare sistemi agentici”, cioè affiancare alle AI autonome dei guardrail software sviluppati in modalità “tradizionale o fondazionale” che ne verifichino le mosse, impongano vincoli e le blocchino in caso di deviazione. Questo approccio orchestrato sta emergendo come best practice: orchestratori che garantiscono sicurezza, accountability e interoperabilità degli agenti AI in processi aziendali, programmati però secondo le modalità dell'informatica classica e non di quella analitica.

6.8 Rischi emergenti e opportunità latenti

“La tecnologia è un servo utile ma un padrone pericoloso.” — Christian Lous Lange (1869–1938)

L'analisi critica della convivenza aziendale, accademica e sociale con l'AI di questi ultimi anni ha reso evidenti alcuni pattern di rischio ricorrenti che si verificano nel delegare decisioni agli algoritmi e che saranno sicuramente esacerbati dalla “trasformazione Agentica” degli stessi.

In primis l'**opacità delle motivazioni**: spesso il perché di certe decisioni prese dall'AI non è chiaro agli umani (il problema di spiegabilità che il Capitolo dedicato all'etica aveva affrontato come quinto principio di Floridi). Se il principale non capisce le azioni dell'agente, la relazione di agenzia è estremamente problematica. Da qui l'enfasi crescente su AI explainability e la riaffermazione del diritto alla spiegazione (che andrebbe accompagnato dal diritto al rifiuto, dell'uso quanto meno, che invece è meno percepito come fondamentale). Altro elemento importante è la **de-responsabilizzazione umana**: c'è il rischio che “lo ha deciso l'algoritmo” diventi l'alibi per non prendersi responsabilità. Un manager potrebbe dire di fronte a un errore catastrofico: “è stata colpa del software”. Questo però non funziona né legalmente (le norme tendono a vietare la cosiddetta responsabilizzazione dell'AI al posto di quella umana) né moralmente con clienti e società. Occorre dunque definire chiaramente, in ogni implementazione di AI agentica, chi ne è il responsabile ultimo: tipicamente dev'esser sempre un referente umano a cui sono attribuite le decisioni dell'AI, come se fossero sue. I **rischi informatici e di sicurezza** non possono altresì essere trascurati: un agente AI connesso ai sistemi aziendali può diventare un vettore d'attacco, una “front door” per gli hacker. Qualsiasi delega all'AI si traduce in nuove superfici di rischio cyber. Bisogna controllare i dati in input (per evitare injection) e mettere limiti alle azioni non supervisionate. L'**impatto sulle persone e sull'organizzazione** è uno dei temi aperti sui quali ci si inizia ora seriamente a soffermare: delegare decisioni all'AI incide sulla struttura organizzativa e sulle persone, in quanto alcuni ruoli inevitabilmente potrebbero ridursi, ridimensionarsi o cambiare. Se l'azienda spinge troppo velocemente sull'automazione, può perdere preziose conoscenze tacite (quelle stesse conoscenze che avevamo identificato come il vero asset nascosto delle imprese e delle organizzazioni). I costi di agenzia “umani” si trasformano in costi di supervisione tecnica per cui il ritorno dell'investimento deve tenere conto dei costi nascenti, non solo degli ipotetici cessanti. Ultimo ma non ultimo bisogna considerare gli **aspetti legali e normativi**: in alcuni settori esistono normative specifiche che di fatto richiedono la presenza umana nella formulazione della decisione finale (e meno male). I confini della delega vanno quindi tracciati, oltre che sulla base della sperata performance e della necessaria etica, anche in base alle norme vigenti. Su questo scenario entra in gioco l'AI Act europeo [43], che in precedenza avevamo collocato nel quadro più ampio dei quattro insiemi (leggi, governance, compliance, etica) che si complementano senza contenersi.

6.9 Superare l'hype, verso un'adozione consapevole

“La realtà è ciò che non scompare quando smetti di crederci.” — Philip K. Dick (1928–1982)

La scelta che già affrontano organizzazioni e società non è se adottare l'IA ma come governare la delega a sistemi che ottimizzano senza comprendere, agiscono senza coscienza e scalano la fallibilità umana a velocità macchina. La teoria classica dell'agenzia fornisce un framework analitico ricco: l'AI è il nuovo agente e noi rimaniamo i principali, con tutto l'onere di selezionare, dare i giusti incentivi, monitorare e assumerci la responsabilità delle azioni. Dove non lo facciamo, i “costi di agenzia” si presenteranno sotto forma di decisioni sbagliate, perdite economiche, danni reputazionali o sanzioni. In un certo senso, addestrare e configurare un AI agent è il nuovo drafting del contratto: dobbiamo codificare per iscritto (nel codice e nei dati) ciò che un tempo negoziavamo a parole con un dipendente. E proprio come un contratto incompleto può portare a liti, un algoritmo addestrato su obiettivi incompleti porta a esiti inattesi. L'hype collasserà: non perché l'IA manca di utilità ma perché le rivendicazioni di agenzia autonoma non possono (ancora?) sopravvivere al contatto con la realtà. Ciò che rimarrà dopo la bolla sarà più prezioso, come di solito avviene: chiarezza sull'IA come strumento potente ma limitato, framework di governance che bilanciano innovazione con responsabilità e valutazione realistica di dove l'IA aumenta il giudizio umano e dove la comprensione umana rimane insostituibile. Prima sostituiamo il marketing dell'“IA agentico” con una descrizione accurata di capacità e limitazioni, prima potremo distribuire queste tecnologie responsabilmente. La teoria classica dell'agenzia ce lo dice da cinque decenni. Dovremmo ascoltare.

Ma la questione più profonda, quella che l'illusione agentica rende urgente senza riuscire a formularla, non riguarda le macchine: riguarda noi. Cosa succede alle persone quando il rapporto quotidiano con sistemi che simulano agency diventa la norma? Come cambia il modo in cui pensiamo, decidiamo, ci rapportiamo alla conoscenza? È la domanda con cui si apre la Parte III di questo libro, che è interamente dedicata alla dimensione cognitiva e umana del rapporto con l'AI affrontando tutte le articolazioni della mia personale, quotidiana, inquietudine, quella che nasce quando ci accorgiamo che la tecnologia non cambia solo cosa facciamo ma, più sottilmente, chi siamo mentre lo facciamo.

Parte III

L'umano al centro (ma quale umano, e
quale centro?)

Siamo ancora convinti di stare soltanto “usando” uno strumento?

“Dov’è la saggezza che abbiamo perduto nella conoscenza? Dov’è la conoscenza che abbiamo perduto nell’informazione?” — T.S. Eliot, Cori da “La Rocca” (1934)

La seconda parte si era chiusa cercando di ridimensionare (o inconsciamente di allontanare il momento del confronto della realtà) la pretesa (che il marketing presenta come “agente autonomo”) che bastasse cambiare la natura di chi esegue (da umano ad algoritmico) per risolvere problemi di delega che la teoria dell’agenzia studia irrisolti da mezzo secolo. Per farlo, in tutta la Parte II, abbiamo analizzato gli “oggetti” (mi stava per scappare “soggetti”) della rivoluzione: i sistemi che si costruiscono sui propri dati, il terreno su cui li si edifica, il coding e le altre “competenze” degli agenti che promettono di accelerare ogni aspetto della transizione. Era rimasto programmaticamente in ombra il soggetto (questa volta ci vuole) che quella rivoluzione dovrebbe abitare. In questo mio dialogo interiore tra oggetto e soggetto si annida un piccolo paradosso che ritengo istruttivo: ci si affanna a stabilire se la macchina sia diventata un soggetto (attribuendogli le dignità, in particolari agli agenti), il soggetto che rischiamo davvero di trascurare è l’essere umano che la usa, lo stesso che pensa di usarla mentre, in misura crescente, ne viene usato. La domanda di questa terza parte non è più “cosa sta cambiando là fuori”, ma “cosa sta cambiando qui dentro”, nella mente di chi pensa, nel gruppo che collabora nel perseguire un fine definito da una potenzialmente nuova catena di responsabilità.

L’ipotesi (perché di ipotesi continuo a trattare, non di teoremi) è che la rivoluzione di **pertinenza** descritta in precedenza abbia un correlato disposto sul lato umano che la narrazione dominante fatta tutta di ore risparmiate, frecce verso l’alto e persone sorridenti, ignora con una sistematicità che ha smesso da tempo di sembrarmi casuale. Il vero collo di bottiglia, e insieme il vero rischio, di questa trasformazione è cognitivo, relazionale, etico e filosofico non certo tecnologico. L’AI generativa, dobbiamo dircelo, non è uno strumento neutro che impugnamo e poi posiamo, ma un agente che modella nuove forme del nostro spazio cognitivo mentre lo usiamo, e lo fa variando i registri (retaggio del mio passato da organista che affiora) attorno ai quali ho organizzato i quattro capitoli di questa parte: le competenze e la cognizione del singolo, la collaborazione del gruppo, la responsabilità del sistema. Avverto fin d’ora, per onestà metodologica, che in queste pagine abbondano i costrutti speculativi e le ipotesi di lavoro non ancora pienamente verificate (o solo verificate in parte od in misura statisticamente ancora poco rilevante) perché preferisco sbagliare in modo utile, e cioè confutabile, che tacere in modo prudente.

Il **Capitolo 7** apre con una diagnosi controintuitiva ma difficile da ignorare: con l’AI generativa una

maggiore competenza tecnica non si traduce in una maggiore consapevolezza, anzi tende a comprometterla. È il paradosso dell'AI literacy, ovverosia la dissociazione tra la confidenza percepita (che cresce) e l'accuratezza metacognitiva (che ristagna o peggiora), amplificata dalla considerazione del fatto che l'uso effettivo degli strumenti è in larghissima parte banale, e che proprio quella banalità costruisce una falsa padronanza che poi ci viene consegnata, intatta, nei contesti dove le conseguenze contano davvero. Dal singolo il fenomeno scala fedelmente all'organizzazione (la *skill ontology* mancante, lo *shadow use*, le pressioni opposte della "AI shame" e della FOMO) fino a recuperare il vocabolario di Mollick, Centauro e Cyborg, ma per denunciarne il limite: sono fotografie, descrivono stati e non storie, e lasciano aperti due debiti che il capitolo successivo è chiamato a saldare.

Il **Capitolo 8** prova a chiudere un primo "buco" trasformando le fotografie in un film (dell'orrore, probabilmente). Mettendo in dialogo tre lenti recenti (l'AI come pre-processore cognitivo, come terzo sistema esterno e come fattore di intensificazione del lavoro) propongo un modello a fasi della "deriva cognitiva", la traiettoria, non inevitabile ma nemmeno improbabile, che scivola dall'*augmentation* consapevole alla dipendenza epistemica, passando per quella zona grigia in cui la delega smette di essere strategica senza che il soggetto se ne accorga. È un capitolo sapore amaro ma anche quello in cui forse mi si palesa l'argine: la "resa cognitiva qualificata", che non chiede di usare meno AI per nostalgia luddista dell'amanuense, ma di sapere cosa stiamo cedendo, perché, con quali rischi e con quali verifiche. Non meno AI, dunque, ma AI governata.

Il **Capitolo 9** compie il salto di scala che cambia la natura del problema, e non soltanto la sua dimensione: dal singolo al gruppo. Prendendo a base empirica lo studio "The Cybernetic Teammate", argomento come l'AI generativa travalichi il proprio statuto di strumento di produttività per diventare un "collega sintetico" capace di replicare almeno tre pilastri della collaborazione umana (performance collettiva, condivisione di *expertise* e connessione sociale), costringendoci a un faticoso lavoro di revisione dei paradigmi consolidati, dalla teoria della complementarità alla ricchezza dei media, fino alla cognizione distribuita e alla teoria dell'attore-rete. È il capitolo in cui l'AI si rivela tecnologia sociale (con tutto ciò che di inquietante questo comporta sul piano dell'attaccamento e dell'influenza emotiva), e che proprio per questo non può chiudersi senza incontrare un nodo che lo attraversa come un basso continuo, e che è di natura etica.

Il **Capitolo 10**, infine, scioglie quel nodo portando la filosofia dentro l'operatività, e non come ornamento ma come necessità. Estendendo sul piano ontoetico l'analisi del collega sintetico, e appoggiandomi soprattutto a Floridi e a Benanti, provo a costruire la versione "pratica ed organizzativa" di quella bussola etica cui avevo tratteggiato le caratteristiche nel terzo capitolo. È il capitolo più "filosofico" e quindi quello in cui compaiono più domande che risposte, il che mi pare semmai un pregio e non un difetto.

Quattro capitoli, dunque, e un solo movimento di obiettivo: dal microscopio puntato sulla singola mente (la sua diagnosi, la sua deriva, la sua possibile cura) all'inquadratura più larga del gruppo che collabora, fino al grandangolo etico-ontologico che tutto comprende. Il filo che li tiene insieme è la convinzione che l'unica difesa disponibile, contro il paradosso, contro la deriva, contro la resa indiscriminata e contro l'attaccamento acritico, abbia sempre la stessa radice e lo stesso nome, ovverosia la consapevolezza, declinata di volta in volta come metacognitiva, relazionale ed etica. Una competenza poco vistosa e molto faticosa, esattamente come quella che, alla fine della Parte II, separava chi crea valore da chi semplicemente consuma token.

Questa terza parte, nel provare a dire cosa sta cambiando in noi, disvela che il sistema di senso più difficile da costruire non è quello che sta fuori, nei dati e nei processi, ma quello che abita dentro, nella mente che pensa e nel gruppo che collabora. Qui, per una volta, la domanda che attraversa l'intero libro smette di essere una metafora e diventa quasi letterale: trasformare la complessità in sistemi di senso significa, in queste

pagine, non perdere la saggezza dentro la conoscenza, né la conoscenza dentro l'informazione. Che poi, a leggerla bene, era la sola cosa che Eliot ci aveva chiesto di non dimenticare.

Capitolo 7

Il paradosso dell'AI Literacy: quando sapere di più fa capire di meno

“Il guaio del mondo è che gli stupidi sono sicuri di tutto e gli intelligenti sono pieni di dubbi.” — Bertrand Russell

Era inevitabile che il cortocircuito, prima o poi, si verificasse. Era, statisticamente, solo questione di tempo. Da quando è iniziata la "corsa all'oro" dell'adozione della AI in azienda (metafora che mi sembra rappresentare bene la situazione che stiamo vivendo: masse di persone che a fatica sanno distinguere la pirite dal rame ma che diventano esperte di ingegneria dei materiali "overnight", attratte da faraoniche promesse a discapito di rischi e difficoltà della "ricerca" e reali benefici che stentano ad arrivare per tutti tranne che per chi vende pale, picconi e setacci) uno dei pochi capisaldi che mi sono sempre, in modo intellettualmente onesto, sentito di poter garantire come non solo utile ma necessario è stato quello della formazione. Rendere le persone consapevoli di costi e benefici e dotarle di qualche "malizia" di base per poter quanto meno "gestire" se non comprendere gli strumenti che stavano entusiasticamente usando mi è sembrato sempre un imperativo morale più che un esercizio di business. Mosso dalla convinzione dell'educatore che tra saperne e non saperne è sempre meglio la prima mi sono imbarcato in questa battaglia contro i mulini a vento che è convincere i decisori aziendali che, se per guidare una macchina serve una patente che si consegue con corsi di settimane di teoria e pratica, per poter evitare di fare danni con uno strumento costruito ad arte per convincerci con la plausibilità di una perfetta sintassi priva di consapevolezza semantica, servissero almeno un paio di giornate di teoria e di pratica per tutti i supposti utilizzatori. E siccome credo che la coerenza sia il valore più prezioso per chi fa un mestiere basato sulla fiducia, mi sono poi reso attore in prima persona del percorso formativo per diverse centinaia di "studenti aziendali" con i quali ho avuto la possibilità di lavorare.

Anche al fine di poter portare, in questi scambi professionali, quanto più valore aggiunto possibile derivante anche dalle mie attività di ricerca accademica, mi sono poi lanciato in questo incessante percorso di lettura critica e differenziale dell'immenso volume di paper, ricerche, studi e saggi (equamente divisi tra autorevoli e seri e fuffa galattica) che mi ha condotto a questo fastidioso cortocircuito ed ad una domanda alla quale ho sentito l'urgenza di provare a darmi una risposta: *"ma non è che, a differenza delle discipline (termine sovraesteso per indicare dalle tecnologie alle teorie) che hanno una dinamica di relazione tendenzialmente*

monodirezionale (ovverosia qualcuno capisce qualcosa rispetto ad un 'fenomeno', lo spiega, lo comprendo, lo assimilo, lo interiorizzo, lo uso) nelle quali lo studio è preconditione per lo sviluppo della consapevolezza metacognitiva, con queste discipline (sovraesteso nuovamente quanto 'fenomeno') che instaurano una relazione non monodirezionale (dire bi-direzionale mi pareva al tempo stesso troppo e troppo poco) funziona diversamente, persino al contrario?"

Mi sono imbattuto, infatti, durante le mie ricerche, in uno studio empirico condotto da Fernandes e colleghi [48] che ha rivelato un fenomeno controintuitivo: con specifico riferimento all'AI Generativa, gli individui con **maggiore** AI literacy dimostrano una **minore** accuratezza metacognitiva quando utilizzano sistemi di intelligenza artificiale generativa per compiti cognitivi complessi. Il paradosso si manifesta attraverso una dissociazione critica tra la confidenza percepita (che risulta significativamente aumentata) e la capacità effettiva non tanto di eseguire con efficienza, quanto di monitorare l'accuratezza delle proprie prestazioni (che invece risulta invariata o, addirittura, peggiorata); ed è tanto più pronunciato quanto più cresce la familiarità con gli aspetti procedurali del lavoro con i *large language model*, ovverosia con il prompting, con la configurazione di parametri, con l'utilizzo di API. Per provare a capirci qualcosa di più, ho cercato di condurre un'analisi che andasse oltre i soli meccanismi psicologici individuali, mettendo in qualche modo in discussione le fondamenta epistemologiche e linguistiche su cui si è costruito il discorso contemporaneo sull'intelligenza artificiale. Come documentato da Floridi e Nobre [49] nel loro studio sul "prestito concettuale" (*conceptual borrowing*) tra l'Intelligenza Artificiale e le Scienze Cognitive (studio i cui elementi sono peraltro ripresi ed espansi nell'ultimo lavoro di Floridi [50]), esiste un cortocircuito linguistico sistemico che precede e alimenta i fenomeni di confusione metacognitiva osservati negli utilizzatori (diversamente e variamente esperti) di sistemi AI. Il cortocircuito si manifesta in una doppia direzione: da un lato, l'AI ha progressivamente adottato un vocabolario antropomorfo che attribuisce ai sistemi computazionali proprietà cognitive tipicamente umane (attenzione, apprendimento, memoria, ragionamento, comprensione); dall'altro, le neuroscienze cognitive hanno adottato un vocabolario derivato dalla teoria dell'informazione e dalle scienze computazionali per descrivere il cervello e la mente (encoding, processing, storage, retrieval, decoding). Questa reciproca appropriazione linguistica non è meramente metaforica ma sistemica, e genera confusione concettuale con conseguenze pratiche significative, particolarmente evidenti proprio nel contesto dell'AI literacy e delle sue manifestazioni paradossali.

7.1 Mappa infografica del capitolo




Figura 7.1: Mappa logica del Capitolo 7

7.2 La banalità dell'uso effettivo: quando la competenza tecnica incontra la poca significatività applicativa

Mentre mi addentravo nell'approfondimento delle manifestazioni sistemiche del paradosso nei contesti organizzativi, sono inciampato in un altro dato empirico che lo amplifica drammaticamente. Analisi condotte su oltre un milione di conversazioni di utenti ChatGPT tra maggio 2024 e giugno 2025 [46] rivelano un pattern tanto sorprendente quanto inquietante: l'utilizzo effettivo degli strumenti di AI generativa si concentra, almeno nei dati disponibili, in larghissima parte su applicazioni di basso valore cognitivo e limitata consequenzialità (intesa come azione generatrice di conseguenze o risultati). Le tre categorie di casi d'uso più frequenti (*Practical Guidance*, *Writing*, *Seeking Information*) includono prevalentemente editing di testi forniti dall'utente, consigli generici su argomenti vari, ricerca di informazioni fattuali (abitudine che sarebbe peraltro, comunque, deprecabile se si fosse in presenza di una reale conoscenza sul modello di funzionamento della AIGen) e modifiche superficiali di contenuti esistenti; e persino le conversazioni di tipo *writing* riguardano in misura significativa non la creazione di contenuto nuovo ma la modifica, la critica, la traduzione o la riformulazione di testo già prodotto dall'utente (nel bene e nel male). I dati disponibili non coprono ancora l'evoluzione successiva al giugno 2025; è quindi plausibile che la quota di messaggi di tipo sofisticato sia cresciuta, anche a causa o grazie dello sviluppo delle capacità agentiche. È però altrettanto plausibile che, contestualmente

ai pattern d'uso evoluti, siano cresciuti anche i task banali, sia per l'aumento della frequenza d'uso degli strumenti da parte di tutte le tipologie di utilizzatori, sia per l'allargamento (ancorché limitato) della platea complessiva. Il punto, comunque, è il paradosso nel paradosso: se la statistica non è una opinione, anche gli individui con elevata AI literacy tecnica impiegano questi strumenti in larghissima parte per operazioni elementari che richiedono valutazione critica minima. Ed è qui che si annida la trappola più sottile, perché l'utilizzo ripetuto dell'AI per compiti a bassa consequenzialità crea le condizioni ideali per lo sviluppo di quella che propongo di chiamare "metacognizione abitudinaria degradata": l'utente sviluppa routine di interazione fluide che generano output frequentemente adeguati (plausibili?) finché i task restano semplici, accumula confidenza globale nelle proprie capacità di utilizzo dell'AI e, nel frattempo, non sviluppa nessuna delle competenze di monitoraggio critico necessarie nei contesti realmente complessi (alimentando peraltro anche quella causa di entropia che è la banalità concettuale). Quando poi gli stessi utenti si trovano di fronte a task più rischiosi, applicano una (over)confidenza calibrata su esperienze di successo in contesti banali a situazioni che richiederebbero una vigilanza metacognitiva di tutt'altro ordine. Il fenomeno non resta confinato all'uso personale. Il Wharton AI Adoption Report [56] osserva che quasi la metà dei leader aziendali utilizza AI generativa quotidianamente (con un incremento significativo rispetto all'anno precedente, e con l'attesa di una ulteriore crescita nel corso di quest'anno), ma gli use case dominanti restano concentrati nelle stesse aree di produttività individuale-procedurale appena descritte. Il "modo d'uso prevalente" invade quindi anche i contesti lavorativi, dove le conseguenze di errori sottovalutati (quando, finalmente, l'AI viene utilizzata per task più significativi) potrebbero invece essere sostanziali. La porta di ingresso all'AI generativa, detto altrimenti, passa per use case banali che mascherano la necessità di sviluppare competenze metacognitive, costruiscono una falsa sensazione di padronanza, e ce la consegnano poi nei contesti in cui le conseguenze contano davvero.

7.3 Dal singolo al sistema: organizzazioni, ontologie mancanti, accesso ineguale

Scalando dal livello individuale, le rilevazioni di Randstad su lavoratori e talent leader, insieme alla ricerca Randstad Enterprise sulle competenze richieste in ventiquattro mercati [52, 54, 53], segnalano che lo stesso pattern si replica fedelmente anche su scala collettiva. Il dato che, a mio giudizio, merita più attenzione è la dissociazione tra l'auto-percezione delle competenze AI e la (quantità e qualità di) formazione effettivamente ricevuta: mentre una parte considerevole dei lavoratori dichiara di credere che le competenze AI miglioreranno le proprie prospettive di carriera e promozione, solo una minoranza molto esigua riporta di aver ricevuto qualsiasi forma di training AI nell'ultimo anno. Non si tratta semplicemente di domanda insoddisfatta di formazione, ma di una manifestazione del paradosso a livello collettivo (che poi si traduce, come ben sappiamo, in tanti piccoli paradossi di Dunning-Kruger): la padronanza superficiale degli strumenti AI consumer viene confusa con una competenza genuina che preparerebbe all'integrazione professionale dell'AI, esattamente come accade nel meccanismo dell'illusione della profondità esplicativa a livello individuale.

Il fenomeno si replica con una certa puntualità anche un piano sopra, in quello delle decisioni delle aziende (a riprova dell'adagio che le organizzazioni, alla fine, sono fatte di persone). I leader si entusiasmano in percentuali schiacciante per AI, automazione e robotica, e dichiarano che l'adozione di queste tecnologie ha migliorato l'attrazione, l'engagement e la retention dei talenti; tuttavia solo una minoranza molto limitata

delle organizzazioni riporta di aver costruito una mappatura sistematica delle competenze (una ontologia, in pratica) attese, trasformate e trasformande. Le organizzazioni sembrano cioè operare sull'assunto implicito che l'adozione di tecnologie AI sarà automaticamente benefica e trasformativa, intendendo per "adozione" l'acquisto di una manciata di licenze del chatbot ritenuto più adeguato accompagnato (neanche sempre) da una spolverata di formazione (magari asincrona, magari sotto forma di qualche video con la profondità di un TikTok), senza riconoscere che la realizzazione effettiva di quei benefici richiede una comprensione profonda e strutturata di quali competenze servano, di come si relazionino alle tecnologie AI, e di come debbano essere sistematicamente identificate, sviluppate e validate [54, 53]. La costruzione di una *skill ontology*, intanto, non è semplicemente una "nice to have" da amministrazione del personale, ma rappresenta l'infrastruttura epistemologica che permette a un'organizzazione di avere consapevolezza metacognitiva delle proprie capacità effettive rispetto all'AI, esattamente come la calibrazione metacognitiva permette agli individui di riconoscere accuratamente i propri limiti e lacune: una sorta di "immunità di gregge" al qualunquismo da AI a tutti i costi. Detto in modo più diretto, un'organizzazione che proclama trasformazione AI-driven senza costruire una *skills ontology* è l'equivalente sistemico esatto di un individuo con elevata AI literacy tecnica ma bassa accuratezza metacognitiva, oververosia operativamente efficiente ed epistemicamente confuso al tempo stesso.

C'è poi una dimensione di accesso che amplifica ulteriormente l'effetto e di cui non si parla mai abbastanza. L'esposizione all'AI (e quindi la probabilità di sviluppare insieme fluency tecnica e potenziali deficit metacognitivi) è distribuita in modo fortemente diseguale lungo la forza lavoro: i *knowledge workers* la utilizzano con frequenza significativamente maggiore rispetto ai *frontline workers*, i lavoratori con educazione universitaria o post-universitaria molto più di quelli con sola formazione secondaria, e sul resto i bias metacognitivi e di *self confidence* ricalcano puntualmente quanto abbiamo visto negli ultimi vent'anni in termini di gender e generazioni (overconfidenza maschile, maggiore resistenza nelle generazioni BabyBoomer rispetto alle GenZ, e via scorrendo) [45, 44]. Su questo terreno fiorisce un fenomeno particolarmente sgradevole, lo *shadow use* dell'AI, che solleva questioni critiche di governance, responsabilità e rischio organizzativo, e che è a sua volta il prodotto di una doppia pressione opposta. Da un lato esiste ed è presente (culturalmente nelle nostre aziende italiane forse più che altrove) la "AI shame" che porta a negare l'utilizzo anche quando palese. Dall'altro, e all'opposto, la FOMO (*fear of missing out*) generata dalla paura della sostituzione, ormai *mainstream* come messaggio, crea incentivi perversi all'overconfidence, spingendo i lavoratori a proiettare sicurezza e competenza nell'uso dell'AI anche quando la loro comprensione effettiva è superficiale, pur di non apparire obsoleti o inadeguati [55]. Il combinato disposto, in entrambe le direzioni, lavora contro la trasparenza necessaria a costruire qualunque calibrazione metacognitiva, individuale o organizzativa.

7.4 Centauro e Cyborg: una grammatica delle posture (prima che diventi una traiettoria)

Fin qui ho descritto un problema senza nominare la possibile soluzione. Ho mostrato che la competenza tecnica può degradare l'accuratezza metacognitiva, che l'uso effettivo è in larga parte banale, che la sovraconfidenza individuale si replica come sovraconfidenza organizzativa, ma ho lasciato implicito il termine di paragone, oververosia che cosa sarebbe, almeno secondo me, una postura non patologica nei confronti dell'AI generativa. È un debito che conviene saldare adesso, prima di passare alle implicazioni, perché senza un vocabolario del comportamento "sano" la diagnosi rimane una requisitoria e le contromisure rischiano di apparire moralistiche.

Il vocabolario più maneggevole che la letteratura recente abbia prodotto è quello reso popolare da Ethan Mollick in *Co-Intelligence* [51] ed ancorato empiricamente, tra gli altri, dagli studi sul campo di Dell'Acqua e colleghi [47]: la distinzione tra l'uso "centauro" e l'uso "cyborg" dell'intelligenza artificiale. Sono due figure mitologiche e cibernetiche usate come metafore di altrettante architetture della collaborazione. Nel paradigma del Centauro la divisione del lavoro tra umano e macchina è decisa a priori e resta riconoscibile: l'essere umano mantiene il controllo sui contenuti che contano e delega all'AI compiti circoscritti, sfruttandola come strumento di potenziamento ma preservando un confine netto tra il proprio contributo e quello della macchina (l'immagine metaforica è quella della creatura metà uomo e metà cavallo, in cui le due nature restano distinguibili anche se cooperano in un solo corpo). Nel paradigma del Cyborg l'integrazione è invece così profonda da risultare quasi inscindibile: umano e AI lavorano in simbiosi continua su ogni sotto-compito, interrogandosi a vicenda in modo dialogico, senza una ripartizione preventiva delle responsabilità e sfumando la capacità di identificare a posteriori chi ha fatto cosa. Mollick offre anche una tassonomia complementare, quella dei "ruoli" che possiamo far assumere all'AI (assistente, partner creativo, coach, esperto, tutor), che è di grande utilità quando si esce dal campo del teorico e si entra in quello applicativo. Ma ciò che interessa qui non è la tassonomia, è l'asimmetria che separa le due figure, un'asimmetria che è facile non vedere perché entrambe vengono di norma presentate come usi "evoluti" e quindi, implicitamente, come traguardi equivalenti quando equivalenti non sono. Il Centauro è protetto da un dispositivo strutturale, ovverosia il confine esplicito tra ciò che decide l'uomo e ciò che esegue la macchina: quel confine non è soltanto una ripartizione di compiti, è un'impalcatura metacognitiva, perché obbliga chi lo presidia a sapere, in ogni momento, che cosa ha delegato e con quale criterio lo valuterà. Il Cyborg quel confine lo dissolve per definizione, e con esso dissolve la struttura: non perché qualcuno decida deliberatamente di abolirlo, ma perché, nella simbiosi continua, presidiarlo smette progressivamente di essere comodo (o sostenibile in termini di costi). Ne discende che quella del Cyborg, inevitabilmente (in quanto più evoluta ed anche più efficace) è una postura strutturalmente più esposta, perché l'unico argine che le resta non è più architetture ma interamente affidato a quella vigilanza metacognitiva che abbiamo desunto essere proprio ciò che si erode per primo, e proprio nei più competenti. Detto altrimenti, ciò che separa un Cyborg ancora consapevole da un utente che si è semplicemente arreso allo strumento non è il grado di integrazione, che è identico, ma una vigilanza che il paradosso dell'AI literacy ci impone di non dare per scontata.

Qui i due fili del capitolo si annodano. Il paradosso dell'AI literacy non è un fenomeno che avviene *accanto* ai paradigmi di Mollick, è precisamente ciò che accade *dentro* di essi quando viene meno l'unica condizione che li tiene in piedi. Un Centauro che perde l'accuratezza metacognitiva non smette di essere un Centauro nella forma, ma il confine che credeva di presidiare diventa una finzione, perché non è più in grado di valutare se ciò che ha delegato sia stato eseguito bene. Un Cyborg che perde quella stessa vigilanza non è un collaboratore aumentato, è un utente in caduta che ha scambiato la fluidità dell'interazione per padronanza del risultato, e che non se ne avvede proprio perché nel Cyborg, a differenza che nel Centauro, non resta più alcun confine la cui violazione possa fargli da campanello d'allarme. I paradigmi, in altre parole, descrivono che cosa la relazione *dovrebbe* essere, il paradosso descrive il punto e il modo esatti in cui essa *comincia* a guastarsi. C'è però un limite, voluto, in questo vocabolario, ed è quello che apre ai ragionamenti sulla dinamica della relazione. Centauro e Cyborg, così come Mollick li propone, sono fotografie: descrivono *stati* della relazione, non la sua *storia*. Non dicono nulla su come si passi dall'uno all'altro, né se quel passaggio sia reversibile, né dove conduca se nessuno lo governa. Eppure tutto ciò di cui ho parlato sino ad ora (la metacognizione abitudinaria degradata, la confidenza calibrata su task banali e poi trasferita acriticamente, l'over-confidence

che si sedimenta a livello organizzativo) suggerisce con insistenza che non stiamo osservando due posizioni stabili, ma due tappe di un movimento che ha una direzione visibile anche se non nota. La domanda che resta aperta è dunque la più scomoda di tutte: si può abitare la postura del Cyborg senza scivolare nella resa, e se sì, in forza di quale competenza, dato che la sola buona volontà parrebbe non bastare?

7.5 Implicazioni per interventi educativi e organizzativi: oltre la literacy tecnica verso la consapevolezza metacognitiva

Come prima parziale risposta alla mia fastidiosa domanda, posso iniziare a dire che gli approcci tradizionali alla formazione AI potrebbero essere non solo insufficienti, ma potenzialmente controproducenti se non accompagnati da interventi esplicitamente mirati alla calibrazione metacognitiva e alla consapevolezza critica del vocabolario tecnico. Lo stimolo che ho dedotto da questi ragionamenti e che ho implementato nei miei modelli educativi sul tema è quello di incorporare esplicitamente tre componenti:

- Primo, formazione metacognitiva esplicita che insegni a discenti non solo come usare l'AI ma anche come monitorare e valutare criticamente la qualità dei propri processi di utilizzo e degli output generati. Questo attraverso pratiche strutturate di self ed etero explanation, prompt di riflessione metacognitiva integrati nei workflow, ed esercizi di calibrazione che aiutino gli individui a sviluppare una comprensione più accurata dei propri limiti e delle situazioni in cui è necessaria verifica esterna o terza.
- Secondo, formazione linguistico-critica che renda consapevoli del vocabolario antropomorfo che permea il campo dell'AI e delle confusioni concettuali che questo vocabolario può generare. Chi partecipa ad un training sull'AI dovrebbe essere esplicitamente istruito sulla differenza tra uso computazionale e uso cognitivo-umano di termini come "attenzione", "comprensione", "ragionamento", sviluppando l'abitudine di disambiguare sistematicamente tra questi sensi quando discute di capacità AI.
- Terzo, formazione orientata alla validazione che insegni competenze pratiche di verifica, testing, e quality assurance appropriate per diversi tipi di output AI e contesti applicativi.

A livello organizzativo, le implicazioni del paradosso rafforzano ancora maggiormente la necessità di ripensare fondamentalmente come le organizzazioni governano, monitorano e supportano l'utilizzo dell'AI da parte dei propri lavoratori. Esiste un bisogno urgente di creare ambienti in cui l'uso dell'AI possa essere trasparente, supportato e appropriatamente supervisionato senza creare incentivi ad un uso "shadow". Questo richiede un equilibrio delicato: da un lato, le organizzazioni devono implementare meccanismi di oversight che prevengano utilizzi rischiosi o disfunzionali dell'AI, dall'altro, devono evitare politiche troppo restrittive e tali da spingere l'utilizzo ancora più in ombra.

Stante che la psicodinamica cognitiva ci ha insegnato da anni che gli adulti consenzienti apprendono solo tramite il confronto tra *peer*, uno degli assi portanti può essere lo sviluppo di "AI champions" a livello organizzativo, ovverosia individui con formazione specializzata non solo nell'uso tecnico dell'AI ma anche nei principi di calibrazione metacognitiva, validazione critica e consapevolezza linguistica. Questi champions devono fornire consulenza a richiesta ai colleghi che utilizzano AI per task rilevanti in termini di impatto, aiutandoli a identificare situazioni ad alto rischio dove la verifica esterna è essenziale, suggerendo strategie di validazione appropriate, e facilitando la riflessione critica sui propri processi di utilizzo. Parallelamente,

le organizzazioni potrebbero implementare "infrastrutture metacognitive" nei propri "Portali AI interni" (strumenti sempre più diffusi per raccogliere e condividere la conoscenza interna e le best practice locali) e nei workflow digitali, incorporando prompt strutturati che incoraggino gli utenti a riflettere criticamente sulla qualità e affidabilità degli output AI prima di prendere decisioni basate su di essi.

7.6 Conclusioni: verso una maturità epistemica nell'era dell'AI generativa (forse)

Siamo nel mezzo di una transizione epistemologica spinta dall'intelligenza artificiale generativa, caratterizzata da una tensione fondamentale tra la rapidità con cui evolviamo nella nostra capacità tecnica di creare e utilizzare sistemi sempre più sofisticati e la lentezza con cui la nostra comprensione personale e organizzativa, concettuale, epistemologica e metacognitiva si adatta a questa nuova realtà tecnologica. Stiamo vivendo un momento storico in cui i confini tra cognizione umana e computazione artificiale stanno diventando progressivamente sfumati nel senso fenomenologico e linguistico dell'esperienza quotidiana di interazione con questi sistemi, anche se le differenze ontologiche rimangono profonde, e questa sfumatura crea condizioni ideali per confusioni che possono avere conseguenze pratiche significative. Solo attraverso uno sforzo coordinato e multidisciplinare che affronti esplicitamente questa transizione epistemologica nelle sue dimensioni cognitive, linguistiche, sociali, organizzative e tecnologiche, rifuggendo le banalizzazioni marketing della "tecnologia a scaffale", sarà possibile trasformare una vulnerabilità empiricamente dimostrata in opportunità per lo sviluppo di forme mature, riflessive e criticamente informate di expertise umana nell'era dell'intelligenza artificiale generativa.

Abbiamo quindi identificato ed isolato una vulnerabilità, il paradosso dell'AI literacy, abbozzandone i contrappesi educativi e organizzativi. Restano due cose importanti da fare:

- la prima è trasformare le fotografie di Mollick in un film: se Centauro e Cyborg non sono due stati stabili tra cui si sceglie una volta per tutte, ma due momenti di un movimento orientato, allora occorre un modello che ne descriva le fasi, gli indicatori osservabili e gli esiti possibili;
- la seconda cosa riguarda un verbo che ho usato con una certa disinvoltura, "arrendersi". Serve formalizzare in qualche modo che delegare all'AI non è, di per sé, il problema, ma che esiste una differenza sostanziale tra una delega governata, verificata e reversibile ed una resa indiscriminata.

Assolutamente non usare "meno AI" per principio, ma costruire la competenza metacognitiva che consente di sapere che cosa si sta cedendo, perché lo si sta cedendo, con quali rischi e con quali verifiche: una competenza che chiamerò "resa cognitiva qualificata" e di cui le tre componenti formative appena proposte sono, a ben vedere, soltanto il primo schizzo.

Capitolo 8

Pensa per noi, ci fa lavorare di più, e continua a sembrarci pure una buona idea

“La civiltà progredisce estendendo il numero di operazioni importanti che possiamo compiere senza pensarci.”

— Alfred North Whitehead, *An Introduction to Mathematics*, 1911

Incurante del passare del tempo il dibattito pubblico sull'intelligenza artificiale continua a oscillare tra due caricature abbastanza comode: da un lato i profeti dell'efficienza *uber alles*, dall'altro i catastrofisti della sostituzione totale. La partita retorica ha oramai stancato anche i più pazienti pur lasciando sullo sfondo una domanda meno spettacolare e (forse per questo) più interessante: *cosa sta succedendo dentro la testa di chi usa l'AI tutti i giorni?* Quando un professionista delega una bozza di analisi a un chatbot o un manager chiede una sintesi invece di leggere venti pagine di un report, non sta solo risparmiando tempo, ma sta anche modificando il modo in cui seleziona informazioni, valuta alternative e misura la fiducia nel giudizio personale.

La ricerca sull'*automation bias* ci dice da almeno trent'anni che gli esseri umani tendono a fidarsi troppo dei sistemi automatizzati (anche quando sbagliano) ed a ridurre progressivamente vigilanza e competenze autonome [67, 66]. L'AI generativa non inventa questo meccanismo, “semplicemente” lo porta dentro domini cognitivi che fino a ieri sembravano più protetti come scrittura, analisi, sintesi e giudizio professionale. Per capirci qualcosa di più (anche alla luce di quanto precedentemente postulato circa l'*AI Literacy*) ho provato a mettere in prospettiva e in dialogo tre contributi recenti che ruotano (consapevolmente) attorno ai risultati degli studi di Kahneman. Il primo è il lavoro di Chiriatti e colleghi sul System 0, l'AI come pre-processore cognitivo che prepara il mondo prima che System 1 e System 2 entrino in scena [58]. Il secondo è la Tri-System Theory di Shaw e Nave, che descrive l'AI come un terzo sistema cognitivo esterno e introduce la distinzione, decisiva, tra *cognitive offloading* e *cognitive surrender* [70]. Il terzo è il contributo organizzativo di Ranganathan e Ye, che mostra come l'AI, invece di alleggerire il lavoro, tenda spesso a intensificarlo [68]. Letti insieme, questi contributi suggeriscono l'instaurarsi di un ciclo piuttosto fastidioso: l'AI espande le capacità percepite, erode parte dell'autonomia cognitiva reale e intensifica il lavoro, il tutto mentre continuiamo a chiamare

questa spirale “progresso” con una certa qual tronfia soddisfazione. Nella prima parte sintetizzo le tre lenti; nella seconda propongo, con il pudore metodologico del caso, due costrutti speculativi (parzialmente originali): un modello a fasi della relazione cognitiva con l’AI e il concetto di “resa cognitiva qualificata”. Speculativi sì, ma in un campo dove il fenomeno corre più veloce della ricerca, l’onestà epistemica è il minimo sindacale.

8.1 Mappa infografica del capitolo



Figura 8.1: Mappa logica del Capitolo 8

8.2 Tre lenti per mettere a fuoco lo stesso fenomeno

8.2.1 System 0: l’AI che pensa prima di te

Il contributo di Chiriatti e colleghi parte da un assunto potente: nel modello di Kahneman [62], System 1 e System 2 presuppongono che il soggetto abbia accesso a informazioni relativamente grezze su cui esercitare intuizione e decisione. Ma cosa succede quando quelle informazioni arrivano già filtrate, sintetizzate, ordinate e riformulate da un’AI? In questo caso il System 1 reagisce a stimoli che non sono più “natural” ma pre-elaborati, e il System 2 ragiona su materiale che “qualcun altro” (o meglio, qualcos’altro) ha già selezionato. È questo il senso del System 0: non un terzo modo di pensare, ma uno strato che si interpone tra mondo e cognizione, plasmando il substrato informativo su cui poi lavorano intuizione e ragionamento.

L’AI non decide necessariamente al posto nostro, ma ridefinisce il nostro spazio delle possibilità cognitive: cosa vediamo, cosa consideriamo rilevante e (quindi) quali opzioni ci appaiono disponibili. È una forma di

framing effect indotto dall'automazione, in cui il sistema non impone una scelta ma rende alcune alternative più salienti di altre [59].

Il merito del modello proposto è (a mio giudizio) collocare l'AI nel modello cognitivo dominante senza forzature. Il limite (forse) è che resta soprattutto concettuale. I framework proposti dagli autori per un'integrazione responsabile sono adeguati forse generici: dicono cosa dovremmo fare, non come farlo, e soprattutto non spiegano cosa succede quando non lo facciamo. Qui diventa utile il “comfort-growth paradox” di Riva [69] per il quale la comodità dell'assistenza AI crea una zona di comfort che inibisce crescita e manutenzione cognitiva. È la vecchia ironia dell'automazione di Bainbridge in versione linguistica e professionale: automatizziamo perché l'umano è imperfetto, poi rendiamo l'umano più fragile togliendogli pratica [57].

8.2.2 Tri-System Theory: l'AI che pensa con te (o al posto tuo)

Shaw e Nave compiono un ulteriore salto di livello: non aggiungono direttamente l'AI al modello di Kahneman, ma propongono di trasformarlo da duale a triadico [70]. L'AI diventa un System 3, cioè un sistema cognitivo esterno al cervello, dotato di velocità, accuratezze, limiti e bias propri. Non è semplicemente uno strumento; è un interlocutore cognitivo che può potenziare, sostituire o deformare il processo decisionale. La distinzione che trovo più utile è tra *cognitive offloading* e *cognitive surrender* che viene così introdotta:

- Il *cognitive offloading* è strategico: delego un compito all'AI, ma mantengo intenzione e capacità di verificare, correggere e integrare l'output.
- La *cognitive surrender* è acritica: accetto l'output senza valutazione indipendente, non necessariamente per pigrizia, ma per fiducia eccessiva, costo percepito della verifica e difficoltà nel capire quando la delega è appropriata.

I tre esperimenti del paper sono interessanti proprio perché mostrano quanto la resa cognitiva sia resistente. Si verifica anche quando i partecipanti vengono avvertiti che l'AI può sbagliare; non diminuisce in modo significativo con incentivi economici legati all'accuratezza e cambia sotto pressione temporale in modi più complessi di quanto ci si aspetterebbe. Il risultato è coerente con la letteratura sull'*automation bias*, che ha più volte mostrato quanto consapevolezza e incentivi siano mitigatori deboli [61]. Ed è coerente anche con quanto ho cercato di mostrare in precedenza ragionando sul paradosso dell'AI Literacy: l'avvertimento “l'AI può sbagliare” tende a rimbalzare proprio su chi avrebbe più bisogno di accoglierlo, oltretutto su chi ha sviluppato una confidenza tecnica sufficiente a sentirsi al riparo dall'errore, ma non una accuratezza metacognitiva sufficiente a riconoscerne le condizioni di occorrenza. La tassonomia dei percorsi cognitivi proposta da Shaw e Nave, da intuizione e deliberazione fino ad *offloading*, *surrender* e *autopilot*, è forse lo strumento più operativo del paper: permette di classificare comportamenti osservabili, non solo stati mentali ipotetici. Il problema è che fotografa il fenomeno più di quanto ne descriva la traiettoria. Dice dove siamo, molto meno come ci arriviamo.

8.2.3 L'intensificazione silente: quando l'AI ti fa lavorare di più

Il contributo di Ranganathan e Ye si colloca su di un piano diverso, e proprio per questo, a mio giudizio, chiude bene il triangolo [68]. Mentre System 0 e Tri-System Theory guardano alla cognizione individuale,

il loro studio osserva per otto mesi una *tech company* e mostra cosa succede a processi, aspettative e ritmi quando l'AI entra davvero nel lavoro quotidiano. Il risultato sfida la narrazione dell'AI come alleggerimento automatico: l'AI può aumentare la produttività percepita senza ridurre il carico, anzi intensificandolo.

- Il primo meccanismo è l'**espansione dei compiti**. Poiché l'AI consente di fare più cose, ciò che prima era opzionale diventa lentamente atteso. Nessuno dice “adesso che hai l'AI fai il doppio”, perché sarebbe troppo onesto e rovinerebbe la poesia, ma la baseline si sposta: un extra diventa standard.
- Il secondo meccanismo è l'erosione dei confini **lavoro/vita**. Se lo strumento è sempre accessibile, il lavoro diventa un fluido che occupa ogni interstizio: la bozza la rifinisco la sera, il report lo genero nel weekend, la feature la faccio fare “al volo” mentre dovrei fare altro. La possibilità tecnica diventa aspettativa implicita, e l'aspettativa implicita diventa norma culturale (ohhh come mi riconosco in questo profilo, finalmente qualcuno ha messo nero su bianco la mia nuova infernale vita *AI assisted*).
- Il terzo meccanismo è la **moltiplicazione del multitasking**. L'AI permette di gestire più thread contemporaneamente, ma questo non elimina il carico: lo frammenta. E la frammentazione ha costi cognitivi ben noti nella letteratura sul *task switching* [65]. Nel contesto AI il problema si amplifica perché il multitasking non è più solo una cattiva abitudine individuale, ma una capacità abilitata dallo strumento e quindi, prima o poi, attesa dall'organizzazione.

Il dato più rivelatore è che i lavoratori percepiscono più produttività senza percepire meno lavoro. Il tempo liberato viene riassorbito da nuovi compiti, e l'organizzazione, vedendo maggiore output, alza le aspettative. Quei nuovi compiti, peraltro, sono spesso del medesimo tenore “banale” che ho avuto modo di descrivere in precedenza analizzando l'uso “effettivo” dell'AI generativa: ovverosia editing, sintesi, riformulazioni e ricerche fattuali, attività a bassa consequenzialità che cementano una confidenza calibrata su un repertorio di successi poco probanti. Questo ciclo resta incompleto se non viene collegato alle dinamiche cognitive individuali: più pressione organizzativa significa meno tempo per verificare, e meno verifica significa più resa cognitiva.

8.3 Lettura sinottica: dove convergono, dove divergono e cosa sembra mancare

“Il mondo del futuro sarà una lotta sempre più impegnativa contro i limiti della nostra intelligenza, non una comoda amaca su cui potremo distenderci ad essere serviti dai nostri robot-schiavi.” — Norbert Wiener, *The Human Use of Human Beings*, 1950

Messi insieme, i tre contributi raccontano una storia che separatamente si fatica a vedere e le cui convergenze sono nette: l'AI non è uno strumento passivo, ma un agente che riorganizza il processo cognitivo; l'integrazione acritica produce rischi robusti; la risposta non può essere affidata alla semplice raccomandazione “stai attento”, che nella storia dell'automazione ha già fatto una discreta quantità di danni per insufficienza strutturale. Come sintetizzava Bainbridge nel 1983, automatizziamo perché l'operatore umano è inaffidabile e inefficiente, e poi gli lasciamo da fare i compiti che non siamo riusciti ad automatizzare [57]: una frase che quarant'anni dopo non ha perso nemmeno una virgola di attualità.

Le tensioni, però, sono ancora più istruttive. La prima è **topologica** (finalmente posso riutilizzare un residuo del mio vissuto accademico mettendo il termine quasi a caso nel testo): System 0 colloca l'AI prima della cognizione umana, come preprocessore; la Tri-System Theory la colloca accanto, come terzo sistema parallelo. Non è una contraddizione perchè quando chiedo esplicitamente all'AI di risolvere un problema, la uso come System 3 ma quando leggo una sintesi già generata, accetto suggerimenti non richiesti oppure apro una dashboard pre-compilata, l'AI funziona come System 0. La stessa tecnologia può stare *prima o accanto*, spesso nello stesso stream di lavoro.

La seconda tensione è **temporale**. System 0 e Tri-System Theory descrivono una condizione; lo studio HBR ha una dimensione diacronica ma non la collega a una teoria cognitiva. Anche in questo caso, come già visto in precedenza riflettendo sulla grammatica delle posture di Mollick, manca la risposta alla domanda più fastidiosa: come evolve nel tempo la relazione tra individuo e AI? La resa cognitiva è un rischio, una fase, un punto di arrivo oppure solo una cattiva abitudine con ottimo marketing? Centauro e Cyborg, System 0 e Tri-System sono fotografie utilissime, ma restano fotografie e quello che serve, per progettare interventi meno ingenui, è il film. La letteratura sull'automazione suggerisce che vigilanza e competenze tendano a degradare con l'esposizione prolungata [66], ma l'AI generativa opera sul linguaggio e su compiti ambigui, quindi ogni estrapolazione diretta va maneggiata con pinze abbastanza lunghe.

La terza tensione è di **livello**. I primi due contributi parlano dell'individuo; il terzo dell'organizzazione. Il collegamento implicito va reso esplicito: la *cognitive surrender* individuale può alimentare l'intensificazione organizzativa, perché chi delega acriticamente produce più output e sposta la baseline; l'intensificazione organizzativa può alimentare la *cognitive surrender*, perché chi è sovraccarico ha meno tempo e meno energia per verificare. È un doppio ciclo di rinforzo, carpiato e con *jeté* finale, che provo a formalizzare nella sezione successiva.

8.4 Un modello a fasi e una competenza da costruire

“Diamo forma ai nostri strumenti, e da quel momento in poi gli strumenti danno forma a noi.” — John M. Culkin, parafrasando Marshall McLuhan, *Saturday Review*, 1967

Preciso subito le coordinate epistemologiche: ciò che segue è speculazione teorica informata. Non ho dati proprietari, non ho ancora condotto esperimenti e pertanto non ho validazione empirica diretta. Quel che mi limito a fare è integrare i tre succitati contributi, la letteratura sull'automazione ed una serie importante di osservazioni maturate in questi due anni di lavoro a fianco delle aziende in progettualità di *A(I)Doption*, senza fingere che questo basti a fare una teoria consolidata. È una ipotesi di lavoro, cioè una cosa meno nobile di una teoria ma più utile di una lamentela. Il punto di partenza è un'osservazione che Kahneman ha sintetizzato con la consueta fastidiosa precisione: siamo molto influenzati da processi completamente automatici sui quali non abbiamo alcun controllo, e non sappiamo di esserne influenzati. La domanda è cosa succede quando quei processi automatici non sono più solo interni al nostro cervello, ma mediati da un sistema esterno?

8.4.1 Le fasi della deriva cognitiva

La prima proposta “pseudo originale” che mi sento di fare è quella di un modello a fasi della relazione cognitiva con l'AI. L'idea di base è che, senza intervento intenzionale, la relazione tenda a scivolare da *augmentation*

consapevole a dipendenza epistemica. Per amore del dramma, e perché ogni modello ha bisogno del suo piccolo melodramma nominale, chiamo questa traiettoria “deriva cognitiva”. Le fasi che propongo per spiegare la traiettoria (consapevole che direzione e verso sono cose diverse) sono cinque:

- **Fase 1) Augmentation consapevole.** L’individuo usa l’AI come strumento ausiliario mantenendo chiara la distinzione tra giudizio personale e output della macchina. Il cognitive offloading è strategico: delego, verifico, correggo ed integro. L’AI opera prevalentemente come System 3, cioè come sistema consultato in modo esplicito. È la fase **Centauro** nella tassonomia di Mollick già precedentemente introdotta [64]: umano e AI lavorano in sequenza su compiti distinti, senza confusione eccessiva di ruoli. Indicatori osservabili: l’output viene modificato in modo sostanziale prima dell’uso; il soggetto sa spiegare i criteri con cui valuta la qualità; restano attive modalità alternative di esecuzione del compito. Nella mia esperienza è anche la fase che dura meno di quanto ci si racconti.
- **Fase 2) Offloading progressivo.** Dopo una serie di esperienze positive, l’individuo riduce frequenza e profondità della verifica. È una scelta localmente razionale: se una cosa funziona dieci volte, perché controllarla l’undicesima? Il problema è che questa razionalità locale produce un effetto globale meno simpatico, cioè l’atrofia graduale della capacità di riconoscere quando il controllo sarebbe necessario. È, a ben vedere, l’altra faccia della medaglia del “ne so abbastanza da non controllare” che ho cercato di descrivere ragionando sul paradosso dell’AI Literacy: la deriva non avviene solo perché si è acquisita una competenza tecnica che si scambia per accuratezza metacognitiva, avviene anche per il semplice fatto che si è iniziato ad usare lo strumento senza inciampi rilevanti. Competenza ed uso ripetuto convergono dunque sullo stesso esito (l’erosione della vigilanza), pur prendendo strade diverse. Qui il *comfort-growth paradox* [69] e l’ironia dell’automazione [57] smettono di essere eleganti concetti e diventano prassi quotidiana. Indicatori osservabili: cresce la quota di output AI usata senza modifiche, diminuisce il tempo di revisione e, peggio, la verifica viene percepita come costo più che come precauzione. È la deriva verso l’uso **Cyborg**: umano e AI si mescolano nel flusso, e i confini diventano più comodi proprio mentre diventano meno leggibili.
- **Fase 3) Cognitive surrender incipiente.** La linea tra offloading strategico e resa cognitiva diventa sfumata. L’individuo non decide più davvero “delego e poi verifico”: usa l’output come base di partenza, o direttamente come prodotto finito, senza un atto deliberativo esplicito sulla delega. È qui che l’AI migra da System 3 a System 0: da sistema parallelo consultato a pre-processore che definisce il campo su cui poi il giudizio opera. È anche il punto preciso in cui quel Cyborg ancora consapevole di cui ho parlato in precedenza scivola, senza accorgersene, nel Cyborg in caduta libera: l’integrazione resta identica, cambia solo che il presidio metacognitivo (l’unico argine rimasto, una volta dissolto quello strutturale del confine Centauro) ha cessato di operare. La transizione è pericolosa proprio perché soggettivamente invisibile. L’utente crede ancora di scegliere, ma il perimetro della scelta è già stato disegnato altrove. Indicatori osservabili: il soggetto fatica a completare in tempi ragionevoli compiti prima svolti senza assistenza e non ricorda l’ultima volta che ha rifiutato o riscritto interamente un output AI. Se intervistato su questo aspetto spesso parla dell’AI come “generalmente affidabile” senza saper dire su quali basi.
- **Fase 4) Normalizzazione.** La cognitive surrender diventa il modo standard di lavorare e si salda con l’intensificazione organizzativa descritta da Ranganathan e Ye [68]. L’organizzazione calibra aspettative,

tempi e quantità di output sulle capacità aumentate. A quel punto tornare alla modalità pre-AI non è più una scelta realistica: non c'è più tempo per fare le cose “a mano”, perché il carico è stato costruito assumendo che la protesì (una sorta di outsourcing very near shore) cognitiva sia sempre disponibile. Il doppio ciclo si stabilizza: la surrender alimenta l'intensificazione, l'intensificazione alimenta la surrender. Indicatori osservabili: non vengono più previsti tempi di esecuzione senza AI e la rimozione temporanea dello strumento produce cali sproporzionati di “Produttività”.

- **Fase 5) Biforcazione.** La traiettoria non ha un solo esito. Da un lato c'è la dipendenza epistemica: individuo e organizzazione non operano più efficacemente senza assistenza AI, non per mancanza di intelligenza ma per erosione di competenze specifiche e pattern di pensiero indipendente. Dall'altro c'è un nuovo equilibrio metacognitivo: la traiettoria viene riconosciuta mediante una delega calibrata, l'autonomia viene mantenuta dove conta e la dipendenza viene resa visibile prima di diventare infrastruttura invisibile.

Cosa determina quale ramo viene imboccato? Non ho una risposta, ma vedo tre fattori plausibili (e non per questo auspicabili) come potenziali cause origine. Il primo è un **evento rivelatore**: un fallimento dell'AI abbastanza visibile da rendere percepibile la dipendenza normalizzata. Il secondo è un **intervento “formativo” esterno**, cioè qualcuno che interrompe il ciclo con domande brutalmente semplici: “saresti in grado di farlo senza AI? Quando è stata l'ultima volta che ci hai provato?” Il terzo è il **design organizzativo intenzionale**: verifiche dell'autonomia cognitiva come manutenzione preventiva delle competenze. Senza almeno uno di questi fattori, la traiettoria naturale tende al *lock-in* e la dipendenza si consolida perché nessuno ha il coraggio di nominarla.

L'analogia con il modello di elaborazione del lutto di Kübler-Ross, che uso spesso anche nelle mie sessioni di *A(I)Doption*, è imperfetta ma utile. Qui la fase iniziale non è negazione dello strumento, ma negazione della trasformazione: “lo uso, ma resto io a decidere, non mi cambia”. La fase più interessante è la terza: nel modello del lutto ci sarebbe la rabbia, cioè il segnale emotivo della perdita mentre qui la rabbia manca, ed è proprio questo il problema. Non c'è perdita percepita, quindi non c'è resistenza. La differenza finale è decisiva: Kübler-Ross converge sull'accettazione *tout court*, mentre il mio modello si biforca tra accettazione inconsapevole della dipendenza e accettazione attiva, intenzionale, di ciò che si è rischiato di perdere. I limiti sono evidenti. Non so se le fasi si presentino in questa sequenza in tutti i contesti; è probabile che dominio, expertise e tipo di compito ricorrentemente delegato cambino molto velocità e direzione del processo. La sequenza potrebbe non essere lineare e gli indicatori sono provvisori e non validati, pertanto servirebbero studi longitudinali con misurazioni ripetute e protocolli di osservazione strutturati. Resta però una utile euristica per progettare interventi di adozione meno ingenui di quelli “inconsapevoli”.

8.4.2 La resa cognitiva qualificata come competenza e non difetto

Per formulare la mia seconda proposta voglio partire da una osservazione che nel paper di Shaw e Nave resta un po' sotto traccia: la *cognitive surrender* non è sempre irrazionale. Se l'AI è accurata, il rischio è basso e il costo della verifica indipendente è alto, seguire l'output dell'AI **può** essere la scelta migliore. Il problema non è la resa in sé bensì la resa indiscriminata, cioè l'incapacità di distinguere quando affidarsi è ragionevole e quando è pericoloso.

È a partire da questa distinzione che provo a saldare un debito che mi ero preso in precedenza, quando avevo abbozzato le tre componenti formative del passaggio dalla AI literacy tecnica alla consapevolezza

metacognitiva, ed avevo introdotto, quasi *en passant*, il termine “resa cognitiva qualificata”. Lo riprendo qui formalizzandolo: non resistere all’AI per nostalgia luddista dell’artigiano amanuense, ma sviluppare la competenza metacognitiva necessaria a navigare tra autonomia piena e affidamento totale. Esiste una circolarità, e sarebbe disonesto nascondersela: se Shaw e Nave mostrano che le persone non sanno distinguere quando delegare, sto proponendo come soluzione **proprio la competenza che manca**. La mia ipotesi però è che la resa osservata negli esperimenti sia comportamento spontaneo in assenza di formazione specifica, non destino antropologico. Nelle attività di formazione che conduco, le sessioni di calibrazione della delega producono almeno nel breve periodo cambiamenti osservabili: più controllo sui compiti ad alta consequenzialità e maggiore consapevolezza dichiarata della propria tendenza alla *surrender*. Sono osservazioni aneddotiche, non dati sperimentali, ma bastano a formulare una domanda empirica sensata: la resa cognitiva qualificata si può insegnare? A che costo? Con quale durata degli effetti? La tradizione del *debiasing* suggerisce prudenza, ma non rassegnazione [60, 63].

Nella formulazione che qui propongo, la resa cognitiva qualificata richiede tre capacità:

- La prima è il **triage cognitivo**: valutare, per ogni compito, il rapporto tra costo della verifica indipendente e rischio dell’accettazione acritica. Una e-mail routinaria e un’analisi finanziaria a supporto di un investimento non meritano lo stesso scrutinio. Banale da dire, meno da praticare quando si lavora di fretta e l’AI produce risposte pulite, assertive e grammaticalmente più sicure di molti colleghi. Per renderlo operativo servono tassonomie condivise: cosa si può delegare quasi interamente, cosa richiede un approccio a campione, cosa richiede controllo completo, cosa non dovrebbe mai uscire senza revisione umana qualificata.
- La seconda è il **monitoraggio della deriva**: riconoscere la propria posizione lungo le fasi del modello e intercettare lo scivolamento dall’offloading strategico alla *surrender* acritica. Qui però c’è un *caveat*: monitorare la propria deriva cognitiva è esso stesso un compito metacognitivo, quindi soggetto agli stessi bias che vorrebbe controllare. Per questo non può restare una pratica solo individuale. Servono feedback esterni, peer review, metriche organizzative e momenti in cui l’uso dell’AI venga discusso come questione di qualità cognitiva del lavoro. Per quanto questo, va detto, presupponga di aver bonificato il terreno da tutte quelle dinamiche di AI shame, FOMO e *shadow use* che ho avuto modo di descrivere in precedenza, e che lavorano sistematicamente contro la trasparenza necessaria a qualunque monitoraggio collettivo onesto.
- La terza è l’**override deliberato**: completare periodicamente compiti senza assistenza AI, non per luddismo ma per mantenere attive le competenze che lo strumento rischia di atrofizzare. L’analogia con l’allenamento fisico è immediata, ma ha un limite: nel corpo abbiamo metriche più stabili, nella cognizione professionale molto meno. Come misuro se un analista sta perdendo la capacità di leggere un bilancio senza assistenza sintetica? Come misuro se un informatico sta perdendo la capacità di fare debug senza copilot? Non sono domande retoriche. Una implementazione seria dell’*override deliberato* dovrebbe prevedere prove periodiche, compiti sentinella e confronti tra performance con e senza AI. Scomodo, certo, ma anche ignorare il problema è una pessima strategia.

La resa cognitiva qualificata non elimina la delega, la rende governabile. Non chiede alle persone di usare meno AI per principio, ma di sapere cosa stanno cedendo, perché lo stanno cedendo, con quali rischi e con quali verifiche. In questo senso non è una virtù ascetica: è una competenza professionale dell’era AI.

8.5 Implicazioni e livelli di impatto

*“A volte i nostri strumenti fanno quello che gli diciamo di fare. Altre volte siamo noi ad adattarci alle loro richieste.” — Nicholas Carr, *The Shallows*, 2010*

Le implicazioni della deriva cognitiva e delle sue risoluzioni in resa si distribuiscono almeno su tre livelli ciascuno dei quali richiede opportuni “aggiustamenti”. A livello **individuale**, serve una igiene cognitiva dell’era AI: sapere la differenza tra augmentation e dipendenza, saper criticamente definire dove ci si trova tra le due, mantenere autonomia dove conta e saper delegare dove è razionale. Il problema è che questa consapevolezza non emerge spontaneamente, come mostrano gli esperimenti di Shaw e Nave. Informare non basta; servono esercizio, feedback e contesti che rendano visibile la delega (o l’assenza, deliberata che sia oppure meno, della medesima).

A livello **organizzativo**, l’adozione AI non può essere progettata solo in termini di efficienza: ore risparmiate, output prodotto, costi ridotti, slide con frecce verso l’alto e persone sorridenti. Va progettata anche in termini cognitivi. Quali competenze rischiamo di atrofizzare? Quali decisioni non dovrebbero mai essere delegate senza supervisione? Quali processi stanno assorbendo il tempo liberato? L’AI practice proposta da Ranganathan e Ye è un buon punto di partenza, ma va fondata anche sulla relazione tra persone e strumenti, non solo sui processi.

A livello di **policy e formazione**, gli *statement* del tipo “ricorda che l’AI può sbagliare” sono utili come i cartelli “attenzione” messi davanti a una buca che nessuno ha intenzione di riparare: servono più a chi li posiziona come sgravio di coscienza che a chi legge come meccanismo di attenzione. Servono pratica deliberata del triage cognitivo, compiti scientemente svolti senza assistenza AI e un processo rigoroso di feedback sulla qualità delle decisioni prese con e senza AI. In ambito formativo questo significa ripensare non solo **cosa** si insegna sull’AI, ma soprattutto **come** si insegna con l’AI.

8.6 Conclusione

Torno alla domanda iniziale: cosa sta succedendo dentro la testa di chi usa l’AI? La risposta che emerge dalla lettura integrata dei tre contributi è che sta succedendo qualcosa di più profondo che la narrazione corrente tutta incentrata sulla produttività stenta ad intercettare (oppure deliberatamente ignora). L’AI non si limita ad accelerare compiti: filtra il campo informativo, diventa sistema cognitivo esterno modificando aspettative organizzative e trasformando la delega in dipendenza senza che il soggetto percepisca questo “spostamento” come perdita.

La buona notizia è che la traiettoria non è definita. La biforcazione del modello esiste (speriamo, visto che affermo sulla base di una idea e di una teoria): possiamo in qualche misura scegliere se scivolare nella dipendenza epistemica oppure costruire un nuovo equilibrio metacognitivo. Ma questo richiede intenzionalità, formazione, design organizzativo e una certa disponibilità a fare domande scomode prima che sia l’incidente a farle per noi. Se il modello a fasi si rivelerà sbagliato nei dettagli vorrà dire qualcuno avrà fatto la ricerca necessaria a confutarlo. Se la resa cognitiva qualificata si rivelerà ingenua, avremo almeno un nome per ciò che ci manca. In un campo che si muove a questa velocità, sbagliare in modo utile resta un contributo che sono orgoglioso di poter dare.

Capitolo 9

Cybernetic teammate: ripensare la collaborazione nell'era dell'AI

“Nessun uomo è un’isola, completo in se stesso; ogni uomo è un pezzo del continente, una parte del tutto.” —
John Donne, *Devotions upon Emergent Occasions*, XVII (1624)

Fino a qui abbiamo affrontato la relazione tra l'individuo e l'intelligenza artificiale generativa guardandola, per così dire, dall'interno: prima isolando quel cortocircuito per cui una maggiore competenza tecnica non si traduce in maggiore accuratezza metacognitiva ma anzi tende a comprometterla, poi costruendo un modello a fasi della deriva cognitiva che descrive la traiettoria (non inevitabile, ma nemmeno improbabile) dall'*augmentation* consapevole alla dipendenza epistemica, passando per quella zona grigia dell'*offloading* progressivo dove la delega smette di essere strategica senza che il soggetto se ne accorga. La resa cognitiva qualificata, proposta come competenza e non come difetto, rappresenta il tentativo di costruire un argine intenzionale a questa traiettoria, ma opera pur sempre sul piano dell'individuo e del suo rapporto con lo strumento.

Resta però scoperta una dimensione che nella pratica quotidiana delle organizzazioni è tutt'altro che secondaria ovverosia quella del gruppo, inteso come più persone che lavorano insieme. Se l'AI modifica il processo cognitivo individuale è ragionevole supporre che modifichi anche le dinamiche collaborative, la distribuzione dei ruoli, la costruzione condivisa di significato e financo le emozioni che attraversano un gruppo di lavoro. Il passaggio dal singolo al team rappresenta in qualche modo un cambio di natura del problema e non solo una sua rappresentazione di “scala”.

La lettura dei risultati dello studio sul campo “The Cybernetic Teammate” [72] e della sua sintesi argomentata fornita da Mollick nel suo blog “One Useful Thing” mi ha fornito l'ancoraggio empirico che userò per affrontare questa dimensione. Con la pazienza del cartografo (ovverosia del topo di biblioteca) che una volta mi caratterizzava e che oggi è persa nell'orgia degli stimoli che si ricevono da ogni dove (e come e quando), sono andato a riprendermi appunti, liste di letture e metaforiche “orecchie” sui fogli ed ho provato a rimmetterli in fila in modo organico per costruire questo capitolo. Ho voluto provocatoriamente fare un giro di montagne russe che alternasse pratica, teoria, pratica ed ancora teoria, mescolando nel pentolone di questa “pozione druidica” (vanno molto di moda queste cose elfiche, druidiche, nevvvero?) una sorta di moto

retrogrado (alla maniera di certe famose composizioni bachiane) che parte dai risultati pratici dello studio succitato per andare a costruirsi attorno la giustificazione teorica a posteriori (come i risultati delle bayesiane che tanto controintuitive appaiono).

Siamo di fronte, a mio giudizio, ad un primo punto di svolta nella ricerca sull'integrazione dell'intelligenza artificiale generativa nei contesti di lavoro, con particolare riferimento ai processi collaborativi (a seconda delle mode organizzative del momento lodati apertamente quanto fintamente agiti o silenziosamente vituperati forse perchè nell'intento esistenti). I risultati empirici confermano che l'AI generativa travalica ampiamente i suoi limiti di strumento di produttività ed efficienza (ed a questo ci eravamo già arrivati anche solo osservandone la differente "natura" e specie nel bestiario tecnologico a nostra disposizione) per arrivare a diventare un efficace "collega sintetico" capace di replicare (copiare? imitare? enfatizzare? abilitare?) almeno tre dei pilastri fondamentali della collaborazione umana: *performance collettiva, condivisione di expertise e connessione sociale*. L'analisi che segue prova a identificare le basi teoriche di questi risultati, sintetizzandone i contributi "rivoluzionari", ovverosia come essi sfidino e riformolino paradigmi consolidati nella teoria organizzativa, nella cognizione distribuita e nella comprensione delle tecnologie sociali.

Il percorso segue la sequenza delle domande alle quali ho provato a darmi delle risposte: se i paradigmi tradizionali siano ancora validi per spiegare la nuova forma del lavoro in team; se l'AI generativa possa essere considerata una tecnologia sociale, e in caso affermativo sotto quali condizioni; e infine, posto che l'AI costituisca una forma "nuova" di conoscenza e che quindi va considerata nella sua globalità, anche tenendo conto dei "suoi" processi cognitivi, se questi ultimi possano modificare quelli umani (e, aggiungo alla luce di quanto appreso nei capitoli precedenti, in che rapporto stia questa modifica con la deriva cognitiva che abbiamo provato a formalizzare). Sulla scorta di queste domande ho poi provato a concettualizzare un modello teorico ed infine ad ipotizzarne delle implicazioni "semi pratiche" che potessero offrire uno spunto di riflessione alle organizzazioni che si trovano ad affrontare questo processo. Come sempre, questo è quello che ne ho capito fino ad oggi. Perché molto altro si spera di capirne ancora in seguito.

9.1 Mappa infografica del capitolo




Figura 9.1: Mappa logica del Capitolo 9

9.2 Riconfigurazione del lavoro in team: il superamento necessario dei paradigmi tradizionali

“Non c’è nulla di più difficile da prendere in mano, più pericoloso da condurre, o più incerto nel suo successo, che prendere l’iniziativa nell’introdurre un nuovo ordine di cose.” — Niccolò Machiavelli, Il Principe

Per affrontare compiutamente l’ambito della riconfigurazione delle dinamiche collaborative nell’era dell’intelligenza artificiale generativa, ho provato ad esplorare tre dimensioni fondamentali che ridefiniscono i paradigmi tradizionali del lavoro in team. Sono passato attraverso al superamento dalla **teoria della complementarità** in favore di una più adeguata **teoria della sostituzione “parziale”**, stante l’evidenza di come l’AI non si limiti a efficientare processi ma possa replicare benefici tipici della collaborazione umana. Successivamente mi sono soffermato sulla **teoria della ricchezza dei media** alla luce delle nuove possibilità offerte dall’interazione con sistemi AI generativa, che nonostante l’apparente “povertà” del media, generano risposte capaci di suscitare inclinazioni e reazioni emotive paragonabili a quelle delle interazioni interpersonali. Infine, ho provato a sviluppare (ulteriormente) i **paradigmi del “centauro/cyborg”** (già ampiamente in precedenza introdotti) e dei team ibridi, analizzando come la fusione sinergica tra intelligenza umana e

artificiale possa creare unità collaborative più efficaci delle loro componenti isolate, ridefinendo radicalmente l'organizzazione e le potenzialità del lavoro collaborativo contemporaneo.

Cominciamo dal primo di questi superamenti. Per ragioni professionali, visto che il mio lavoro come consulente da sempre si caratterizza come un incerto navigare tra processi, organizzazione e tecnologie, sin da quando ero “giovane” ho cercato di farmi una qualche conoscenza base di teoria organizzativa. Quella più tradizionale (e rassicurante per quanto mi riguarda) ha sempre concettualizzato la **tecnologia principalmente come complemento efficientante al lavoro umano** [71]. Ben ancorate al caposaldo del principio di complementarità queste teorie presuppongono che le tecnologie migliorino l'efficienza degli esseri umani in compiti specifici, senza sostituire le dinamiche di collaborazione interpersonale ma solo eventualmente facilitandole come ambiscono a fare le cosiddette “piattaforme tecnologiche di collaborazione”. L'evidenza empirica invece sfida questa dicotomia, fornendo prova del fatto che l'AI generativa può in alcuni casi sostituirsi alla collaborazione umana ottenendone (almeno parzialmente) i medesimi benefici. Questo transito verso una *inclinazione* (potevo scriverlo senza inclinare il carattere?) all'efficacia si caratterizza ovviamente anche nella progressiva perdita di neutralità morale delle tecnologie, cosa che mi fa pensare che, alla luce di quanto già argomentato a proposito del framework ConcrEthica, si renda necessario allargare lo sguardo sul tema etico anche in riferimento a questo nuovo paradigma di collaborazione. La nascente fenomenologia richiede l'elaborazione di una sorta di “teoria della sostituzione parziale” che giustifichi il fatto che le tecnologie possano replicare non solo funzioni cognitive (sic!), ma anche elementi sociali e relazionali del lavoro in team. Provando a mettere in questa prospettiva il lavoro di Zammuto [77] sull'*affordance* organizzativa, possiamo teorizzare che l'AI generativa implementa una nuova categoria di azione (*affordance* appunto), quella di collaborazione, che permette agli individui di accedere ai benefici della collaborazione senza necessariamente coinvolgere altri esseri umani.

Una delle basi teoriche che uso spesso nei miei corsi per spiegare l'impatto trasformativo delle tecnologie digitali è la paradossale distinzione “*Richness vs Reach*” (viene meglio in inglese, ovviamente) che si fonda su di una interpretazione, un po' tirata per i capelli come sono di solito tutte le mie interpretazioni teoriche di cui finisco per convincermi, della teoria della ricchezza dei media di Daft e Lengel, che classifica le tecnologie di comunicazione in base alla loro capacità di veicolare una variegata gamma di segnali sociali, **suggerendo che media più “ricchi” facilitino collaborazioni più efficaci**. Quello che considero paradossale è il fatto che la quantità di interazioni possibili, di fatto il *reach*, può essere indipendente dalla ricchezza del messaggio scambiato nel corso delle interazioni. Si aggiunga a questo che è dimostrato, per quanto empiricamente, che l'aumento di possibilità di interazione non necessariamente si traduce in aumento della collaborazione. La riprova di questa affermazione è il fallimento sostanziale degli spazi di lavoro “aperti” che avrebbero dovuto aumentare la quantità di collaborazione in funzione dell'aumento delle possibilità e che si sono invece rivelati essere solo posti scomodi dove le persone si isolano usando le tecnologie che permettono di ignorare selettivamente il prossimo (pionieristici furono in questo campo il Walkman della Sony alimentato a batteria, invenzione di quel Goodenough a cui abbiamo già reso onore e lode in precedenza). L'interazione sistematica (e consapevole) con l'AI generativa sfida questo paradosso da un'altra prospettiva: rappresentando un medium tutto sommato povero, genera risposte che producono (o possono produrre) inclinazioni e reazioni emotive paragonabili a quelle che scaturiscono dalle interazioni umane. Mi sovviene il dubbio che gli estensori dell'AI Act abbiano abusato proprio di termini come “reazione emotiva” che a prima vista potrebbero apparire fuori contesto nel rigido protocollo del burocrate in salsa EU proprio per queste ragioni. Questo paradosso nel paradosso suggerisce pertanto la necessità di riformulare la teoria della ricchezza dei media, considerando non

solo la *quantità* di segnali trasmessi, ma anche la *qualità* dei risultati prodotti dall'interazione e la sua capacità di stimolare risposte cognitive ed emotive che supportano il processo di collaborazione. Si potrebbe teorizzare l'utilizzo di una sorta di “**indice di ricchezza adattiva**” che premia la capacità di un mezzo tecnologico di adattarsi alle esigenze cognitive e sociali degli utilizzatori, anziché limitarsi a fungere da semplice mezzo di trasmissione efficiente di tali segnali.

Resta da considerare il terzo superamento, quello che porta verso i team ibridi veri e propri. Un fondamento teorico importante emerge dal concetto di utilizzo evoluto dell'AI generativa, ovvero sia in quelle modalità definite da Mollick come “centauro” e “cyborg” [64], paradigmi che nel percorso di questo libro sono già stati introdotti ragionando sul paradosso dell'AI literacy e sulla deriva cognitiva, e dei quali anche solo implicitamente si conoscono ormai tanto le potenzialità quanto le insidie. Questi modelli paradigmatici di utilizzo evoluto prevedono una combinazione interattiva di interlocuzioni tra intelligenza umana ed AI guidate in modo consapevole dall'uomo che produce risultati maggiormente significativi di quelli ottenibili da entrambi gli attori se considerati separatamente. Nel contesto organizzativo, questo si traduce in un nuovo modello di team dove unità ibride di intelligenze U-A (umano-artificiali) operano come entità collaborative coerenti a patto di attribuire a ciascuna di esse un ruolo peculiare: la GenAI può fornire una velocità di calcolo, una memoria enciclopedica e una neutralità di pensiero (entro certi limiti che con l'espandersi notevolmente dello strato “intermedio” tra interfaccia e modello diventa sempre più questionabile), mentre all'umano spetta il compito di completare queste caratteristiche con la creatività, il giudizio e la contestualizzazione semantica. Lo studio dal quale siamo partiti per questa digressione [72] conferma questa intuizione: i team composti da due persone più AI sono stati in grado di produrre le soluzioni qualitativamente migliori in assoluto, triplicando le possibilità di generare soluzioni nel top 10% di qualità. Questo suggerisce che il modello di “centauro/cyborg collettivo”, dove multiple intelligenze umane si fondono con l'AI, potrebbe rappresentare il picco di efficacia collaborativa in certi contesti decisionali complessi. Il dato, peraltro, acquista un significato ulteriore se riletto alla luce del modello a fasi della deriva cognitiva proposto nel capitolo precedente: la questione non è se il centauro/cyborg collettivo funzioni (lo studio dimostra che funziona per quanto oramai datato e svolto in condizioni statistiche non esattamente rilevanti), ma come si garantisce che funzioni in modo sostenibile nel tempo, senza scivolare lungo la traiettoria che porta dall'*augmentation* consapevole alla dipendenza epistemica?

9.3 L'AI come tecnologia sociale: applicazioni ed approfondimenti teorici

*“Ci aspettiamo sempre più dalla tecnologia e sempre meno gli uni dagli altri.” — Sherry Turkle, *Insieme ma soli**

Chiarita la sostanziale peculiarità della tecnologia che chiamiamo GenAI nella sua capacità di ridisegno delle dinamiche della collaborazione è il momento di indagare una eventuale ulteriore singolarità della stessa, per lo meno considerandone la capacità (efficacia) di agire sociale. Per farlo dobbiamo affrontare un po' più di petto quelle dimensioni relative alla capacità di influenza “emotiva” che prima abbiamo solo citato e pertanto dovremo dotarci di qualche strumento formale relativo allo spettro più propriamente sociale: gli elementi simbolici mediati dalla tecnologia (almeno in ragione del loro ruolo come matrice e radice del linguaggio),

quelli “affettivi” (che roba brutta che ho scritto) che caratterizzano l’attaccamento ai dispositivi ed il senso di “gratificazione” che deriva dal meccanismo dei feedback. Se in larga parte vi sembrerà di leggere la supercazzola sarete, in altrettanto larga parte, probabilmente nel giusto, ma per questo mi sento solo in parte colpevole. Croce e delizia delle scienze sociali è proprio la necessaria adozione di un linguaggio formale per spiegare un insieme di fattualità che sono evidenze comportamentali, e per quanto fuori dai miei ambiti di interesse abituali, ho sempre provato fascinazione ed urgenza di comprensione di quei meccanismi che sono alla base dell’influenza sull’agire.

Gran parte della letteratura sull’impatto della trasformazione tecnologica nei contesti organizzativi presenta risultati che si possono polarizzare nel favore verso il determinismo tecnologico oppure il costruttivismo sociale. I risultati empirici dello studio [72], che mi sento alla luce delle sperimentazioni più artigianali e meno dotate di “mezzo di contrasto” per leggerne i risultati che ho condotto specialmente in università su queste modalità di interazione/collaborazione assistita, suggeriscono invece un paradigma di “interazione simbolico-tecnologica” in cui l’AI non determina (solo, unicamente) comportamenti né è (solo, unicamente) plasmata dalle interpretazioni sociali. Al contrario essa partecipa attivamente (per “attivamente” intendo tramite la generazione di una perfetta sintassi calata nello spazio semantico definito dall’interazione e dalla collaborazione, e non certo in virtù di una qualche sua propria consapevolezza) nella costruzione di significati condivisi. L’interazione tra le intelligenze U-A diventa un processo di co-costruzione di significati che influenza sia l’output pratico (che da sintattico diventa semantico quando vestito opportunamente di significato, dalla componente U, l’unica dotata di consapevolezza, a volte) sia l’esperienza soggettiva. Quest’ultimo ambito lo consideriamo ovviamente dal lato umano della relazione, basandoci sui feedback dei partecipanti, perché sulla “qualità dell’esperienza” da parte dell’elegante pezzetto di silicio che stiamo antropomorfizzando all’eccesso mi sentirei di soprassedere per il momento. La capacità dell’AI di influenzare le emozioni dei partecipanti suggerisce che essa non solo elabora informazioni, ma partecipa, influenzandola, anche alla determinazione della dimensione simbolica ed emotiva del lavoro. Quest’ultima evidenza, che riletta attraverso la lente del framework “ConcrEthica” esposto nella prima parte di questo libro si presenta in tutta la sua problematicità, rimarca la necessità di condurre un ragionamento etico approfondito sul tema. Stiamo toccando il nervo scoperto della questione che possiamo riassumere in una domanda che diventa ad ogni release degli strumenti di GenAI sempre più retorica: *quale neutralità morale ci aspettiamo ancora da strumenti in grado di influenzare lo spazio emotivo in modo così profondo da impattare sulla dimensione simbolica della rappresentazione delle nostre azioni?*

Da questa influenza emotiva discende un fenomeno ancora più sottile, quello dell’attaccamento. I risultati “emotivi” riportati dai partecipanti allo studio sono, non sorprendentemente, per lo più positivi. Al netto dell’effetto curiosità e dell’entusiasmo preventivo relativo al coinvolgimento in un vero e proprio “esperimento sociale” di questa portata, i feedback riportati dai partecipanti dei gruppi che hanno interagito in modo estensivo con l’AI possono essere interpretati attraverso una rilettura della teoria dell’attachment tecnologico. La suddetta teoria postula che gli esseri umani possano sviluppare legami emotivi e psicologici significativi con i dispositivi tecnologici e le rappresentazioni digitali (avatar), simili per certi aspetti ai legami di attaccamento che formano con altre persone. Se ci guardiamo attorno sembra impossibile non riscontrarne profilo e caratteri nella quotidianità pensando in primo luogo al nostro personale attaccamento ai dispositivi tecnologici che ci accompagnano e che consultiamo incessantemente tramite gesti rituali codificati ed in grado di catalizzare interesse ed attenzione nonché di generare risposte emotive accuratamente pilotate con specifici meccanismi di ricompensa. Ovunque scorgiamo gli elementi alla base della originale rilettura contemporanea della teoria offerta da Suh [76] che introduce il concetto di doppia congruenza per spiegare

l'attaccamento ai propri “sé” digitali (avatar o twin) e rilevare come questo opera simultaneamente attraverso dimensioni emotive (identificazione personale) e funzionali (utilità percepita), influenzando significativamente l'esperienza dell'utente e generando soddisfazione sia edonistica che utilitaristica. L'interazione ripetuta, la personalizzazione, l'antropomorfizzazione e l'integrazione degli oggetti tecnologici nella costruzione dell'identità personale contribuiscono alla creazione ed al rafforzamento di questi legami, che in casi estremi probabilmente andrebbero definiti patologici.

Quello che i risultati dello studio suggeriscono è agghiacciante, sotto il profilo antropologico e sociale. Gli utilizzatori possono sviluppare relazioni simil-sociali con l'AI generativa che soddisfano bisogni di connessione creando un senso di presenza sociale (non solo di utilità o di finalità) che, pur essendo ontologicamente diverso dall'interazione umana, soddisfa bisogni psicologici simili mediando (replicando? imitando?) esperienze socializzanti anche in ambienti di lavoro strutturati. Sappiamo che le persone tendono istintivamente a trattare i computer dotati di elementi sociali come interlocutori umani, applicando norme sociali (in positivo ed in negativo) anche con la consapevolezza razionale della loro natura “meccanica” (ritornano gli echi dei riferimenti fatti in ambito di Literacy, sotto altra forma). Gli esempi volendo si sprecano: da quelli propriamente accademici ed “alti” (come i riferimenti ad Eliza di J. Weizenbaum del 1966), agli insulti (quasi rituali) indirizzati alla macchina del pagamento del pedaggio autostradale o ai messaggi telefonici registrati che ci molestano quotidianamente, che tutti abbiamo sperimentato. La possibilità di relazione in linguaggio naturale (oltre che nelle altre forme e nature che la caratterizzano, dalla visione all'ascolto) delle AI generative amplifica questo effetto, creando un'esperienza che si avvicina all'interazione con un interlocutore reale. La caratteristica (programmatica) dello stile di comunicazione “neutro positiva” ed incoraggiante delle AI generative (in termine tecnico, paracula), come anche documentato in letteratura [75], potrebbe spiegare perché i partecipanti dei gruppi che prevedevano l'uso dell'AI hanno riportato emozioni più positive rispetto a chi lavorava senza AI. L'AI può fungere da catalizzatore emotivo positivo e da facilitatore comunicativo, nonostante la mancanza di emozioni autentiche, ma in presenza, è bene ripeterlo, di una implicita moralità o quanto meno di responsabilità (quanto meno) codificata, visto che **è capace di inclinare ad un determinato comportamento**.

9.4 Cognizione distribuita e AI: ripensare i confini della “conoscenza” tra umano e non-umano

“Le cose stesse agiscono? Certamente sì, se per azione intendiamo fare la differenza.” — Bruno Latour, Reassembling the Social

Quanto delineato fino qui evidenzia la necessità di rapportarsi a queste tecnologie considerandole molto di più che dei “contenitori” di conoscenza accessibili in forma più smart rispetto a quanto fattibile in modo esclusivamente “algoritmico” con le basi dati tipiche dell'informatica tradizionale. In quanto medium di interazione sociale devono essere analizzate anche in termini di processo cognitivo per comprendere come contribuiscano ad esso in concerto o in complemento ai processi cognitivi tradizionalmente umani. Non ci interessa solo indagare la conoscenza che questi algoritmi esprimono ma come questi possano diventare parte attiva del processo di generazione della medesima e come l'agire (sulla base di questa conoscenza) e la distribuzione della medesima sia oggetto di potenziale trasformazione. La connessione con il tema della

cognitive surrender e dell'*offloading* cognitivo affrontato nel capitolo precedente è qui diretta: se l'AI è parte attiva del processo cognitivo, la delega non è più solo una questione di efficienza ma una riconfigurazione dell'architettura stessa degli spazi cognitivi nei team.

Il punto di partenza obbligato per ragionare su questo è la teoria della cognizione distribuita. Se oggi parliamo agevolmente di computazione distribuita lo dobbiamo anche a chi teorizzò una suddivisione ed una dispersione “connessa” delle facoltà cognitive responsabili di questa “computazione”, come fece Hutchins [73] nel 1995 teorizzando la cognizione distribuita e disegnando una mappa di riferimento che concettualizza i processi cognitivi nella loro distribuzione tra attori umani, artefatti e ambiente. Quel che Hutchins non poteva preconizzare era che trent'anni dopo la sua concettualizzazione si affacciasse nelle reti (o nei sistemi) cognitivi che erano stati teorizzati un agente tecnologico con delle caratteristiche differenti da quelli da lui identificati. L'AI generativa rappresenta un tipo qualitativamente nuovo di nodo in questi sistemi cognitivi distribuiti, capace non solo di amplificare processi cognitivi esistenti ma anche di generarne di nuovi e quindi **attivo** come, ma in modo diverso, gli attori umani. L'AI generativa trascende il ruolo di semplice artefatto media per diventare un attore cognitivo semi-autonomo (oggi è più sexy identificare questi spazi di semi-autonomia come “agentici”) che trasforma attivamente, in qualche modo ridisegnandoli, i confini tra i diversi ambiti di competenze ed expertise. La capacità dell'AI di omogeneizzare l'approccio di professionisti con background diversi, come descritto nello studio [72] e surrogabile dalla mia personale esperienza professionale nell'accompagnamento di aziende all'adozione dell'AI nei loro processi, suggerisce che essa non solo supporta, ma **ristruttura fondamentalmente l'architettura cognitiva distribuita nel team**.

Su questa base, Dell'Acqua [72] suggerisce di lavorare in estensione della Actor-Network Theory (ANT) teorizzando un modello in cui umani e AI agiscono come “attanti simmetrici” nella rete collaborativa di Latour [74]. Questo significa che i partecipanti alla rete, umani e tecnologici, hanno potenzialmente pari capacità di influenzare la rete, che non esiste una gerarchia predeterminata in cui gli umani controllano sempre gli oggetti del “sapere” e che l'insieme delle capacità di agire e influenzare è distribuita in modo omogeneo attraverso la rete. In questa prospettiva, l'AI non è semplicemente uno strumento ma un att-qualcosa (direi attore attivo oppure attante come piace dire a Latour per tracciare netto il solco rispetto a quelle che potrebbero essere considerate caratteristiche “umane”) che modifica attivamente le relazioni, le pratiche e le identità all'interno della rete, contribuendo alla traslazione di interessi e alla stabilizzazione di nuove configurazioni socio-tecniche. Il lettore che ricorda la genealogia del principio di autorità affrontata nel primo capitolo riconoscerà qui una eco significativa: la stessa progressione dall'autorità umana all'autorità algoritmica che abbiamo ricostruito su scala storica si riproduce, in scala ridotta ma non meno significativa, all'interno di ogni team ibrido. La capacità dell'AI di generare risultati emotivi positivi suggerisce che essa possa fungere da “mediatore” piuttosto che da semplice “intermediario” sempre nella terminologia ANT (ricordiamo che un intermediario trasporta significato senza alterarlo, come un messaggero che consegna un testo inalterato, mentre un mediatore trasforma attivamente ciò che trasporta, come un traduttore che necessariamente reinterpreta il messaggio che traduce), modificando così le relazioni all'interno della rete socio-tecnica, trasformando attivamente il significato e gli effetti del lavoro collaborativo. Questa concettualizzazione sfida ulteriormente le distinzioni ontologiche tra umano e non-umano nei sistemi di lavoro, suggerendo una forma di “simmetria asimmetrica” (come mi piacciono questi voli pindarici, come sguazzo in questi apparenti ed assolutamente inutili quasi-ossimori) in cui l'AI può replicare alcune, ma non tutte, o per lo meno oggi non ancora tutte, le dimensioni dell'agire umano.

Un elemento significativo su cui ritengo valga la pena fare un affondo riguarda il concetto di memoria

trans-attiva del gruppo, e come questa venga estesa dall'AI. L'AI diventa un nodo attivo della memoria collettiva: i membri umani della rete possono “delegare” all'AI sotto-compiti mentali (oserei dire, in qualche modo, cognitivi) specifici, come raccolta dati, sintesi di documenti, esplorazione di ipotesi alternative, liberando risorse cognitive umane per concentrarsi su aspetti che richiedono intuizione, valutazioni morali o creatività non convenzionale. Quanto poi questo processo di delega, o di *off-loading* cognitivo (concetto che conosciamo ormai nella sua ambivalenza, avendone analizzato tanto la versione strategica quanto quella che sconfina nella *cognitive surrender*), rappresenti un vantaggio “evolutivo” nel modo in cui la conoscenza viene distribuita e processata all'interno delle organizzazioni e quando invece inserisca un rischio di perdita di dominio e di “possesso” delle informazioni stesse è forse troppo presto per dirlo. L'evidenza innegabile è che a fronte di un modello di utilizzo (integrazione) della GenAI con le caratteristiche centauro/cyborg si modifica nuovamente il ruolo della tecnologia stessa che non è più per nulla solo un deposito di informazioni ma un elaboratore attivo, capace di generare nuova conoscenza nella forma di inferenze e output che influenzano il pensiero degli umani nonché degli altri nodi tecnologici se rileggiamo lo schema in ottica agantica. Questo ampliamento della cognizione distribuita si traduce in un'aumentata capacità del sistema considerato nel suo complesso di generare idee, accedere a conoscenza e velocizzare i cicli di apprendimento.

9.5 Verso un nuovo modello teorico: il framework del “CyberMate”

“Tutti i modelli sono sbagliati, ma alcuni sono utili.” — George E. P. Box

Integrando queste diverse prospettive teoriche si potrebbe provare a proporre l'embrione di un nuovo (o diverso) framework concettuale, il “CyberMate”, che teorizza l'AI generativa come un'entità che trascende le categorizzazioni binarie di strumento/collaboratore, materiale/sociale, o umano/non-umano, per operare come un agente ibrido nei sistemi collaborativi costituiti da “motori cognitivi” di diversa natura. Questo framework si basa su quattro proposizioni teoriche.

Proposizione 1. L'AI generativa crea una nuova categoria di opportunità di azione collaborativa, intendendo con questo le “possibilità funzionali” che un ambiente o un oggetto offre ai suoi utilizzatori, evidenziando sia il potenziale di interazione che la relazione intrinseca tra l'utente e l'elemento con cui interagisce. Questa nuova *affordance* collaborativa permette agli individui di accedere ai benefici cognitivi, sociali ed emotivi tradizionalmente associati alla collaborazione umana, pur mantenendo caratteristiche ontologicamente distinte dall'interazione umana.

Proposizione 2. A differenza delle tecnologie precedenti che tendevano a sostituire funzioni specifiche o a complementare con una finalità esclusivamente di efficienza le capacità esistenti, l'AI generativa opera attraverso la “sostituzione parziale e quasi simmetrica”, replicando simultaneamente elementi cognitivi, sociali ed emotivi dell'interazione umana, sebbene con variazioni qualitative.

Proposizione 3. L'esperienza di collaborazione con l'AI generativa è mediata dall'intreccio dinamico tra caratteristiche tecniche dell'AI (capacità di elaborazione linguistica, personalizzazione, adattabilità) e caratteristiche socio-cognitive dell'essere umano (percezione di agency, antropomorfizzazione, fiducia).

Proposizione 4. L'efficacia dell'AI come CyberMate dipende dalla sua capacità e rapidità di navigare fuori dalla “valle del disagio cognitivo”, ovvero la zona in cui l'AI è sufficientemente avanzata da replicare processi cognitivi umani complessi, ma non abbastanza da riprodurre perfettamente la totalità dell'esperienza

collaborativa umana, e le risposte pur sembrando corrette ci “suonano” strane. Questa valle, rileggendo la curva di Kübler-Ross della gestione del lutto e adattandola alla risposta umana e organizzativa all'adozione dell'AI si trova proprio nel punto di minimo della curva.

9.6 Implicazioni pratiche nella progettazione organizzativa

“Non si può gestire oggi il cambiamento con le regole di ieri, sperando di essere ancora in affari domani.” —
Peter Drucker

Inevitabile, visto il mio ruolo e la mia professione, non provare a trovare una sintesi pratica ed operativa del quadro teorico corroborato *ad anteriori* dagli esiti sperimentali, quanto meno per poter condividere qualche ragionamento strutturato con chi si sta impegnando in questo percorso. Nella transizione dalla teoria alla pratica rilevano le riconfigurazioni organizzative rese necessarie dall'integrazione dell'intelligenza artificiale nei processi collaborativi, i nuovi ruoli professionali e l'impatto che dobbiamo attenderci sui processi decisionali in un contesto organizzativo aumentato dalla GenAI.

Il primo fronte è quello delle dimensioni e della composizione dei team. Il dato empirico, che sostiene la “tesi” per cui **un individuo con AI** può eguagliare le performance di **un team tradizionale**, impone una revisione delle strutture organizzative. Le aziende potrebbero adottare configurazioni più flessibili, alternando tra team snelli di “umani aumentati” (cioè di micro-team umano/AI) per attività dove velocità ed efficienza sono prioritarie, e team ibridi più ampi per situazioni in cui la diversità di prospettive umane potenziata dall'AI genera i risultati migliori. Questo richiede un ripensamento fondamentale dei modelli di staffing e della progettazione dei ruoli, considerando l'AI come un fattore di moltiplicazione della capacità produttiva e creativa e non solo come un tool di informatica “classica”.

Da questa riconfigurazione discende, come secondo fronte, l'emergere di nuovi ruoli e una progressiva democratizzazione dell'esperienza e della competenza. L'integrazione dell'AI nei flussi di lavoro fa emergere l'esigenza di definire e formare nuovi ruoli: figure di **AI facilitator** con competenze avanzate nell'interazione con l'AI che possono supportare i team nella formulazione e nella strutturazione di prompt robusti ed efficaci, e ruoli di mediazione tra domini di conoscenza, poiché l'AI tende naturalmente a collegare conoscenze diverse e a rendere i contributi degli specialisti più integrati. La democratizzazione delle esperienze, che non deve però accompagnarsi alla banalizzazione delle stesse, evidenziata dalla capacità dell'AI di bilanciare le soluzioni proposte da persone di estrazione diversa, potrebbe favorire strutture organizzative più orizzontali e permeabili, dove il sapere è più diffuso e accessibile.

Il terzo fronte, forse il più delicato, riguarda l'impatto sui processi decisionali e la necessità di una nuova governance. L'adozione diffusa dell'AI nei processi collaborativi richiede infatti nuovi modelli di **governance** che vanno definiti e strutturati a priori. Si conferma essere uno strumento fondamentale l'AI Manifesto (di cui, insieme a tutti gli altri dispositivi organizzativi parleremo diffusamente nella quarta parte) che, tra le altre cose, deve definire: policy chiare su quali tipi di decisioni possono essere delegate all'AI e quali richiedono supervisione umana; meccanismi di accountability per gestire responsabilità in caso di errori derivanti da suggerimenti dell'AI; ruoli di controllo e regia che fungano da controllori interni dell'AI vegliando anche sugli aspetti etici derivanti. Il concetto di “fiducia calibrata” o di “fiducia relativa” diventa un elemento cruciale. Una fiducia troppo bassa nei risultati algoritmici vanifica i benefici che l'AI può portare; per converso una

fiducia troppo alta rischia di stimolare l'organizzazione ad accettare acriticamente output potenzialmente errati facendo assurgere all'AI un ruolo di oracolo che di fatto sarebbe un “declassamento” nella scala evolutiva in chiave organizzativa del modello di relazione. Siamo dalle parti delle tensioni che hanno aiutato a definire la **resa cognitiva qualificata** trasposte dal piano individuale a quello organizzativo: **non meno AI, ma più AI governata**.

Resta infine, sullo sfondo di tutti questi fronti, la questione dell'evoluzione del knowledge work e delle nuove competenze. Una delle questioni che questa “dimostrazione pratica” sostenuta da giustificazioni teoriche a posteriori lascia in sospeso è quella relativa alla ridefinizione del significato della conoscenza e dell'intelligenza e, soprattutto, del ruolo dell'esperienza. Il knowledge work è potenzialmente destinato ad evolvere verso un modello di gestione dell'intelligenza ibrida, dove il valore del lavoratore risiede sempre più nella capacità di orchestrare contributi di altre intelligenze (umane e artificiali). Questo implica una minore enfasi sul nozionismo tecnico (surrogabile dall'AI), una maggiore importanza delle soft skills come pensiero critico, creatività, leadership ed empatia, e lo sviluppo di competenze meta-cognitive per monitorare e guidare i processi di pensiero AI-umano. Quel che per me rimane sullo sfondo, e che solo parzialmente viene coperto dalle succitate soft skills, è la codifica “simbolica” dell'esperienza come oggetto di valore cognitivo che in un riorientamento molto orientato al nuovo (orientato al generato, per fare cacofonia) trova poco spazio. Rendere esplicita la conoscenza tacita costruita sulla base dell'esperienza è una delle sfide ancora non affrontate nemmeno in termini teorici: siamo ancora (sostanzialmente) fermi a Nonaka ed al paradosso di Polanyi anche se, ultimamente, qualche “tentativo” di successo in questa direzione mi sento di poter dire di averlo fatto.

9.7 Come il collega sintetico si imbriglia in un nodo etico

I risultati empirici dello studio da cui è partita questa riflessione ci invitano a una fondamentale riconcettualizzazione del ruolo dell'AI nei contesti di lavoro collaborativo. L'emergere del “CyberMate” richiede una revisione dei paradigmi teorici esistenti e lo sviluppo di nuovi framework concettuali che catturino adeguatamente la natura ibrida di questa nuova forma di collaborazione.

Il passaggio da una concezione dell'AI come strumento a quella dell'AI come compagno di squadra rappresenta non solo un cambiamento tecnologico, ma un fondamentale riorientamento ontologico che ridefinisce i confini tra umano e non-umano nei sistemi di lavoro contemporanei. Con l'evoluzione delle organizzazioni verso forme più ibride, dove feedback loop uomo-macchina generano nuovi modi di apprendere e risolvere problemi, le strutture stesse di collaborazione ed esperienza stanno subendo una trasformazione radicale. Le organizzazioni che sapranno progettare efficacemente questa integrazione, orchestrando intelligenze umane e artificiali in un ecosistema coerente e produttivo, guadagneranno un vantaggio significativo nell'economia della conoscenza emergente. Per farlo dovranno iniziare con una robusta azione di formazione ed educazione all'uso delle tecnologie e contestualmente all'identificazione di piloti che permettano di verificare nel proprio contesto organizzativo l'adeguatezza delle rilevanze teorico-pratiche descritte.

Ma c'è una dimensione che attraversa ogni sezione di questo capitolo come un basso continuo, e che non può restare implicita: se l'AI è un mediatore e non un intermediario, se partecipa alla costruzione di significati condivisi, se influenza la dimensione emotiva e simbolica del lavoro, se ridisegna l'architettura della cognizione distribuita, allora la questione della collaborazione uomo-AI non è mai solo una questione organizzativa. È, inevitabilmente, una questione etica. Ed è a questa dimensione, all'ontoetica della collaborazione tra intelligenze di natura diversa, che il capitolo successivo è dedicato.

Capitolo 10

Ontoetica della collaborazione: quando la filosofia diventa necessità operativa

“I limiti del mio linguaggio significano i limiti del mio mondo.” — Ludwig Wittgenstein, *Tractatus logico-philosophicus*, 5.6 (1921)

Il capitolo precedente si è chiuso su una constatazione che attraversava ogni sua sezione come un basso continuo e che a un certo punto non poteva più restare implicita: se l’AI generativa è un mediatore e non un semplice intermediario, se partecipa alla costruzione di significati condivisi, se influenza la dimensione emotiva e simbolica del lavoro e ridisegna l’architettura della cognizione distribuita, allora la questione del “CyberMate” non è mai stata soltanto una questione organizzativa. È, inevitabilmente, (anche, almeno anche) una questione etica. Avevo “giustificato e corroborato” (più che dimostrato, lo riconosco) l’idea che l’AI generativa potesse replicare elementi sostanziali della collaborazione umana, superando i confini della mera strumentalità per configurarsi come agente attivo nei processi cognitivi e sociali. Ma se accettiamo anche solo parzialmente questa conclusione, ci troviamo di fronte a una trasformazione che ci obbliga a una riflessione su cosa significhi “essere” all’interno di questo nuovo ecosistema ibrido di intelligenze, e su come si distribuisca in un simile ecosistema la responsabilità morale.

Questo capitolo si propone allora di estendere sul piano filosofico ed etico l’analisi del “CyberMate” sviluppata nel Capitolo precedente ricalcando nel percorso la sequenza delle domande che mi sono posto ragionando astrattamente sull’argomento. Sono partito da un’analisi ontologica dell’AI generativa, riprendendo alcuni principi noti su come essa ridefinisca i confini tradizionali tra strumento e collaboratore. Ho provato poi a mettere in fila quel poco che ho capito dell’etica dell’informazione, concentrandomi sul tema della responsabilità distribuita che emerge quando l’AI diventa un attore significativo nei processi decisionali. Ho cercato quindi una sintesi ontoetica utile a interpretare le trasformazioni del lavoro collaborativo, proponendo un’integrazione di principi fondamentali per orientare l’ingresso dell’AI nei contesti professionali. Infine, ho tentato di definire qualche elemento utile allo sviluppo di un’etica della collaborazione umano-AI (d’ora in avanti, per brevità, U-A) capace di rispondere alle sfide poste da questo rapporto ibrido. Mi sono reso conto, alla fine, di aver scritto qualcosa che si potrebbe persino classificare come “filosofico”, se non altro perché vi

compaiono più domande che risposte, e questo, in un dominio che muta a ogni rilascio di modello, parrebbe semmai un bene più che un male.

Come sempre non ho la pretesa di inventare nulla, ma soltanto di razionalizzare (prima di tutto per me stesso) quello che leggo e studio. Per questo farò grande appello alla prospettiva infoetica e ontoetica sviluppata da Luciano Floridi, integrandola con le riflessioni sulla tecno-etica e sull'algor-etica di Paolo Benanti, nel tentativo di delineare un quadro interpretativo che aiuti a comprendere le implicazioni profonde di questa nuova forma di collaborazione. E poiché di collaborazione tra intelligenze di natura diversa si tratta, non nascondo una certa soddisfazione nel constatare che anche questo capitolo, come del resto buona parte del libro, è il prodotto di un lavoro condotto in team con quei “CyberMate” sintetici che ne sono al tempo stesso oggetto e strumento (resi “edotti” dei miei precedenti deliri sui temi in oggetto, sempre istruiti a procedere passo dopo passo sulla base dei miei feedback e delle mie correzioni). Vi è in questo, lo ammetto, una qualche forma di implicita ironia che mi diverte. C'è però anche un mandato più serio, che dichiaro fin d'ora: questo capitolo chiude un cerchio aperto nel Capitolo 3. Lì avevo argomentato perché serva una “bussola etica” e perché ancora non ne abbiamo davvero una, calando l'etica dell'informazione sulla catena del valore digitale; qui quella bussola viene portata dentro l'operatività concreta dei team ibridi. È il punto del libro in cui la filosofia smette (spero) di essere ornamento e diventa necessità operativa.

10.1 Mappa infografica del capitolo



Figura 10.1: Mappa logica del Capitolo 10

10.2 Dalla teoria alla filosofia: l'ontologia dell'informazione e il “CyberMate”

*“Il pericolo del passato era che gli uomini diventassero schiavi. Il pericolo del futuro è che gli uomini diventino robot.” — Erich Fromm, *Psicanalisi della società contemporanea*, 1955*

Come aveva argomentato già in tempi non sospetti (o quanto meno non inquinati da “iperHype”) Floridi [85], stiamo vivendo una “quarta rivoluzione” dopo quelle copernicana, darwiniana e freudiana: una rivoluzione che ridefinisce radicalmente il nostro posizionamento ontologico. In questo quadro l'AI generativa rappresenta un agente plasmante, che contribuisce attivamente a modificare l’“infosfera”, ovvero quello spazio di “dati” entro il quale tutti gli enti, sia analogici sia digitali, esistono come “organismi informazionali”. Il concetto di “CyberMate” introdotto nel capitolo precedente può essere riletto attraverso questa nuova lente: l'AI generativa come attore dell'infosfera che trascende la dicotomia strumento/collaboratore per assumere una posizione ontologica nuova e ibrida. Ciò solleva, evidentemente, questioni fondamentali su cosa significhi “essere” in questo contesto e su come siano definiti (più ancora che su quali siano) i confini tra le diverse entità informazionali. È la stessa “sfocatura dei confini” tra il mondo digitale, dove le decisioni vengono prese, e il mondo reale, dove le loro conseguenze si riverberano, che già il framework ConcrEthica ci aveva imposto di prendere sul serio, e che nel contesto dei team U-A diventa, se possibile, ancora più marcata.

Per orientarsi entro questa sfocatura conviene attrezzarsi con uno strumento metodologico preciso. Uno dei più efficaci (almeno per me, per arrivare a capire qualcosa) introdotti da Floridi nei suoi lavori è quello di “livello di astrazione” (LoA) [83]: l'analisi delle interfacce che si presentano ai diversi livelli di astrazione, dalla “blueprint” progettuale fino alla UI con cui interagiamo, ci permette di accedere a (ed allo stesso tempo di costruire), diverse rappresentazioni della realtà. L'interazione con l'AI generativa ci costringe a negoziare costantemente, oscillando, tra livelli di astrazione differenti nel corso della nostra esperienza d'uso: il livello dell'interazione concreta (l'interfaccia testuale o multimodale attraverso cui l'interazione avviene), il livello sintattico, semantico e pragmatico (la struttura, il significato e l'uso delle informazioni scambiate) e il livello sociale e simbolico (l'interpretazione, personale e collettiva, di quell'interazione). Quando l'interazione avviene nel contesto di un team ibrido, a mio giudizio questi livelli di astrazione si sovrappongono e si intrecciano, dando origine a una realtà collaborativa ibrida che non è riducibile né unicamente all'apporto umano né a quello artificiale. Questo fenomeno, che mi sentirei di chiamare di “co-costruzione ontologica”, amplia notevolmente la teoria dell'interazione simbolico-tecnologica già introdotta nel capitolo precedente (dove l'AI non determina i comportamenti né è semplicemente plasmata dalle interpretazioni sociali, ma partecipa alla costruzione di significati condivisi), arricchendola però di una dimensione etico-filosofica che lì restava implicita.

C'è poi un'ulteriore prospettiva filosofica utile, ed è quella del pluralismo ontologico, che troviamo in Bruno Latour [74] e in Karen Barad [78], i quali hanno postulato non la sostanza discreta delle entità, ma piuttosto agenti che “intra-agiscono” (*intra-acting*) ed emergono attraverso processi relazionali. La proposta di considerare l'AI come “attante simmetrico” nella rete collaborativa (la teoria dell'attore-rete è già stata variamente “disturbata ed implicitamente abusata” nei capitoli precedenti, dalla genealogia dell'autorità del Capitolo 1 fino alla cognizione distribuita del Capitolo 9) si allinea con questa visione, ma richiede un'ulteriore elaborazione per comprendere la natura di questo tipo di entità. Non troppo lontano dal vero dovrebbe essere

il concetto di “ente graduale” per descrivere l’AI generativa nel contesto collaborativo: un’entità che manifesta gradi diversi di capacità di agire, di intenzionalità e di influenza a seconda del contesto di interazione e del livello di astrazione considerato. Questa prospettiva ci permette di superare la dicotomia “o è un agente o non lo è” per accogliere una comprensione più sfumata e contestuale della presenza dell’AI nei processi collaborativi, comprensione resa del resto necessaria proprio dalla natura ibrida dell’interazione.

10.3 Etica dell’informazione e responsabilità distribuita

“Agisci in modo che le conseguenze della tua azione siano compatibili con la permanenza di un’autentica vita umana sulla terra.” — Hans Jonas, Il principio responsabilità, 1979

L’etica dell’informazione, che abbiamo cominciato a comprendere grazie agli studi di Luciano Floridi [84], prevede (e qui mi perdonerà la banalizzazione, sempre che per sbaglio mi legga o che qualcuno gli riporti il mio “banalone”) di estendere la considerazione morale a tutti gli enti informazionali, sulla base di una “metafisica” dell’informazione, scusandomi per il termine ma non sapendo come altro definirla, che considera le entità in funzione del loro valore informazionale intrinseco. La definizione che mi sono sempre permesso di richiamare è, grossomodo, quella di *un nuovo ramo dell’etica che studia e valuta i problemi morali legati ai dati (nella loro generazione, registrazione, cura, elaborazione, diffusione, condivisione e uso), agli algoritmi (intelligenza artificiale, agenti artificiali, apprendimento automatico e robot inclusi) e alle relative pratiche e infrastrutture (dall’innovazione responsabile alla programmazione, dai protocolli ai codici professionali), al fine di formulare e sostenere soluzioni moralmente corrette*. Sviluppando il framework ConcrEthica, avevo provato a calare questa definizione sulla “catena del valore digitale”, identificando le questioni etiche a ciascun livello del processo di trasformazione informazionale: la datificazione (acquisizione, conservazione e trattamento dei dati), con le sue questioni di sicurezza, privacy e consenso nella rappresentazione del mondo attraverso i dati; la sintesi analitica (dall’informazione alla strutturazione semantica), con i problemi dell’interpretazione, dell’identificazione dei bias e dell’integrità dei dati; i processi correlativi (la generazione della conoscenza), con le questioni di accessibilità e controllabilità, l’esigenza di evitare correlazioni spurie e di assicurare significatività statistica; e infine la decisione e l’azione (l’applicazione della conoscenza), dove rilevano il mantenimento del primato dell’etica sociale nella transizione dal digitale al reale e il diritto di scegliere di non applicare supporti digitali alle decisioni ultime.

Riportata nel contesto del “CyberMate”, questa struttura logica fa sorgere una serie di questioni che chiamerei senza enfasi esistenziali. Se l’AI generativa può effettivamente influenzare stati emotivi e processi decisionali umani, quanta responsabilità morale le dobbiamo attribuire? Come concettualizzare l’idea stessa di “bene”, o di “benessere”, riferita a un sistema collaborativo ibrido umano-AI? E quali principi dovrebbero guidare l’integrazione dell’AI nei contesti di collaborazione umana? Sono domande che nel Capitolo 3 si ponevano sul singolo soggetto e sull’organizzazione, e che qui si ripropongono moltiplicate dalla natura relazionale del team.

Proprio la prima di queste domande, quella sulla responsabilità, merita di essere sviluppata. Un aspetto particolarmente rilevante emerso dall’analisi del “CyberMate” riguarda infatti la distribuzione della capacità di agire tra umani e AI. Se adottiamo la prospettiva della cognizione distribuita e la teoria dell’attore-rete (entrambe già richiamate nel capitolo precedente), dobbiamo conseguentemente adottare anche una concezione

di responsabilità distribuita. La responsabilità morale, in altre parole, non appartiene più esclusivamente agli agenti umani, ma si distribuisce attraverso la rete socio-tecnica. Questo non significa attribuire responsabilità morale all'AI nel senso tradizionale del termine, ma piuttosto riconoscere alcune cose, ad esempio che le decisioni emergono da un sistema collaborativo complesso entro il quale l'AI gioca un ruolo attivo oppure che la responsabilità deve essere concettualizzata a livello sistemico, oltre che individuale, oppure anche che gli umani mantengono comunque diversi “livelli” di responsabilità: quella legata alla configurazione e alla costruzione del sistema, e quella legata al suo utilizzo (o al suo mancato utilizzo). Il concetto di responsabilità distribuita non è certo nuovo, ed era già presente, sotto le forme della morale distribuita e di una responsabilità che si estende attraverso la rete di agenti umani e non umani senza attribuire piena capacità morale agli agenti artificiali, nei lavori di Floridi sull'etica dell'informazione [84]. La domanda che lo tsunami della GenAI ci costringe a riformulare è se quella conclusione, formulata in un'epoca di AI assai meno “efficace” dell'attuale, regga ancora.

A questo interrogativo si affianca, illuminandolo da un'altra angolazione, la riflessione di un secondo autore. Nella mia ricerca di una visione ampia, anche se non necessariamente unitaria, un altro dei filosofi dei quali ho sempre cercato di seguire i lavori è padre Paolo Benanti, che ha proposto e articolato il concetto di “algor-etica” come riflessione sulla dimensione etica intrinseca agli algoritmi e ai sistemi di intelligenza artificiale [79]. Secondo Benanti gli algoritmi non sono neutri, ma incorporano valori, visioni del mondo e assunzioni che hanno profonde implicazioni etiche. Questa posizione si salda perfettamente con il cambio di “natura” della tecnologia che l'AI generativa impone, ovvero la transizione da una tecnologia orientata unicamente (meramente) all'efficienza verso tecnologie orientate all'efficacia, transizione che già precedentemente avevo additato come causa radice della progressiva perdita di neutralità morale degli strumenti. Da strumento puramente orientato a un obiettivo di efficienza, da perseguire attraverso l'amplificazione delle capacità umane, e che perciò relega le considerazioni etiche al solo impiego che se ne fa, a mano a mano che ci si sposta nella direzione dell'efficacia la tecnologia inizia ad assumere una sorta di intenzionalità che può indirizzare l'uomo verso determinati comportamenti. Questa intenzionalità implicita rappresenta un cambio paradigmatico nella moralità della tecnologia stessa.

Nel contesto più ampio della collaborazione, dei team ibridi e del paradigma del “CyberMate”, l'algor-etica ci aiuta a interrogarci su almeno tre fronti: i valori impliciti incorporati nei modelli di AI generativa e il modo in cui questi influenzano le dinamiche collaborative; la necessità di una “literacy algoritmica” come competenza fondamentale per un'interazione consapevole con l'AI (competenza che il lettore riconoscerà come il rovescio costruttivo del paradosso dell'AI literacy discusso nel Capitolo 7); e l'importanza di pratiche di progettazione etica “by design”, che considerino fin dall'inizio dello sviluppo l'impatto dei sistemi di AI sui processi collaborativi. Un elemento particolarmente rilevante dell'approccio di Benanti è l'attenzione alla dimensione antropologica: l'algor-etica non si limita a considerare gli effetti dell'AI sulla società, ma esplora come questa trasformi la nostra comprensione stessa dell'umano. Nel nostro contesto ciò si traduce in un'analisi di come la collaborazione con l'AI stia ridefinendo le nostre concezioni di creatività, *expertise* e intelligenza, con particolare attenzione al concetto, articolato da Benanti, di “human in the loop” [82], che pone l'accento sul mantenimento dell'autonomia decisionale umana, in piena coerenza con i principi etici proposti da Floridi.

10.4 Ontoetica e trasformazione del lavoro collaborativo

*“Non abbiamo bisogno di macchine che pensino come le persone, ma di persone che sappiano pensare con le macchine.” — Garry Kasparov, *Deep Thinking*, 2017*

Il lavoro del “meta-divulgatore” (come mi diverto a definirmi) impone, a un certo punto, di fare sintesi delle diverse prospettive, cercando tra le fonti un equilibrio che spesso non esiste, e di proporre un quadro di riferimento unitario. Questa volta il compito si è rivelato più arduo, perché il solo modello che mi è parso capace di valorizzare i diversi elementi è una rilettura dell’approccio “ontoetico” ispirato al lavoro di Floridi [86], estesa specificamente per cogliere le trasformazioni del lavoro collaborativo nell’era dell’AI generativa. L’ontoetica rappresenta una sintesi tra ontologia ed etica: riconosce che le questioni sul “che cosa è” (ontologia) e sul “che cosa dovrebbe essere” (etica) sono inestricabilmente connesse quando si ha a che fare con tecnologie trasformatrici come l’AI generativa. La cassetta degli attrezzi ontoetica ci permette di affrontare simultaneamente la ridefinizione ontologica delle entità coinvolte nella collaborazione (umani, AI, team ibridi), le implicazioni etiche di questa ridefinizione per le pratiche organizzative e le responsabilità che emergono dalla nuova configurazione ontologica.

Partendo da questo approccio e integrando i principi etici fondamentali proposti da Floridi [87], possiamo definire (e qui confesso un onesto “copia, incolla e adatta” di quelli già introdotti nel Capitolo 3) quattro principi ontoetici fondamentali, pensati per orientare l’integrazione dell’AI generativa nei contesti collaborativi.

Principio di benevolenza del team. Contribuire positivamente allo sviluppo umano attraverso l’arricchimento delle capacità collaborative e cognitive dei team ibridi.

Principio di autonomia graduale. Riconoscere gradi diversi di autonomia tanto negli agenti umani quanto in quelli artificiali, e progettare sistemi collaborativi che rispettino e valorizzino appropriatamente questi diversi gradi, riservando però sempre all’umano la facoltà di scegliere se utilizzare l’AI e se accettarne gli output.

Principio di trasparenza ontologica. Rendere espliciti i diversi ruoli ontologici e le diverse capacità degli agenti (U e A) coinvolti nella collaborazione, evitando sia l’antropomorfizzazione ingannevole dell’AI sia la sua riduzione a semplice strumento.

Principio di responsabilità distribuita ma asimmetrica. Riconoscere la distribuzione della responsabilità lungo la rete collaborativa, mantenendo tuttavia un’asimmetria fondamentale che riconduca e valorizzi le meta-responsabilità in capo agli agenti umani.

L’applicazione di questi principi non è priva di tensioni e di dilemmi. Provando a tradurli in domande, ne emergono almeno quattro, che non ammettono soluzioni universali. Il primo è il dilemma tra **autonomia e controllo**: come bilanciare l’autonomia necessaria a una collaborazione U-A efficace con l’esigenza di mantenere un controllo significativo sui processi decisionali? Il secondo è quello tra **sostituzione e complementarità**: come navigare eticamente il continuum tra la sostituzione di funzioni collaborative umane e l’arricchimento complementare delle stesse (continuum che in precedenza avevo chiamato “sostituzione parziale”)? Il terzo riguarda **identità e ibridazione**: come preservare un senso di identità professionale e personale in un contesto di crescente ibridazione cognitiva con i sistemi di AI? Il quarto, infine, oppone **democratizzazione e specializzazione**: come bilanciare la democratizzazione dell’*expertise* resa possibile dall’AI con il valore

della conoscenza specialistica e dell'esperienza umana? Sono dilemmi che non si risolvono una volta per tutte, ma che richiedono una negoziazione continua e contestuale, sostenuta dai principi ontoetici appena enunciati.

10.5 Verso un'etica della collaborazione umano-AI

“La tecnica non è neutra: crea un mondo a sua immagine e somiglianza.” — Jacques Ellul, *Il sistema tecnico*, 1977

L'integrazione dell'AI generativa nei contesti collaborativi richiede un ripensamento dell'etica professionale tradizionale. Studiosi dell'etica professionale come Pellegrino e Thomasma [88] hanno evidenziato come le professioni si fondino su un impegno fiduciario verso determinati beni o valori. In questa prospettiva, l'avvento dei team ibridi sostenuti dalla AI generativa solleva alcune questioni fondamentali ad esempio come si trasforma il rapporto fiduciario professionale quando è mediato o potenziato dall'AI oppure quali nuove competenze professionali diventano (maggiormente) rilevanti in un contesto di collaborazione U-A ed in conseguenza a questo come si ridefiniscono i confini della responsabilità professionale all'interno di un sistema di cognizione distribuita. L'etica professionale così trasformata dovrà di certo integrare le virtù tradizionali (competenza, integrità, responsabilità) con nuove meta-virtù: la già citata “literacy algoritmica”, una “saggezza collaborativa ibrida” e quella che chiamerei “responsabilità infrastrutturale”, ovvero la capacità di assumersi la responsabilità per le infrastrutture socio-tecniche che la collaborazione U-A rendono possibile.

Accanto alla dimensione professionale ne emerge poi un'altra, forse meno evidente ma non meno cruciale, che riguarda a mio giudizio la dimensione emotiva e sociale della collaborazione con l'AI. Da sempre filosofi e sociologi hanno sottolineato l'importanza dell'attenzione e della presenza autentica nelle relazioni umane. L'attenzione, che diventa segno tangibile (espresso in modo non verbale) di rispetto, definisce i confini della fiducia reciproca, ed è da qui che discendono le tonnellate di teorie sull'ascolto attivo che abbiamo ormai imparato a considerare quasi parte dell'arredo delle competenze sociali e professionali (il portaombrelli delle competenze “soft”). Nel contesto della collaborazione U-A diventa allora fondamentale un'**etica dell'attenzione** che riconosca i rischi di un'attenzione frammentata o meramente strumentale nei confronti dell'AI (con l'avvertenza, quasi ovvia, che l'unico lato dell'equazione che possa soffrire di questo deficit è quello umano), che valorizzi forme di presenza autentica anche in contesti tecnologicamente mediati tra le componenti umane, e che preservi, prevedendoli come vincolo esplicito, spazi di attenzione e di collaborazione puramente umani (un insieme di interazioni U-U) all'interno degli ecosistemi collaborativi ibridi. L'attaccamento tecnologico messo in luce nel capitolo precedente richiede insomma un'etica della giusta distanza: né il rifiuto luddista né l'immersione acritica, ma una relazione calibrata che preservi spazi di autonomia e di riflessione. È, sotto altra forma, la stessa tensione che guardandola dalla prospettiva “soggettiva” avevo provato a governare con il modello a fasi della deriva cognitiva e con la nozione di “resa cognitiva qualificata”: non meno AI, ma AI governata facendola in contesto organizzativo diventare una norma relazionale.

Né la dimensione professionale né quella dell'attenzione possono però restare confinate al piano individuale o interpersonale, e qui si arriva al livello più ampio del ragionamento. La dimensione etica del “CyberMate” richiede infatti un approccio di governance che consideri i sistemi collaborativi nella loro interezza, a partire dai modelli “sociali” organizzativi rappresentati dalle aziende. Bisogna sempre ricordare, come avevo argomentato in precedenza, che è necessario distinguere tra leggi, governance, compliance ed etica, riconoscendo che

l’auspicabile convergenza tra questi insiemi di “codici” si esprime nella loro intersezione, ma che non possiamo attenderci che da un insieme di leggi o regolamenti emergano, da soli, indicazioni e prescrizioni di carattere propriamente etico. Rileggendo i principi ontoetici, è possibile ipotizzare un framework di governance articolato su una triade di livelli di “astrazione”. Al **livello micro** operano le pratiche individuali di interazione etica con l’AI: lo sviluppo della literacy algoritmica e l’esercizio consapevole della meta-responsabilità, dove è fondamentale implementare i principi etici in ogni fase della catena del valore digitale, dalla datificazione alla decisione. Al **livello meso** si collocano le politiche organizzative che promuovano trasparenza, accountability, equità e “arricchimento reciproco” nei sistemi collaborativi ibridi: è qui che trovano collocazione i meccanismi di governance capaci di assicurare una progettazione etica “by design” delle soluzioni di AI collaborativa, e qui che lo strumento dell’AI Manifesto mostra tutta la sua utilità operativa. Al **livello macro**, infine, agiscono le regolamentazioni, gli standard e le norme sociali che definiscono i confini etici dell’integrazione dell’AI nei contesti collaborativi e professionali: normative come l’AI Act incorporano già alcuni principi etici irrinunciabili nella nascente relazione tra l’uomo e queste tecnologie, ma resta necessario un lavoro di implementazione concreta di tali principi, esteso anche alle dimensioni di interazione di team (e qui ritorna il giudizio, formulato in precedenza, di un AI Act “necessario ma insufficiente”). Da un punto di vista pratico, ciò che attraversa tutti e tre i livelli è il disagio crescente per la sfocatura dei confini tra il mondo digitale, dove le decisioni vengono prese, e il mondo reale, dove le conseguenze delle azioni si riverberano.

10.6 Dalla bussola etica alla pratica della collaborazione

La “bussola etica” di cui temevo l’assenza all’inizio del libro non è un oggetto astratto da contemplare, ma uno strumento da impugnare nella pratica quotidiana dei team ibridi. Se una cosa abbiamo capito, è che dobbiamo superare le dicotomie semplicistiche, strumento contro collaboratore, umano contro non-umano, per riconoscere la natura graduale e contestuale delle entità coinvolte nei nuovi team U-A postulati dal “CyberMate”. Le sfide etiche che ci troviamo di fronte non sono semplicemente problemi da risolvere, ma rappresentano l’occasione per ripensare in profondità cosa significhi collaborare, creare conoscenza e assumersi responsabilità nell’era dell’intelligenza artificiale. In questo senso l’ontoetica, e la sua estensione ai concetti di team, non è soltanto una riflessione sulle implicazioni dell’AI, ma una finestra su nuovi modi di essere e di collaborare nel mondo contemporaneo.

La sfocatura dei confini che il digitale ci ha obbligato a considerare diventa, nel contesto dei team U-A, sempre più marcata. Questo richiede un ulteriore ripensamento delle nostre categorie filosofiche tradizionali e una rinnovata attenzione alle dimensioni etiche della collaborazione. È esattamente per questo che ho parlato di filosofia come necessità operativa, e non come lusso speculativo: perché senza quelle categorie, e senza quella bussola, l’operatività dei prossimi capitoli rischierebbe di muoversi a tentoni. Quanto alla domanda se basti tutto ciò, la risposta onesta, come al solito, è che siamo soltanto all’inizio.

Parte IV

Governare la complessità

Bibliografia

Capitolo 1

- [1] Weber, Max. *Wirtschaft und Gesellschaft*. J.C.B. Mohr (Paul Siebeck), Tübingen, 1922. (Traduzione italiana: *Economia e società*, Edizioni di Comunità, Milano, 1961).
- [2] Foucault, Michel. *L'ordre du discours*. Gallimard, Paris, 1971. (Traduzione italiana: *L'ordine del discorso*, Einaudi, Torino, 1972).
- [3] Foucault, Michel. *Surveiller et punir. Naissance de la prison*. Gallimard, Paris, 1975. (Traduzione italiana: *Sorvegliare e punire. Nascita della prigione*, Einaudi, Torino, 1976).
- [4] Latour, Bruno. *Science in Action: How to Follow Scientists and Engineers Through Society*. Harvard University Press, Cambridge, MA, 1987.
- [5] Latour, Bruno. *Nous n'avons jamais été modernes. Essai d'anthropologie symétrique*. La Découverte, Paris, 1991. (Traduzione italiana: *Non siamo mai stati moderni*, Elèuthera, Milano, 1995).
- [6] Lasch, Christopher. *The Culture of Narcissism: American Life in an Age of Diminishing Expectations*. W. W. Norton & Company, New York, 1979.
- [7] Pariser, Eli. *The Filter Bubble: What the Internet Is Hiding from You*. Penguin Press, New York, 2011.
- [8] Pasquale, Frank. *The Black Box Society: The Secret Algorithms That Control Money and Information*. Harvard University Press, Cambridge, MA, 2015.

Capitolo 2

- [9] Challapally, Aditya, Chris Pease, Ramesh Raskar e Pradyumna Chari. *The GenAI Divide: State of AI in Business 2025*. Tech report, MIT NANDA Project, 2025.
- [10] Schumpeter, Joseph A. *Capitalism, Socialism and Democracy*. Harper & Brothers, New York, 1942. (Traduzione italiana: *Capitalismo, socialismo e democrazia*, Etas, Milano, 2001).
- [11] LeGrande, Craig e Venky Lakshminarayanan. *AI-Driven Value Management: How AI Can Help Bridge the Gap Across the Enterprise to Achieve Customer Success*. John Wiley & Sons, Hoboken, NJ, 2024.

- [12] Thomas, Rob, Paul Zikopoulos e Kate Soule. *AI Value Creators: Beyond the Generative AI User Mindset*. O'Reilly Media, Sebastopol, CA, 2025.
- [13] Musiol, Martin. *Generative AI: Navigating the Course to the Artificial General Intelligence Future*. John Wiley & Sons, Hoboken, NJ, 2024.

Capitolo 3

- [14] Floridi, Luciano. *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford University Press, Oxford, 2023.
- [15] Floridi, Luciano. *The Fourth Revolution: How the Infosphere is Reshaping Human Reality*. Oxford University Press, Oxford, 2014.
- [16] Floridi, Luciano. *Digital Philosophy and Ethics*. Corso a.a. 2023–2024, Bologna Lectures, YouTube.
- [17] Benanti, Paolo. *Human in the Loop. Decisioni umane e intelligenze artificiali*. Mondadori Università, Milano, 2022.
- [18] Benanti, Paolo. *Digital Age. Teoria del cambio d'epoca. Persona, famiglia e società*. Edizioni San Paolo, Cinisello Balsamo, 2020.
- [19] Benanti, Paolo. *La grande invenzione. Il linguaggio come tecnologia, dalle pitture rupestri al GPT-3*. Edizioni San Paolo, Cinisello Balsamo, 2021.
- [20] Jobin, Anna, Marcello Ienca e Effy Vayena. “The global landscape of AI ethics guidelines”. *Nature Machine Intelligence*, 1, 389–399, 2019.
- [21] Hagendorff, Thilo. “The Ethics of AI Ethics: An Evaluation of Guidelines”. *Minds and Machines*, 30, 99–120, 2020.

Capitolo 4

- [22] Challapally, Aditya, Chris Pease, Ramesh Raskar e Pradyumna Chari. *The GenAI Divide: State of AI in Business 2025*. Tech report, MIT NANDA Project, 2025
- [23] Thomas, Rob, Paul Zikopoulos e Kate Soule. *AI Value Creators: Beyond the Generative AI User Mindset*. O'Reilly Media, Sebastopol, CA, 2025.
- [24] LeGrande, Craig e Venky Lakshminarayanan. *AI-Driven Value Management: How AI Can Help Bridge the Gap Across the Enterprise to Achieve Customer Success*. John Wiley & Sons, Hoboken, NJ, 2024.

Capitolo 5

- [25] DAMA International. *DAMA-DMBOK: Data Management Body of Knowledge*. 2nd Edition Revised, Technics Publications, Basking Ridge, NJ, 2024.
- [26] Redman, Thomas C. *Data Driven: Profiting from Your Most Important Business Asset*. Harvard Business Press, Boston, MA, 2008.
- [27] Gartner. *Lack of AI-Ready Data Puts AI Projects at Risk*. Report, febbraio 2025.
- [28] Gartner. *Organizations with Successful AI Initiatives Invest Up to Four Times More in Data and Analytics Foundations*. Report, aprile 2026.
- [29] Osservatorio Innovazione Digitale nelle PMI. *PMI, prospettive di analisi per la trasformazione digitale: stato dell'arte e passi per il futuro*. Politecnico di Milano, Milano, 2025.
- [30] Osservatorio Artificial Intelligence. *Artificial Intelligence: adozione, trasformazione, equilibrio*. Politecnico di Milano, Milano, febbraio 2026.
- [31] Moretti, Franco. *Distant Reading*. Verso Books, London/New York, 2013.
- [32] Floridi, Luciano. *Distant Writing: Literary Production in the Age of Artificial Intelligence*. SSRN preprint, 2025.
- [33] Bender, Emily M., Timnit Gebru, Angelina McMillan-Major e Shmargaret Shmitchell. “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?”. *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT '21)*, 610–623, 2021.
- [34] Brown, Tom B., Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever e Dario Amodei. “Language Models are Few-Shot Learners”. *Advances in Neural Information Processing Systems*, 33, 1877–1901, 2020.

Capitolo 6

- [35] Wharton Human-AI Research e GBK Collective. *Accountable Acceleration: Gen AI Fast-Tracks Into the Enterprise*. 2025 AI Adoption Report, 2025.
- [36] Jensen, Michael C. e William H. Meckling. “Theory of the Firm: Managerial Behavior, Agency Costs and Ownership Structure”. *Journal of Financial Economics*, 3(4), 305–360, 1976.
- [37] Eisenhardt, Kathleen M. “Agency Theory: An Assessment and Review”. *Academy of Management Review*, 14(1), 57–74, 1989.

- [38] Ross, Stephen A. “The Economic Theory of Agency: The Principal’s Problem”. *American Economic Review*, 63(2), 134–139, 1973.
- [39] Jarrahi, Mohammad Hossein e Paavo Ritala. “Rethinking AI Agents: A Principal-Agent Perspective”. *California Management Review*, 2025.
- [40] Floridi, Luciano. *La differenza fondamentale. Artificial Agents: una nuova filosofia dell’intelligenza artificiale*. Mondadori, Milano, 2025.
- [41] Mollick, Ethan. “Almost an Agent: What GPTs can do”. *One Useful Thing*, 7 novembre 2023.
- [42] Simon, Herbert A. “A Behavioral Model of Rational Choice”. *Quarterly Journal of Economics*, 69(1), 99–118, 1955.
- [43] Parlamento Europeo e Consiglio. *Regolamento (UE) 2024/1689 del 13 giugno 2024 che stabilisce regole armonizzate sull’intelligenza artificiale (AI Act)*. Gazzetta ufficiale dell’Unione europea, 12 luglio 2024.

Capitolo 7

- [44] Beauchene, Vinciane, Sylvain Duranton, Nipun Kalra e David Martin. *AI at Work: Momentum Builds, but Gaps Remain*. Boston Consulting Group, 26 giugno 2025.
- [45] Bick, Alexander, Adam Blandin e David J. Deming. *The Rapid Adoption of Generative AI*. NBER Working Paper No. 32966. National Bureau of Economic Research, 2024. DOI: 10.3386/w32966.
- [46] Chatterji, Aaron, Thomas Cunningham, David J. Deming, Zoe Hitzig, Christopher Ong, Carl Yan Shan e Kevin Wadman. *How People Use ChatGPT*. NBER Working Paper No. 34255. National Bureau of Economic Research, 2025. DOI: 10.3386/w34255.
- [47] Dell’Acqua, Fabrizio, Edward McFowland III, Ethan R. Mollick, Hila Lifshitz-Assaf, Katherine C. Kellogg, Saran Rajendran, Lisa Kraye, François Candelon e Karim R. Lakhani. *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality*. Harvard Business School Technology & Operations Management Unit Working Paper No. 24-013 / The Wharton School Research Paper, 2023. DOI: 10.2139/ssrn.4573321.
- [48] Fernandes, Daniela, Steeven Villa, Salla Nicholls, Otso Haavisto, Daniel Buschek, Albrecht Schmidt, Thomas Kosch, Chenxinran Shen e Robin Welsch. “AI makes you smarter but none the wiser: The disconnect between performance and metacognition”. *Computers in Human Behavior*, 175, 108779, 2026. DOI: 10.1016/j.chb.2025.108779.
- [49] Floridi, Luciano e Anna C. Nobre. “Anthropomorphising Machines and Computerising Minds: The Crosswiring of Languages Between Artificial Intelligence and Brain & Cognitive Sciences”. *Minds and Machines*, 34(1), 1–9, 2024. DOI: 10.1007/s11023-024-09670-4.
- [50] Floridi, Luciano. *La differenza fondamentale. Artificial Agency: una nuova filosofia dell’intelligenza artificiale*. Mondadori, Milano, 2025.

- [51] Mollick, Ethan. *Co-Intelligence: Living and Working with AI*. Portfolio / Penguin, New York, 2024.
- [52] Randstad. *More than Half of Workers Believe AI Skills Will Future-Proof Their Careers, but Only 13% Have Been Offered Such Training Opportunities - Randstad Data Reveals*. Comunicato stampa, 5 settembre 2023.
- [53] Randstad Enterprise. *2025 Global In-demand Skills Research*. 2025.
- [54] Randstad Enterprise. *AI, Skills, and Flexibility in a “Talent Multiverse”: Randstad Enterprise Highlights Top Priorities for Talent Leaders in 2025*. Comunicato stampa, 6 febbraio 2025.
- [55] WalkMe. *Employees Left Behind in Workplace AI Boom, New WalkMe Survey Finds*. Comunicato stampa, 27 agosto 2025.
- [56] Korst, Jeremy, Stefano Puntoni e Prasanna Tambe. *Accountable Acceleration: Gen AI Fast-Tracks Into the Enterprise. 2025 AI Adoption Report*. Wharton Human-AI Research & GBK Collective, University of Pennsylvania, ottobre 2025.

Capitolo 8

- [57] Bainbridge, L. *Ironies of automation*. Automatica, 19(6), 775-779, 1983.
- [58] Chiriatti, M. et al. *System 0: Transforming Artificial Intelligence into a Cognitive Extension*. Cyberpsychology, Behavior, and Social Networking, 2025.
- [59] Cummings, M. L. *Automation bias in intelligent time critical decision support systems*. AIAA 1st Intelligent Systems Technical Conference, 2004.
- [60] Fischhoff, B. *Debiasing*. In D. Kahneman, P. Slovic, & A. Tversky (Eds.), *Judgment Under Uncertainty: Heuristics and Biases* (pp. 422-444). Cambridge University Press, 1982.
- [61] Goddard, K., Roudsari, A., & Wyatt, J. C. *Automation bias: a systematic review of frequency, effect mediators, and mitigators*. Journal of the American Medical Informatics Association, 19(1), 121-127, 2012.
- [62] Kahneman, D. *Thinking, Fast and Slow*. Farrar, Straus and Giroux, 2011.
- [63] Larrick, R. P. *Debiasing*. In D. J. Koehler & N. Harvey (Eds.), *Blackwell Handbook of Judgment and Decision Making* (pp. 316-338). Blackwell Publishing, 2004.
- [64] Mollick, E. *Co-Intelligence: Living and Working with AI*. Portfolio/Penguin, 2024.
- [65] Monsell, S. *Task switching*. Trends in Cognitive Sciences, 7(3), 134-140, 2003.
- [66] Parasuraman, R., & Manzey, D. *Complacency and bias in human use of automation: an attentional integration*. Human Factors, 52(3), 381-410, 2010.

- [67] Parasuraman, R., & Riley, V. *Humans and automation: use, misuse, disuse, abuse*. Human Factors, 39(2), 230-253, 1997.
- [68] Ranganathan, A., & Ye, X. M. *AI Doesn't Reduce Work — It Intensifies It*. Harvard Business Review, febbraio 2026.
- [69] Riva, G. *The Architecture of Cognitive Amplification: Enhanced Cognitive Scaffolding as a Resolution to the Comfort-Growth Paradox in Human-AI Cognitive Integration*. Working paper, 2025.
- [70] Shaw, S. D., & Nave, G. *Thinking—Fast, Slow, and Artificial: How AI is Reshaping Human Reasoning and the Rise of Cognitive Surrender*. The Wharton School, University of Pennsylvania, 2026.

Capitolo 9

- [71] Autor, D. H. (2015). *Why Are There Still So Many Jobs? The History and Future of Workplace Automation*. *Journal of Economic Perspectives*, 29(3), 3-30.
- [72] Dell'Acqua, F., Ayoubi, C., Lifshitz, H., Sadun, R., Mollick, E., Mollick, L., Han, Y., Goldman, J., Nair, H., Taub, S. & Lakhani, K. R. (2025). *The Cybernetic Teammate: A Field Experiment on Generative AI Reshaping Teamwork and Expertise*. Working Paper 25-043, Harvard Business School.
- [73] Hutchins, E. (1995). *Cognition in the Wild*. MIT Press.
- [74] Latour, B. (2007). *Reassembling the Social: An Introduction to Actor-Network-Theory*. Oxford University Press.
- [75] Li, J. Z., Herderich, A. & Goldenberg, A. (2024). *Skill but Not Effort Drive GPT Overperformance over Humans in Cognitive Reframing of Negative Scenarios*. Working Paper.
- [76] Suh, K. S., Kim, H. & Suh, E. K. (2011). *What If Your Avatar Looks Like You? Dual-Congruity Perspectives for Avatar Use*. *MIS Quarterly*, 35(3), 711-729.
- [77] Zammuto, R. F., Griffith, T. L., Majchrzak, A., Dougherty, D. J. & Faraj, S. (2007). *Information Technology and the Changing Fabric of Organization*. *Organization Science*, 18(5), 749-762.

Capitolo 10

- [78] Barad, K. (2007). *Meeting the Universe Halfway: Quantum Physics and the Entanglement of Matter and Meaning*. Duke University Press.
- [79] Benanti, P. (2018). *Oracoli. Tra algoretica e algocrazia*. Luca Sossella Editore.
- [80] Benanti, P. (2020). *Digital Age. Teoria del cambio d'epoca. Persona, famiglia e società*. San Paolo Edizioni.

- [81] Benanti, P. (2021). *La grande invenzione. Il linguaggio come tecnologia, dalle pitture rupestri al GPT-3*. Edizioni San Paolo.
- [82] Benanti, P. (2023). *Human in the loop. Decisioni umane e intelligenze artificiali*. Mondadori Università.
- [83] Floridi, L. (2008). The method of levels of abstraction. *Minds and Machines*, 18(3), 303-329.
- [84] Floridi, L. (2013). *The Ethics of Information*. Oxford University Press.
- [85] Floridi, L. (2014). *The Fourth Revolution: How the Infosphere is Reshaping Human Reality*. Oxford University Press.
- [86] Floridi, L. (2019). *The Logic of Information: A Theory of Philosophy as Conceptual Design*. Oxford University Press.
- [87] Floridi, L. (2023). *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford University Press.
- [88] Pellegrino, E. D. & Thomasma, D. C. (1993). *The Virtues in Medical Practice*. Oxford University Press.