



Distant Reading 4.0

Meta-Analisi comparative, riflessioni
concettuali ed epistemologiche ed
elementi pratici ed applicativi





Il problema della scala

Viviamo sommersi da una mole di informazioni testuali impossibile da gestire umanamente . L'obiettivo è trasformare una collezione disordinata di testi in conoscenza strutturata.

Due approcci storici ci vengono in aiuto: il Distant Reading (umanistico) e la Revisione Sistemática(scientifico).



Distant Reading

Origine: Studi letterari (Franco Moretti).

Obiettivo: Esplorare pattern e tendenze in grandi inskinnis di testi (es. tutti i romanzi dell'800).

Approccio: Esplorativo, genera nuove domande.

Revisione Sistematica

Origine: Ambito medico-scientifico od in generale para-scientifico (ad esempio economico).

Obiettivo: Rispondere a una domanda specifica minimizzando i bias.

Approccio: Evidence-based, sintesi rigorosa.

Cosa hanno in comune?

**Distant
Reading**

**Revisione
Sistematica**

- **Scala
Macro:**

Entrambi
analizzano corpora estesi,
non singoli testi.


- **Metodo:**

Necessità di protocolli
definiti per
selezionare e filtrare
il materiale.

- **Sintesi:**

Distillare un
significato aggregato
da una mole di
informazioni.

LLM come lettori “distanti”



L'addestramento di un LLM è una forma estrema e automatizzata di **distant reading**. I modelli “leggono” **miliardi** di token costruendo **mappe statistiche** di concetti e relazioni.

Potenziale: **Automatizzare sintesi, classificazioni e individuazione di pattern** su scala massiva.






Che parola brutta: opacità

- **Mancanza di intenzionalità:** L'LLM processa in modalità statistica, non "comprende" semanticamente.
- **Hallucinations:** Rischio di inventare dettagli basandosi sulla probabilità linguistica.
- **Opacità delle fonti:** Difficoltà nel risalire al testo originale che ha generato l'informazione.



Sinergia Uomo-Macchina



- L'uomo mantiene il **senso critico** e la **responsabilità** interpretativa.
- La **macchina** offre potenza di **calcolo** e lettura su larga scala.
- Necessità di passare da un **uso passivo** a un **uso strutturato** degli strumenti AI.



Chunking & Overlap



- Suddividere testi lunghi in “**chunk**” (segmenti) gestibili per la memoria del modello.
- Creare **sovrapposizioni** (overlap) tra i segmenti per non perdere il contesto ai bordi.
- Best Practice: Usare **tag espliciti** per indicare al modello dove inizia e finisce il contesto sovrapposto.



Gestione dell'Overlap

Mantenere la sequenzialità logica tramite tagging esplicito.

- Per garantire che l'LLM mantenga la "memoria" della sequenza logica, è necessario creare **sovrapposizioni** tra i segmenti.
- La regola del pollice preve **chunk** al **80%** della della capacità massima del prompt, riservando il resto all'overlap.
- L'istruzione chiave: chiedere al modello di operare sul contenuto del capitolo corrente, ma considerando il contesto fornito dai tag.


```
<OVERLAPFROMCHAPTERn-1>  
... (righe finali del chunk  
precedente)  
</OVERLAPFROMCHAPTERn-1>
```

```
<CHAPTERn>  
... (contenuto centrale da  
analizzare)  
</CHAPTERn>
```

```
<OVERLAPTOCHAPTERn+1>  
... (righe iniziali del  
chunk successivo)  
</OVERLAPTOCHAPTERn+1>
```

Il contenuto in `<OVERLAPFROMCHAPTERn-1>` deve corrispondere esattamente al contenuto `<OVERLAPTOCHAPTERn+1>` del segmento precedente.

Strategia MapReduce



Step 1 (**Map**): L'LLM analizza separatamente ogni chunk generando output intermedi (es. riassunti parziali).

Step 2 (**Reduce**): Si riagggregano i risultati chiedendo una sintesi unificata che mantenga la coerenza.

Risultato: Un "**reading sintetico progressivo**" che evita la perdita di dettagli.

Retrieval Augmented Generation



Mitigare le **allucinazioni** collegando l'LLM a un **database documentale controllato**. Il modello recupera solo i **passaggi rilevanti** e li **cita**, emulando il **rigore della revisione sistematica**. Ideale per sintesi basate su **evidenze verificabili**.





Verso il Distant Reading 4.0

"La macchina per la forza
bruta, l'uomo per il
significato."

- Un **approccio ibrido** permette di gestire l'**overload informativo** senza perdere la **profondità di analisi**.

