

Distant Reading potenziato da LLM

Meta-Analisi comparative, riflessioni concettuali ed epistemologiche ed elementi pratici ed applicativi

Riccardo Bovetti

[LinkedIn](#) | [All you need it thought](#)

Maggio 2025

Sommario

Ancora una volta, ed una volta ancora, mi sono trovato schiavo di una necessità: quella di provare a dare una forma ad una disordinata collezione di appunti raccolti come risposta ad una suggestione. Il “casus belli” questa volta è stata la lettura di un articolo del prof. Luciano Floridi sulla tematica del “Distant Writing” [1] e dai riferimenti (indiretti) in esso contenuti circa le metodologie di “Distant Reading. Questa porta aperta su concettualizzazioni importanti di processi metodologici che possono sembrare “intuitivi” (certo, una volta che li si sono compresi) mi ha fatto intravedere altri spiragli di luce che filtravano da altre porte concettuali precedentemente solo schiuse interrogandomi sul fatto che queste potessero in qualche modo essere connesse. Queste porte “schiuse” sono la metodologia della Systematic Review (metodo che ha sempre soddisfatto la mia necessità di ordine razionale nell’apprendimento e che ho sempre “immaginato” molto più versatile di quanto i suoi estensori avessero fatto intendere – al punto che l’applicazione della Systematic Review a contesti di contenuto differenti da quelli medico scientifici, e nello specifico a quelli Economico Manageriali, fu l’argomento di tesi che assegnai al mio primo tesista) ed il deep learning applicato alle fonti dati di “natura testuale” che di fatto è la meccanica di addestramento degli LLM che negli ultimi due anni hanno radicalmente trasformato la nostra esperienza digitale. Mi sono quindi baloccato nell’indagare possibili similitudini nonché certe e sostanziali differenze ed a costruire un framework teorico pratico nel quale poter “sperimentare” consapevolmente qualche esercizio di “distant reading 4.0”. Per scrivere questo breve meta-saggio mi sono, come sempre, avvalso di un paio di collaboratori (ChatGpt o3 utilizzato in modalità deep research ed Claude 3.7 Sonnet) ai quali ho sottoposto i miei materiali alla ricerca di (in)congruenze, riferimenti bibliografici alternativi od aggiuntivi (utilizzando largamente le tecniche descritte in appendice) e per verificare la presunta originalità di alcune mie epifanie. L’assoluta mancanza di originalità nelle mie conclusioni mi rassicura circa la relativa bontà delle medesime e mi riposiziona nello spazio che io stesso preferisco considerare il mio, ovvero sia quello di meta-divulgatore entusiasta.

Indice

1	Introduzione introduttiva	3
2	Distant Reading e Revisioni Sistematiche: analogie e differenze	3
3	LLM come lettori distanti: parallelismi con il distant reading	7
4	Conclusioni preliminari	10
5	Appendice: Metodologie applicate ed esempi operativi	10
5.1	Appendicite in nuce	10
5.2	Appendice sana	13
	Riferimenti bibliografici	15

1 Introduzione introduttiva

Il distant reading è un approccio sviluppato nell’ambito degli studi letterari e delle digital humanities, che mi ricordo di aver letto e sottolineato a matita nei lavori Franco Moretti [2]. Consapevole della modalità di funzionamento di entrambi gli approcci, ho pertanto ritenuto impossibile che i modelli linguistici di grandi dimensioni (Large Language Models, LLM) addestrati su enormi quantità di dati testuali, non potessero offrire nuove possibilità per potenziare, eventualmente trasformandolo, il distant reading (bravo te, bella idea.. soprattutto originale, vero?). I grandi modelli linguistici sono capaci di “comprendere” (l’antropomorfizzazione delle caratteristiche di queste sequenze di 0 ed 1 processate da pezzi di silicio alimentati a corrente continua è la misura della nostra fondamentale incapacità di adattarci veramente al nuovo) e generare linguaggio in modo coerente (sintatticamente perfetto, semanticamente non pervenuto), avendo letto (in termini computazionali) miliardi di “casi di uso ed occorrenza” di lessemi (o token se preferite la lingua della perfida Albione) provenienti da libri, articoli, siti web e altre fonti di natura testuale [3]. Il risultato del processo di addestramento è una sorta di conoscenza distribuita delle strutture linguistiche e dei contenuti presenti nel linguaggio naturale. Il definendo paradigma di Distant reading potenziato da LLM (Distant Reading 4.0 in onore al fatto che se non metti un 4.0 in un titolo vali meno di poco) si riferisce dunque alla proposta di utilizzo di questi modelli per supportare l’analisi di grandi corpora testuali, automatizzando sintesi, classificazioni tematiche, individuazione di pattern e perfino generazione di nuove ipotesi di ricerca a partire dai dati testuali. L’analisi di grandi moli di testi (con o senza l’ausilio di strumenti) risuona con la metodologia delle systematic review (revisioni sistematiche) utilizzata in ambito scientifico, che ho voluto pertanto porre in quadro comparativo evidenziando analogie strutturali, differenze epistemologiche e possibili sinergie metodologiche tra i due approcci. Dall’altro lato, il processo di addestramento dei Large Language Models permette di vederli come “lettori computazionali massivi” (anche un po’ compulsivi) che effettuano una forma estrema e automatica di distant reading sul corpus sterminato di testi disponibile in formato digitale. Questa duplice prospettiva auspico che permetta al lettore (occasionale ma spero consenziente) di ragionare in termini generali e concettuali sulle implicazioni di affidare la lettura e l’analisi testuale alle macchine, fornendo nel contempo qualche suggerimento (basato sull’esperienza personale dell’autore) circa la modalità di rendere maggiormente efficace questo efficientissimo strumento.

2 Distant Reading e Revisioni Sistematiche: analogie e differenze

Le revisioni sistematiche sono uno strumento cardine della ricerca scientifica (soprattutto in campo medico, ma ormai diffuso anche in altre discipline) per riassumere in modo rigoroso l’evidenza disponibile su una certa domanda di ricerca. La metodologia prevede passaggi strutturati e codificati [4].:

- formulare una domanda chiara

- definire criteri di inclusione per gli studi
- cercare sistematicamente in database bibliografici
- selezionare gli studi rilevanti secondo criteri predefiniti
- valutarne la qualità
- estrarre i dati e sintetizzarli qualitativamente o quantitativamente (ad esempio tramite meta-analisi)

L'obiettivo è minimizzare i bias e offrire una visione d'insieme affidabile su ciò che la letteratura scientifica indica riguardo a quello specifico argomento, o meglio quesito sull'argomento. La forza di una revisione sistematica risiede nella completezza (idealmente considera tutta la letteratura rilevante), nella trasparenza metodologica (ogni passo è documentato e replicabile) e nella sintesi critica dell'evidenza che non può essere effettuato altrimenti che da un esperto.

Il distant reading, pur nascendo in un contesto disciplinare diverso (letterario anziché medico-scientifico), condivide alcune somiglianze strutturali con il processo di revisione sistematica. Entrambi gli approcci si occupano di corpora estesi di testi o documenti piuttosto che di singoli elementi. Invece di concentrarsi su un singolo studio scientifico o su un singolo atto di produzione letteraria, l'attenzione si sposta sull'insieme: decine di trial clinici in un caso, migliaia di libri nell'altro. In entrambi i casi vi è l'esigenza di passare al setaccio una grande mole di informazioni testuali, distillandone un significato aggregato finalizzato alla risposta di un quesito in termini di produzione di una sintassi nuova, auspicabilmente dotata di una semantica riferita. Possiamo quindi individuare una prima analogia nella scala macroscopica dell'analisi: sia la revisione sistematica sia il distant reading adottano una prospettiva d'insieme, cercando pattern ricorrenti, convergenze o divergenze all'interno di un insieme vasto di testi. Un'altra analogia risiede nella necessità di adottare (definire prima e seguire poi) una metodologia ben definita. Così come le revisioni sistematiche seguono protocolli standard (spesso preregistrati, con linee guida come il protocollo PRISMA per rendere conto del flusso di selezione degli studi), anche un progetto di distant reading deve stabilire criteri chiari: ad esempio quale corpus di testi verrà analizzato, con quali tecniche (analisi di frequenza, topic modeling, sentiment analysis, reti di co-occorrenze, ecc.) e con quali obiettivi interpretativi. In altre parole, in entrambi gli approcci occorre selezionare e filtrare il materiale di partenza in modo ragionato. Nel caso della revisione questo avviene attraverso criteri di inclusione/esclusione degli articoli (es. tipo di studio, popolazione, intervento, esiti, qualità metodologica); nel caso del distant reading avviene tramite la definizione del corpus (es. tutti i romanzi di un determinato periodo storico digitalizzati, oppure articoli di una certa testata giornalistica o di un autore di un certo periodo) e la preparazione dei dati (pulizia del testo, normalizzazione) prima delle analisi computazionali. Nonostante queste analogie, esistono profonde differenze epistemologiche tra i due approcci.

Una differenza centrale riguarda il tipo di domanda e il fine conoscitivo. La revisione sistematica nasce per rispondere a una domanda specifica, spesso volta a risolvere un problema pratico o a

verificare un'ipotesi (ad esempio: “Questo farmaco è efficace nel trattare una certa malattia?”). Il suo approccio è di tipo evidence-based, mirato a trarre conclusioni sintetiche dall'insieme di studi migliori disponibili su quel tema [5]. Il distant reading, invece, spesso adotta un approccio più esplorativo e aperto: non sempre vi è una domanda chiusa a cui rispondere, quanto piuttosto l'obiettivo di scoprire tendenze e fenomeni emergenti dai dati letterari. Ad esempio, negli studi di Moretti si riportano l'utilizzo del distant reading per esplorare come i generi letterari nascano e si evolvano nel tempo, o per identificare relazioni tra stile e contesto storico su larga scala [6]. In questi casi l'analisi serve a generare nuove domande o prospettive critiche, più che a confermare un'ipotesi predefinita (e l'utilizzo del verbo generare nel contesto di una ricerca volta a capire se e come l'intelligenza artificiale generativa possa giocare un ruolo non è una scelta casuale).

Un'altra differenza epistemologica riguarda il ruolo dell'interpretazione umana. Nelle revisioni sistematiche, nonostante l'ausilio di protocolli standard, l'interpretazione e la sintesi finale restano fortemente guidate dall'esperto umano, che valuta la solidità delle evidenze e la loro rilevanza. Nel distant reading, soprattutto quello potenziato da metodi computazionali, c'è una maggiore delega alle macchine per l'identificazione dei pattern, soprattutto dove tali dati sono esprimibili in termini di correlazioni. Ciò può portare a risultati sorprendenti e non intuitivi, ma richiede poi un momento critico in cui il ricercatore umano interpreta quei pattern alla luce del contesto culturale e teorico. Ad esempio, un algoritmo potrebbe rivelare che certe parole legate all'emozione compaiono con frequenza decrescente nei romanzi di un determinato periodo storico, ma spetta allo studioso dare un senso a questo dato: rappresenta un cambiamento di sensibilità? una variazione nei generi letterari in voga? È qui che la distant reading rimane ancorata all'ermeneutica umanistica, mentre la revisione sistematica tende a collocarsi nell'ambito delle scienze empiriche con inferenze più dirette sui dati aggregati [5]. Il ruolo dell'umano (sempre centrale, sempre almeno “in the loop” come, non mi stuferò mai di scriverlo, queste tecnologie richiedono) rispetta pertanto l'attitudine maggiormente spiccata verso la causalità rispetto alla correlazione.

La trasparenza e replicabilità costituiscono un altro punto di divergenza. Per tradizione, le revisioni sistematiche pubblicano in dettaglio i loro metodi (fonti bibliografiche consultate, stringhe di ricerca, criteri di selezione, ecc.) affinché altri possano replicare o aggiornare lo studio [4]. Nel distant reading, soprattutto nella pratica delle digital humanities, la replicabilità può risultare più complessa: i dataset testuali usati talvolta non sono facilmente condivisibili o riproducibili (si pensi a collezioni di testi non interamente disponibili open access), e le procedure computazionali possono essere idiosincratiche (termine elegante che significa “a cazzo”). Tuttavia, la tendenza recente è verso una maggiore condivisione di codice e dataset anche nelle digital humanities, proprio mutuando l'enfasi sulla replicabilità tipica delle scienze [6]. In questo senso si intravede una contaminazione metodologica positiva: i progetti di distant reading stanno adottando pratiche più sistematiche nella documentazione dei processi, ispirandosi agli standard delle revisioni sistematiche in ambito scientifico. Senza la pretesa di esaustività alcuna riporto una tabella di sintesi (AI Generated ovviamente) che permette di rendere il parallelo di alcune caratteristiche fondazionali dei due metodi.

Caratteristica	Revisione Sistemática	Distant Reading
Scopo	Rispondere a una domanda specifica sintetizzando le evidenze disponibili (spesso per decisioni pratiche o avanzamento teorico su un quesito definito).	Esplorare pattern e tendenze in un grande insieme di testi, spesso per generare nuove ipotesi o ottenere una visione d'insieme, ad esempio, su fenomeni letterari/culturali.
Selezione del corpus	Studi selezionati tramite criteri rigorosi (inclusione/esclusione) e ricerca esaustiva in database accademici, per assicurare completezza e qualità.	Testi scelti in base a un progetto di ricerca (es. tutti i romanzi di un'epoca, un genere, una collezione digitale). La rappresentatività può essere limitata dalla disponibilità dei testi digitali e dalle scelte del ricercatore.
Metodologia di analisi	Lettura integrale e valutazione critica di ciascun studio; estrazione di dati chiave; sintesi narrativa o quantitativa (meta-analisi).	Analisi computazionale su testi: statistiche linguistiche (frequenze, distribuzioni), modelli di topic, analisi di sentiment, reti semantiche, ecc., spesso senza lettura manuale dei singoli testi.
Ruolo dell'umano vs macchina	L'umano conduce tutte le fasi (con possibili supporti software per gestione bibliografica); interpretazione interamente guidata da expertise umana.	La macchina identifica pattern (via algoritmi di machine learning); l'umano interviene nell'impostare l'analisi e nell'interpretare i risultati globali.
Bias e controllo di qualità	Fortemente basata su valutazione critica: esclusione di studi di bassa qualità, analisi del rischio di bias, valutazione della robustezza delle evidenze.	Rischio di bias derivante dal corpus (es. testi disponibili digitalmente non rappresentano l'intero universo), dagli algoritmi utilizzati (probabilistici e statistici). Il controllo qualità avviene calibrando metodi e confrontando con conoscenze pregresse, ma standard formali meno codificati.

Caratteristica	Revisione Sistemática	Distant Reading
Output	Risposta documentata alla domanda di ricerca, con conclusioni trasparenti e supportate da riferimenti (ad es. “le evidenze suggeriscono che X è efficace per Y”).	Visualizzazioni, modelli o sintesi quantitative che rivelano tendenze (ad es. grafici sull’evoluzione di un tema nei testi nel tempo), accompagnate da un’interpretazione discorsiva dei risultati.

Opportunità di integrazione: le analogie e differenze evidenziate fin qui suggeriscono possibili sinergie metodologiche. Le revisioni sistematiche possono beneficiare di tecniche proprie del distant reading, ad esempio l’uso di algoritmi di text mining e NLP (natural language processing) per automatizzare la fase di screening e analisi della letteratura. Già oggi sono in sviluppo strumenti che impiegano il machine learning per aiutare i revisori a identificare studi rilevanti in grandi moli di riferimenti bibliografici, riducendo il carico di lavoro manuale [7]. I Large Language Models, in particolare, si sono dimostrati utili per generare riassunti dei paper, estrarre informazioni chiave e persino formulare sintesi preliminari dei risultati di un corpus di studi scientifici [8]. Ad esempio, prototipi di assistenti basati su LLM possono leggere centinaia di abstract e restituire agli scienziati una panoramica tematica, o evidenziare quali studi supportano o confutano una certa tesi. Questo approccio computazionale rispecchia lo spirito del distant reading (leggere a distanza, per estrarre schemi generali) applicato però alla letteratura scientifica e con lo scopo di accelerare l’evidenza aggregata.

D’altro canto, il distant reading potrebbe evolvere adottando sempre maggiormente la rigosità delle revisioni sistematiche. In particolare, potrebbe adottare pratiche più sistematiche nella selezione dei testi (documentando meglio perché si include o esclude un certo sotto-corpus), nella registrazione dei parametri di analisi e nell’esplicitare i limiti dell’analisi svolta. Ad esempio, in un progetto di distant reading sulla narrativa italiana del 900, si potrebbe dichiarare esplicitamente quali database digitali sono stati usati per raccogliere i testi e quali periodi sono coperti, analogamente a come una review scientifica dichiara le fonti delle sue evidenze. Inoltre, l’uso di tecniche di campionamento statisticamente valide e l’attenzione ai bias di pubblicazione/archiviazione dei testi potrebbero arricchire la solidità delle conclusioni tratte. Questa “contaminazione” metodologica renderebbe il distant reading più robusto e comparabile, facilitando ad esempio studi replicativi o meta-analisi di risultati di distant reading prodotti da gruppi diversi.

3 LLM come lettori distanti: parallelismi con il distant reading

L’addestramento dei modelli linguistici di grandi dimensioni (large language models) può essere visto come un caso limite di distant reading, in cui però il lettore è la macchina stessa. Durante la fase di training gli LLM processano in modo automatico quantità enormi di test. In altre parole,

ha effettuato una “lettura” su scala non praticabile per un essere umano, costruendo internamente rappresentazioni statistiche di come le parole si combinano, quali frasi sono grammaticalmente e sintatticamente plausibili nel contesto semantico che viene analizzato, quali conoscenze ricorrono nel corpus, e così via. Questo processo può essere interpretato come una forma estrema di distant reading automatizzato: il modello non legge con l’intento cosciente di comprendere (e peraltro, poverino, come potrebbe avere questo intento?), ma assorbe pattern linguistici e informativi dall’intero insieme di testi (...brividi puri). Il parallelismo tra distant reading e training di LLM emerge considerando gli obiettivi e i risultati di questi processi. Nel distant reading tradizionale, il fine è spesso estrarre conoscenza quantitativa su un corpus (ad esempio, la curva di popolarità di un genere letterario nel tempo, o le reti di relazioni fra personaggi in un insieme di romanzi) e poi interpretarla. Nel caso del LLM, il fine dell’addestramento è costruire un modello generativo capace di continuare testi plausibili; tuttavia, per riuscirci, il modello deve aver catturato implicitamente moltissimi pattern di conoscenza (di nuovo parliamo di contesti semantici, come sempre anche a sproposito) presenti nei dati. Ad esempio, un LLM addestrato su vasta scala “sa” (in termini di pesi che vengono attribuiti alle sue reti neurali nascoste) che Roma è la capitale d’Italia, che Shakespeare era un drammaturgo inglese, che la sequenza “C’era una volta” probabilisticamente (con riferimento alla cultura di base che ha definito il suo corpus di addestramento) introduce una fiaba, e così via, perché tutte queste associazioni erano distribuite nella statistica dei testi che ha elaborato. In un certo senso, il modello ha tracciato mappe di collegamenti tra concetti, termini e contesti d’uso in ambiti semantici su un intero spazio letterario-culturale, analogamente a come un progetto di distant reading potrebbe mappare reti di personaggi o temi nei romanzi. La differenza è che nel distant reading classico queste mappe sono esplicite e interpretate dallo studioso, mentre nel LLM sono implicite nei miliardi di parametri della rete neurale.

Per approfondire il parallelismo ho provato a rivedere, per quanto mi è noto, il processo di analisi. Un ricercatore che applica la metodologia del distant reading tipicamente svolge i seguenti passi: raccoglie un corpus digitale, lo pulisce e lo organizza, applica algoritmi (ad es. topic modeling per scoprire temi latenti, o clustering per trovare gruppi di testi simili), quindi esamina i risultati e ne deriva un’interpretazione teorica. Nel training di un LLM avviene qualcosa di concettualmente simile: il corpus (testi in linguaggio naturale accessibili in formato digitale) viene preprocessato; l’algoritmo di apprendimento automatico (una rete neurale transformer) scandisce ripetutamente i testi trovando schemi di co-occorrenza e sequenze probabili; il risultato è un modello che incapsula una rappresentazione generalizzata di quel corpus in una enorme tabella n-dimensionale di relazione tra i lessemi. In ambedue i casi, gran parte del lavoro consiste nel trovare schemi ricorrenti nel testo. Il ricercatore umanista potrebbe scoprire che nei romanzi dell’ottocento inglese aumentano i termini legati all’industrializzazione nei romanzi; il LLM imparerà che il contesto “rivoluzione industriale” spesso co-occorre con certe parole tecniche o con date specifiche del XIX secolo, al punto da saper generare frasi su quel tema imitandone lo stile.

Tuttavia, i limiti e differenze di questo parallelismo sono cruciali. Un LLM non possiede intenzionalità né comprensione semantica alcuna: “legge” (ricordate poche righe sopra il mio

chiosare sulla mancanza di un linguaggio specifico? .. ecco siamo di nuovo da quelle parti) nel senso che macina dati e ottimizza una funzione matematica (predire la parola successiva), il che è ben diverso dalla lettura critica umana che attribuisce senso, contesto e valore qualitativo ai testi [10]. Il distant reading condotto da studiosi, pur delegando agli algoritmi la scoperta di pattern quantitativi, resta ancorato a interpretazioni e teorie sul significato di quei pattern che non sono automaticamente presenti nel pattern stesso. Invece, il modello addestrato ingloba tutto indiscriminatamente: testi di alta qualità e testi banalissimi, verità e disinformazione, letteratura canonica e contenuti effimeri del web. Ciò lo rende potente (perché abbraccia l'ampiezza del linguaggio naturale) ma anche pericolosamente opaco e incline a errori. L'esempio è il fenomeno delle allucinazioni per cui possiamo aspettarci che in una sintesi di un argomento svolta in modo plausibile siano presenti dettagli inventati semplicemente in funzione della probabilità (mediata dalla temperatura) che certe sequenze di parole erano comuni nel corpus di addestramento.

Un ulteriore aspetto di confronto riguarda la scala e il rapporto con l'umano. Il distant reading nasce anche dalla consapevolezza che un singolo studioso non può leggere tutto; deve quindi affidarsi a strumenti che comprimano l'informazione. Gli LLM realizzano questa compressione dell'informazione su una scala senza precedenti: l'intera letteratura viene compressa nei pesi di un modello di dimensioni dell'ordine di centinaia di miliardi di parametri [9]. Questo comporta che il modello può in teoria attingere (seppure in modo indiretto) a conoscenze provenienti da qualsiasi testo presente nel suo training quando produce un output. In pratica, se chiediamo a un LLM di aiutarci ad analizzare un corpus (funzione di assistente al distant reading), esso può sintetizzare informazioni che provengono da zone diversissime della letteratura o del sapere. Va però sottolineato che l'informazione fornita da un LLM è priva di garanzie di affidabilità e fonte. Mentre in un distant reading tradizionale lo studioso può risalire ai testi originali per verificare un pattern (ad es. controllare quali romanzi presentano effettivamente il calo di frequenza di un certo termine), un LLM tipicamente non rende esplicito da quali fonti ha appreso un'informazione e può mescolare contesti diversi. Ciò contrasta con l'ideale metodologico della revisione sistematica – e della ricerca scientifica in generale – in cui ogni affermazione dovrebbe essere giustificata da riferimenti precisi. Alcuni sviluppi recenti cercano di unire i benefici del LLM con l'esigenza di rigore, ad esempio collegando i modelli a database documentali per fornire risposte con fonti (cosiddetti sistemi RAG retrieval-augmented generation). Tali sistemi consentono al modello di selezionare ed identificare documenti pertinenti e citarli mentre genera una risposta, emulando in parte il processo di una revisione sistematica (dove si citano articoli specifici). Questa è un'ulteriore area di sovrapposizione metodologica: addestriamo agli LLM a comportarsi più come revisori sistematici, dando risposte supportate da evidenze, in modo da mitigare la tendenza a inventare contenuti.

Infine, è interessante notare che gli LLM stessi possono diventare oggetto di distant reading. Così come uno studioso analizza un corpus letterario per capire la cultura di un'epoca, altri studiosi iniziano ad analizzare il comportamento linguistico di modelli come GPT per capire cosa "hanno imparato" dalla mole di testi [10]. Si tratta di aprire il cofano e guardare con occhi diversi il motore di "calcolo", ad esempio, analizzando le associazioni che il modello fa tra certi concetti,

o studiando sistematicamente dove il modello sbaglia, possiamo ottenere una sorta di mappa delle conoscenze e bias incorporati. Questo è un distant reading di secondo livello: leggere attraverso l’LLM ciò che esso ha assorbito dalla letteratura. Tale ricerca incrocia informatica, linguistica e scienze cognitive, e rappresenta un nuovo fronte in cui la metodologia umanistica (interpretare pattern linguistici) si applica a un artefatto tecnologico frutto a sua volta di un distant reading automatizzato.

4 Conclusioni preliminari

La prospettiva di un supporto “sostanziale” degli LLM all’evoluzione delle metodologie di Distant Reading e di Systematic Review solleva più questioni di quante risposte sia riuscito a darmi (non dico darvi nella speranza, certezza, che abbiate abbandonato la sfida al primo epistemologico oppure, per i più testardi, al quell’ermeneutico buttato lì in scioltezza) in queste poche pagine. Quali aspetti dell’esperienza umana di lettura vanno perduti quando deleghiamo la sintesi di un testo (di qualsiasi natura) ad una macchina? In che modo il pregiudizio insito nei dati di addestramento (ad esempio una sovra-rappresentazione di testi in lingua inglese o di certe opinioni dominanti della cultura che è espressione del materiale di addestramento) influenza la visione del mondo che un LLM ci restituisce? Ogni volta che affronto un capitolo sulle trasformazioni atto facilitate/portate dall’intelligenza artificiale mi trovo a scivolare inevitabilmente su etica, epistemologia ed ontologia e sulla certezza dobbiamo usare con cautela i risultati di questi ricordando sempre che essi sono frutto di correlazioni statistiche e non di comprensione intenzionale. L’evoluzione del distant reading “boosted” dagli LLM rappresenta di sicuro una frontiera affascinante a patto che l’uomo e la macchina continuino il balletto che le vede operare in sinergia: la macchina per la sua potenza di calcolo e di lettura su larga scala, l’uomo per la capacità di attribuire significato, valore e direzione all’analisi prodotta in forza bruta. Avendo però sempre chiaro a chi spetta il senso critico e la responsabilità interpretativa. (Almeno ancora per un pò).

5 Appendice: Metodologie applicate ed esempi operativi

5.1 Appendicite in nuce

Per quanto non abbia mai condotto progetti di Distant Reading propriamente detti mi sono trovato, nel corso di questi ultimi due anni, a rivoluzionare il mio approccio alla lettura ed alla “meta ricerca” in ambito professionale ed accademico (chi mi legge sa che per rispetto di quelli che fanno veramente lavoro di ricerca preferisco schermirmi dietro ad un “meta”, che come un “dottò” a Napoli, non si nega a nessuno) adottando laddove possibile strumenti di AI a supporto. La ragione è presto detta: la mole di testi, articoli, studi che leggo annualmente per supportare la mia ridicola produzione è importante e dovendo io “negoziare” il tempo per questa attività con il mio “day job” la considero da sempre un limite alla varietà dei miei studi. Per riuscire a perseguire i miei obiettivi ho dovuto sviluppare un approccio “bizzarro” alla lettura dei testi (specialmente

quelli, e sono la maggior parte, di provenienza accademica anglosassone/americana): siccome molti dei testi accademici (o pseudo tali) concentrano nella parte centrale e finale i concetti “salienti” (lasciando ai capitoli introduttivi quella che quando racconto questo mio “metodo” descrivo come la storia di Adamo ed Eva) io di solito parto dal fondo e non dall’inizio. Leggo l’introduzione o l’abstract. Poi vado all’ultimo capitolo, lo leggo segnandomi le cose che non capisco e poi procedo a ritroso capitolo per capitolo finché la lista delle cose “incomprensibili” non ha trovato piena spiegazione. A quel punto mi fermo perché i capitoli che stanno tra l’abstract e l’ultimo concetto spiegato di solito non contengono cose “indimenticabili”. La produzione di “contenuti” di carattere scientifico (o pseudo tale collocando in questo contenitore anche i miei deliri) è immensa ed in costante aumento (anche grazie alla facilità con la quale oggi è possibile “pubblicarle”, cioè renderle disponibili ad un potenziale lettore) così come in costante riduzione è il tempo (e le energie) che personalmente posso dedicare a questa attività. Da un punto di vista morale e scientifico questa cosa potrebbe anche essere non necessariamente ed unicamente negativa: il meno tempo a disposizione dovrebbe, accompagnando un contestuale sviluppo della mia “saggezza” rendermi maggiormente qualitativo nella scelta degli argomenti di ricerca e studio nei quali mi cimento. D’altro canto però avendo scelto di occuparmi di tematiche legate all’AI mi devo confrontare con una rapidità di evoluzione della materia e con una sorta di FOMO (Fear of Missing Out) rispetto ad elementi che potrebbero essere epifanici che in qualche modo spingono verso una “orizzontalità a profondità limitata”. Tutta questa premessa per dire che, ovviamente, uno dei miei primi casi applicativi dell’intelligenza artificiale generativa è stato quello legato alla lettura ed alla sintesi di articoli e di testi che, se da un primo screening automatico basato su certi parametri si fossero confermati portatori di qualche “interesse” per la mia ricerca, sarebbero diventati oggetto della mia attenta ed umanissima lettura. Devo dire che il mio grado di soddisfazione relativamente ai risultati che sono ad ottenere da questa modalità d’uso è stato molto variabile nel tempo (complici sia la mia capacità di usare in modo “ottimale” gli strumenti sia la percepibile differenza nella capacità elaborativa degli strumenti stessi tra una versione e l’altra). Riporto una breve storia dei miei personali travagli in merito, ampiamente trascurabile peraltro.

Luglio 2023 volendo dedicare parte significativa delle mie vacanze d’agosto ad un tema di ricerca relativo all’impatto della trasformazione digitale sul ruolo del Controller in azienda (parte di un cimento editoriale fatto con un “collega” dell’Università Cattolica, professore lui sul serio, che a distanza di due anni è ancora più nell’intenzione che nella realtà) mi sono procurato un vasto database di articoli e pubblicazioni (sia di “white” che di “black” literature) ed ho provato ad usare strumenti di GenAI (ChatGPT4, all’epoca) per avere sintesi, comparison e cross references lavorando esclusivamente sui prompt. **Risultato:** impatto sicuramente rilevante in termini di efficienza, trascurabile in termini di efficacia perché l’attendibilità era molto limitata soprattutto sui testi lunghi. Per cui al netto di alcuni articoli che sono riuscito a “scartare” (ma che oggettivamente avrei scartato anche solo leggendone l’abstract) l’esperienza è stata poco significativa.

Luglio 2024 stesso contesto, diverso argomento di studio, diversi strumenti, consapevolezza ed approccio. Per quanto le performance fossero molto migliori (radicalmente) con la versione ChatGPT4o (anche in questo caso per il combinato disposto della migliore performance dello strumento e per la maggiore capacità da parte mia di usare lo strumento stesso) la performance e l'attendibilità del risultato sintetico (volendo qui intendere sia di "sintesi" che di "sintesi" - ovverosia tanto sommario quanto artificiale) tendeva a degradare, nei testi lunghi, verso la fine del testo, cosa in totale contrasto con la mia metodologia di lettura sopra descritta (e con il paradossale effetto di avere più informazioni sulla storia di "Adamo ed Eva" che sul contenuto distintivo del documento, quanto meno distintivo ai fini della mia ricerca). Ho pertanto provato a sviluppare un GPTs istruendolo in modo strutturato e rigoroso via prompt per procedere nella lettura come avrei fatto io. La non perfetta capacità di identificare la struttura (capitoli etc) dei testi ha reso il risultato molto meno efficace di quanto teoricamente avrei potuto aspettarmi tanto che, intestardendomi su questo tentativo, sono stato obbligato ad usare una tecnica di forza bruta per ottenere dei risultati accettabili: scaricato un LLM locale, costruito un RAG via tonnellate di codice Python (scritte, manco a dirlo in co-design con un l'AI in qualche calda serata tra una zanzara ed un discreto numero di calici di vino) strutturato un metodo di "chunking" del file che permettesse di fare in modo "pseudo-automatico" (che vuol dire anche pseudo-manuale) la strutturazione dei capitoli e fatto "lavorare" secondo il mio perverso metodo di lettura. **Risultato:** accettabile/buono in termini di attendibilità, ovviamente discutibile l'impatto sull'efficienza se si considera sia il tempo/costo dei vari tentativi e poi dello sviluppo della soluzione (e del suo utilizzo). Sulla lunga distanza ancora più discutibile per il fatto che, oggi, lo stesso GTPs costruito 10 mesi fa, senza alcuna modifica, ha performance che sono comparabili o anche superiori alla mia "usine a gas" programmata con cazzuolate di codice.

Primo quarter 2025 per alcuni dei miei ultimi articoli ho voluto sperimentare una ulteriore modalità operativa: costruendomi delle liste di lettura usando strumenti come Perplexity, sfruttando diversi strumenti (GPT4.5 ed o3, Claude 3.7, Gemini) in modalità "deep research" e facendoli "cooperare" con me e tra loro a partire da mie ricerche, integrando queste ricerche con testi e contenuti letti (in modo abbastanza efficiente sia forward che backward) in una modalità operativa che ho già in precedenza citato come la modalità "Cyborg". **Risultato:** ancora troppo presto per valutarlo però di sicuro, se devo considerare innanzitutto l'impatto "emotivo" che questa realtà di lettura "aumentata" ha prodotto in me, rilevo un significativo aumento della mia produttività in "senso lato". Ovvero, avendo la possibilità di sottoporre ad uno screening preventivo "cautamente affidabile" una grande mole di testi che possono o non possono essere attinenti ad una mia idea di ricerca mi sono trovato spesso a lanciarmi nella ricerca di connessioni bizzarre che avevo da molto tempo in testa senza avere fisicamente il tempo di completare anche solo il percorso di individuazione delle fonti.

Long Story short probabilmente ho aumentato il numero di cose che vengono scritte e "pubblicate" e che non vale la pena di leggere neanche con una lettura di quelle "trasversali".

Pertanto per mitigare questo mio senso di colpa latente nell’aver aumentato la quantità di pattume mediatico formattato da articolo che è disponibile in rete vorrei condividere un po’ delle tecniche che ho utilizzato affinché qualcuno, magari sperimentandole, produca a sua volta qualcosa di non indimenticabile così da far dimenticare rapidamente le mie già non indimenticabili produzioni.

5.2 Appendice sana

In questa sezione provo a descrivere metodologie pratiche (dalla segmentazione dei testi al prompting gerarchico) che ho utilizzato durante nel percorso che ho descritto precedentemente con l’obiettivo di mostrare come ho perseguito l’obiettivo di combinare scala automatica e controllo esperto attraverso un impiego mirato degli LLM. Un secondo elemento chiave è definire (in anticipo, su carta, usando lo strumento principe di ogni bravo programmatore: carta e matita) strategie di prompting efficaci. Gli LLM vanno guidati con istruzioni chiare su cosa, come e dove cercare od eventualmente produrre da ogni testo. Bisogna abituarsi a fornire al modello un briefing contestuale: ad esempio indicando chiaramente il tema del progetto e gli aspetti d’interesse, in modo da ottenere risposte quanto più possibile mirate e circostanziate. Aspetto cruciale quanto mai irrinunciabile è la preparazione del corpus da analizzare. Se la collezione di testi è molto ampia (decine o centinaia di documenti, o milioni di parole), è necessario suddividerla in chunk gestibili, tenendo conto dei limiti di contesto dei modelli LLM (tipicamente qualche migliaio di token per prompt con capacità in crescita nelle ultime versioni o per scelta degli editori – ad esempio Google). In pratica, ogni documento lungo va segmentato in parti più piccole (ad esempio sezioni o paragrafi o capitoli - senza pretendere che la nostra comprensione e nozione di capitolo sia implicitamente compresa) che l’LLM possa leggere singolarmente. Idealmente i chunk dovrebbero avere una dimensione massima leggermente inferiore a quella massima gestibile dai singoli prompt (regola del pollice: 80%) e prevedere sempre una certa sovrapposizione tra parti adiacenti, così da non perdere contesto ai “bordi” di ciascun segmento. La gestione di questi overlap, per esperienza personale, è l’unico modo di garantire che la focalizzazione “fetta per fetta” sia sulla parte centrale ma esista nella memoria dello strumento la sequenzialità logica del procedere. Ho trovato efficace l’utilizzo del TAGGING per segnalare questi elementi di overlap, però forse è efficace perché mi rassicura con il suo composto ordine logico più che per un reale valore aggiunto in termini di performance. Nello specifico io utilizzo:

```
<OVERLAPFROMCHAPTERn-1>... </OVERLAPFROMCHAPTERn-1> <CHAPTERn>...</CHAPTERn>  
<OVERLAPTOCHAPTERn+1>...</OVERLAPTOCHAPTERn+1>
```

come sequenza di tag che identificano ogni chunk ovviamente mettendo:

- nel chunkM come <OVERLAPFROMCHAPTERn-1> esattamente le stesse “righe” che ho messo nel chunkM-1 come <OVERLAPTOCHAPTERn+1>
- e specificando che le operazioni sono da compiere sul contenuto del <CHAPTERn> ma tenendo in considerazione dell’intero contesto.

Un altro elemento chiave è, ovviamente, definire (sperimentare, modificare, adattare) strategie di prompting adeguate all'obiettivo. Consapevole di dire ovvietà, ma altrettanto consapevole che queste ovvietà non sempre corrispondono a comportamenti, adottare una strategia di prompting ALMENO organizzata in termini di CONTESTO, TASK ed INFORMAZIONI dovrebbe non essere nemmeno in discussione. Una strategia che ho trovato particolarmente efficace è stata quella di organizzare l'elaborazione in più fasi gerarchiche, secondo un approccio MapReduce. In un primo step (Map), l'LLM analizza separatamente ogni documento o ogni chunk, generando un output intermedio (ad esempio il riassunto di ciascun testo, oppure l'estrazione di determinate informazioni chiave da quel segmento). In un secondo step (Reduce), si riaggregano e sintetizzano i risultati di tutti i chunk, chiedendo al modello di fornire una visione d'insieme mantenendo coerenza tra le relazioni implicite ed esplicite nei stesi analizzati. Questo approccio gerarchico a più livelli può essere implementato iterativamente: prima a livello di singolo documento, poi a livello di insieme di documenti. Ad esempio, si può istruire l'LLM a leggere ciascun articolo di un corpus e a produrre per ognuno un breve abstract; successivamente, si forniscono all'LLM tutti gli abstract generati chiedendo di stilare una sintesi unificata, evidenziando temi comuni e differenze. Questo prompting a livelli successivi (paragrafo → documento → collezione) consente una sorta di reading sintetico progressivo: l'LLM costruisce insight passo dopo passo, evitando di perdere dettagli importanti e mantenendo coerenza anche su corpora estesi ed è particolarmente efficace se si è in grado di preparare il corpus con tutti i necessari overlap sopra citati. Infine, per insiemi di contenuti particolarmente vasti o eterogenei, risulta ancora una soluzione costosa ma largamente efficiente l'integrazione interattiva tra LLM e tecniche di Retrieval Augmented Generation (RAG). Come già precedentemente citato, questo schema prevede che i documenti vengano indicizzati tramite tecniche di embedding vettoriali: ogni chunk di testo è rappresentato come un vettore numerico in uno spazio di "contesto semantico". Quando successivamente si effettua una "analisi", questa viene tradotta in una ricerca di similarità tra i vettori per recuperare solo i passaggi più rilevanti (l'ho già detto: in termini probabilistici E statistici?). Una volta fatto questo si passano all'LLM "generalista" solo questi chunk selezionati, chiedendo una elaborazione limitata ad essi. In tal modo l'LLM opera su una conoscenza semanticamente contestuale mirata, riducendo al minimo sia il rumore "di fondo" che il rischio di superare i limiti di contesto (che si traduce, quando va bene, in allucinazioni). L'approccio RAG è particolarmente utile per implementare la mia bizzarra modalità di revisione della letteratura "scientifica" perché invece tentare di far leggere all'LLM centinaia di articoli per intero, si possono preparare estrazioni dai paper solo delle sezioni pertinenti (es. abstract, conclusioni, ed i diversi capitoli come oggetti "separati" di contenuto) facendoli sintetizzare al modello generalista nell'ordine preferito.

Riferimenti bibliografici

Riferimenti bibliografici

- [1] Floridi, Luciano. “Distant Writing: Literary Production in the Age of Artificial Intelligence.” SSRN (preprint), Revised May 3, 2025.
- [2] Moretti, F. (2013). *Distant Reading*. Verso Books.
- [3] Brown, T. B., Mann, B., Ryder, N., et al. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems* 33 (NeurIPS 2020), 1877-1901.
- [4] Page, M. J., et al. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372:n71.
- [5] Gough, D., Oliver, S., & Thomas, J. (2017). *An Introduction to Systematic Reviews*. SAGE Publications.
- [6] Underwood, T. (2019). *Distant Horizons: Digital Evidence and Literary Change*. University of Chicago Press.
- [7] Marshall, I. J., et al. (2018). Machine learning for identifying relevant studies for systematic reviews: an evaluation and practitioner’s guide. *Systematic Reviews*, 7:139.
- [8] Teperikidis, L., Boulmpou, V., Papadopoulos, A., & Biondi-Zoccai, G. (2024). Using ChatGPT to perform a systematic review: a tutorial. *Minerva Cardiology and Angiology*, 72(6), 547-567.
- [9] Floridi, L. & Chiriatti, M. (2020). GPT-3: Its Nature, Scope, Limits, and Consequences. *Minds and Machines*, 30(4), 681-694.
- [10] Bender, E. M., Gebru, T., et al. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of ACM FAccT 2021*, 610-623.